

数学那可太好玩了

之

赌徒
概率论

THE ELEGANT GAMBLE

PROBABILITY, STATISTICS, AND STOCHASTIC MODELS ACROSS FIELDS

编者

王观旭

零号书 · 统计学理论及其应用

概率论 · 数理统计与统计推断 · 贝叶斯统计 · 随机过程与金融数学 · 回归分析
时间序列分析 · 广义回归分析 · 寿险精算学 · 生物统计与生存分析 · 非寿险精算学 · 空间统计



赌徒概率论 © 2024 by 王观旭 is licensed under CC BY-NC-ND 4.0.

To view a copy of this license, visit <http://creativecommons.org/licenses/by-nc-nd/4.0/>

序

由于编者水平有限，疏漏之处在所难免，恳请读者批评指正。^{*}

收到纸质版的读者可进入<https://guanxuwang-files.github.io/files/Teaching/GamblerP.pdf>下载电子版，一切内容以电子版为准。本书已添加 CC BY-NC-ND 4.0 许可证（详见本书封面页）。此许可证要求重复使用的用户向创建者提供信用。它允许再用户以未经改编的形式以任何媒介或格式复制和分发材料，并且仅用于非商业目的。[†]

特别感谢带我走向数学之路的领路人：

塔长征先生 徐 枫女士

每一个学习都是曾经的错误，
每一个错误都是未来的学习。

编 者

^{*}编者个人主页：guanxuwang.github.io，请用邮箱联系，欢迎读者提出意见和建议。

[†]This license requires that reusers give credit to the creator. It allows reusers to copy and distribute the material in any medium or format in unadapted form and for noncommercial purposes only.

目录

I 概率论	1
1 概率初步	3
1.1 集合	3
1.2 概率模型	5
1.2.1 概率模型的基本构成	5
1.2.2 概率模型	5
1.3 概率的性质及运算	6
1.3.1 概率的加法公式	6
1.4 条件概率	6
1.4.1 条件概率的定义	6
1.4.2 乘法公式	7
1.4.3 全概率公式	8
1.4.4 贝叶斯公式	8
1.5 独立性	9
1.5.1 两个事件的独立性	9
1.5.2 多个事件的相互独立性	9
1.5.3 试验的独立性	10
2 随机变量及其分布	11
2.1 随机变量及其分布	11
2.1.1 随机变量	11
2.1.2 随机变量的分布函数	11
2.1.3 离散随机变量的概率分布列	12
2.1.4 连续随机变量的概率密度函数	13
2.2 随机变量的数学期望和方差	13
2.2.1 随机变量的数学期望	13
2.2.2 随机变量的方差与标准差	15
2.2.3 切比雪夫不等式	15
2.3 常用离散分布	16
2.3.1 二项分布	16
2.3.2 泊松分布	18
2.3.3 超几何分布	19
2.3.4 几何分布与负二项分布	20

2.4	常用连续分布	22
2.4.1	正态分布	22
2.4.2	均匀分布	25
2.4.3	指数分布	26
2.4.4	伽马分布	28
2.4.5	贝塔分布	29
2.5	随机变量函数的分布	31
2.5.1	离散随机变量函数的分布	31
2.5.2	连续随机变量函数的分布	32
2.6	分布的其他特征数	35
2.6.1	k 阶矩	35
2.6.2	变异系数	35
2.6.3	分位数	36
2.6.4	中位数	37
2.6.5	偏度系数	37
2.6.6	峰度系数	38
II	数理统计与统计推断	39
III	贝叶斯统计	41
1	常见分布及关系	43
1.1	离散型随机变量	43
1.2	连续型随机变量	44
1.3	伽马函数与贝塔函数	44
1.3.1	伽马函数	44
1.3.2	贝塔函数	45
2	贝叶斯模型的推导与 Gibbs 采样	47
2.1	联合概率密度函数和全条件分布	47
2.1.1	联合概率密度函数 (Joint Probability Distribution Function)	47
2.1.2	全条件分布 (Full Conditional Distribution)	47
2.2	Gibbs 采样	48
2.2.1	使用 Gibbs 采样样本生成后验预测分布样本	49
2.2.2	为什么丢弃初始样本? 多条链如何帮助决定丢弃数量?	50
2.2.3	怎么用你手上的这些采样数据去做预测?	51
3	Poisson 模型与共轭分布及 Jeffreys 先验	53
3.1	似然函数的推导	53
3.2	共轭先验的定义及 Gamma 分布共轭性质的证明	53
3.2.1	共轭先验	53
3.2.2	先验分布: Gamma 分布	54
3.3	求参数 λ 的 Jeffreys 先验 $p(\lambda)$	54

3.4	Jeffreys 先验是否是一个合法的先验分布?	55
3.5	使用 Jeffreys 先验的后验分布是否合法?	55
3.6	使用 Jeffreys 先验能否用于推断?	56
3.7	应用	56
3.7.1	预测概率	56
3.7.2	后验更新	57
4	Beta 分布与二项分布模型及最大后验估计 (MAP)	59
4.1	Beta 分布的均值和方差公式	59
4.2	使用 Beta 先验计算后验分布	59
4.3	计算后验分布的最大后验估计 (maximum a posteriori, MAP)	60
4.4	使用 R 模拟估计 95% 的后验区间	60
5	分层模型 (Hierarchical Model) 和 Nimble 编程	61
5.1	将 Nimble 模型规范转化为标准统计表示	61
5.2	分层模型	61
5.3	WinBUGS (Bayesian inference Using Gibbs Sampling)	63
6	贝叶斯决策理论与损失函数	69
6.1	定义贝叶斯期望损失和贝叶斯动作	69
6.2	特定损失函数下的贝叶斯动作	70
6.3	平方损失函数下的贝叶斯动作	71
IV	随机过程与金融数学	73
1	预备知识	75
1.1	矩母函数与特征函数	75
1.1.1	矩母函数	77
1.1.2	特征函数	77
1.2	测度论	79
1.2.1	Lebesgue 积分	79
1.2.2	测度变换	79
2	随机过程的基本概念和基本类型	83
2.1	基本概念	83
2.2	有限维分布与 Kolmogorov 定理	83
2.3	随机过程的基本类型	86
2.3.1	平稳过程	86
2.3.2	独立增量和平稳增量	87
3	泊松过程	89
3.1	泊松过程定义	89
3.2	与泊松过程相联系的若干分布	91
3.2.1	X_n 和 T_n 的分布	91

3.2.2 事件发生时刻的条件分布	92
3.3 泊松过程的推广	94
3.3.1 非齐次泊松过程	94
3.3.2 复合泊松过程	96
3.3.3 条件泊松过程	98
4 更新过程	99
5 马尔可夫链	101
5.1 基本概念	101
5.1.1 定义和性质	101
5.1.2 多步转移概率与 C-K 方程	105
5.2 状态的分类及性质	109
V 回归分析	115
VI 时间序列分析	117
VII 广义回归分析	119
VIII 寿险精算学	121
IX 生物统计与生存分析	123
1 Clinical Trial	125
1.1 Definitions	125
1.2 Hypothesis Test	127
1.3 Sample Sizes Calculations	128
1.4 Meta-Analysis	129
1.4.1 Main statistical objectives	129
1.4.2 Binary response variables: Death (Failure) / Survival (Success)	129
1.4.3 Meta-analytic models	131
2 Epidemiology	133
2.1 Definitions	133
2.2 Sensitivity (敏感度) & Specificity (特异性)	133
2.3 Standardisation	134
2.3.1 Direct standardisation	134
2.3.2 Indirect standardisation	135
2.4 Measuring the Association between a Risk Factor and Disease	135
2.5 Stratification (分层)	137

3 Survival Analysis	141
3.1 Fundamentals	141
3.1.1 The exponential distribution	142
3.1.2 The Weibull distribution	143
3.2 Exploratory analyses for survival data	143
3.2.1 Estimating the survival function	143
3.2.2 Quantifying uncertainty in the survival function	145
3.2.3 Estimating the hazard function	146
3.2.4 Assessing the proportional hazards assumption	146
3.3 Hypothesis testing for survival functions	147
3.4 Modelling survival data – the Cox proportional hazards model	148
 X 非寿险精算学	 153
 XI 空间统计	 155
1 Introduction	157
1.1 地统计学过程	157
1.1.1 定义	157
1.1.2 目标	157
1.2 区域单元 (面元) 过程	158
1.2.1 定义	158
1.2.2 目标	158
1.3 空间点过程	159
1.3.1 定义	159
1.3.2 目标	159
 2 Geostatistics (地统计学)	 161
2.1 Geostatistical theory (理论)	161
2.1.1 Means, variances and covariances (均值, 方差和协方差)	161
2.1.2 Stationarity and isotropy (平稳性与各向同性)	162
2.1.3 Gaussian process (高斯过程)	163
2.1.4 Valid covariance function (协方差函数的有效性判断)	163
2.1.5 Variogram (变异函数)	164
2.2 Autocovariance and semi-variogram models (自协方差和半变异模型)	166
2.3 Geostatistical modelling (建模)	168
2.3.1 Overall modelling strategy (建模策略)	168
2.3.2 Exploratory data analysis (EDA)	169
2.3.3 Plotting the data (制图)	169
2.3.4 Modelling the mean function (均值函数建模)	169
2.3.5 Investigating the presence of spatial autocorrelation (调查空间自相关是否存在)	169
2.4 Parameter estimation (参数估计)	172

2.5	Model adequacy and comparison (模型适宜度与比较)	175
2.5.1	Spatial residuals (空间残差)	175
2.5.2	Model selection (模型选择)	176
2.6	Spatial prediction (空间预测)	176
2.6.1	Kriging (克里金插值)	177
3	Areal unit processes (区域单元过程)	183
3.1	Exploratory Analysis for Areal Unit Data (EDA)	183
3.1.1	Mapping (制图)	183
3.1.2	Defining spatial closeness (空间邻近性)	183
3.1.3	Estimating the extent of spatial autocorrelation (估计空间自相关程度)	184
3.2	Gaussian Markov random field theory (高斯马尔可夫随机场理论)	187
3.2.1	Hammersley-Clifford theorem (GMRF 的充分条件)	188
3.2.2	Conditional autoregressive (CAR) models (条件自回归模型)	190
3.3	Modelling areal unit data (建模)	193
3.3.1	Modelling framework (建模框架)	193
3.3.2	Parameter estimation (参数估计)	194
3.3.3	An alternative estimation approach (参数估计的替代办法)	194
3.4	Extensions to the ICAR model (内在条件自回归模型的扩展)	194
4	Point Process (点过程)	197
4.1	Point process theory (理论)	198
4.2	Modelling and testing for complete spatial randomness (CSR) (完全随机的建模与测试)	199
4.2.1	A model for complete spatial randomness (CSR 的建模)	199
4.2.2	Testing for complete spatial randomness (CSR 的测试)	201
4.3	Modelling spatially varying intensities (空间变化强度的建模)	203
4.3.1	Model and data likelihood (模型与数据似然)	203
4.3.2	Non-parametric estimation of $\lambda(\mathbf{s})$ (强度函数的非参数估计)	204
4.3.3	Parametric models for $\lambda(\mathbf{s})$ (强度函数的参数模型)	205
4.4	Overview of models for clustered point processes (聚类点过程的模型)	205
4.4.1	Processes with offspring (后代)	205
4.4.2	Processes generated by thinning (稀疏/减薄/抽稀)	205
4.4.3	Log Gaussian Cox processes	206
5	Supplement	207
5.1	OLS	207
5.2	Research (past paper Q4)	208
5.2.1	2021 – areal process	208
5.2.2	2022 – geostatistical	209
5.2.3	2024 – mixed process	211

Part I

概率论

Chapter 1

概率初步

1.1 集合

高中阶段所习得的相关集合的概念不再赘述，此处介绍大学概率论中在高中时期并未接触到的有关内容。

由属于集合 A 或属于集合 B 的元素组成的集合称为 A 和 B 的**并**，记作 $A \cup B$ 。既属于 A 又属于 B 的元素组成的集合称为 A 和 B 的**交**，记作 $A \cap B$ 。这些集合可用下列公式表达：

$$\bigcup_{n=1}^{\infty} S_n = S_1 \cup S_2 \cup S_3 \cup \cdots = \{x \mid \exists n, \text{s.t. } x \in S_n\},$$

$$\bigcap_{n=1}^{\infty} S_n = S_1 \cap S_2 \cap S_3 \cap \cdots = \{x \mid \forall n, \text{s.t. } x \in S_n\}.$$

集合 $\{x \in \Omega \mid x \notin S\}$ 称为集合 S 相对于 Ω 的**补集**，记作 S^c 。注意 $\Omega^c = \emptyset$ 。




图 1.1: 并、交、补的韦恩图演示

如果两个集合的交集为空集，那么将这两个集合称为**不相交的**。更一般地，如果任何两个集合没有公共元素，那么将它们称为**互不相交的**。如果这组集合中的集合互不相交，且它们的并为 Ω ，则将这组集合称为集合 Ω 的**分割**。

由此可得集合的若干运算性质如下，

1. 交换律

$$A \cup B = B \cup A, \quad AB = BA$$




图 1.2: 互不相交与分割的韦恩图演示

2. 结合律

$$(A \cup B) \cup C = A \cup (B \cup C),$$

$$(AB)C = A(BC).$$

3. 分配律

$$(A \cup B) \cap C = AC \cup BC,$$

$$(A \cap B) \cup C = (A \cup C) \cap (B \cup C).$$

4. 对偶律 (德·摩根 (De Morgan) 定理)

事件并的对立等于对立的交: $\overline{A \cup B} = \bar{A} \cap \bar{B},$

事件交的对立等于对立的并: $\overline{A \cap B} = \bar{A} \cup \bar{B}.$

Proof. (德·摩根定理 (事件并的对立等于对立的交) 的证明)

设 $\omega \in \overline{A \cup B}$, 即 $\omega \notin A \cup B$, 这表明 ω 既不属于 A , 也不属于 B , 这意味着 $\omega \notin A$ 和 $\omega \notin B$ 同时成立, 所以 $\omega \in \bar{A}$ 与 $\omega \in \bar{B}$ 同时成立, 于是有 $\omega \in \bar{A} \cap \bar{B}$, 这说明

$$\overline{A \cup B} \subset \bar{A} \cap \bar{B}.$$

反之, 设 $\omega \in \bar{A} \cap \bar{B}$, 即同时有 $\omega \in \bar{A}$ 和 $\omega \in \bar{B}$, 从而同时有 $\omega \notin A$ 和 $\omega \notin B$, 这意味着 ω 不属于 A 与 B 中的任一个, 即 $\omega \notin A \cup B$, 也就是有 $\omega \in \overline{A \cup B}$, 这说明

$$\overline{A \cup B} \supseteq \bar{A} \cap \bar{B}.$$

综合上述两方面, 可得

$$\overline{A \cup B} = \bar{A} \cap \bar{B}.$$

德莫根公式可推广到多个事件及可列个事件场合:

$$\overline{\bigcup_{i=1}^n A_i} = \bigcap_{i=1}^n \bar{A}_i; \quad \overline{\bigcup_{i=1}^{\infty} A_i} = \bigcap_{i=1}^{\infty} \bar{A}_i;$$

$$\overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \bar{A}_i; \quad \overline{\bigcap_{i=1}^{\infty} A_i} = \bigcup_{i=1}^{\infty} \bar{A}_i.$$

1.2 概率模型

1.2.1 概率模型的基本构成

概率模型是对不确定现象的数学描述，下面列出了它的两个基本构成：

1. **样本空间** Ω ：一个试验的所有可能结果的集合。
2. **概率律**：试验结果的集合 A （称为**事件**）确定一个非负数 $\Pr(A)$ （称为事件 A 的**概率**），而这个非负数刻画了我们对事件 A 的认识或所产生的信念的程度。

1.2.1.1 样本空间

每一个概率模型都关联着一个**试验**，这个试验将产生一个**试验结果**。该试验的所有可能结果形成**样本空间**，用 Ω 表示样本空间。样本空间的子集，即某些试验结果的集合，称为**事件**。

在确定样本空间的时候，不同的试验结果必须是相互排斥的，这样，在试验过程中才只可能产生唯一的一个结果。

1.2.1.2 概率律

概率律在直观上，它确定了任何结果或者任何结果的集合（称为事件）的似然程度。更精确一点说，它给每一个事件 A ，确定一个数 $\Pr(A)$ ，称为事件 A 的概率。如下给出概率的公理化定义。

定义 1.2.1 概率的公理化定义

设 Ω 为一个样本空间 $\mathcal{F}$ 为 Ω 的某些子集组成的一个事件域。如果对任一事件 $A \in \mathcal{F}$ 定义在 $\mathcal{F}$ 上的一个实值函数 $\Pr(A)$ 满足：

1. 非负性公理：若 $A \in \mathcal{F}$ ，则 $\Pr(A) \geq 0$ ；
2. 正则性公理： $\Pr(\Omega) = 1$ ；
3. 可列可加性公理：若 $A_1, A_2, \dots, A_n, \dots$ 互不相容，有

$$\Pr\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \Pr(A_i), \quad (1.1)$$

则称 $\Pr(A)$ 为事件 A 的概率称三元素 $(\Omega, \mathcal{F}, P)$ 为**概率空间**。

1.2.2 概率模型

1.2.2.1 离散概率模型

设样本空间由有限个可能的结果组成，则事件的概率可由组成这个事件的试验结果的概率所决定。事件 $S = \{s_1, s_2, \dots, s_n\}$ 的概率是 $\Pr(s_i)$ 之和，即

$$\Pr(S) = \Pr(s_1) + \Pr(s_2) + \dots + \Pr(s_n).$$

此处用简单的记号 $\Pr(s_i)$ 表示事件 $\{s_i\}$ 的概率，而不用正式的记号 $\Pr(\{s_i\})$ 。

若设样本空间为 $\Omega = \{s_1, s_2, \dots, s_n\}$ ，并且每个试验结果是等概率的。利用正则性公理可知 $\Pr(s_i) = \frac{1}{n}, i = 1, 2, \dots, n$ ，则得到**离散均匀概率律**，即**古典概型**。

设样本空间由 n 个等可能性的试验结果组成, 因此每个试验结果组成的事件 (称为基本事件) 的概率是相等的. 由此得到

$$\Pr(A) = \frac{\text{含事件 } A \text{ 的试验结果数}}{n}.$$

1.2.2.2 连续概率模型

若试验的样本空间是一个连续集合, 其相应的概率律与离散情况有很大的差别. 在离散情况下, 用基本事件的概率就可以确定概率律, 但连续情况却不同. **几何概型**便是其中一种.

1.3 概率的性质及运算

1.3.1 概率的加法公式

当事件之间互不相容时, 有限可加性或可列可加性给出了求事件并的概率的公式. 下面给出对一般的事件 (不一定互不相容), 求任意两个事件并的概率加法公式, 以及求任意 n 个事件并的概率加法公式. 这些性质在计算概率时是非常有用的.

定理 1.3.1 加法公式

对任意两个事件 A, B , 有

$$\Pr(A \cup B) = \Pr(A) + \Pr(B) - \Pr(AB).$$

对任意 n 个事件 $A_1, A_2, \dots, A_n$, 有

$$\begin{aligned} \Pr\left(\bigcup_{i=1}^n A_i\right) &= \sum_{i=1}^n \Pr(A_i) - \sum_{1 \leq i < j \leq n} \Pr(A_i A_j) + \sum_{1 \leq i < j < k \leq n} \Pr(A_i A_j A_k) \\ &\quad + \dots + (-1)^{n-1} \Pr(A_1 A_2 \dots A_n). \end{aligned}$$

推论 1.3.1 半可加性

对任意两个事件 A, B , 有

$$\Pr(A \cup B) \leq \Pr(A) + \Pr(B). \quad (1.2)$$

对任意 n 个事件 $A_1, A_2, \dots, A_n$, 有

$$\Pr\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \Pr(A_i). \quad (1.3)$$

1.4 条件概率

1.4.1 条件概率的定义

所谓条件概率, 它是指在某事件 B 发生的条件下, 求另一事件 A 的概率, 记为 $\Pr(A|B)$, 它与 $\Pr(A)$ 是不同的两类概率. 这个关系具有一般性, 即条件概率是两个无条件概率之商, 这就是条件概率的定义.

定义 1.4.1 条件概率

设 A 与 B 是样本空间 Ω 中的两事件, 若 $\Pr(B) > 0$, 则称

$$\Pr(A|B) = \frac{\Pr(AB)}{\Pr(B)}.$$

为“在 B 发生下 A 的条件概率”, 简称条件概率.

我们要注意的是: 条件概率 $\Pr(A|B)$ 是在给定 B 下讨论事件 A 的概率, 那么概率的性质对 $\Pr(\cdot|B)$ 而言是否都成立呢? 譬如

$$\Pr(\bar{A}|B) = 1 - \Pr(A|B),$$

$$\Pr(A_1 \cup A_2|B) = \Pr(A_1|B) + \Pr(A_2|B) - \Pr(A_1 A_2|B)$$

这些概率性质都成立吗? 为此我们只要能验证条件概率满足三条公理即可回答这个问题.

定理 1.4.1

条件概率是概率, 即若设 $\Pr(B) > 0$, 则

1. $\Pr(A|B) \geq 0, A \in \mathcal{F}$,
2. $\Pr(\Omega|B) = 1$,
3. 若 $\mathcal{F}$ 中的 $A_1, A_2, \dots, A_n, \dots$ 互不相容, 则

$$\Pr\left(\bigcup_{n=1}^{\infty} A_n|B\right) = \sum_{n=1}^{\infty} \Pr(A_n|B).$$

Proof. 用条件概率的定义很容易证明前两点. 下面来证明第三点. 因为 $A_1, A_2, \dots, A_n, \dots$ 互不相容, 所以 $A_1 B, A_2 B, \dots, A_n B, \dots$ 也互不相容, 故

$$\begin{aligned} P\left(\bigcup_{n=1}^{\infty} A_n | B\right) &= \frac{P\left(\left(\bigcup_{n=1}^{\infty} A_n\right) B\right)}{\Pr(B)} = \frac{P\left(\bigcup_{n=1}^{\infty} (A_n B)\right)}{\Pr(B)} \\ &= \sum_{n=1}^{\infty} \frac{\Pr(A_n B)}{\Pr(B)} = \sum_{n=1}^{\infty} \Pr(A_n | B). \end{aligned}$$



以下给出条件概率特有的三个非常实用的公式: 乘法公式、全概率公式和贝叶斯公式.

1.4.2 乘法公式**定理 1.4.2 乘法公式**

亦称为条件概率公式的衍生公式.

1. 若 $\Pr(B) > 0$, 则

$$\Pr(AB) = \Pr(B) \Pr(A|B).$$

图 1.3: 样本空间的一个分割 ($n = 5$)图 1.4: 用 B 和 $\bar{B}$ 来分割样本空间

2. 若 $\Pr(A_1 A_2 \cdots A_{n-1}) > 0$, 则

$$\Pr(A_1 \cdots A_n) = \Pr(A_1) \Pr(A_2|A_1) \Pr(A_3|A_2 A_1) \cdots \Pr(A_n|A_1 \cdots A_{n-1}).$$

1.4.3 全概率公式

定理 1.4.3 全概率公式

设 $B_1, B_2, \dots, B_n$ 为样本空间 Ω 的一个分割, 即 $B_1, B_2, \dots, B_n$ 互不相容, 且 $\bigcup_{i=1}^n B_i = \Omega$, 如果 $\Pr(B_i) > 0, i = 1, 2, \dots, n$, 则对任一事件 A 有

$$\Pr(A) = \sum_{i=1}^n \Pr(B_i) \Pr(A|B_i).$$

对于全概率公式要注意以下两点:

1. 全概率公式的最简单形式: 假如 $0 < \Pr(B) < 1$, 则

$$\Pr(A) = \Pr(B) \Pr(A|B) + \Pr(\bar{B}) \Pr(A|\bar{B});$$

2. 条件 $B_1, B_2, \dots, B_n$ 为样本空间的一个分割, 可改成 $B_1, B_2, \dots, B_n$ 互不相容, 且 $A \subset \bigcup_{i=1}^n B_i$, 性质全概率公式仍然成立.

1.4.4 贝叶斯公式

在乘法公式和全概率公式的基础上立即可推得一个很著名的公式.

定理 1.4.4 贝叶斯公式

设 $B_1, B_2, \dots, B_n$ 是样本空间 Ω 的一个分割, 即 $B_1, B_2, \dots, B_n$ 互不相容, 且 $\bigcup_{i=1}^n B_i = \Omega$, 如果 $\Pr(A) > 0, \Pr(B_i) > 0, i = 1, 2, \dots, n$, 则

$$\Pr(B_i|A) = \frac{\Pr(B_i) \Pr(A|B_i)}{\sum_{j=1}^n \Pr(B_j) \Pr(A|B_j)}, i = 1, 2, \dots, n.$$

1.5 独立性

独立性是概率论中又一个重要概念，利用独立性可以简化概率的计算. 下面先讨论两个事件之间的独立性，然后讨论多个事件之间的相互独立性，最后讨论试验之间的独立性.

1.5.1 两个事件的独立性

两个事件之间的独立性是指：一个事件的发生不影响另一个事件的发生.

另外，从概率的角度看，事件 A 的条件概率 $\Pr(A|B)$ 与无条件概率 $\Pr(A)$ 的差别在于：事件 B 的发生改变了事件 A 发生的概率，也即事件 B 对事件 A 有某种“影响”. 如果事件 B 的发生对事件 A 的发生毫无影响，即有 $\Pr(A|B) = \Pr(A)$. 由此又可推出 $\Pr(B|A) = \Pr(B)$ ，即事件 A 发生对 B 也无影响，可见独立性是相互的，它们都等价于

$$\Pr(AB) = \Pr(A) \Pr(B).$$

另外对 $\Pr(B) = 0$ ，或 $\Pr(A) = 0$ ，上式仍然成立. 为此，我们以此为基础作为两个事件相互独立的定义.

定义 1.5.1 相互独立

如果 $\Pr(AB) = \Pr(A) \Pr(B)$ 成立，则称事件 A 与 B **相互独立**，简称 A 与 B **独立**，否则称 A 与 B **不独立**或**相依**.

在许多实际问题中，两个事件相互独立大多是根据经验（相互有无影响）来判断的.

定理 1.5.1

若事件 A 与 B 独立，则 A 与 $\bar{B}$ 独立； $\bar{A}$ 与 B 独立； $\bar{A}$ 与 $\bar{B}$ 独立.

Proof. 由概率的性质知

$$\Pr(A\bar{B}) = \Pr(A) - \Pr(AB).$$

又由 A 与 B 的独立性知

$$\Pr(AB) = \Pr(A) \Pr(B),$$

所以

$$\Pr(A\bar{B}) = \Pr(A) - \Pr(A) \Pr(B) = \Pr(A)[1 - \Pr(B)] = \Pr(A) \Pr(\bar{B}).$$

这表明 A 与 $\bar{B}$ 独立. 类似可证 $\bar{A}$ 与 B 独立， $\bar{A}$ 与 $\bar{B}$ 独立.

1.5.2 多个事件的相互独立性

定义 1.5.2 三个事件的相互独立性

设 A, B, C 是三个事件，如果有

$$\begin{cases} \Pr(AB) = \Pr(A) \Pr(B), \\ \Pr(AC) = \Pr(A) \Pr(C), \\ \Pr(BC) = \Pr(B) \Pr(C), \end{cases} \quad (1.4)$$

则称 A, B, C 两两独立. 若还有

$$\Pr(ABC) = \Pr(A) \Pr(B) \Pr(C), \quad (1.5)$$

则称 A, B, C 相互独立.

由此我们可以定义三个以上事件的相互独立性.

定义 1.5.3 三个以上事件的相互独立性

设有 n 个事件 $A_1, A_2, \dots, A_n$, 对任意的 $1 \leq i < j < k \dots \leq n$, 如果以下等式均成立

$$\begin{cases} \Pr(A_i A_j) = \Pr(A_i) \Pr(A_j), \\ \Pr(A_i A_j A_k) = \Pr(A_i) \Pr(A_j) \Pr(A_k), \\ \vdots \\ \Pr(A_1 A_2 \dots A_n) = \Pr(A_1) \Pr(A_2) \dots \Pr(A_n), \end{cases} \quad (1.6)$$

则称此 n 个事件 $A_1, A_2, \dots, A_n$ 相互独立.

从上述定义可以看出, n 个相互独立的事件中的任意一部分内仍是相互独立的, 而且任意一部分与另一部分也是独立的. 可以证明: 将相互独立事件中的任一部分换为对立事件, 所得的诸事件仍为相互独立的.

1.5.3 试验的独立性

利用事件的独立性可以定义两个或更多个试验的独立性.

定义 1.5.4 试验的独立性

设有两个试验 E_1 和 E_2 , 假如试验 E_1 的任一结果 (事件) 与试验 E_2 的任一结果 (事件) 都是相互独立的事件, 则称这两个试验相互独立.

例如掷一枚硬币 (试验 E_1) 与掷一颗骰子 (试验 E_2) 是相互独立的试验.

类似地可以定义 n 个试验 $E_1, E_2, \dots, E_n$ 的相互独立性: 如果 E_1 的任一结果、 E_2 的任一结果、……、 E_n 的任一结果都是相互独立的事件, 则称试验 $E_1, E_2, \dots, E_n$ 相互独立. 如果这 n 个独立试验还是相同的, 则称其为 n 重独立重复试验. 如果在 n 重独立重复试验中, 每次试验的可能结果为两个: A 或 $\bar{A}$, 则称这种试验为 n 重伯努利试验.

例如掷 n 枚硬币、掷 n 颗骰子、检查 n 个产品等, 都是 n 重独立重复试验.

Chapter 2

随机变量及其分布

2.1 随机变量及其分布

2.1.1 随机变量

定义 2.1.1 随机变量

定义在样本空间 Ω 上的实值函数 $X = X(\omega)$ 称为**随机变量**, 常用大写字母 X, Y, Z 等表示随机变量, 其取值用小写字母 x, y, z 等表示. 假如一个随机变量仅取有限个或可列个值, 则称其为**离散随机变量**. 假如一个随机变量的可能取值充满数轴上的一个区间 (a, b) , 则称其为**连续随机变量**, 其中 a 可以是 $-\infty$, b 可以是 ∞ .

这个定义表明: 随机变量 X 是样本点 ω 的一个函数, 这个函数可以是不同样本点对应不同的实数, 也允许多个样本点对应同一个实数. 这个函数的自变量 (样本点) 可以是数, 也可以不是数, 但因变量一定是实数.

与微积分中的变量不同, 概率论中的随机变量 X 是一种“随机取值的变量”. 以认识离散随机变例, 我们不仅要知道 Y 取哪些值, 而且还要知道它取这些值的概率各是多少, 这就需要分布的概念. 有没有分布是区分一般变量与随机变量的主要标志.

2.1.2 随机变量的分布函数

定义 2.1.2 分布函数

设 X 是一个随机变量, 对任意实数 x , 称

$$F(x) = \Pr(X \leq x)$$

为随机变量 X 的**分布函数**. 且称 X 服从 $F(x)$, 记为 $X \sim F(x)$. 有时也可用 $F_X(x)$ 以表明是 X 的**分布函数** (把 X 作为 F 的下标) .

从分布函数的定义可见, 任一随机变量 X (离散的或连续的) 都有一个分布函数. 有了分布函数, 就可据此算得与随机变量 X 有关事件的概率. 下面先证明分布函数的三个基本性质.

定理 2.1.1 分布函数的基本性质

任一分布函数 $F(x)$ 都具有如下三条基本性质:

1. **单调性:** $F(x)$ 是定义在整个实数轴 $(-\infty, \infty)$ 上的单调非减函数, 即对任意的 $x_1 < x_2$, 有 $F(x_1) \leq F(x_2)$.
2. **有界性:** 对任意的 x , 有 $0 \leq F(x) \leq 1$, 且

$$F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0,$$

$$F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1.$$

3. **右连续性:** $F(x)$ 是 x 的右连续函数, 即对任意的 x_0 , 有

$$\lim_{x \rightarrow x_0+} F(x) = F(x_0),$$

即

$$F(x_0 + 0) = F(x_0).$$

以上三条基本性质是分布函数必须具有的性质, 还可以证明: 满足这三个基本性质的函数一定是某个随机变量的分布函数. 从而这三个基本性质成为判别某个函数是否能成为分布函数的充要条件.

2.1.3 离散随机变量的概率分布列

对离散随机变量而言, 常用以下定义的分布列来表示其分布.

定义 2.1.3 离散随机变量的概率分布列

设 X 是一个离散随机变量, 如果 X 的所有可能取值是 $x_1, x_2, \dots, x_n, \dots$ 则称 X 取 x_i 的概率

$$p_i = p(x_i) = \Pr(X = x_i), i = 1, 2, \dots, n, \dots$$

为 X 的概率分布列或简称为分布列, 记为 $X \sim \{p_i\}$, 分布列也可用如下列表方式来表示:

X	x_1	x_2	$\cdots$	x_n	$\cdots$
$\Pr$	$p(x_1)$	$p(x_2)$	$\cdots$	$p(x_n)$	$\cdots$

或记成

$$\begin{pmatrix} x_1 & x_2 & \cdots & x_n & \cdots \\ p(x_1) & p(x_2) & \cdots & p(x_n) & \cdots \end{pmatrix}$$

定理 2.1.2 分布列的基本性质

分布列的基本性质有如下两点:

1. 非负性: $p(x_i) \geq 0, i = 1, 2, \dots$;
2. 正则性: $\sum_{i=1}^{\infty} p(x_i) = 1$.

以上两条基本性质是分布列必须具有的性质,也是判别某个数列是否成为分布列的充要条件. 由离散随机变量 X 的分布列很容易写出 X 的分布函数:

$$F(x) = \sum_{x_i \leq x} p(x_i)$$

2.1.4 连续随机变量的概率密度函数

定义 2.1.4

设随机变量 X 的分布函数为 $F(x)$, 如果存在实数轴上的一个非负可积函数 $p(x)$, 使得对任意实数 x 有

$$F(x) = \int_{-\infty}^x p(t) dt$$

则称 $p(x)$ 为 X 的**概率密度函数**, 简称为**密度函数**或**密度**. 同时称 X 为**连续随机变量**, 称 $F(x)$ 为**连续分布函数**.

至此我们完成了连续随机变量及其分布的定义. 从 (2.1.4) 式还可以看出, 在 $F(x)$ 导数存在的点上有

$$F'(x) = p(x).$$

$F(x)$ 是(累积)概率函数, 其导数 $F'(x)$ 是概率密度函数, 由此可看出 $p(x)$ 被称为概率密度函数的理由.

定理 2.1.3 密度函数的基本性质

有如下两点:

1. 非负性: $p(x) \geq 0$;
2. 正则性: $\int_{-\infty}^{\infty} p(x) dx = 1$.

以上两条基本性质是密度函数必须具有的性质,也是确定或判别某个函数是否成为密度函数的充要条件. 譬如已知某个函数 $p(x)$ 为密度函数, 若 $p(x)$ 中有待定常数, 则该常数必定是利用正则性 $\int_{-\infty}^{\infty} p(x) dx = 1$ 来确定的.

2.2 随机变量的数学期望和方差

2.2.1 随机变量的数学期望

2.2.1.1 数学期望的概念

定义 2.2.1 离散随机变量的数学期望

设离散随机变量 X 的分布列为

$$p(x_i) = \Pr(X = x_i), i = 1, 2, \dots, n, \dots$$

如果

$$\sum_{i=1}^{\infty} |x_i| p(x_i) < \infty$$

则称

$$\mathbb{E}[X] = \sum_{i=1}^{\infty} x_i p(x_i) \quad (2.1)$$

为随机变量 X 的**数学期望**, 或称为该分布的数学期望, 简称**期望**或**均值**. 若级数 $\sum_{k=1}^{\infty} |x_k| p(x_k)$ 不收敛, 则称 X 的数学期望不存在.

定义 2.2.2 连续随机变量的数学期望

设连续随机变量 X 的密度函数为 $p(x)$. 如果

$$\int_{-\infty}^{\infty} |x| p(x) dx < \infty$$

则称

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x p(x) dx \quad (2.2)$$

为 X 的**数学期望**, 或称为该分布 $p(x)$ 的数学期望, 简称**期望**或**均值**. 若 $\int_{-\infty}^{\infty} |x| p(x) dx$ 不收敛, 则称 X 的数学期望不存在.

定理 2.2.1

若随机变量 X 的分布用分布列 $p(x_i)$ 或用密度函数 $p(x)$ 表示, 则 X 的某一函数 $g(X)$ 的数学期望为

$$\mathbb{E}[g(X)] = \begin{cases} \sum g(x_i) p(x_i), & \text{在离散场合;} \\ \int_{-\infty}^{\infty} g(x) p(x) dx, & \text{在连续场合.} \end{cases} \quad (2.3)$$

2.2.1.2 数学期望的性质

性质 2.2.1

数学期望的性质有如下三点:

1. 若 c 是常数, 则 $\mathbb{E}[c] = c$.
2. 对任意常数 a , 有

$$\mathbb{E}[aX] = a\mathbb{E}[X].$$

3. 对任意的两个函数 $g_1(x)$ 和 $g_2(x)$, 有

$$\mathbb{E}[g_1(X) \pm g_2(X)] = \mathbb{E}[g_1(X)] \pm \mathbb{E}[g_2(X)].$$

2.2.2 随机变量的方差与标准差

2.2.2.1 方差与标准差的概念

定义 2.2.3 方差与标准差

若随机变量 X^2 的数学期望 $\mathbb{E}[X]^2$ 存在, 则称偏差平方 $(X - \mathbb{E}[X])^2$ 的数学期望 $\mathbb{E}[(X - \mathbb{E}[X])^2]$ 为随机变量 X (或相应分布) 的**方差**, 记为

$$\text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] = \begin{cases} \sum (x_i - \mathbb{E}[X])^2 p(x_i), & \text{在离散场合;} \\ \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 p(x) dx, & \text{在连续场合.} \end{cases} \quad (2.4)$$

称方差的正平方根 $\sqrt{\text{Var}[X]}$ 为随机变量 X (或相应分布) 的**标准差**, 记为 $\sigma(X)$, 或 σ_X .

2.2.2.2 方差的性质

以下均假定随机变量的方差是存在的.

性质 2.2.2

1. 在实际计算方差时, 比定义更常用的性质:

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

2. 常数的方差为 0, 即 $\text{Var}[c] = 0$, 其中 c 是常数.

3. 若 a, b 是常数, 则 $\text{Var}[aX + b] = a^2 \text{Var}[X]$.

2.2.3 切比雪夫不等式

定理 2.2.2

设随机变量 X 的数学期望和方差都存在, 则对任意常数 $\epsilon > 0$, 有

$$\Pr(|X - \mathbb{E}[X]| \geq \epsilon) \leq \frac{\text{Var}[X]}{\epsilon^2}$$

或

$$\Pr(|X - \mathbb{E}[X]| < \epsilon) \geq 1 - \frac{\text{Var}[X]}{\epsilon^2}$$

Proof. 设 X 是一个连续随机变量, 其密度函数为 $p(x)$. 记 $E(X) = a$, 我们有

$$\begin{aligned} \Pr(|X - a| \geq \epsilon) &= \int_{\{x: |x-a| \geq \epsilon\}} p(x) dx \leq \int_{\{x: |x-a| \geq \epsilon\}} \frac{(x-a)^2}{\epsilon^2} p(x) dx \\ &\leq \frac{1}{\epsilon^2} \int_{-\infty}^{\infty} (x-a)^2 p(x) dx = \frac{\text{Var}[X]}{\epsilon^2}. \end{aligned}$$

由此可知, 切比雪夫不等式对连续随机变量成立, 对于离散随机变量亦可类似进行证明.

在概率论中, 事件“ $|X - \mathbb{E}[X]| \geq \epsilon$ ”称为**大偏差**, 其概率 $P(|X - \mathbb{E}[X]| \geq \epsilon)$ 称为**大偏差发生概率**. 切比雪夫不等式给出大偏差发生概率的上界, 这个上界与方差成正比, 方差愈大上界也愈大.

以下定理进一步说明了方差为 0 就意味着随机变量的取值集中在一点上.

定理 2.2.3

若随机变量 X 的方差存在, 则 $\text{Var}[X] = 0$ 的充要条件是 X 几乎处处为某个常数 a , 即 $P(X = a) = 1$.

Proof. 充分性是显然的, 下面证必要性. 设 $\text{Var}[X] = 0$, 这时 $\mathbb{E}[X]$ 存在. 因为

$$\{|X - \mathbb{E}[X]| > 0\} = \bigcup_{n=1}^{\infty} \left\{ |X - \mathbb{E}[X]| \geq \frac{1}{n} \right\},$$

所以有

$$\begin{aligned} \Pr(|X - \mathbb{E}[X]| > 0) &= \Pr\left(\bigcup_{n=1}^{\infty} \left\{ |x - \mathbb{E}[X]| \geq \frac{1}{n} \right\}\right) \\ &\leq \sum_{n=1}^{\infty} \Pr\left(|X - \mathbb{E}[X]| \geq \frac{1}{n}\right) \leq \sum_{n=1}^{\infty} \frac{\text{Var}[X]}{(1/n)^2} = 0 \end{aligned}$$

其中最后一个不等式用到了切比雪夫不等式. 由此可知

$$\Pr(|X - \mathbb{E}[X]| > 0) = 0,$$

因而有

$$\Pr(|X - \mathbb{E}[X]| = 0) = 1,$$

即

$$\Pr(X = \mathbb{E}[X]) = 1,$$

这就证明了结论, 且其中的常数 a 就是 $\mathbb{E}[X]$.

2.3 常用离散分布

2.3.1 二项分布

2.3.1.1 二项分布

如果记 X 为 n 重伯努利试验中成功 (记为事件 A) 的次数, 则 X 的可能取值为 $0, 1, \dots, n$. 记 p 为每次试验中 A 发生的概率, 即 $\Pr(A) = p$, 则 $\Pr(\bar{A}) = 1 - p$.

因为 n 重伯努利试验的基本结果可以记作

$$\omega = (\omega_1, \omega_2, \dots, \omega_n),$$

其中 ω_i 或者为 A , 或者为 $\bar{A}$. 这样的 ω 共有 2^n 个, 这 2^n 个样本点 ω 组成了样本空间 Ω .

下面求 X 的分布列, 即求事件 $\{X = k\}$ 的概率. 若某个样本点

$$\omega = (\omega_1, \omega_2, \dots, \omega_n) \in \{X = k\},$$

意味着 $\omega_1, \omega_2, \dots, \omega_n$ 中有 k 个 A , $n-k$ 个 $\bar{A}$, 所以由独立性知

$$p(\omega) = p^k(1-p)^{n-k}.$$

而事件 $\{X = k\}$ 中这样的 ω 共有 $\binom{n}{k}$ 个, 所以 X 的分布列为

$$\Pr(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, k = 0, 1, \dots, n.$$

这个分布称为 **二项分布**, 记为 $X \sim b(n, p)$.

容易验证其和恒为 1, 即

$$\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = [p + (1-p)]^n = 1.$$

由此可见, 二项概率 $\binom{n}{k} p^k (1-p)^{n-k}$ 恰好是二项式 $[p + (1-p)]^n$ 的展开式中的第 $k+1$ 项, 这正是其名称的由来.

2.3.1.2 二点分布

$n = 1$ 时的二项分布 $b(1, p)$ 称为**二点分布**, 或称 **0-1 分布**, 其分布列为:

$$P(X = x) = p^x(1-p)^{1-x}, x = 0, 1.$$

或记为

X	0	1
P	$1-p$	p

n 重伯努利试验是由 n 个相同的、独立进行的伯努利试验组成, 若将第 i 个伯努利试验中 A 出现的次数记为 X_i ($i = 1, 2, \dots, n$), 则 X_i 相互独立, 且服从相同的二点分布 $b(1, p)$. 此时其和

$$X = X_1 + X_2 + \dots + X_n,$$

就是 n 重伯努利试验中 A 出现的总次数, 它服从二项分布 $b(n, p)$. 这就是二项分布 $b(n, p)$ 与二点分布 $b(1, p)$ 之间的联系, 即二项分布随机变量是 n 个独立同分布的二点分布随机变量之和.

2.3.1.3 二项分布的期望和方差

设随机变量 $X \sim b(n, p)$, 则

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k=0}^n k \binom{n}{k} p^k (1-p)^{n-k} \\ &= np \sum_{k=1}^n \binom{n-1}{k-1} p^{k-1} (1-p)^{(n-1)-(k-1)} \\ &= np[p + (1-p)]^{n-1} = np. \end{aligned}$$

又因为

$$\begin{aligned}
 \mathbb{E}[X^2] &= \sum_{k=0}^n k^2 \binom{n}{k} p^k (1-p)^{n-k} \\
 &= \sum_{k=1}^n (k-1+1)k \binom{n}{k} p^k (1-p)^{n-k} \\
 &= \sum_{k=1}^n k(k-1) \binom{n}{k} p^k (1-p)^{n-k} + \sum_{k=1}^n k \binom{n}{k} p^k (1-p)^{n-k} \\
 &= \sum_{k=2}^n k(k-1) \binom{n}{k} p^k (1-p)^{n-k} + np \\
 &= n(n-1)p^2 \sum_{k=2}^n \binom{n-2}{k-2} p^{k-2} (1-p)^{(n-2)-(k-2)} + np \\
 &= n(n-1)p^2 + np.
 \end{aligned}$$

由此得 X 的方差为

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = n(n-1)p^2 + np - (np)^2 = np(1-p).$$

因为二点分布是 $n=1$ 时的二项分布 $b(1, p)$, 所以二点分布的数学期望为 p , 方差为 $p(1-p)$.

2.3.2 泊松分布

2.3.2.1 泊松分布

泊松分布的概率分布列是

$$\Pr(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, 2, \dots,$$

其中参数 $\lambda > 0$, 记为 $X \sim P(\lambda)$.

对泊松分布而言, 很容易验证其和为 1:

$$\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1.$$

2.3.2.2 泊松分布的数学期望和方差

设随机变量 $X \sim \text{Poisson}(\lambda)$, 则

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda.$$

这表明: 泊松分布 $P(\lambda)$ 的数学期望就是参数 λ .

又因为

$$\begin{aligned}
 \mathbb{E}[X^2] &= \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{\infty} k \frac{\lambda^k}{(k-1)!} e^{-\lambda} \\
 &= \sum_{k=1}^{\infty} [(k-1) + 1] \frac{\lambda^k}{(k-1)!} e^{-\lambda} \\
 &= \lambda^2 e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} + \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\
 &= \lambda^2 + \lambda.
 \end{aligned}$$

由此得 X 的方差为

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

也就是说, 泊松分布 $\text{Poisson}(\lambda)$ 中的参数 λ 既是数学期望又是方差.

2.3.2.3 二项分布的泊松近似

泊松分布还有一个非常实用的特性, 即可以用泊松分布作为二项分布的一种近似. 在二项分布 $b(n, p)$ 中, 当 n 较大时, 计算量是令人烦恼的. 而在 p 较小时使用以下的泊松定理, 可以减少二项分布中的计算量.

定理 2.3.1 泊松定理

在 n 重伯努利试验中, 记事件 A 在一次试验中发生的概率为 p_n (与试验次数 n 有关), 如果当 $n \rightarrow \infty$ 时, 有 $np_n \rightarrow \lambda$, 则

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}. \quad (2.5)$$

Proof. 记 $np_n = \lambda_n$, 记 $p_n = \lambda_n/n$, 我们可得

$$\begin{aligned} \binom{n}{k} p_n^k (1 - p_n)^{n-k} &= \frac{n(n-1) \cdots (n-k+1)}{k!} \left(\frac{\lambda_n}{n}\right)^k \left(1 - \frac{\lambda_n}{n}\right)^{n-k} \\ &= \frac{\lambda_n^k}{k!} \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) \left(1 - \frac{\lambda_n}{n}\right)^{n-k}. \end{aligned}$$

对固定的 k 有

$$\lim_{n \rightarrow \infty} \lambda_n = \lambda; \quad \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda_n}{n}\right)^{n-k} = e^{-\lambda}; \quad \lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) = 1.$$

从而

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}$$

对任意的 k ($k = 0, 1, 2, \dots$) 成立. 定理得证.

由于泊松定理是在 $np_n \rightarrow \lambda$ 条件下获得的, 故在计算二项分布 $b(n, p)$ 时, 当 n 很大, p 很小, 而乘积 $\lambda = np$ 大小适中时, 可以用泊松分布作近似, 即

$$\binom{n}{k} p_n^k (1 - p_n)^{n-k} \approx \frac{(np)^k}{k!} e^{-np}, \quad k = 0, 1, 2, \dots \quad (2.6)$$

2.3.3 超几何分布

2.3.3.1 超几何分布

从一个有限总体中进行不放回抽样常会遇到超几何分布.

设有 N 个产品, 其中有 M 个不合格品. 若从中不放回地随机抽取 n 个, 则其中含有的不合格品的个数 X 服从超几何分布, 记为 $X \sim h(n, N, M)$. 超几何分布的概率分布列为

$$\Pr(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \dots, r,$$

其中 $r = \min\{M, n\}$, 且 $M \leq N, n \leq N, n, N, M$ 均为正整数.

若要验证以上给出的确实为一个概率分布列, 只须注意到有组合等式

$$\sum_{k=0}^r \binom{M}{k} \binom{N-M}{n-k} = \binom{N}{n}$$

即可.

2.3.3.2 超几何分布的数学期望和方差

若 $X \sim \text{Hypergeometric}(n, N, M)$, 则 X 的数学期望为

$$\mathbb{E}[X] = \sum_{k=0}^r k \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}} = n \frac{M}{N} \sum_{k=1}^r \frac{\binom{M-1}{k-1} \binom{N-M}{n-k}}{\binom{N-1}{n-1}} = n \frac{M}{N}.$$

又因为

$$\begin{aligned} \mathbb{E}[X^2] &= \sum_{k=1}^r k^2 \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}} = \sum_{k=2}^r k(k-1) \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}} + n \frac{M}{N} \\ &= \frac{M(M-1)}{\binom{N}{n}} \sum_{k=2}^r k(k-1) \binom{M-2}{k-2} \binom{N-M}{n-k} + n \frac{M}{N} \\ &= \frac{M(M-1)}{\binom{N}{n}} \binom{N-2}{n-2} + n \frac{M}{N} = \frac{M(M-1)n(n-1)}{N(N-1)} + n \frac{M}{N}, \end{aligned}$$

由此得 X 的方差为

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{nM(N-M)(N-n)}{N^2(N-1)}.$$

2.3.3.3 超几何分布的二项近似

当 $n \ll N$ 时, 即抽取个数 n 远小于产品总数 N 时, 每次抽取后, 总体中的不合格品率 $p = \frac{M}{N}$ 改变甚微, 所以不放回抽样可近似地看成放回抽样, 这时超几何分布可用二项分布近似:

$$\frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}} \cong \binom{n}{k} p^k (1-p)^{n-k}, \text{ 其中 } p = \frac{M}{N}.$$

2.3.4 几何分布与负二项分布

2.3.4.1 几何分布

在伯努利试验序列中, 记每次试验中事件 A 发生的概率为 p , 如果 X 为事件 A 首次出现时的试验次数, 则 X 的可能取值为 $1, 2, \dots$, 称 X 服从几何分布, 记为 $X \sim \text{Geo}(p)$, 其分布列为

$$P(X = k) = (1-p)^{k-1}p, \quad k = 1, 2, \dots.$$

2.3.4.2 几何分布的数学期望和方差

设随机变量 X 服从几何分布 $\text{Geo}(p)$, 令 $q = 1 - p$, 利用逐项微分可得 X 的数学期望为

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k=1}^{\infty} k p q^{k-1} = p \sum_{k=1}^{\infty} k q^{k-1} = p \sum_{k=1}^{\infty} \frac{dq^k}{dq} \\ &= p \frac{d}{dq} \left(\sum_{k=0}^{\infty} q^k \right) = p \frac{d}{dq} \left(\frac{1}{1-q} \right) = \frac{p}{(1-q)^2} = \frac{1}{p}. \end{aligned}$$

又因为

$$\begin{aligned}
 \mathbb{E}[X^2] &= \sum_{k=1}^{\infty} k^2 p q^{k-1} = p \left[\sum_{k=1}^{\infty} k(k-1) q^{k-1} + \sum_{k=1}^{\infty} k q^{k-1} \right] \\
 &= p q \sum_{k=1}^{\infty} k(k-1) q^{k-2} + \frac{1}{p} = p q \sum_{k=1}^{\infty} \frac{d^2}{dq^2} q^k + \frac{1}{p} \\
 &= p q \frac{d^2}{dq^2} \left(\sum_{k=1}^{\infty} q^k \right) + \frac{1}{p} = p q \frac{d^2}{dq^2} \left(\frac{1}{1-q} \right) + \frac{1}{p} \\
 &= p q \frac{2}{(1-q)^3} + \frac{1}{p} = \frac{2q}{p^2} + \frac{1}{p},
 \end{aligned}$$

由此得 X 的方差为

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{2q}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{1-p}{p^2}.$$

2.3.4.3 几何分布的无记忆性

定理 2.3.2 几何分布的无记忆性

设 $X \sim \text{Geo}(p)$, 则对任意正整数 m 与 n 有

$$\Pr(X > m+n | X > m) = \Pr(X > n).$$

在证明之前先解释上述概率等式的含义. 在一列伯努利试验序列中, 若首次成功 (A) 出现的试验次数 X 服从几何分布, 则事件“ $X > m$ ”表示前 m 次试验中 A 没有出现. 假如在接下去的 n 次试验中 A 仍未出现, 这个事件记为“ $X > m+n$ ”. 这个定理表明: 在前 m 次试验中 A 没有出现的条件下, 则在接下去的 n 次试验中 A 仍未出现的概率只与 n 有关, 而与以前的 m 次试验无关, 似乎忘记了前 m 次试验结果, 这就是无记忆性.

Proof. 因为

$$\Pr(X > n) = \sum_{k=n+1}^{\infty} (1-p)^{k-1} p = \frac{p(1-p)^n}{1-(1-p)} = (1-p)^n,$$

所以对任意的正整数 m 与 n , 条件概率

$$\begin{aligned}
 \Pr(X > m+n | X > m) &= \frac{\Pr(X > m+n)}{\Pr(X > m)} = \frac{(1-p)^{m+n}}{(1-p)^m} \\
 &= (1-p)^n = \Pr(X > n).
 \end{aligned}$$

2.3.4.4 负二项分布

作为几何分布的一种延伸, 我们注意下面的**负二项分布**, 亦称**巴斯卡分布**:

在伯努利试验序列中, 记每次试验中事件 A 发生的概率为 p , 如果 X 为事件 A 第 r 次出现时的试验次数, 则 X 的可能取值为 $r, r+1, \dots, r+m, \dots$. 称 X 服从**负二项分布**或**巴斯卡分布**, 其分布列为

$$\Pr(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots \quad (2.7)$$

记为 $X \sim \text{Nb}(r, p)$. 当 $r = 1$ 时, 即为几何分布.

这是因为在次伯努利试验中, 最后一次一定是 A , 而前 $k-1$ 次中 A 应出现 $r-1$ 次, 由二项分布知其概率为 $\binom{k-1}{r-1} p^{r-1} (1-p)^{k-r}$, 再乘以最后一次出现 A 的概率 p , 即得 (2.7).

可以算得负二项分布的数学期望为 r/p , 方差为 $r(1-p)/p^2$. 从直观上看这是合理的, 因为首次出现 A 的平均试验次数是 $1/p$, 那么第 r 个 A 出现所需的平均试验次数是 r/p .

如果将第一个 A 出现的试验次数记为 X_1 , 第二个 A 出现的试验次数 (从第一个 A 出现之后算起) 记为 X_2 , 第 r 个 A 出现的试验次数 (从第 $r-1$ 个 A 出现之后算起) 记为 X_r , 则 X_i 独立同分布, 且 $X_i \sim \text{Geo}(p)$. 此时有 $X = X_1 + X_2 + \cdots + X_r \sim \text{Nb}(r, p)$, 即负二项分布的随机变量可以表示成 r 个独立同分布的几何分布随机变量之和.

2.4 常用连续分布

2.4.1 正态分布

正态分布是概率论与数理统计中最重要的一个分布, 高斯 (Gauss) 在研究误差理论时首先用正态分布来刻画误差的分布, 所以正态分布又称为高斯分布. 本书第四章的中心极限定理表明: 一个变量如果是由大量微小的、独立的随机因素的叠加结果, 那么这个变量一定是正态变量. 因此很多随机变量可以用正态分布描述或近似描述, 譬如测量误差、产品重量、人的身高、年降雨量等都可用正态分布描述.

2.4.1.1 正态分布的密度函数和分布函数

若随机变量 X 的密度函数为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty, \quad (2.8)$$

则称 X 服从**正态分布**, 称 X 为**正态变量**, 记作 $X \sim N(\mu, \sigma^2)$. 其中参数 $-\infty < \mu < \infty, \sigma > 0$. 其密度函数 $p(x)$ 的图形如图 2.1(a) 所示. $p(x)$ 是一条钟形曲线, 中间高、二边低、左右关于 μ 对称, μ 是正态分布的中心, 且在 $x = \mu$ 附近取值的可能性大, 在两侧取值的可能性小. $\mu \pm \sigma$ 是该曲线的拐点.




图 2.1: 正态分布

正态分布 $N(\mu, \sigma^2)$ 的分布函数为

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt.$$

它是一条光滑上升的 S 形曲线, 见图 2.1(b).

图中给出了在 μ 和 σ 变化时, 相应正态密度曲线的变化情况.

- 从图 (a) 中可以看出: 如果固定, 改变 μ 的值, 则图形沿 x 轴平移, 而不改变其形状. 也就是说正态密度函数的位置由参数 μ 所确定, 因此亦称 μ 为**位置参数**.
- 从图 (b) 中可以看出: 如果固定 μ , 改变 σ 的值, 则 σ 愈小, 曲线呈高而瘦; σ 愈大, 曲线呈矮而胖. 也就是说正态密度函数的尺度由参数 σ 所确定, 因此称 σ 为**尺度参数**.

2.4.1.2 标准正态分布

称 $\mu = 0, \sigma = 1$ 时的正态分布 $N(0, 1)$ 为标准正态分布.

通常记标准正态变量为 U , 记标准正态分布的密度函数为 $\phi(u)$, 分布函数为 $\Phi(u)$, 即

$$\phi(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}, \quad -\infty < u < \infty,$$

$$\Phi(u) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^u e^{-\frac{t^2}{2}} dt, \quad -\infty < u < \infty.$$

由于标准正态分布的分布函数不含任何未知参数, 故其值 $\Phi(u) = P(U \leq u)$ 完全可以算出, 附表 2 对 $u \geq 0$ 给出了 $\Phi(u)$ 的值, 利用这张表可以算得

- $\Phi(-u) = 1 - \Phi(u)$.
- $\Pr(U > u) = 1 - \Phi(u)$.
- $\Pr(a < U < b) = \Phi(b) - \Phi(a)$.
- $\Pr(|U| < c) = 2\Phi(c) - 1$.

2.4.1.3 一般正态分布的标准化

正态分布有一个家族

$$\mathcal{P} = \{N(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma > 0\},$$

标准正态分布 $N(0, 1)$ 是其一个成员. 实际上很少有随机变量恰好服从标准正态分布. 以下定理说明: 对一般正态分布都可以通过一个线性变换 (标准化) 化成标准正态分布. 因此与正态变量有关的一切事件的概率都可通过查标准正态分布函数表获得. 由此可见标准正态分布 $N(0, 1)$ 对一般正态分布 $N(\mu, \sigma^2)$ 的计算起着关键的作用.

定理 2.4.1

若 $X \sim N(\mu, \sigma^2)$, 则 $U = \frac{X - \mu}{\sigma} \sim N(0, 1)$.

Proof. 记 X 与 U 的分布函数分别为 $F_X(x)$ 与 $F_U(u)$, 则由分布函数的定义知

$$\begin{aligned} F_U(u) &= \Pr(U \leq u) = \Pr\left(\frac{X - \mu}{\sigma} \leq u\right) \\ &= \Pr(X \leq \mu + \sigma u) = F_X(\mu + \sigma u). \end{aligned}$$

由于正态分布函数是严格单调增函数, 且处处可导, 因此若记 X 与 U 的密度函数分别为 $p_X(x)$ 与 $P_U(u)$, 则有

$$P_U(u) = \frac{d}{du} F_X(\mu + \sigma u) = p_X(\mu + \sigma u) \cdot \sigma = \frac{1}{\sqrt{2\pi}} e^{-u^2/2},$$

由此得

$$U = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

由以上定理, 我们马上可以得到一些在实际中有用的计算公式, 若 $N(\mu, \sigma^2)$, 则

$$\Pr(X \leq c) = \Phi\left(\frac{c - \mu}{\sigma}\right).$$

$$\Pr(a < X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right).$$

2.4.1.4 正态分布的数学期望与方差

设随机变量 $X \sim N(\mu, \sigma^2)$, 由于 $U = \frac{X - \mu}{\sigma} \sim N(0, 1)$, 所以 U 的数学期望为

$$\mathbb{E}[U] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u e^{-\frac{u^2}{2}} du,$$

注意到上述积分的被积函数为一个奇函数, 所以其积分值等于 0, 即 $E(U) = 0$. 又因为 $X = \mu + \sigma U$, 所以由数学期望的线性性得

$$\mathbb{E}[X] = \mu + \sigma \times 0 = \mu.$$

也就是说, 正态分布 $N(\mu, \sigma^2)$ 中 μ 为数学期望.

又因为

$$\begin{aligned} \text{Var}[U] &= \mathbb{E}[U^2] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u^2 e^{-\frac{u^2}{2}} du \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u^2 e^{-\frac{u^2}{2}} du \\ &= \frac{1}{\sqrt{2\pi}} \left(-u e^{-\frac{u^2}{2}} \Big|_{-\infty}^{\infty} + \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du \right) \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du = \frac{1}{\sqrt{2\pi}} \sqrt{2\pi} = 1. \end{aligned}$$

因为 $X = \sigma U + \mu$, 所以由方差的性质得

$$\text{Var}[X] = \text{Var}[\sigma U + \mu] = \sigma^2.$$

这说明, 正态分布 $N(\mu, \sigma^2)$ 中另一个参数 σ^2 就是方差.

在求正态分布的数学期望和方差中, 用到了一种变换: 令 $U = \frac{X - \mu}{\sigma}$, 由 $\mathbb{E}[U] = 0, \text{Var}[U] = 1$, 然后再去求出 X 的数学期望和方差. 这个变换具有普遍意义, 也就是对任意随机变量 X , 如果 X 的数学期望为 μ , 方差为 σ^2 , 则称

$$X^* = \frac{X - \mu}{\sigma}$$

为 X 的**标准化随机变量**, 且可得

$$\mathbb{E}[X^*] = 0, \quad \text{Var}[X^*] = 1.$$

2.4.1.5 正态分布的 3σ 原则

设 $X \sim N(\mu, \sigma^2)$, 则

$$\Pr(|X - \mu| < k\sigma) = \Phi(k) - \Phi(-k) = \begin{cases} 0.6826, & k = 1; \\ 0.9545, & k = 2; \\ 0.9973, & k = 3 \end{cases} \quad (2.9)$$

从上式中可以看出: 尽管正态变量的取值范围是 $(-\infty, \infty)$, 但它的 99.73% 的值落在 $\mu - 3\sigma, \mu + 3\sigma$ 内. 这个性质被实际工作者称作是正态分布的“ 3σ 原则”. 正态分布的 3σ 原则在实际工作中很有用, 工业生产上用的控制图, 和一些产品质量指数 (如 C_p, C_{pk}) 都是根据 3σ 原则制定的.

2.4.2 均匀分布

2.4.2.1 均匀分布的密度函数和分布函数

若随机变量 X 的密度函数 (见图 (a)) 为

$$p(x) = \begin{cases} \frac{1}{b-a}, & a < x < b; \\ 0, & \text{其他.} \end{cases} \quad (2.10)$$

则称 X 服从区间 (a, b) 上的均匀分布, 记作 $X \sim U(a, b)$, 其分布函数 (见图 (b)) 为

$$F(x) = \begin{cases} 0, & x < a; \\ \frac{x-a}{b-a}, & a \leq x < b; \\ 1, & x \geq b. \end{cases} \quad (2.11)$$




图 2.2: (a, b) 上的均匀分布

均匀分布的背景可视作随机点 X 落在区间 (a, b) 上的位置.

2.4.2.2 均匀分布的数学期望和方差

设随机变量 $X \sim U(a, b)$, 则

$$\mathbb{E}[X] = \int_a^b \frac{x}{b-a} dx = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2},$$

这正是区间 (a, b) 的中点.

又因为

$$\mathbb{E}[X^2] = \int_a^b \frac{x^2}{b-a} dx = \frac{b^3 - a^3}{3(b-a)} = \frac{a^2 + ab + b^2}{3},$$

由此得 X 的方差为

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4} = \frac{(b-a)^2}{12}.$$

2.4.3 指数分布

2.4.3.1 指数分布的密度函数和分布函数

若随机变量 X 的密度函数（见图 2.3）为

$$p(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0; \\ 0, & x < 0, \end{cases} \quad (2.12)$$

则称 X 服从**指数分布**, 记作 $X \sim \text{Exp}(\lambda)$, 其中参数 $\lambda > 0$. 指数分布的分布函数为

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0; \\ 0, & x < 0. \end{cases}$$




图 2.3: 参数为 λ 的指数分布密度函数

因为指数分布随机变量只可能取非负实数, 所以指数分布常被用作各种“寿命”分布, 譬如电子元件的寿命、动物的寿命、电话的通话时间、随机服务系统中的服务时间等都可假定服从指数分布. 指数分布在可靠性与排队论中有着广泛的应用.

2.4.3.2 指数分布的数学期望和方差

设随机变量 $X \sim \text{Exp}(\lambda)$, 则

$$\begin{aligned} \mathbb{E}[X] &= \int_0^{\infty} x \lambda e^{-\lambda x} dx = \int_0^{\infty} x d(-e^{-\lambda x}) \\ &= -xe^{-\lambda x} \Big|_0^{\infty} + \int_0^{\infty} e^{-\lambda x} dx = -\frac{1}{\lambda} e^{-\lambda x} \Big|_0^{\infty} = \frac{1}{\lambda}. \end{aligned}$$

在指数分布中, 有时记 $\theta = 1/\lambda$, 则 θ 为指数分布的数学期望.

又因为

$$\begin{aligned} \mathbb{E}[X^2] &= \int_0^{\infty} x^2 \lambda e^{-\lambda x} dx = \int_0^{\infty} x^2 d(-e^{-\lambda x}) \\ &= -x^2 e^{-\lambda x} \Big|_0^{\infty} + 2 \int_0^{\infty} x e^{-\lambda x} dx = \frac{2}{\lambda^2}, \end{aligned}$$

由此得 X 的方差为

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.$$

2.4.3.3 指数分布的无记忆性

下面给出指数分布在连续分布类中所特有的一个性质.

定理 2.4.2 指数分布的无记忆性

如果 $X \sim \text{Exp}(\lambda)$, 则对任意 $s > 0, t > 0$, 有

$$P(X > s + t | X > s) = P(X > t). \quad (2.13)$$

上式的含义为: 记 X 是某种产品的使用寿命 (h), 若 X 服从指数分布, 那么已知此产品使用了 s h 没发生故障, 则再能使用 t h 而不发生故障的概率与已使用的 s h 无关, 只相当于重新开始使用 t h 的概率, 即对已使用过的 s h 没有记忆.

Proof. 因为 $X \sim \text{Exp}(\lambda)$, 所以 $\Pr(X > s) = e^{-\lambda s}, s > 0$. 又因为

$$\{X > s + t\} \subseteq \{X > s\},$$

于是条件概率

$$\Pr(X > s + t | X > s) = \frac{\Pr(X > s + t)}{\Pr(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \Pr(X > t).$$

这就证明 (2.13) 式.

指数分布的无记忆性与几何分布的无记忆性是类似的.

以下例子说明了泊松分布与指数分布的关系.

例 2.4.1

如果某设备在任何长为 t 的时间 $[0, t]$ 内发生故障的次数 $N(t)$ 服从参数为 λt 的泊松分布, 则相继两次故障之间的时间间隔 T 服从参数为 λ 的指数分布.

Solution. 设 $N(t) \sim \text{Pr}(\lambda t)$, 即

$$\Pr(N(t) = k) = \frac{(\lambda t)^k}{k!} e^{-\lambda t}, \quad k = 0, 1, \dots$$

注意到两次故障之间的时间间隔 T 是非负随机变量, 且事件 $\{T \geq t\}$ 说明此设备在 $[0, t]$ 内没有发生故障, 即 $\{T \geq t\} = \{N(t) = 0\}$, 由此我们得

当 $t < 0$ 时, 有 $F_T(t) = P(T \leq t) = 0$;

当 $t \geq 0$ 时, 有

$$F_T(t) = \Pr(T \leq t) = 1 - \Pr(T > t) = 1 - \Pr(N(t) = 0) = 1 - e^{-\lambda t},$$

所以 $T \sim \text{Exp}(\lambda)$, 相继两次故障之间的时间间隔 T 服从参数为 λ 的指数分布.

2.4.4 伽马分布

2.4.4.1 伽马函数

称以下函数

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx \quad (2.14)$$

为**伽马函数**, 其中参数 $\alpha > 0$. 伽马函数具有如下性质:

2.4.4.2 伽马分布

若随机变量 X 的密度函数为

$$p(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, & x \geq 0; \\ 0, & x < 0, \end{cases} \quad (2.15)$$

则称 X 服从**伽马分布**, 记作 $X \sim \text{Ga}(\alpha, \lambda)$, 其中 $\alpha > 0$ 为形状参数, $\lambda > 0$ 为尺度参数. 图 2.4 给出若干条 λ 固定、 α 不同的伽马密度函数曲线, 从图中可以看出:

- $0 < \alpha < 1$ 时, $p(x)$ 是严格下降函数, 且在 $x = 0$ 处有奇异点;
- $\alpha = 1$ 时, $p(x)$ 是严格下降函数, 且在 $x = 0$ 处 $p(0) = \lambda$;
- $1 < \alpha \leq 2$, $p(x)$ 是单峰函数, 向上凸、后下凸;
- $2 < \alpha$ 时, $p(x)$ 是单峰函数, 先下凸、中间上凸、后下凸. 且 α 越大, $p(x)$ 越近似于正态分布.




图 2.4: λ 固定、不同 α 的伽玛密度曲线

2.4.4.3 伽马分布 $\text{Ga}(\alpha, \lambda)$ 的数学期望和方差

利用伽马函数的性质, 不难算得伽马分布 $\text{Ga}(\alpha, \lambda)$ 的数学期望为

$$\mathbb{E}[X] = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^{\infty} x^\alpha e^{-\lambda x} dx = \frac{\Gamma(\alpha+1)}{\Gamma(\alpha)} \frac{1}{\lambda} = \frac{\alpha}{\lambda},$$

又因为

$$\mathbb{E}[X^2] = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^{\infty} x^{\alpha+1} e^{-\lambda x} dx = \frac{\Gamma(\alpha+2)}{\lambda^2 \Gamma(\alpha)} = \frac{\alpha(\alpha+1)}{\lambda^2},$$

由此得 X 的方差为

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{\alpha(\alpha+1)}{\lambda^2} - \left(\frac{\alpha}{\lambda}\right)^2 = \frac{\alpha}{\lambda^2}.$$

2.4.4.4 伽玛分布的两个特例

伽玛分布有两个常用的特例:

1. $\alpha = 1$ 时的伽玛分布就是指数分布, 即

$$Ga(1, \lambda) = Exp(\lambda). \quad (2.16)$$

2. 称 $\alpha = n/2, \lambda = 1/2$ 时的伽玛分布是自由度为 n 的 χ^2 (卡方) 分布, 记为 $\chi^2(n)$, 记

$$Ga\left(\frac{n}{2}, \frac{1}{2}\right) = \chi^2(n), \quad (2.17)$$

其密度函数为

$$p(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1}, & x > 0; \\ 0, & x \leq 0. \end{cases} \quad (2.18)$$

这里 n 是 χ^2 分布的唯一参数, 称为自由度, 它可以是正实数, 但更多的是取正整数, 其统计含义以后再介绍.

因为 χ^2 分布是特殊的伽玛分布, 故由伽玛分布的期望和方差, 很容易得到 χ^2 分布的期望和方差为

$$\mathbb{E}[X] = n, \quad \text{Var}[X] = 2n.$$

2.4.5 贝塔分布

2.4.5.1 贝塔函数

称以下函数

$$\text{Beta}(a, b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx \quad (2.19)$$

为**贝塔函数**, 其中参数 $a > 0, b > 0$. 贝塔函数具有如下性质:

1. $\text{Beta}(a, b) = \text{Beta}(b, a)$.

Proof. 在 (2.19) 的积分中令 $y = 1 - x$, 即得

$$\text{Beta}(a, b) = \int_1^0 (1-y)^{a-1} y^{b-1} (-dy) = \int_0^1 (1-y)^{a-1} y^{b-1} dy = \text{Beta}(b, a).$$

2. 贝塔函数与伽玛函数间有关系

$$\text{Beta}(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}. \quad (2.20)$$

Proof. 由伽玛函数的定义知

$$\Gamma(a)\Gamma(b) = \int_0^\infty \int_0^\infty x^{a-1} y^{b-1} e^{-(x+y)} dx dy,$$

作变量变换 $x = uv, y = u(1 - v)$, 其雅可比行列式 $J = -u$, 故

$$\begin{aligned}\Gamma(a)\Gamma(b) &= \int_0^\infty \int_0^1 (uv)^{a-1} [u(1-v)]^{b-1} e^{-u} u \, du \, dv \\ &= \int_0^\infty u^{a+b-1} e^{-u} \int_0^1 v^{a-1} (1-v)^{b-1} \, dv \, du = \Gamma(a+b) \text{Beta}(a, b),\end{aligned}$$

由此证得 (2.20) 式.

2.4.5.2 贝塔分布

若随机变量 X 的密度函数为

$$p(x) = \begin{cases} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}, & 0 < x < 1, \\ 0, & \text{其他,} \end{cases} \quad (2.21)$$

则称 X 服从**贝塔分布**, 记作 $X \sim Be(a, b)$, 其中 $a > 0, b > 0$ 都是形状参数. 因为服从贝塔分布 $Be(a, b)$ 的随机变量是仅在区间 $(0, 1)$ 取值的, 所以不合格品率、机器的维修率、市场的占有率、射击的命中率等各种比率选用贝塔分布作为它们的概率分布是恰当的, 只要选择合适的参数 a 与 b 即可.

2.4.5.3 贝塔分布 $Be(a, b)$ 的数学期望和方差

利用贝塔函数的性质, 不难算得贝塔分布 $Be(a, b)$ 的数学期望为

$$\begin{aligned}\mathbb{E}[X] &= \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \int_0^1 x^a (1-x)^{b-1} \, dx \\ &= \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \cdot \frac{\Gamma(a+1)\Gamma(b)}{\Gamma(a+b+1)} = \frac{a}{a+b}.\end{aligned}$$

又因为

$$\begin{aligned}\mathbb{E}[X]^2 &= \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \int_0^1 x^{a+1} (1-x)^{b-1} \, dx \\ &= \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \cdot \frac{\Gamma(a+2)\Gamma(b)}{\Gamma(a+b+2)} \\ &= \frac{a(a+1)}{(a+b)(a+b+1)}.\end{aligned}$$

由此得 X 的方差为

$$\text{Var}[X] = \frac{a(a+1)}{(a+b)(a+b+1)} - \left(\frac{a}{a+b}\right)^2 = \frac{ab}{(a+b)^2(a+b+1)}.$$

以下我们将常用分布的期望和方差以表格形式放在一起.

表 2.1: 常用分布的数学期望和方差

分布	分布列 p_k 或分布密度 $p(x)$	期望	方差
----	------------------------	----	----

续表

0-1 分布	$p_k = p^k(1-p)^{1-k}, k=0,1.$	p	$p(1-p)$
二项分布 $b(n, p)$	$p_k = \binom{n}{k} p^k (1-p)^{n-k}, k=0,1,\dots,n.$	np	$np(1-p)$
泊松分布 $P(\lambda)$	$p_k = \frac{\lambda^k}{k!} e^{-\lambda}, k=0,1,\dots.$	λ	λ
超几何分布 $h(n, N, M)$	$p_k = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, k=0,1,\dots,r$ $r = \min\{M, n\}.$	$n \frac{M}{N}$	$\frac{nM(N-M)(N-n)}{N^2(N-1)}$
几何分布 $\text{Geo}(p)$	$p_k = (1-p)^{k-1} p, k=1,2,\dots.$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
负二项分布 $Nn(r, p)$	$p_k = \binom{k-1}{r-1} (1-p)^{k-r} p^r, k=r, r+1,\dots.$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
正态分布 $N(\mu, \sigma^2)$	$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, -\infty < x < \infty$	μ	σ^2
均匀分布 $U(a, b)$	$p(x) = \frac{1}{b-a}, a < x < b.$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布 $\text{Exp}(\lambda)$	$p(x) = \lambda e^{-\lambda x}, x \geq 0.$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
伽马分布 $\text{Ga}(\alpha, \lambda)$	$p(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, x \geq 0.$	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$
$\chi^2(n)$ 分布	$p(x) = \frac{x^{n/2-1} e^{-x/2}}{\Gamma(n/2) 2^{n/2}}, x \geq 0.$	n	$2n$
贝塔分布 $Be(a, b)$	$p(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}, 0 < x < 1.$	$\frac{a}{a+b}$	$\frac{ab}{(a+b)^2(a+b+1)}$

注：表中仅列出各分布密度函数的非零区域。

2.5 随机变量函数的分布

设 $y = g(x)$ 是定义在直线上的一个函数, X 是一个随机变量, 那么 $Y = g(X)$ 作为 X 的函数, 同样也是一个随机变量. 我们要研究的问题是: 已知随机变量 X 的分布, 如何求出另一个随机变量 $Y = g(X)$ 的分布.

寻求随机变量函数的分布, 是概率论的基本技巧, 在概率论与数理统计中经常要用到这些技巧. 下面对离散和连续两种场合分别讨论随机变量函数的分布.

2.5.1 离散随机变量函数的分布

离散随机变量函数的分布是比较容易求得的. 设 X 是离散随机变量, X 的分布列为

X	x_1	x_2	$\cdots$	x_n	$\cdots$
P	$p(x_1)$	$p(x_2)$	$\cdots$	$p(x_n)$	$\cdots$

则 $Y = g(X)$ 也是一个离散随机变量. 此时 Y 的分布列就可很简单地表示为

$$\begin{array}{c|cccc} Y & g(x_1) & g(x_2) & \cdots & g(x_n) & \cdots \\ \hline P & p(x_1) & p(x_2) & \cdots & p(x_n) & \cdots \end{array}$$

当 $g(x_1), g(x_2), \dots, g(x_n), \dots$ 中有某些值相等时, 则把那些相等的值分别合并, 并把对应的概率相加即可.

2.5.2 连续随机变量函数的分布

求离散随机变量函数的分布是很简单的事. 而对连续随机变量 X , 我们分以下几种情况讨论 $Y = g(X)$ 的分布.

2.5.2.1 当 $g(x)$ 为严格单调时

在这种情况下有以下定理.

定理 2.5.1

设 X 是连续随机变量, 其密度函数为 $p_X(x)$. $Y = g(X)$ 是另一个随机变量, 若 $y = g(x)$ 严格单调, 其反函数 $h(y)$ 有连续导函数, 则 $Y = g(X)$ 的密度函数为

$$p_Y(y) = \begin{cases} p_X[h(y)]|h'(y)|, & a < y < b; \\ 0, & \text{其他.} \end{cases} \quad (2.22)$$

其中 $a = \min\{g(-\infty), g(\infty)\}, b = \max\{g(-\infty), g(\infty)\}$.

Proof. 不妨设 $g(x)$ 是严格单调增函数, 这时它的反函数 $h(y)$ 也是严格单调增函数, 且 $h(y) > 0$. 记 $a = g(-\infty), b = g(\infty)$, 这意味着 $y = g(x)$ 仅在区间 (a, b) 取值, 于是

当 $y < a$ 时,

$$F_Y(y) = P(Y \leq y) = 0;$$

当 $y > b$ 时,

$$F_Y(y) = P(Y \leq y) = 1;$$

当 $a \leq y \leq b$ 时,

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(g(X) \leq y) \\ &= P(X \leq h(y)) = \int_{-\infty}^{h(y)} p(x) dx. \end{aligned}$$

由此得 Y 的密度函数为

$$p_Y(y) = \begin{cases} p_X[h(y)]h'(y), & a < y < b; \\ 0, & \text{其他.} \end{cases}$$

同理可证当 $g(x)$ 是严格单调减函数时, 结论也成立. 但此时要注意 $h'(y) < 0$, 故要加绝对值符号, 这时 $a = g(\infty), b = g(-\infty)$.

利用以上定理, 我们来证明几个很有用的结论, 并用定理形式表示.

定理 2.5.2

设随机变量 X 服从正态分布 $N(\mu, \sigma^2)$, 则当 $a \neq 0$ 时, 有 $Y = aX + b \sim N(a\mu + b, a^2\sigma^2)$.

Proof. 当 $a > 0$ 时, $Y = aX + b$ 是严格增函数, 仍在 $(-\infty, \infty)$ 上取值, 其反函数为 $X = (Y - b)/a$, 故由定理可得

$$\begin{aligned} p_Y(y) &= p_X\left(\frac{y-b}{a}\right) \frac{1}{a} = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}\left(\frac{y-b}{a}-\mu\right)^2} \frac{1}{a} \\ &= \frac{1}{\sqrt{2\pi}(a\sigma)} e^{-\frac{(y-a\mu-b)^2}{2a^2\sigma^2}}. \end{aligned}$$

这就是正态分布 $N(a\mu + b, a^2\sigma^2)$ 的密度函数.

当 $a < 0$ 时, $Y = aX + b$ 是严格减函数, 仍在 $(-\infty, \infty)$ 上取值, 其反函数为 $X = (Y - b)/a$, 由定理 ?? 可得

$$p_Y(y) = \frac{1}{\sqrt{2\pi}(|a|\sigma)} e^{-\frac{(y-a\mu-b)^2}{2a^2\sigma^2}}.$$

这个定理表明: 正态变量的线性变换仍为正态变量, 其数学期望和方差可直接从线性变换求得. 若取 $a = 1/\sigma, b = -\mu/\sigma$, 则 $Y = aX + b \sim N(0, 1)$, 此即上一节的定理 ??.

定理 2.5.3 对数正态分布

设随机变量 $X \sim N(\mu, \sigma^2)$, 则 $Y = e^X$ 的概率密度函数为

$$p_Y(y) = \begin{cases} \frac{1}{\sqrt{2\pi}y\sigma} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}, & y > 0; \\ 0, & y \leq 0. \end{cases} \quad (2.23)$$

Proof. $Y = e^x$ 是严格增函数, 它仅在 $(0, \infty)$ 上取值, 其反函数为 $x = \ln y$, 由定理可得

当 $y \leq 0$ 时, $F_Y(y) = 0$, 从而 $p_Y(y) = 0$.

当 $y > 0$ 时, Y 的密度函数为

$$p_Y(y) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}} \frac{1}{y} = \frac{1}{\sqrt{2\pi}y\sigma} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}$$

定理得证.

这个分布被称为**对数正态分布**, 记为 $LN(\mu, \sigma^2)$, 其中 μ 称为对数均值, σ 称为对数方差. 对数正态分布 $LN(\mu, \sigma^2)$ 也是一个常用分布, 实际中有不少随机变量服从对数正态分布, 譬如

- 绝缘材料的寿命服从对数正态分布.
- 设备故障的维修时间服从对数正态分布.
- 家中两个小孩的年龄差服从对数正态分布.

定理 2.5.4

设随机变量 X 服从伽玛分布 $Ga(\alpha, \lambda)$, 则当 $k > 0$, 有 $Y = kX \sim Ga(a, \lambda/k)$.

Proof. 因为 $k > 0$, 所以 $y = kx$ 是严格增函数, 它仍在 $(0, \infty)$ 上取值, 其反函数为 $x = y/k$, 由定理可得

当 $y < 0$ 时, $p_Y(y) = 0$.

当 $y \geq 0$ 时,

$$p_Y(y) = p_X\left(\frac{y}{k}\right) \frac{1}{k} = \frac{\lambda^\alpha}{k\Gamma(\alpha)} \left(\frac{y}{k}\right)^{\alpha-1} e^{-\lambda \frac{y}{k}} = \frac{(\lambda/k)^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\frac{\lambda}{k}y}.$$

此即 $Ga(\alpha, \lambda/k)$ 的密度函数, 结论得证.

这个结论是很有用的, 譬如当 $X \sim Ga(\alpha, \lambda)$, 则 $2\lambda X \sim Ga(\alpha, 1/2) = \chi^2(2\alpha)$, 即任一伽玛分布可转化为 χ^2 分布.

定理 2.5.5

若 X 的分布函数 $F_X(x)$ 为严格单调增的连续函数, 其反函数 $F_X^{-1}(y)$ 存在, 则 $Y = F_X(X)$ 服从 $(0, 1)$ 上的均匀分布 $U(0, 1)$.

Proof. 下求 $Y = F_X(X)$ 的分布函数. 由于分布函数 $F_X(x)$ 仅在 $[0, 1]$ 区间上取值, 故

当 $y < 0$ 时, 因为 $\{F_X(X) \leq y\}$ 是不可能事件, 所以

$$F_Y(y) = \Pr(Y \leq y) = \Pr(F_X(X) \leq y) = 0.$$

当 $0 \leq y < 1$ 时, 有

$$\begin{aligned} F_Y(y) &= \Pr(Y \leq y) = \Pr(F_X(X) \leq y) \\ &= \Pr(X \leq F_X^{-1}(y)) = F_X(F_X^{-1}(y)) = y. \end{aligned}$$

当 $y \geq 1$ 时, 因为 $\{F_X(X) \leq y\}$ 是必然事件, 所以

$$F_Y(y) = \Pr(Y \leq y) = \Pr(F_X(X) \leq y) = 1.$$

综上所述, $Y = F_X(X)$ 的分布函数为

$$F_Y(y) = \begin{cases} 0, & y < 0; \\ y, & 0 \leq y < 1; \\ 1, & y \geq 1. \end{cases}$$

证正是 $(0, 1)$ 上均匀分布的分布函数, 所以 $Y \sim U(0, 1)$.

2.6 分布的其他特征数

数学期望和方差是随机变量最重要的两个特征数. 此外, 随机变量还有一些其他的特征数, 以下逐一给出它们的定义.

2.6.1 k 阶矩

定义 2.6.1

设 X 为随机变量, k 为正整数. 如果以下的数学期望都存在, 则称

$$\mu_k = E(X^k) \quad (2.24)$$

为 X 的 k 阶原点矩. 称

$$\nu_k = E[X - E(X)]^k \quad (2.25)$$

为 X 的 k 阶中心矩.

显然, 一阶原点矩就是数学期望, 二阶中心矩就是方差. 由于 $|X|^{k-1} \leq |X|^k + 1$, 故 k 阶矩存在时, $k-1$ 阶矩也存在, 从而低于 k 的各阶矩都存在.

中心矩和原点矩之间有一个简单的关系, 事实上

$$\nu_k = E[X - E(X)]^k = E(X - \mu_1)^k = \sum_{i=0}^k \binom{k}{i} \mu_i (-\mu_1)^{k-i},$$

故前四阶中心矩可分别用原点矩表示如下:

$$\nu_1 = 0;$$

$$\nu_2 = \mu_2 - \mu_1^2;$$

$$\nu_3 = \mu_3 - 3\mu_2\mu_1 + 2\mu_1^3;$$

$$\nu_4 = \mu_4 - 4\mu_3\mu_1 + 6\mu_2\mu_1^2 - 3\mu_1^4.$$

2.6.2 变异系数

方差 (或标准差) 反映了随机变量取值的波动程度, 但在比较两个随机变量的波动大小时, 如果仅看方差 (或标准差) 的大小有时会产生不合理的现象. 这有两个原因: (1) 随机变量的取值有量纲, 不同量纲的随机变量用其方差 (或标准差) 去比较它们的波动大小不太合理. (2) 在取值的量纲相同的情况下, 取值的大小有一个相对性问题, 取值较大的随机变量的方差 (或标准差) 也允许大一些.

所以要比较两个随机变量的波动大小时, 在有些场合使用以下定义的变异系数来进行比较, 更具可比性.

定义 2.6.2 变异系数

设随机变量 X 的二阶矩存在, 则称比值

$$C_v(X) = \frac{\sqrt{\text{Var}[X]}}{E(X)} = \frac{\sigma(X)}{E(X)} \quad (2.26)$$

为 X 的变异系数.

因为变异系数是以其数学期望为单位去度量随机变量取值波动程度的特征数, 标准差的量纲与数学期望的量纲是一致的, 所以变异系数是一个无量纲的量.

2.6.3 分位数

定义 2.6.3 分位数

设连续随机变量 X 的分布函数为 $F(x)$, 密度函数为 $p(x)$. 对任意 $p \in (0, 1)$, 称满足条件

$$F(x_p) = \int_{-\infty}^{x_p} p(x) dx = p \quad (2.27)$$

的 x_p 为此分布的 p 分位数, 又称下侧 p 分位数.

分位数 x_p 是把密度函数下的面积分为两块, 左侧面积恰好为 p .

同理我们称满足条件

$$1 - F(x'_p) = \int_{x'_p}^{\infty} p(x) dx = p \quad (2.28)$$

的 x'_p 为此分布的上侧 p 分位数.

上侧分位数 x'_p 也是把密度函数下的面积分为两块, 但右侧面积恰好为 p (见图 2.5(b)).




图 2.5: 分位数与上侧分位数的区别

要善于区分分位数与上侧分位数的差别, 本书指定用分位数表, 而有一些书使用的是上侧分位数表, 无论用什么表, 书中都有说明.

分位数与上侧分位数是可以相互转换的, 其转换公式如下.

$$x'_p = x_{1-p}; \quad x_p = x'_{1-p}. \quad (2.29)$$

分位数在统计中经常被使用, 特别对统计中常用的三大分布: χ^2 分布、 t 分布和 F 分布, 都特地编制了它们的分位数表. 以后分别以 $\chi^2_{\alpha}(n)$, $t_{\alpha}(n)$, $F_{\alpha}(n, m)$ 记这些分布的 α 分位数. 例如 $\alpha = 0.05$, $n = 10$, $m = 15$ 时, 查附表 3、附表 4、附表 5, 可得

$$\chi^2_{1-\alpha}(n) = 18.307; \quad t_{1-\alpha} = 1.8125; \quad F_{1-\alpha}(n, m) = 2.54.$$

譬如, 记某种轴承的寿命为 T , t_p 为此寿命分布的 p 分位数, 则 $t_{0.1} = 1000$ (h), 表明此种轴承中约有 90% 寿命超过 1000 小时. 若记另一种轴承的寿命为 Z , p 分位数为 z_p . 则当 $z_{0.1} = 1500$ (h) 时, 从 0.1 的分位数上说明后者的质量比前者更高一些.

2.6.4 中位数

定义 2.6.4 中位数

设连续随机变量 X 的分布函数为 $F(x)$, 密度函数为 $p(x)$. 称 $p = 0.5$ 时的 p 分位数 $x_{0.5}$ 为此分布的**中位数**, 即 $x_{0.5}$ 满足

$$F(x_{0.5}) = \int_{-\infty}^{x_{0.5}} p(x) dx = 0.5. \quad (2.30)$$

中位数的图形见下面图 2.6.




图 2.6: 连续随机变量的中位数

中位数与均值一样都是随机变量位置的特征数, 但在某些场合可能中位数比均值更能说明问题. 譬如, 某班级学生的考试成绩的中位数为 80 分, 则表明班级中的有一半同学的成绩低于 80 分, 另一半同学的成绩高于 80 分. 而如果考试成绩的均值是 80 分, 则无法得出如此明确的结论.

又譬如, 记 X 为 A 国人的年龄, Y 为 B 国人的年龄, $x_{0.5}$ 和 $y_{0.5}$ 分别为 X 和 Y 的中位数, 则 $x_{0.5} = 40$ (岁) 说明 A 国约有一半的人年龄小于等于 40 岁、一半的人年龄大于等于 40 岁. 而 $y_{0.5} = 50$ (岁) 则说明 B 国更趋于老龄化.

2.6.5 偏度系数

定义 2.6.5 偏度系数

设随机变量 X 的三阶矩存在, 则称比值

$$\beta_1 = \frac{E[X - E(X)]^3}{[E(X - E(X))^2]^{3/2}} = \frac{\nu_3}{(\nu_2)^{3/2}} \quad (2.31)$$

为 X 的分布的**偏度系数**, 简称**偏度**.

偏度系数可以描述分布的形状特征, 其取值的正负反映的是

- 当 $\beta_1 > 0$ 时, 分布为正偏或右偏, 见图 ??(a).
- 当 $\beta_1 = 0$ 时, 分布关于其均值 $E(X)$ 对称, 见图 ??(b).
- 当 $\beta_1 < 0$ 时, 分布为负偏或左偏, 见图 ??(c).

譬如, 正态分布 $N(\mu, \sigma^2)$ 是关于其均值 $E(X) = \mu$ 是对称的, 所以正态分布的偏度 $\beta_1 = 0$.




图 2.7: 三种不同偏度的分布

2.6.6 峰度系数

定义 2.6.6 峰度系数

设随机变量 X 的四阶矩存在, 则称比值

$$\beta_2 = \frac{E[X - E(X)]^4}{[E(X - E(X))^2]^2} - 3 = \frac{\nu_4}{(\nu_2)^2} - 3 \quad (2.32)$$

为 X 的分布的**峰度系数**, 简称**峰度**.

峰度系数也是用于描述分布的形状特征, 但峰度系数与偏度系数的差别是: 偏度系数刻画的是分布的对称性, 而峰度系数刻画的是分布的峰峭性.

峰度系数把正态分布的峰峭性作为标准, 因为正态分布 $N(\mu, \sigma^2)$ 的四阶中心矩为 $\nu_4 = 3\sigma^4$, 所以其峰度系数为

$$\beta_2 = \frac{\nu_4}{(\nu_2)^2} - 3 = \frac{3\sigma^4}{\sigma^4} - 3 = 0.$$

这说明: 任一正态分布的峰度 $\beta_2 = 0$.

可见, 这里谈论的“峰度”不是指密度函数的峰值高低, 那么“峰度”的含义到底是什么呢? 或者换句话说, 我们应该如何刻画密度函数的峰峭性呢? 我们知道从图形上看密度函数曲线下的面积等于 1, 若随机变量取值较集中, 则其密度函数的峰值必高无疑, 所以密度函数峰值的高低含有随机变量取值的集中程度. 为了消除这个因素, 我们不妨考察“标准化”后的分布的峰峭性, 即用

$$X^* = \frac{X - E(X)}{\sqrt{\text{Var}[X]}}$$

的四阶原点矩 $E[(X^*)^4]$ 考察密度函数的峰值, 再考虑到任一标准正态分布的四阶原点矩等于 3, 所以就有了以上峰度系数的定义.

综上所述, 一个分布的峰度系数 β_2 反映了以下情况:

- 当 $\beta_2 < 0$ 时, 则标准化后的分布形状比标准正态分布更平坦, 称为**低峰度**.
- 当 $\beta_2 = 0$ 时, 则标准化后的分布形状与标准正态分布相当.
- 当 $\beta_2 > 0$ 时, 则标准化后的分布形状比标准正态分布更尖峭, 称为**高峰度**.

Part II

数理统计与统计推断

Part III

贝叶斯统计

Chapter 1

常见分布及关系

1.1 离散型随机变量

二项分布: $X \sim \text{Binomial}(n, p)$

描述重复独立伯努利试验 n 次后成功 k 次数的分布, 参数为试验次数 n 和成功概率 p .

$$\Pr(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \mathbb{N}. \quad \implies \quad \begin{cases} \mathbb{E}[X] = np, \\ \text{Var}[X] = np(1-p). \end{cases}$$

其中,

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} = \frac{\Gamma(n+1)}{\Gamma(k+1)\Gamma(n-k+1)}.$$

负二项分布: $X \sim \text{NegBin}(r, p)$

描述重复独立伯努利试验中, 经历了 k 次失败才能获得第 r 次成功的分布, 成功概率为 p .

$$\Pr(X = k) = \binom{k+r-1}{k} (1-p)^k p^r, \quad k \in \mathbb{N}. \quad \implies \quad \begin{cases} \mathbb{E}[X] = \frac{r(1-p)}{p}, \\ \text{Var}[X] = \frac{r(1-p)}{p^2}. \end{cases}$$

若更关心的是总共进行了多少次试验, 即 $n = k + r$, 最后一次成功 (确定的).

$$\Pr(N = n) = \binom{n-1}{r-1} p^r (1-p)^{n-r}, \quad n \geq r, n \in \mathbb{N}. \quad \implies \quad \begin{cases} \mathbb{E}[N] = \frac{r}{p}, \\ \text{Var}[N] = \frac{r(1-p)}{p^2}. \end{cases}$$

泊松分布: $X \sim \text{Poisson}(\lambda)$

表示单位时间或空间内某事件发生次数的分布, 参数为事件的平均发生率 λ .

$$\Pr(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k \in \mathbb{N}. \quad \implies \quad \begin{cases} \mathbb{E}[X] = \lambda, \\ \text{Var}[X] = \lambda. \end{cases}$$

1.2 连续型随机变量

正态分布: $X \sim \mathcal{N}(\mu, \sigma^2)$

中心在 μ , 标准差为 σ 的钟形分布.

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \implies \begin{cases} \mathbb{E}[X] = \mu, \\ \text{Var}[X] = \sigma^2. \end{cases}$$

指数分布: $X \sim \text{Exp}(\lambda)$

中心在 μ , 标准差为 σ 的钟形分布.

$$f(x) = \lambda e^{-\lambda x}, x > 0. \implies \begin{cases} \mathbb{E}[X] = \frac{1}{\lambda}, \\ \text{Var}[X] = \frac{1}{\lambda^2}. \end{cases}$$

伽马分布: $X \sim \text{Gamma}(\alpha, \lambda)$

形状参数 $\alpha > 0$, 尺度参数 $\lambda > 0$.

$$f(x) = \frac{\lambda^\alpha x^{\alpha-1} e^{-\lambda x}}{\Gamma(\alpha)}, x > 0. \implies \begin{cases} \mathbb{E}[X] = \frac{\alpha}{\lambda}, \\ \text{Var}[X] = \frac{\alpha}{\lambda^2}. \end{cases}$$

显然, $X \sim \text{Gamma}(1, \lambda)$ 时, $f(x) = \lambda e^{-\lambda x}$, 等价于 $X \sim \text{Exp}(\lambda)$.

贝塔分布: $X \sim \text{Beta}(\alpha, \beta)$

两个形状参数 $\alpha > 0$ 和 $\beta > 0$ 分别控制左侧和右侧区间.

$$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{\mathbf{B}(\alpha, \beta)}, x \in [0, 1]. \implies \begin{cases} \mathbb{E}[X] = \frac{\alpha}{\alpha + \beta}, \\ \text{Var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}, \\ \text{Mode}[X] = \frac{\alpha - 1}{\alpha + \beta - 2}, \alpha, \beta > 1. \end{cases}$$

显然, $X \sim \text{Beta}(1, 1)$ 时, $f(x) = 1$, 等价于 $X \sim \text{Uniform}(0, 1)$.

1.3 伽马函数与贝塔函数

1.3.1 伽马函数

Gamma 函数定义为:

$$\Gamma(n) = \int_0^\infty t^{n-1} e^{-t} dt \implies \int_0^\infty x^n e^{-ax} dx = \frac{\Gamma(n+1)}{a^{n+1}}. \quad (1.1)$$

并且对于正整数 ($n \in \mathbb{N}^*$), 有,

$$\Gamma(n) = (n-1)!$$

对于任意正数 $x > 0$, 有,

$$\Gamma(x+1) = x\Gamma(x), \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}. \implies \Gamma\left(x + \frac{1}{2}\right) = (x-1)!\sqrt{\pi}.$$

1.3.2 贝塔函数

Beta 函数定义为:

$$\boldsymbol{B}(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} \mathrm{d}x \quad (1.2)$$

用伽马函数表示

$$\boldsymbol{B}(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

Chapter 2

贝叶斯模型的推导与 Gibbs 采样

2.1 联合概率密度函数和全条件分布

2.1.1 联合概率密度函数 (Joint Probability Distribution Function)

通过条件概率公式和先验概率递归表示. 公式如下:

$$\begin{aligned} p(\mathbf{y}, \mu, \tau) &= p(\mathbf{y}|\mu, \tau)p(\mu)p(\tau) \\ &= p(\mu)p(\tau) \prod_{i=1}^n p(y_i|\mu, \tau) \end{aligned} \quad (2.1)$$

假设

$$\begin{aligned} y_i|\mu, \tau &\sim \mathcal{N}(\mu, \tau^{-1}), \\ \mu &\sim \mathcal{N}(1, 1), \\ \tau &\sim \text{Ga}(2, 1). \end{aligned}$$

因此

$$\begin{aligned} p(\mathbf{y}, \mu, \tau) &= p(\mathbf{y}|\mu, \tau)p(\mu)p(\tau) \\ &= p(\mu)p(\tau) \prod_{i=1}^n p(y_i|\mu, \tau) \\ &= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(\mu-1)^2}{2}\right) \cdot \frac{1^2 \tau^{2-1} e^{-\tau}}{\Gamma(2)} \cdot \prod_{i=1}^n \frac{1}{\sqrt{2\pi\tau^{-1}}} \exp\left(-\frac{(y_i-\mu)^2}{2\tau^{-1}}\right) \\ &= (2\pi)^{-\frac{1}{2}} \exp\left(-\frac{(\mu-1)^2}{2}\right) \cdot \tau \exp(-\tau) \cdot \prod_{i=1}^n (2\pi)^{-\frac{1}{2}} \tau^{\frac{1}{2}} \exp\left(-\frac{(y_i-\mu)^2}{2\tau^{-1}}\right) \\ &= (2\pi)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\mu-1)^2\right) \cdot \tau \exp(-\tau) \cdot (2\pi)^{-\frac{n}{2}} \tau^{\frac{n}{2}} \exp\left(-\frac{\tau}{2} \sum_{i=1}^n (y_i-\mu)^2\right) \\ &= (2\pi)^{-\frac{n+1}{2}} \tau^{\frac{n}{2}+1} \exp\left(-\frac{1}{2} \left[(\mu-1)^2 + \tau \sum_{i=1}^n (y_i-\mu)^2 \right] \right) \exp(-\tau) \end{aligned}$$

2.1.2 全条件分布 (Full Conditional Distribution)

根据贝叶斯公式

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} \propto p(y|x)p(x) = p(x, y). \quad (2.2)$$

接上题

$$\begin{aligned}
 p(\mu|\mathbf{y}, \tau) &\propto p(\mathbf{y}, \mu, \tau) \\
 &= (2\pi)^{-\frac{n+1}{2}} \tau^{\frac{n}{2}+1} \exp\left(-\frac{1}{2}\left[(\mu-1)^2 + \tau \sum_{i=1}^n (y_i - \mu)^2\right]\right) \exp(-\tau) \\
 &\propto \exp\left(-\frac{1}{2}\left[(\mu-1)^2 + \tau \sum_{i=1}^n (y_i - \mu)^2\right]\right) \\
 &= \exp\left(-\frac{(1+\tau n)}{2}\left[\mu - \frac{1+\tau n\bar{y}}{1+\tau n}\right]^2 + \text{const.}\right) \\
 &\propto \exp\left(-\frac{(1+\tau n)}{2}\left(\mu - \frac{1+\tau n\bar{y}}{1+\tau n}\right)^2\right) \implies \mu|\mathbf{y}, \tau \sim \mathcal{N}\left(\frac{1+\tau n\bar{y}}{1+\tau n}, (1+\tau n)^{-1}\right).
 \end{aligned}$$

同理

$$\begin{aligned}
 p(\tau|\mathbf{y}, \mu) &\propto p(\mathbf{y}, \mu, \tau) \\
 &= (2\pi)^{-\frac{n+1}{2}} \tau^{\frac{n}{2}+1} \exp\left(-\frac{1}{2}\left[(\mu-1)^2 + \tau \sum_{i=1}^n (y_i - \mu)^2\right]\right) \exp(-\tau) \\
 &\propto \tau^{\frac{n}{2}+1} \exp\left(-\frac{\tau}{2} \sum_{i=1}^n (y_i - \mu)^2\right) \exp(-\tau) \\
 &= \tau^{\frac{n}{2}+1} \exp\left(-\left[1 + \frac{1}{2} \sum_{i=1}^n (y_i - \mu)^2\right] \tau\right) \implies \tau|\mathbf{y}, \mu \sim \text{Ga}\left(\frac{n}{2} + 21 + \frac{1}{2} \sum_{i=1}^n (y_i - \mu)^2\right).
 \end{aligned}$$

2.2 Gibbs 采样

Gibbs 采样提供了一种间接的方法, 通过依次从全条件分布中采样来逼近后验分布.

一句话总结: 吉布斯采样是一种从复杂多维后验分布中抽样的办法, 是马尔可夫链蒙特卡洛 (MCMC) 方法的一种。

假设我们有一个高维参数向量 $\theta = (\theta_1, \theta_2, \dots, \theta_n)$, 但很难直接从其后验分布 $p(\theta|y)$ 采样. 那我索性直接就不解, 我就靠“采样”给他描述出来.

我们想了解一个奇形怪状的水池 (水池就是后验分布), 但你不能直接画出它的形状. 那咋整? **Gibbs 这傻波一就说:** 我就往里面扔小球, 然后看球最后落在哪些区域多. 那我就把这个水池的形状给描绘出来了. MCMC 其实道理也差不多.

Gibbs 采样的思路是:

1. 分解后验分布:

计算每个参数的全条件分布 $p(\theta_i|\theta_{-i}, y)$, 其中 θ_{-i} 表示除 θ_i 以外的所有参数.

2. 循环采样:

- 先固定所有其他参数, 从 $p(\theta_1|\theta_2, \theta_3, \dots, \theta_n, y)$ 中采样新的 θ_1 ;
- 再固定新的 θ_1 和其他参数, 从 $p(\theta_2|\theta_1, \theta_3, \dots, \theta_n, y)$ 中采样新的 θ_2 ;
- ...
- 最后固定新的 θ_{n-1} 和其他参数, 从 $p(\theta_n|\theta_1, \theta_2, \dots, \theta_{n-1}, y)$ 中采样新的 θ_n .

这形成了一个马尔可夫链, 经过足够长的采样后, 样本会收敛到后验分布 $p(\theta|y)$.

例 2.2.1 Gibbs 采样两参数举例

假设有两个参数 θ_1, θ_2 , 目标是从后验分布 $p(\theta_1, \theta_2|y)$ 采样:

1. 选择一个初始值 $\theta_2^{(0)}$.
2. 迭代以下步骤 T 次:
 - **Step 1.** 从条件分布 $p(\theta_1|\theta_2^{(t-1)}, y)$ 采样新的 $\theta_1^{(t)}$.
 - **Step 2.** 从条件分布 $p(\theta_2|\theta_1^{(t)}, y)$ 采样新的 $\theta_2^{(t)}$.
3. 经过一定的“burn-in” (前几个样本丢弃), 最终的样本可以用于逼近后验分布.

接上题:

- (1) Initialise $\tau^{(0)}$ in the support of this parameter. E.g. sample them from the prior.
- (2) for $k = 1, \dots, K$
 - Draw $\mu^{(k)}$ from $p(\mu|\tau^{(k-1)}, \mathbf{y})$
 - Draw $\tau^{(k)}$ from $p(\tau|\mu^{(k)}, \mathbf{y})$
- (3) Discard burn-in and optionally thin-out.

2.2.1 使用 Gibbs 采样样本生成后验预测分布样本

Explain how you could use samples $(\mu^{(t)}, \tau^{(t)}), t = 1, \dots, T$ from the Gibbs sampler to generate samples from the posterior predictive distribution for a new (independent) observation $\tilde{y}$.

解释如何利用从 Gibbs 采样器中得到的样本 $(\mu^{(t)}, \tau^{(t)}), t = 1, \dots, T$, 生成新的 (独立的) 观测 y 的后验预测分布的样本?

例 2.2.2

Gibbs 采样已经生成了一组从后验分布 $p(\mu, \tau|y)$ 中抽取的样本:

$$\{(\mu^{(t)}, \tau^{(t)}) : t = 1, \dots, T\}$$

根据贝叶斯理论, 新的独立观测 $\tilde{y}$ 的后验预测分布为:

$$p(\tilde{y}|y) = \int p(\tilde{y}|\mu, \tau)p(\mu, \tau|y)d\mu d\tau$$

在 Gibbs 采样的情况下, 我们可以通过以下步骤近似生成 y 的样本:

1. 丢弃 **burn-in** 样本 (初始未收敛样本).
2. 使用剩下的样本 $(\mu^{(t)}, \tau^{(t)})$:
 - 对于每一个样本 $(\mu^{(k)}, \tau^{(k)})$, 生成 $\tilde{y}^{(k)} \sim N(\mu^{(k)}, (\tau^{(k)})^{-1})$.
 - 这表示 $\tilde{y}$ 的预测分布依赖于当前的 μ 和 τ 值.
3. 最终, 所有生成的 $\tilde{y}^{(k)}$ 样本 ($k = 1, \dots, T'$) 将近似于后验预测分布 $p(\tilde{y}|y)$.

Solution:

Having collected draws from our Gibbs sampler, discard the burn-in, and possibly thin-out. For every remaining draw, take current $(\mu^{(k)}, \tau^{(k)})$, plug them into the likelihood $\tilde{y}|\mu, \tau \sim \mathcal{N}(\mu, \tau^{-1})$ and generate a sample from this distribution. The resulting set of samples are coming from the posterior predictive distribution.

收集了我们的 Gibbs 抽样结果后, 丢弃预热期数据, 可能还需要进行数据稀疏化. 对于每个剩余的抽样, 取当前的 $(\mu^{(k)}, \tau^{(k)})$, 将它们代入似然函数 $\tilde{y}|\mu, \tau \sim \mathcal{N}(\mu, \tau^{-1})$, 并从这个分布中生成一个样本. 得到的样本集来自后验预测分布.

2.2.2 为什么丢弃初始样本? 多条链如何帮助决定丢弃数量?

1. 为什么在 Gibbs 采样中通常丢弃初始样本?
2. 运行多条链如何帮助决定丢弃的数量?

例 2.2.3

1. 为什么丢弃初始样本?

Gibbs 采样是一种马尔可夫链方法, 初始状态通常与目标分布 (后验分布) 不一致. 采样过程需要一些时间达到平稳分布, 这段时间被称为 **burn-in** 阶段.

- **初始样本的问题:** 在 burn-in 阶段, 样本未收敛到目标分布, 可能会过多依赖初始值, 导致偏差.
- **丢弃的目的:** 通过丢弃初始样本, 确保最终用于推断的样本接近后验分布.

2. 多条链如何帮助判断丢弃数量?

运行多条链 (从不同的初始值出发), 可以帮助检测马尔可夫链是否已经收敛到目标分布.

- **方法:**
 - 从不同的初始点运行多条链.
 - 对每条链绘制参数值的时间序列图, 观察是否在一定时间后趋于一致.
- **判断 burn-in 阶段:**

当多条链的采样值开始收敛并在相同区域波动时, 可以确定 burn-in 阶段结束. 在此之前的样本应被丢弃.

Solution:

The Gibbs sampler is a Markov chain. Markov chains take time to reach equilibrium, i.e. settle into their limiting distribution. So one needs to eliminate initial draws which will not yet be sampled from the correct distribution. These initial draws are called the burn-in period.

吉布斯抽样是一种马尔可夫链. 马尔可夫链需要时间才能达到平衡, 即进入其极限分布. 因此, 需要消除那些尚未从正确分布中抽取的初始抽取. 这些初始抽取被称为预热期.

Multiple chains started from different initial points will all converge to the same limiting distribution along their own trajectories. A time plot of all the chains will indicate when all the chains come together, and samples prior to that point should be discarded as burn-in.

从不同初始点开始的多个链都将沿着自己的轨迹收敛到相同的极限分布. 所有链的时间图将指示所有链何时聚集在一起, 并且在那之前的样本应被视为预热期而被丢弃.

2.2.3 怎么用你手上的这些采样数据去做预测？

例 2.2.4

假设有一个样本 $(\lambda(t), \beta(t)), t = 1, \dots, T$, 来自 λ 和 β 的联合后验分布。解释如何使用它来计算一个新实验 $(n+1)$ 对未来观测值 $\tilde{y}_{n+1}$ 的后验预测分布的估计。

Solution:

For each sample from the joint posterior distribution of $\lambda(t)$ and β , take a draw of

$$\lambda_{n+1} \sim \text{Exp, Gamma, Poisson, Beta} \cdots (\beta)$$

using `rexp`, `rgamma`, `rpois`, `rbeta`, $\dots$ in R, and then we draw

$$\tilde{y}_{n+1} \sim \text{Exp, Gamma, Poisson, Beta} \cdots (\lambda_{n+1}).$$

Then set $\{\tilde{y}_{n+1}^{(t)} : t = 1, 2, \dots, T\}$ are samples from the posterior predictive distribution of $\tilde{y}_{n+1}$.

2.2.3.0.1 特别提示 在这道题里, 是让我们预测, 即**新实验** $(n+1)$, 那么这时候控制 $\tilde{y}_{n+1}$ 的参数 λ_{n+1} 并不在后验中有任何出现, 因此需要重新抽取. 但是如果题目只要求对第 j 组观测值的后验描述, 即**没有强调**是**新实验** $(n+1)$ 那么这时候 λ_{n+1} 并不用重新抽取.

Chapter 3

Poisson 模型与共轭分布及 Jeffreys 先验

给定一个时间段内的公交车到达次数 y , 建模为一个泊松分布:

$$p(y|\lambda) = \frac{\lambda^y}{y!} e^{-\lambda}, \quad \lambda > 0, y = 0, 1, 2, \dots$$

3.1 似然函数的推导

似然函数描述的是在参数已知的情况下, 观测数据的联合概率. 泊松分布的概率密度函数为:

$$p(y_i|\lambda) = \frac{\lambda^{y_i}}{y_i!} e^{-\lambda}, \quad i = 1, \dots, n$$

由于观测值是独立的, 联合似然函数为:

$$\begin{aligned} L(\lambda) &= p(y_1, \dots, y_n|\lambda) = \prod_{i=1}^n p(y_i|\lambda) = \prod_{i=1}^n \frac{\lambda^{y_i}}{y_i!} e^{-\lambda} \\ &= \frac{\lambda^{\sum_{i=1}^n y_i}}{\prod_{i=1}^n y_i!} \exp(-n\lambda) \end{aligned}$$

3.2 共轭先验的定义及 Gamma 分布共轭性质的证明

3.2.1 共轭先验

在贝叶斯统计中, 如果后验分布 $p(\lambda|\mathbf{y})$ 和先验分布 $p(\lambda)$ 属于同一分布族, 则称该先验分布为**共轭先验**. 共轭先验的优点是计算简单, 后验分布的参数可以直接通过数据更新.

Suppose the prior distribution comes from a particular family of distributions, e.g. the gamma distributions. If the posterior distribution (obtained via Bayes' theorem) is from the same family of distributions (with parameters modified by the data), then the prior is conjugate to the likelihood.

假设先验分布来自特定的分布族, 例如 Gamma 分布. 如果后验分布 (通过贝叶斯定理获得) 来自同一分布族 (参数由数据修改), 则先验分布与似然函数是共轭的.

3.2.2 先验分布: Gamma 分布

假设先验分布为 Gamma 分布 $\text{Gamma}(\alpha, \beta)$, 先验为:

$$p(\lambda) = \frac{\beta^\alpha \lambda^{\alpha-1} e^{-\beta\lambda}}{\Gamma(\alpha)} \propto \lambda^{\alpha-1} e^{-\beta\lambda}$$

泊松分布的似然函数为:

$$L(\lambda|\mathbf{y}) = \frac{\lambda^{\sum_{i=1}^n y_i}}{\prod_{i=1}^n y_i!} \exp(-n\lambda) \propto \lambda^{\sum_{i=1}^n y_i} \exp(-n\lambda)$$

后验分布按贝叶斯公式计算:

$$\begin{aligned} p(\lambda|\mathbf{y}) &= \frac{p(\mathbf{y}|\lambda)p(\lambda)}{p(\mathbf{y})} \\ &\propto L(\lambda|\mathbf{y})p(\lambda) \\ &\propto \lambda^{\sum_{i=1}^n y_i} \exp(-n\lambda) \cdot \lambda^{\alpha-1} e^{-\beta\lambda} \\ &= \lambda^{\alpha-1+\sum_{i=1}^n y_i} \exp(-(\beta+n)\lambda) \\ &\Rightarrow \lambda|\mathbf{y} \sim \text{Gamma}\left(\alpha + \sum_{i=1}^n y_i, \beta + n\right) \end{aligned} \quad (3.1)$$

代入似然函数和先验分布:

$$p(\lambda|\mathbf{y}) \propto [\lambda^{\sum_{i=1}^n y_i} e^{-n\lambda}] \cdot [\lambda^{\alpha-1} e^{-\beta\lambda}]$$

i.e. the posterior is also a Gamma distribution, therefore the prior is conjugate. (即, 后验分布也是一个 Gamma 分布, 因此先验分布是共轭的.)

3.3 求参数 λ 的 Jeffreys 先验 $p(\lambda)$

Jeffreys 先验是一种非信息先验 (Non-informative Prior), 定义为:

$$p(\lambda) \propto \sqrt{J(\lambda)} \quad (3.2)$$

其中 $J(\lambda)$ 是参数 λ 的 Fisher 信息量, 定义为:

$$J(\lambda) = \mathbb{E} \left[\left(\frac{\partial}{\partial \lambda} \log p(\mathbf{y}|\lambda) \right)^2 \right] = -\mathbb{E} \left[\frac{\partial^2}{\partial \lambda^2} \log L(\lambda) \middle| \lambda \right] \quad (3.3)$$

因此,

$$\begin{aligned}
 L(\lambda) &= \frac{\lambda^{\sum_{i=1}^n y_i}}{\prod_{i=1}^n y_i!} \exp(-n\lambda). \\
 \log L(\lambda) &= \log(\lambda^{\sum_{i=1}^n y_i}) - \log\left(\prod_{i=1}^n y_i!\right) + \log(\exp(-n\lambda)) \\
 &= \left(\sum_{i=1}^n y_i\right) \log \lambda + \text{const.} - n\lambda. \\
 \frac{\partial}{\partial \lambda} \log L(\lambda) &= \frac{1}{\lambda} \sum_{i=1}^n y_i - n. \\
 \frac{\partial^2}{\partial \lambda^2} \log L(\lambda) &= -\frac{1}{\lambda^2} \sum_{i=1}^n y_i. \\
 \mathbb{E}\left[\frac{\partial^2}{\partial \lambda^2} \log L(\lambda) \middle| \lambda\right] &= -\frac{1}{\lambda^2} \sum_{i=1}^n \mathbb{E}[y_i] = -\frac{n\lambda}{\lambda^2} = -\frac{n}{\lambda}. \\
 J(\lambda) &= \frac{n}{\lambda}. \\
 p(\lambda) &= \sqrt{\frac{n}{\lambda}} \propto \frac{1}{\sqrt{\lambda}}.
 \end{aligned}$$

3.4 Jeffreys 先验是否是一个合法的先验分布?

一个先验分布 $p(\lambda)$ 合法的条件是其积分必须有限:

$$\int_0^\infty p(\lambda) d\lambda < \infty$$

因此,

$$\int_0^\infty \frac{1}{\sqrt{\lambda}} d\lambda = \left[2\lambda^{\frac{1}{2}}\right]_0^\infty = \infty,$$

i.e. the normalisation constant does not exist. 因此 Jeffreys 先验是**不合法的** (improper).

3.5 使用 Jeffreys 先验的后验分布是否合法?

后验分布是否合法取决于后验分布 $p(\lambda|\mathbf{y})$ 是否为正则分布 (proper distribution), 即

$$\int_0^\infty p(\lambda|\mathbf{y}) d\lambda = 1.$$

使用 Jeffreys 先验 $p(\lambda) \propto \frac{1}{\sqrt{\lambda}}$ 等价于 $\text{Gamma}\left(\frac{1}{2}, 0\right)$. 由3.2.2可知, 其后验分布为:

$$\lambda|\mathbf{y} \sim \text{Gamma}\left(\frac{1}{2} + \sum_{i=1}^n y_i, n\right)$$

and as long as $n \geq 1$, it is a proper (normalised) probability distribution. So, the posterior is proper. 这是因为

- 参数 $\alpha = \frac{1}{2} + \sum_{i=1}^n y_i = \frac{1}{2} + n\bar{y}$ 保证了伽玛分布的形状参数始终为正;
- 参数 $\beta = n \geq 1$ 保证了规模参数始终有效.

3.6 使用 Jeffreys 先验能否用于推断?

正如3.4 和 3.5所说, 即使 Jeffreys 先验不合法, 也能通过得到合法的后验分布用于推断, 即:

$$\begin{aligned}
 p(\lambda|\mathbf{y}) &\propto p(\mathbf{y}|\lambda)p(\lambda) = L(\lambda) \underbrace{p(\lambda)}_{\propto \frac{1}{\sqrt{\lambda}}} \\
 &\propto \frac{\lambda^{\sum_{i=1}^n y_i}}{\prod_{i=1}^n y_i!} \exp(-n\lambda) \cdot \frac{1}{\sqrt{\lambda}} \\
 &\propto \lambda^{-\frac{1}{2} + \sum_{i=1}^n y_i} \exp(-n\lambda) \\
 &\propto \text{Gamma}\left(\frac{1}{2} + \sum_{i=1}^n y_i, n\right)
 \end{aligned}$$

从而再次验证3.5所得到的结论.

3.7 应用

3.7.1 预测概率

假设观测数据的模型 $p(\tilde{y}|\theta)$, 后验分布为 $p(\theta|\mathbf{y})$, 那么后验预测分布为

$$p(\tilde{y}|\mathbf{y}) = \int_0^\infty p(\tilde{y}|\theta)p(\theta|\mathbf{y}) \, d\theta.$$

例 3.7.1

Assume an improper prior $p(\lambda) = \lambda^{-\frac{1}{2}}$. You observe that three buses arrive at this bus stop within the first and the second hours $y_1 = y_2 = 3$. With what probability (down to three places after the decimal point) would you expect four buses to arrive at this bus stop within the third hour $p(\tilde{y}_3 = 4|y_1, y_2) = ?$

Hint: Assume $\Gamma(6.5) \approx 287.8853$ and $\Gamma(10.5) \approx 1133278$.

假设一个不恰当的先验 $p(\lambda) = \lambda^{-\frac{1}{2}}$. 你观察到在前两小时内有三辆公交车到达这个公交车站, $y_1 = y_2 = 3$. 你期望在第三小时内有多少概率 (精确到小数点后三位) 会有四辆公交车到达这个公交车站 $p(\tilde{y}_3 = 4|y_1, y_2) = ?$

使用 Jeffreys 先验 $p(\lambda) \propto \frac{1}{\sqrt{\lambda}}$ 等价于 $\text{Gamma}\left(\frac{1}{2}, 0\right)$. 由3.2.2中 Eq.3.1可知, 其后验分布为:

$$\lambda|y_1, y_2 \sim \text{Gamma}\left(\frac{1}{2} + \sum_{i=1}^2 y_i, 2\right) = \text{Gamma}\left(6\frac{1}{2}, 2\right)$$

Next, we need to derive the posterior predictive distribution $p(\tilde{y}_3|y_1, y_2)$:

$$\begin{aligned}
 p(\tilde{y}_3|y_1, y_2) &= \int_0^\infty p(\tilde{y}_3|\lambda, y_1, y_2)p(\lambda|y_1, y_2) \, d\lambda = \int_0^\infty p(\tilde{y}_3|\lambda)p(\lambda|y_1, y_2) \, d\lambda \\
 &= \int_0^\infty \frac{\lambda^{\tilde{y}_3}}{\tilde{y}_3!} e^{-\lambda} \cdot \frac{2^{6.5}}{\Gamma(6.5)} \lambda^{6.5-1} e^{-2\lambda} \, d\lambda \\
 &= \frac{2^{6.5}}{\tilde{y}_3! \cdot \Gamma(6.5)} \int_0^\infty \lambda^{\tilde{y}_3+5.5} e^{-3\lambda} \, d\lambda \\
 &= \frac{2^{6.5}}{\tilde{y}_3! \cdot \Gamma(6.5)} \cdot \frac{\Gamma(\tilde{y}_3 + 6.5)}{3^{\tilde{y}_3+6.5}}. \tag{*}
 \end{aligned}$$

Due to the Eq.1.1, so that

$$\int_0^\infty \lambda^{\tilde{y}_3+5.5} e^{-3\lambda} d\lambda \stackrel{n=\tilde{y}_3+5.5}{=} \int_0^\infty \lambda^n e^{-3\lambda} d\lambda = \frac{\Gamma(n+1)}{3^{n+1}} = \frac{\Gamma(\tilde{y}_3+6.5)}{3^{\tilde{y}_3+6.5}}.$$

Therefore,

$$\begin{aligned} p(\tilde{y}_3 = 4 | y_1, y_2) &= \frac{2^{6.5}}{4! \cdot \Gamma(6.5)} \cdot \frac{\Gamma(4+6.5)}{3^{4+6.5}} \\ &= \frac{2^{6.5}}{4! \cdot \Gamma(6.5)} \cdot \frac{\Gamma(10.5)}{3^{10.5}} \approx \frac{90.5097}{24 \cdot 287.8853} \cdot \frac{1133278}{102275.8681} \approx 0.145. \end{aligned}$$

3.7.2 后验更新

例 3.7.2

You observe that 2, 1 and 3 buses arrive at this bus stop within the first three hours $\mathbf{y} = (2, 1, 3)$. You subsequently discover that in the fourth hour of the bus stop there were fewer than 3 buses arrived. Derive the updated posterior for λ . Make sure that this posterior is properly normalised.

你观察到分别有 2、1 和 3 辆公交车在前三个小时内到达这个公交车站，即 $\mathbf{y} = (2, 1, 3)$ 。随后你发现，在公交车站的第四个小时内，到达的公交车少于 3 辆。推导出 λ 的更新后验。确保这个后验是正确归一化的。

由 3.2.2 中 Eq.3.1 可知，其后验分布为：

$$\lambda | \mathbf{y} \sim \text{Gamma} \left(\frac{1}{2} + \sum_{i=1}^3 y_i, 2 \right) = \text{Gamma}(6.5, 3).$$

于是有，

$$\begin{aligned} p(\lambda | \mathbf{y} = (2, 1, 3), z < 3) &\propto p(z < 3 | \lambda) p(\lambda | \mathbf{y}) \\ &= \left(\frac{e^{-\lambda} \lambda^0}{0!} + \frac{e^{-\lambda} \lambda^1}{1!} + \frac{e^{-\lambda} \lambda^2}{2!} \right) \frac{3^{6.5} \lambda^{5.5} e^{-3\lambda}}{\Gamma(6.5)} \\ &\propto \left(1 + \lambda + \frac{1}{2} \lambda^2 \right) e^{-\lambda} \cdot \lambda^{5.5} e^{-3\lambda} \\ &= \lambda^{5.5} e^{-4\lambda} + \lambda^{6.5} e^{-4\lambda} + \frac{1}{2} \lambda^{7.5} e^{-4\lambda} \end{aligned}$$

确保后验分布是一个合法的概率分布，因此要进行归一化 (normalise)，即引入一个归一化常数 C ，使得

$$\begin{aligned} C \int_0^\infty \left(\lambda^{5.5} e^{-4\lambda} + \lambda^{6.5} e^{-4\lambda} + \frac{1}{2} \lambda^{7.5} e^{-4\lambda} \right) d\lambda &= 1 \\ C \left(\int_0^\infty \lambda^{5.5} e^{-4\lambda} d\lambda + \int_0^\infty \lambda^{6.5} e^{-4\lambda} d\lambda + \frac{1}{2} \int_0^\infty \lambda^{7.5} e^{-4\lambda} d\lambda \right) &= 1 \\ C \left(\frac{\Gamma(6.5)}{4^{6.5}} + \frac{\Gamma(7.5)}{4^{7.5}} + \frac{1}{2} \frac{\Gamma(8.5)}{4^{8.5}} \right) &= 1 \\ C &= \frac{1}{\frac{\Gamma(6.5)}{4^{6.5}} + \frac{\Gamma(7.5)}{4^{7.5}} + \frac{1}{2} \frac{\Gamma(8.5)}{4^{8.5}}} \end{aligned}$$

因此得到每一个部分的权重分别为

$$C \frac{\Gamma(6.5)}{4^{6.5}}, \quad C \frac{\Gamma(7.5)}{4^{7.5}}, \quad C \frac{1}{2} \frac{\Gamma(8.5)}{4^{8.5}}$$

于是得到最终的结果

$$p(\lambda|\mathbf{y} = (2, 1, 3), z < 3) = C \left(\frac{\Gamma(6.5)}{4^{6.5}} \text{Gamma}(6.5, 4) + \frac{\Gamma(7.5)}{4^{7.5}} \text{Gamma}(7.5, 4) + \frac{1}{2} \frac{\Gamma(8.5)}{4^{8.5}} \text{Gamma}(8.5, 4) \right)$$

Chapter 4

Beta 分布与二项分布模型及最大后验估计 (MAP)

1. 某批产品中单个产品不合格的概率为 θ , $\theta \in (0, 1)$.
2. 先验分布: $\theta \sim \text{Beta}(\alpha, \beta)$.
 - 均值为: $\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}$.
 - 方差为: $\text{Var}[\theta] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$.
 - 众数为: $\frac{\alpha - 1}{\alpha + \beta - 2}$.
3. 采样观测: 从某批次中抽取 $n = 20$ 个产品, 其中 $k = 1$ 个不合格.

4.1 Beta 分布的均值和方差公式

例 4.1.1

Select a Beta prior for θ such that its mean is 0.01 and its standard deviation is 0.01.

$$\begin{cases} \mu = 0.01 = \frac{\alpha}{\alpha + \beta}, \\ \sigma = 0.01 = \sqrt{\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}}. \end{cases} \Rightarrow \begin{cases} \beta = 99\alpha, \\ 100\alpha = 98. \end{cases} \Rightarrow \begin{cases} \alpha = 0.98, \\ \beta = 97.02. \end{cases}$$

So, the prior satisfying our requirements is $\text{Beta}(0.98, 97.02)$.

4.2 使用 Beta 先验计算后验分布

We are obviously working with a binomial model for component failure:

$$y|\theta \sim \text{Binomial}(\theta, n).$$

As the prior is conjugate, the posterior is derived as

$$\theta|y \sim \text{Beta}(\alpha + k, \beta + n - k) = \text{Beta}(0.98 + 1, 97.02 + 19) = \text{Beta}(1.98, 116.02).$$

4.3 计算后验分布的最大后验估计 (maximum a posteriori, MAP)

Key point: MAP 估计是后验分布的众数.

As the posterior is

$$\theta|y \sim \text{Beta}(1.98, 116.02),$$

the MAP estimate of θ is

$$\frac{\alpha - 1}{\alpha + \beta - 2} = \frac{1.98 - 1}{1.98 + 116.02 - 2} = \frac{0.98}{116} \approx 0.0084.$$

4.4 使用 R 模拟估计 95% 的后验区间

First we take a large sample of θ from the posterior:

```
1 theta <- rbeta(1000000, 1.5, 68.5)
```

The quantiles (0.025 and 0.975) of this sample then estimate the bounds of the 95% central posterior interval for θ :

```
1 quantile(theta, probs=c(0.025,0.975))
```

Chapter 5

分层模型（Hierarchical Model）和 Nimble 编程

Consider a Nimble model defined using the following code:

```
1 exam_code <- nimbleCode({  
2   for (j in 1:N) {  
3     y[j] ~ dnorm(mu[j], sd = sigma)  
4     mu[j] ~ dnorm(theta[j], tau)  
5     theta[j] <- beta_0 + beta_1 * log(x[j]) + beta_2 * x[j]  
6   }  
7   beta_0 ~ dnorm(0, sd = 10)  
8   beta_1 ~ dnorm(0, sd = 10)  
9   beta_2 ~ dnorm(0, sd = 10)  
10  sigma ~ dexp(1)  
11  tau ~ dexp(10)  
12 })
```

where x and y are vectors from our data set.

5.1 将 Nimble 模型规范转化为标准统计表示

合并 4, 5 行可以写作

$$\mu_j | \beta_0, \beta_1, \beta_2, \tau \sim \mathcal{N}(\beta_0 + \beta_1 \log(x_j) + \beta_2 x_j, \tau_2), \quad j = 1, \dots, N, \text{ independently}$$

5.2 分层模型

We consider N independent observations of y coming from a normal distribution with the same variance σ^2 , but the mean μ_j is different for every observation. The mean μ_j for observation j has a normal prior with mean $\beta_0 + \beta_1 \log(x_j) + \beta_2 x_j$, where $\beta_0, \beta_1, \beta_2$ are hyperparameters, and the variance for the prior on μ_j is τ^2 . Hyperpriors on β are normal with zero mean and variance 100 independently for every β . Hyperpriors for σ and τ are exponential with rates 1 and 10 correspondingly.

Row	Standard statistical notation
3	$y_j \mu_j, \sigma \sim \mathcal{N}(\mu_j, \sigma^2), j = 1, \dots, N, \text{independently}$
4	$\mu_j \theta, \tau \sim \mathcal{N}(\theta, \tau^2), j = 1, \dots, N, \text{independently}$
5	$\theta = \beta_0 + \beta_1 \log(x_j) + \beta_2 x_j$
7	$\beta_0 \sim \mathcal{N}(0, 100)$
8	$\beta_1 \sim \mathcal{N}(0, 100)$
9	$\beta_2 \sim \mathcal{N}(0, 100)$
10	$\sigma \sim \text{Exp}(1)$
11	$\tau \sim \text{Exp}(10)$

我们考虑 N 个独立观测值 y ，这些观测值来自一个具有相同方差 σ^2 的正态分布，但每个观测值的均值 μ_j 是不同的。观测值 j 的均值 μ_j 具有一个正态先验分布，其均值为 $\beta_0 + \beta_1 \log(x_j) + \beta_2 x_j$ ，其中 $\beta_0, \beta_1, \beta_2$ 是超参数， μ_j 的先验分布的方差为 τ^2 。超参数 β 的先验分布是均值为零、方差为 100 的独立正态分布。参数 σ 和 τ 的超先验分布是指数分布，其率参数分别为 1 和 10。

One advantage of the hierarchical structure is 'borrowing strengths' (or 'sharing information'): we allow information from other replicates to influence estimation of μ_j for any particular replicate (via their effects on β and τ).

分层结构的一个优点是“信息借用”（或“信息共享”）：我们允许其他重复实验的信息通过其对 β 和 τ 的影响来影响某一特定重复实验的 μ_j 的估计。

In detail,

1. 第一层: 观测模型

$y_j \sim N(\mu_j, \sigma^2)$: 每个观测值 y_j 服从均值为 μ_j 、方差为 σ^2 的正态分布。

2. 第二层: 均值的先验分布

每个均值 μ_j 服从一个正态分布

$$\mu_j \sim \mathcal{N}(\theta_j, \tau^2)$$

其中 $\theta_j = \beta_0 + \beta_1 \log(x_j) + \beta_2 x_j$.

3. 第三层: 回归系数和参数的超先验分布

模型中涉及一些超参数, 这些参数本身有先验分布:

- 回归系数 $\beta_0, \beta_1, \beta_2$: 服从正态分布

$$\beta_0, \beta_1, \beta_2 \sim \mathcal{N}(0, 100).$$

- 观测误差方差 σ^2 : 其平方根 σ 服从指数分布

$$\sigma \sim \text{Exp}(1).$$

- μ_j 方差的参数 τ^2 : 其精度 (τ^{-1}) 服从指数分布:

$$\tau \sim \text{Exp}(10).$$

答案中提到分层模型的一个核心优点是**信息借用 (borrowing strengths)**, 这也是分层模型的关键优势之一。

什么是信息借用？ 在分层模型中, 所有观测值 $y_1, y_2, \dots, y_N$ 并不是独立的, 而是通过模型的参数 (如 $\beta_0, \beta_1, \beta_2, \tau$) 建立了联系.

信息共享的作用

- 如果某些观测点的数据较少或不稳定, 模型可以通过从其他观测点中“借用信息”来改善这些点的参数估计.
- 例如, 观测点 j 的均值 μ_j 的估计会受到其他观测点的影响, 因为它们共享相同的全局参数 β 和 τ .

具体体现在本题中的信息借用

- 回归系数 $\beta_0, \beta_1, \beta_2$ 和方差参数 τ 是全局共享的.
- 每个 μ_j 的估计可以通过共享的 β 和 τ 从其他观测点的信息中受益, 特别是在某些 x_j 数据稀缺的情况下.

优点总结

1. **提高稳定性:** 对于某些稀疏数据点, 信息借用可以改善参数估计的稳定性。
2. **捕捉层次结构:** 分层模型可以更好地反映数据中的多层次依赖关系。
3. **减少过拟合:** 因为分层模型对全局参数施加了先验约束, 从而避免了仅基于个体点的过拟合。

直观总结

1. 模型结构:
 - 第一层: 观测值 y_j 的分布.
 - 第二层: 均值 μ_j 的分布.
 - 第三层: 全局参数 (β, σ, τ) 的先验分布.
2. 分层模型的核心:
 - 通过全局参数 (如 β, τ) 的共享, 建立了个体观测之间的联系.
 - 数据稀疏时, 模型可以利用全局信息来改善个体估计.
3. 分层模型的优点:
 - 信息共享与借用.
 - 捕捉数据中的多层次关系.
 - 提高稀疏数据下的推断效果.

5.3 WinBUGS (Bayesian inference Using Gibbs Sampling)

例 5.3.1 WinBUGS

Consider the simple linear regression model:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, 1/\tau) \quad i = 1, \dots, n, \quad \text{independently,}$$

where β_0 is the intercept parameter, β_1 is the slope parameter, and τ is the precision of the normally distributed observation noise. We can rewrite the above model as

$$y_i | \beta_0, \beta_1, \tau, x_i \sim \mathcal{N}\left(\beta_0 + \beta_1 x_i, \frac{1}{\tau}\right), \quad i = 1, \dots, n, \quad \text{independently.}$$

Having observed some n data (x_i, y_i) , we want to infer the posterior of model parameters β_0, β_1 , and τ in a fully Bayesian way, using the following priors:

$$\left. \begin{aligned} \beta_0 &\sim \mathcal{N}(\mu_0, 1/\tau_0) \\ \beta_1 &\sim \mathcal{N}(\mu_1, 1/\tau_1) \\ \tau &\sim \text{Gamma}(\alpha, \beta) \end{aligned} \right\} \text{independently}$$

with fixed real values for hyperparameters $\mu_0, \mu_1, \tau_0, \tau_1, \alpha, \beta$.

Define this model for performing sampling from the parameter posterior using WinBUGS, i.e., provide the model description that goes within `model{...}` in WinBUGS.

```
1 model {
2   for (i in 1:n) {
3     y[i] ~ dnorm(mu[i], tau)
4     mu[i] <- beta0 + beta1 * x[i]
5     # 显式定义均值 mu[i]
6   }
7   beta0 ~ dnorm(mu0, tau0)
8   beta1 ~ dnorm(mu1, tau1)
9   tau ~ dgamma(alpha, beta)
10 }
```

```
1 model {
2   for (i in 1:n) {
3     y[i] ~ dnorm(beta0 + beta1 * x[i],
4                 tau)
5     # 直接写模型
6   }
7   beta0 ~ dnorm(mu0, tau0)
8   beta1 ~ dnorm(mu1, tau1)
9   tau ~ dgamma(alpha, beta)
10 }
```

例 5.3.2 接上题

Derive necessary full conditional distributions, and describe how you can build a Gibbs sampler to draw samples from the posterior $p(\beta_0, \beta_1, \tau | x, y)$.

Solution. 通过上题知道

$$y_i | \beta_0, \beta_1, \tau, x_i \sim \mathcal{N}\left(\beta_0 + \beta_1 x_i, \frac{1}{\tau}\right),$$

则

$$\begin{aligned} p(y_i | \beta_0, \beta_1, \tau, x_i) &= \frac{1}{\sqrt{2\pi \frac{1}{\tau}}} \exp \left\{ -\frac{[y_i - (\beta_0 + \beta_1 x_i)]^2}{2 \frac{1}{\tau}} \right\} \\ &= \sqrt{\frac{\tau}{2\pi}} \exp \left\{ -\frac{\tau}{2} (y_i - \beta_0 - \beta_1 x_i)^2 \right\}. \end{aligned}$$

由于 $y_1, \dots, y_n$ 是独立的, 因此联合似然函数为所有 pdf 的乘积:

$$\begin{aligned} p(\mathbf{y}|\beta_0, \beta_1, \tau, \mathbf{x}) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\frac{1}{\tau}}} \exp\left\{-\frac{[y_i - (\beta_0 + \beta_1 x_i)]^2}{2\frac{1}{\tau}}\right\} \\ &= \left(\frac{\tau}{2\pi}\right)^{\frac{n}{2}} \exp\left\{-\frac{\tau}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2\right\} \\ &\propto \tau^{\frac{n}{2}} \exp\left\{-\frac{\tau}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2\right\}. \end{aligned}$$

我们还知道

$$\beta_0 \sim \mathcal{N}(\mu_0, 1/\tau_0), \quad \beta_1 \sim \mathcal{N}(\mu_1, 1/\tau_1),$$

则

$$\begin{aligned} p(\beta_k) &= \frac{1}{\sqrt{2\pi\frac{1}{\tau_k}}} \exp\left\{-\frac{(\beta_k - \mu_k)^2}{2\frac{1}{\tau_k}}\right\} \\ &= \sqrt{\frac{\tau_k}{2\pi}} \exp\left\{-\frac{\tau_k}{2} (\beta_k - \mu_k)^2\right\} \\ &\propto \exp\left\{-\frac{\tau_k}{2} (\beta_k - \mu_k)^2\right\}. \end{aligned}$$

同样的

$$\tau \sim \text{Gamma}(\alpha, \beta),$$

则

$$\begin{aligned} p(\tau) &= \frac{\beta^\alpha \tau^{\alpha-1}}{\Gamma(\alpha)} \exp\{-\beta\tau\} \\ &\propto \tau^{\alpha-1} \exp\{-\beta\tau\}. \end{aligned}$$

因此得到后验分布. We aim to draw samples from the following posterior:

$$\begin{aligned} &p(\beta_0, \beta_1, \tau | x, y) \\ &\propto p(y|x, \beta_0, \beta_1, \tau) p(\beta_0) p(\beta_1) p(\tau) \\ &= \tau^{\frac{n}{2}} \exp\left\{-\frac{\tau}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2\right\} \times \exp\left\{-\frac{\tau_0}{2} (\beta_0 - \mu_0)^2\right\} \times \exp\left\{-\frac{\tau_1}{2} (\beta_1 - \mu_1)^2\right\} \times \tau^{\alpha-1} \exp\{-\beta\tau\}. \end{aligned}$$

推导 Gibbs 采样器需要模型参数的完整条件分布 (一): β_0 的采样部分.

$$\begin{aligned}
& p(\beta_0 | \beta_1, \tau, x, y) \\
&= \tau^{\frac{n}{2}} \underbrace{\exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\}}_{\text{含 } \beta_0 \text{ 的项}} \times \underbrace{\exp \left\{ -\frac{\tau_0}{2} (\beta_0 - \mu_0)^2 \right\}}_{\text{含 } \beta_0 \text{ 的项}} \times \exp \left\{ -\frac{\tau_1}{2} (\beta_1 - \mu_1)^2 \right\} \times \tau^{\alpha-1} \exp \{-\beta\tau\} \\
&\propto \exp \left\{ -\frac{1}{2} \left(\tau \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 + \tau_0 (\beta_0 - \mu_0)^2 \right) \right\} \\
&\propto \exp \left\{ -\frac{1}{2} \left(\tau \sum_{i=1}^n (\beta_0^2 - 2\beta_0(y_i - \beta_1 x_i)) + \tau_0 (\beta_0^2 - 2\mu_0 \beta_0) \right) \right\} \quad \text{只保留含 } \beta_0 \text{ 的部分, 其他直接胡萝卜鸡} \\
&= \exp \left\{ -\frac{1}{2} \left[\beta_0^2 (n\tau + \tau_0) - 2\beta_0 \left(\tau \sum_{i=1}^n (y_i - \beta_1 x_i) + \tau_0 \mu_0 \right) \right] \right\} \\
&= \exp \left\{ -\frac{n\tau + \tau_0}{2} \left[\beta_0^2 - 2\beta_0 \frac{\tau \sum_{i=1}^n (y_i - \beta_1 x_i) + \tau_0 \mu_0}{n\tau + \tau_0} \right] \right\} \\
&\propto \exp \left\{ -\frac{n\tau + \tau_0}{2} \left[\beta_0 - \frac{\tau \sum_{i=1}^n (y_i - \beta_1 x_i) + \tau_0 \mu_0}{n\tau + \tau_0} \right]^2 \right\} \quad \text{配方剩下的 const. 指定是不含 } \beta_0 \text{ 的} \\
&\propto \mathcal{N} \left(\frac{\tau \sum_{i=1}^n (y_i - \beta_1 x_i) + \tau_0 \mu_0}{n\tau + \tau_0}, \frac{1}{n\tau + \tau_0} \right).
\end{aligned}$$

推导 Gibbs 采样器需要模型参数的完整条件分布 (二): β_1 的采样部分.

$$\begin{aligned}
& p(\beta_0 | \beta_1, \tau, x, y) \\
&= \tau^{\frac{n}{2}} \underbrace{\exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\}}_{\text{含 } \beta_1 \text{ 的项}} \times \exp \left\{ -\frac{\tau_0}{2} (\beta_0 - \mu_0)^2 \right\} \times \underbrace{\exp \left\{ -\frac{\tau_1}{2} (\beta_1 - \mu_1)^2 \right\}}_{\text{含 } \beta_1 \text{ 的项}} \times \tau^{\alpha-1} \exp \{-\beta\tau\} \\
&\propto \exp \left\{ -\frac{1}{2} \left(\tau \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 + \tau_1 (\beta_1 - \mu_1)^2 \right) \right\} \\
&\propto \exp \left\{ -\frac{1}{2} \left(\tau \sum_{i=1}^n (\beta_1^2 x_i^2 - 2\beta_1(y_i - \beta_0)x_i) + \tau_1 (\beta_1^2 - 2\mu_1 \beta_1) \right) \right\} \quad \text{只保留含 } \beta_1 \text{ 的部分, 其他直接胡萝卜鸡} \\
&= \exp \left\{ -\frac{1}{2} \left[\beta_1^2 \left(\tau \sum_{i=1}^n x_i^2 + \tau_1 \right) - 2\beta_1 \left(\tau \sum_{i=1}^n (y_i - \beta_0)x_i + \tau_1 \mu_1 \right) \right] \right\} \\
&= \exp \left\{ -\frac{\tau \sum_{i=1}^n x_i^2 + \tau_1}{2} \left[\beta_1^2 - 2\beta_1 \frac{\tau \sum_{i=1}^n (y_i - \beta_0)x_i + \tau_1 \mu_1}{\tau \sum_{i=1}^n x_i^2 + \tau_1} \right] \right\} \\
&\propto \exp \left\{ -\frac{\tau \sum_{i=1}^n x_i^2 + \tau_1}{2} \left[\beta_1 - \frac{\tau \sum_{i=1}^n (y_i - \beta_0)x_i + \tau_1 \mu_1}{\tau \sum_{i=1}^n x_i^2 + \tau_1} \right]^2 \right\} \quad \text{配方剩下的 const. 指定是不含 } \beta_0 \text{ 的} \\
&\propto \mathcal{N} \left(\frac{\tau \sum_{i=1}^n (y_i - \beta_0)x_i + \tau_1 \mu_1}{\tau \sum_{i=1}^n x_i^2 + \tau_1}, \frac{1}{\tau \sum_{i=1}^n x_i^2 + \tau_1} \right).
\end{aligned}$$

推导 Gibbs 采样器需要模型参数的完整条件分布 (三): τ 的采样部分.

$$\begin{aligned}
 & p(\tau | \beta_0, \beta_1, x, y) \\
 &= \underbrace{\tau^{\frac{n}{2}} \exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\}}_{\text{含 } \tau \text{ 的项}} \times \exp \left\{ -\frac{\tau_0}{2} (\beta_0 - \mu_0)^2 \right\} \times \exp \left\{ -\frac{\tau_1}{2} (\beta_1 - \mu_1)^2 \right\} \times \underbrace{\tau^{\alpha-1} \exp \{-\beta\tau\}}_{\text{含 } \tau \text{ 的项}} \\
 &\propto \tau^{\frac{n}{2}} \exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\} \tau^{\alpha-1} \exp \{-\beta\tau\} \\
 &= \tau^{\frac{n}{2} + \alpha - 1} \exp \left\{ -\tau \left(\frac{1}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 + \beta \right) \right\} \\
 &\propto \text{Gamma} \left(\frac{n}{2} + \alpha, \frac{1}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 + \beta \right).
 \end{aligned}$$

最后, 制定 Gibbs 抽样算法.

- Initialise $\beta_0 = \beta_0^{(0)}$, $\beta_1 = \beta_1^{(0)}$, and $\tau = \tau^{(0)}$.
- For $k = 1, 2, \dots, K$,
 - Draw $\beta_0^{(k)}$ from $\mathcal{N} \left(\frac{\tau^{(k-1)} \sum_{i=1}^n (y_i - \beta_1^{(k-1)} x_i) + \tau_0 \mu_0}{n\tau^{(k-1)} + \tau_0}, \frac{1}{n\tau^{(k-1)} + \tau_0} \right)$;
 - Draw $\beta_1^{(k)}$ from $\mathcal{N} \left(\frac{\tau^{(k-1)} \sum_{i=1}^n (y_i - \beta_0^{(k)} x_i) + \tau_1 \mu_1}{\tau^{(k-1)} \sum_{i=1}^n x_i^2 + \tau_1}, \frac{1}{\tau^{(k-1)} \sum_{i=1}^n x_i^2 + \tau_1} \right)$;
 - Draw $\tau^{(k)}$ from $\text{Gamma} \left(\frac{n}{2} + \alpha, \frac{1}{2} \sum_{i=1}^n (y_i - \beta_0^{(k)} - \beta_1^{(k)} x_i)^2 + \beta \right)$.
- Discard burn-in and optionally thin-out.

请注意在 Gibbs 采样中标记时样本索引的使用! 也就是 $\beta_0^{(k)}$ 和 $\beta_0^{(k-1)}$ 的区别.

Chapter 6

贝叶斯决策理论与损失函数

Consider a problem of estimating the rate parameter λ of the Poisson model for data $y_1, \dots, y_n$ with the value ('action') a , using a Gamma prior on the rate parameter λ :

$$y_i | \lambda \sim \text{Poisson}(\lambda), i = 1, \dots, n, \text{ independently,} \\ \lambda | \gamma, \beta \sim \text{Gamma}(\gamma, \beta).$$

6.1 定义贝叶斯期望损失和贝叶斯动作

贝叶斯决策理论

1. 贝叶斯决策理论通过**损失函数**来度量决策与真实参数值之间的偏差.
2. 贝叶斯期望损失 (**Bayesian expected loss**) 是损失函数在后验分布下的期望值:

$$\rho(\pi, a) = \mathbb{E}[L(\lambda, a) | \mathbf{y}] = \int_{\Theta} L(\lambda, a) p(\lambda | \mathbf{y}) d\lambda \quad (6.1)$$

- $L(\lambda, a)$ 是损失函数, 表示在真实参数值为 λ 时选择 a 的代价.
- π 表示后验分布 $p(\lambda | \mathbf{y})$.

3. 贝叶斯动作 (**Bayes action**) 是使期望损失最小化的决策 a_π

$$a^\pi = \arg \min_a \rho(\pi, a) = \arg \min_a \int_{\Theta} L(\lambda, a) p(\lambda | \mathbf{y}) d\lambda \quad (6.2)$$

例 6.1.1

Define the Bayesian expected loss $\rho(\pi, a)$ and the Bayes action a^π in the context of making decision in Bayesian framework and using some loss function $L(\lambda, a)$.

Solution. If $\pi(\lambda) = p(\lambda | \mathbf{y})$ is the believed probability distribution of λ at the time of decision making, the Bayesian expected loss of an action a is Equation (6.1).

A Bayes action a^π is then an action $a \in \mathcal{A}$ that minimises $\rho(\pi, a)$. Or in layman's terms (以通俗的话来说), the best bet for a future action a .

6.2 特定损失函数下的贝叶斯动作

例 6.2.1

给定损失函数:

$$L(\lambda, a) = \frac{(\lambda - a)^2}{\lambda}$$

证明在观察了 n 个数据点 $y_1, \dots, y_n$ 后, 贝叶斯行动 a^π 采用 λ 的最大后验估计形式. 假设 $n > 0$ 且 $\sum_{i=1}^n y_i > 1$.

Solution. 步骤如下:

6.2.0.0.1 Step 1. 推导贝叶斯期望损失 (根据 Eq.6.1):

$$\begin{aligned} \rho(\pi, a) &= \mathbb{E}[L(\lambda, a) | \mathbf{y}] = \mathbb{E}\left[\frac{(\lambda - a)^2}{\lambda} \middle| \mathbf{y}\right] \\ &= \mathbb{E}\left[\frac{\lambda^2 - 2a\lambda + a^2}{\lambda} \middle| \mathbf{y}\right] \\ &= \mathbb{E}\left[\frac{\lambda^2}{\lambda} \middle| \mathbf{y}\right] - 2a\mathbb{E}\left[\frac{\lambda}{\lambda} \middle| \mathbf{y}\right] + a^2\mathbb{E}\left[\frac{1}{\lambda} \middle| \mathbf{y}\right] \\ &= \mathbb{E}[\lambda | \mathbf{y}] - 2a + a^2\mathbb{E}\left[\frac{1}{\lambda} \middle| \mathbf{y}\right] \end{aligned}$$

6.2.0.0.2 Step 2. 求偏导 (根据 Eq.6.2), 即

$$\frac{\partial \rho(\pi, a)}{\partial a} = 0,$$

由于当前先验分布 (prior distribution) 得到后验分布 (posterior distribution, Eq.3.1) 为

$$\lambda | \mathbf{y} \sim Ga\left(\gamma + \sum_{i=1}^n y_i, \beta + n\right) \implies p(\lambda | \mathbf{y}) = \frac{(\beta + n)^{\gamma + \sum_{i=1}^n y_i}}{\Gamma(\gamma + \sum_{i=1}^n y_i)} \lambda^{\gamma + \sum_{i=1}^n y_i - 1} \exp(-(\beta + n)\lambda).$$

从而得到贝叶斯期望损失最小时的贝叶斯动作:

$$\begin{aligned} \frac{\partial \rho(\pi, a)}{\partial a} &= \frac{\partial}{\partial a} \left(\mathbb{E}[\lambda | \mathbf{y}] - 2a + a^2 \mathbb{E}\left[\frac{1}{\lambda} \middle| \mathbf{y}\right] \right) \\ &= -2 + 2a \mathbb{E}\left[\frac{1}{\lambda} \middle| \mathbf{y}\right] \\ &= -2 + 2a \int_0^\infty \frac{1}{\lambda} p(\lambda | \mathbf{y}) d\lambda \\ &= -2 + 2a \int_0^\infty \frac{1}{\lambda} \cdot \frac{(\beta + n)^{\gamma + \sum y_i}}{\Gamma(\gamma + \sum y_i)} \lambda^{\gamma + \sum y_i - 1} \exp(-(\beta + n)\lambda) d\lambda \\ &= -2 + 2a \frac{(\beta + n)^{\gamma + \sum y_i}}{\Gamma(\gamma + \sum y_i)} \int_0^\infty \lambda^{\gamma + \sum y_i - 2} \exp(-(\beta + n)\lambda) d\lambda \\ &\stackrel{\text{Eq.1.1}}{=} -2 + 2a \frac{(\beta + n)^{\gamma + \sum y_i}}{\Gamma(\gamma + \sum y_i)} \cdot \frac{\Gamma(\gamma + \sum y_i - 1)}{(\beta + n)^{\gamma + \sum y_i - 1}} \\ &\stackrel{\Gamma(a+1)=a\Gamma(a)}{=} -2 + 2a \frac{\beta + n}{\gamma + \sum y_i - 1} = 0 \end{aligned}$$

解得:

$$a = \frac{\gamma + \sum_{i=1}^n y_i - 1}{\beta + n}.$$

6.2.0.0.3 Step 3. 求二阶偏导, 以证实上值为最小值.

$$\frac{\partial^2 \rho(\pi, a)}{\partial a^2} = 2 \frac{\beta + n}{\gamma + \sum_{i=1}^n y_i - 1} > 0$$

as long as $n > 0$, and $\sum_{i=1}^n y_i > 1$.

6.3 平方损失函数下的贝叶斯动作

例 6.3.1

给定损失函数替换为:

$$L(\lambda, a) = (\lambda - a)^2.$$

Solution. 步骤同例6.2.1完全一致:

6.3.0.0.1 Step 1. 推导贝叶斯期望损失 (根据 Eq.6.1):

$$\begin{aligned} \rho(\pi, a) &= \mathbb{E}[L(\lambda, a)|\mathbf{y}] = \mathbb{E}[(\lambda - a)^2|\mathbf{y}] \\ &= \mathbb{E}[\lambda^2 - 2a\lambda + a^2|\mathbf{y}] \\ &= \mathbb{E}[\lambda^2|\mathbf{y}] - 2a\mathbb{E}[\lambda|\mathbf{y}] + a^2 \end{aligned}$$

6.3.0.0.2 Step 2. 求偏导 (根据 Eq.6.2), 即

$$\frac{\partial \rho(\pi, a)}{\partial a} = 0,$$

由于当前先验分布 (prior distribution) 得到后验分布 (posterior distribution, Eq.3.1) 为

$$\lambda|\mathbf{y} \sim Ga\left(\gamma + \sum_{i=1}^n y_i, \beta + n\right)$$

从而得到贝叶斯期望损失最小时的贝叶斯动作:

$$\frac{\partial \rho(\pi, a)}{\partial a} = \frac{\partial}{\partial a} (\mathbb{E}[\lambda^2|\mathbf{y}] - 2a\mathbb{E}[\lambda|\mathbf{y}] + a^2) = -2\mathbb{E}[\lambda|\mathbf{y}] + 2a = 0$$

解得:

$$a = \mathbb{E}[\lambda|\mathbf{y}].$$

6.3.0.0.3 Step 3. 求二阶偏导, 以证实上值为最小值.

$$\frac{\partial^2 \rho(\pi, a)}{\partial a^2} = 2 > 0$$

which is strictly positive, it is a minimum, so the Bayes action:

$$a^\pi = \mathbb{E}[\lambda|\mathbf{y}] = \frac{\gamma + \sum_{i=1}^n y_i - 1}{\beta + n}.$$

Part IV

随机过程与金融数学

Chapter 1

预备知识

学习《随机过程》需要良好的《概率论》基础，《概率论》部分本章节将不再赘述，只介绍一些补充内容.

1.1 矩母函数与特征函数

1.1.0.0.1 Riemann-Stieltjes 积分 设 $g(x), F(x)$ 为有限区间 $(a, b]$ 上的实值函数, $a = x_0 < x_1 < \cdots < x_n = b$ 为 $(a, b]$ 的一个分割, 令

$$\Delta F(x_i) = F(x_i) - F(x_{i-1}), \xi_i \in [x_{i-1}, x_i], 1 \leq i \leq n,$$

$\lambda = \max_{1 \leq i \leq n} (x_i - x_{i-1})$, 如果当 $\lambda \rightarrow 0$ 时, 极限

$$\lim_{\lambda \rightarrow 0} \sum_{i=1}^n g(\xi_i) \Delta F(x_i)$$

存在, 且与分割的选择以及 $\xi_i \in [x_{i-1}, x_i]$ 的取法无关, 则称该极限值为函数 $g(x)$ 关于 $F(x)$ 在 $(a, b]$ 上的 Riemann-Stieltjes 积分, 记为

$$\int_a^b g(x) dF(x) = \lim_{\lambda \rightarrow 0} \sum_{i=1}^n g(\xi_i) \Delta F(x_i).$$

当 $F(x) = x$ 时, Riemann-Stieltjes 积分即为 Riemann 积分. Riemann-Stieltjes 积分可以看成是求曲线 $g(x)$ 下方的面积问题的推广, 用 $\Delta F(x_i) = F(x_i) - F(x_{i-1})$ 作为小区间 $(x_{i-1}, x_i]$ 的广义长度, 以 $g(\xi_i)$ 近似曲边梯形的高度, 用矩形面积近似曲边梯形面积.

关于 Riemann-Stieltjes 积分存在的条件, 这里不做更进一步的讨论, 只给出一个简单的充分条件: 若函数 $g(x)$ 连续, $F(x)$ 单调, 则 Riemann-Stieltjes 积分存在. 本书中用到的 $g(x)$ 为连续函数, $F(x)$ 为分布函数, 因此积分的存在性不成问题.

定义 1.1.1 有界变差函数

设 $f(x)$ 是定义在 $[s, t]$ 的实值函数, 作分割 $\Delta: s = t_0 < t_1 < \cdots < t_n = t$, 记

$$\nu_\Delta = \sum_{i=0}^{n-1} |f(t_{i+1}) - f(t_i)|,$$

令

$$\bigvee_s^t(f) = \sup\{\nu_\Delta : \Delta \text{ 为 } [s, t] \text{ 的任意分割}\},$$

并称其为 f 在 $[s, t]$ 的全变差; 如果 $\bigvee_s^t(f) < \infty$, 则称 $f(x)$ 是 $[s, t]$ 上的有界变差函数, 记作

$$f \in \text{BV}([s, t])$$

$\text{BV}([s, t])$ 构成一个线性空间. 有界变差函数可以写成两个增函数的差, 几乎处处可微. 闭区间上连续可微函数必为有界变差.

定理 1.1.1 有界变差函数

若对任意的 $[a, b]$ 上连续函数 $g(x)$, 关于 $F(x)$ 都是在 $[a, b]$ Riemann-Stieltjes 可积的, 则 $F(x)$ 是 $[a, b]$ 上的有界变差函数. 反之, 连续函数关于有界变差函数 Riemann-Stieltjes 可积的.

为了后面的需要, 将积分推广到无限区间上:

$$\begin{aligned} \int_a^\infty g(x) \, dF(x) &= \lim_{b \rightarrow +\infty} \int_a^b g(x) \, dF(x), \\ \int_{-\infty}^b g(x) \, dF(x) &= \lim_{a \rightarrow -\infty} \int_a^b g(x) \, dF(x), \\ \int_{-\infty}^\infty g(x) \, dF(x) &= \lim_{a \rightarrow -\infty, b \rightarrow +\infty} \int_a^b g(x) \, dF(x). \end{aligned}$$

与 Riemann 积分不同的是

$$\int_{a-}^a dF(x) = \lim_{\delta \rightarrow 0+} \int_{a-\delta}^a dF(x) = F(a) - F(a-),$$

当 $F(x)$ 在 $x = a$ 处有跳跃时, 上式的值等于 $F(x)$ 在 a 点的跳跃高度. 当 $F(x)$ 是一个阶梯函数时, Riemann-Stieltjes 积分成为一个级数, 即设 $F(x)$ 在 $x = x_i$ 处有跳跃高度 $p_i, i = 1, 2, \dots$, 则

$$\int_{-\infty}^\infty g(x) \, dF(x) = \sum_{i=1}^\infty g(x_i) p_i.$$

如果 $F(x)$ 是分布函数, 对于离散型和连续型这两种常用情形, 有

$$\int_a^b g(x) \, dF(x) = \begin{cases} \sum_{i=1}^\infty g(x_i) f(x_i), & \text{离散情形,} \\ \int_a^b g(x) f(x) \, dx, & \text{连续情形.} \end{cases}$$

其中 $f(\cdot)$ 为 $F(x)$ 的概率质量函数或者概率密度函数.

Riemann-Stieltjes 积分的一些基本性质:

1. 线性性质:

$$\int_a^b [\alpha g_1(x) + \beta g_2(x)] \, dF(x) = \alpha \int_a^b g_1(x) \, dF(x) + \beta \int_a^b g_2(x) \, dF(x).$$

2. 区间可加性:

$$\int_a^b g(x) dF(x) = \int_a^c g(x) dF(x) + \int_c^b g(x) dF(x), c \in (a, b).$$

3. 广义长度:

$$\int_a^b dF(x) = F(b) - F(a),$$

其中 a, b 均可有限或无穷大.

4. 测度可加性:

$$\int_a^b g(x) d[\alpha F_1(x) + \beta F_2(x)] = \alpha \int_a^b g(x) dF_1(x) + \beta \int_a^b g(x) dF_2(x).$$

5. 若 $g(x) \geq 0$, $F(x)$ 单调不减, $b > a$, 则 $\int_a^b g(x) dF(x) \geq 0$.

1.1.1 矩母函数

定义 1.1.2 矩母函数

设随机变量 X 的分布函数为 $F_X(x)$, 令

$$M_X(t) = \mathbb{E}[e^{tX}] = \int_{-\infty}^{\infty} e^{tx} dF_X(x),$$

若 $M_X(t)$ 在某个长度大于 0 的包含原点的区间上取有限值, 则称 $M_X(t)$ 为 X 的**矩母函数**.

如果 X 是仅取非负值的随机变量, 则 $M_X(t)$ 在 $(-\infty, 0]$ 上有限. 假设对 $M_X(t)$ 求导时, 求导运算与求期望运算可以交换次序, 有

$$M'_X(t) = \mathbb{E}[Xe^{tX}]$$

$$M''_X(t) = \mathbb{E}[X^2 e^{tX}]$$

$$\vdots$$

$$M_X^{(n)}(t) = \mathbb{E}[X^n e^{tX}],$$

令 $t = 0$, 得到

$$M_X^{(n)}(0) = \mathbb{E}[X^n], n = 1, 2, \dots$$

当矩母函数存在时, 它唯一地决定分布, 因此我们能够用矩母函数刻画随机变量的概率分布. 矩母函数还经常用来讨论独立随机变量和的分布.

1.1.2 特征函数

定义 1.1.3 特征函数

若随机变量 X 的分布函数为 $F_X(x)$, 则称

$$\phi_X(t) = M_X(it) = \mathbb{E}[e^{itX}] = \int_{-\infty}^{\infty} e^{itx} dF_X(x)$$

为 X 的特征函数.

特征函数总存在且定义于 $(-\infty, \infty)$. 如果 F_X 有密度 $f(x)$, 则 $\phi_X(t)$ 就是 $f(x)$ 的 Fourier 变换:

$$\phi_X(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx.$$

特征函数是一个实变量的复值函数, 因为 $|e^{itx}| = 1$, 所以它对一切实数 t 都有定义. 可以看成是实部与虚部分别积分的结果:

$$\phi_X(t) = \int_{-\infty}^{\infty} \cos(tx) dF_X(x) + i \int_{-\infty}^{\infty} \sin(tx) dF_X(x).$$

性质 1.1.1

特征函数有如下性质:

1. 有界性: $|\phi(t)| \leq 1 = \phi(0)$;

2. 共轭对称性: $\phi(-t) = \overline{\phi(t)}$;

3. 一致连续性:

$$|\phi(t+h) - \phi(t)| \leq \int_{-\infty}^{\infty} |e^{ihx} - 1| dF(x);$$

4. 线性变换的作用: 设 $Y = aX + b$, 则 Y 的特征函数是 $\phi_Y(t) = e^{ibt} \phi_X(at)$;

5. 两个相互独立的随机变量之和的特征函数等于它们的特征函数之积;

6. 非负定性: 对于任意的正整数 n , 任意实数 $t_1, \dots, t_n$ 及复数 $\lambda_1, \dots, \lambda_n$, 有

$$\sum_{k=1}^n \sum_{j=1}^n \phi(t_k - t_j) \lambda_k \overline{\lambda_j} \geq 0.$$

7. 设随机变量 X 有 n 阶矩存在, 则它的特征函数 n 阶导数存在, 且当 $k \leq n$ 时, 有

$$\phi^{(k)}(0) = i^k \mathbb{E}[X^k],$$

其中 i 表示虚数单位.

特别地, 特征函数可作如下带皮阿诺型余项的 Taylor 展开:

$$\phi(t) = 1 + it\mathbb{E}[X] + \frac{(it)^2}{2!} \mathbb{E}[X^2] + \dots + \frac{(it)^n}{n!} \mathbb{E}[X^n] + o(t^n).$$

由于特征函数只与分布函数有关, 所以称为分布的特征函数. 另一方面, 有下述定理.

定理 1.1.2 唯一性定理

分布函数由其特征函数唯一决定.

1.2 测度论

1.2.1 Lebesgue 积分

对概率空间 $(\Omega, \mathcal{F}, P)$ 上的非负随机变量 X , 定义取 $0 = y_0 < y_1 < \cdots < y_n$, 当 $n \rightarrow \infty$ 时 $y_n \rightarrow \infty$, 且 $\max_{1 \leq k \leq n} (y_k - y_{k-1}) \rightarrow 0$, 则

$$\lim_{n \rightarrow \infty} \sum_{k=1}^n y_{k-1} P(y_{k-1} < X \leq y_k)$$

存在且不依赖于 $\{y_k\}$ 的选取, 定义此极限为

$$\int_{\Omega} X(\omega) \, dP(\omega).$$

称这样的积分为 Lebesgue 积分. 定义

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) \, dP(\omega).$$

对一般的随机变量 X , 令

$$X^+ = \max(X, 0), \quad X^- = \max(-X, 0),$$

则 $X = X^+ - X^-$, 若 $\int_{\Omega} X^+(\omega) \, dP(\omega)$ 和 $\int_{\Omega} X^-(\omega) \, dP(\omega)$ 至少有一个为有限值, 则定义

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) \, dP(\omega) = \int_{\Omega} X^+(\omega) \, dP(\omega) - \int_{\Omega} X^-(\omega) \, dP(\omega) = \mathbb{E}[X^+] - \mathbb{E}[X^-].$$

考虑 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, 可以定义关于 $A \in \mathcal{B}(\mathbb{R})$ 的函数 $L(A)$ 满足

1. $L(A) \geq 0$;
2. $L([a, b]) = b - a, -\infty < a < b < \infty$;
3. 对互不相交的 $A_n \in \mathcal{B}(\mathbb{R})$, 有 $L(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} L(A_n)$,

称 $L(\cdot)$ 为 Lebesgue 测度.

对 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, 若函数 $g(x)$ 满足

$$\{x : g(x) \leq y\} \in \mathcal{B}(\mathbb{R}), \quad \forall y \in \mathbb{R},$$

称 $g(x)$ 是 Borel 可测函数. 对 Borel 可测函数 $g(x)$, 可类似定义 $\int_{\mathbb{R}} g(x) dL(x)$, 称为 Lebesgue 积分.

当 $g(x)$ 黎曼可积时必 Lebesgue 可积, 而且积分相等, 所以将 Lebesgue 积分也记成

$$\int_{-\infty}^{\infty} g(x) \, dx.$$

区间上的 Lebesgue 积分可类似定义, 也可以定义成

$$\int_a^b g(x) \, dx = \int_{\mathbb{R}} g(x) I_{[a,b]}(x) \, dL(x).$$

1.2.2 测度变换

定理 1.2.1

设 $(\Omega, \mathcal{F}, P)$ 为概率空间, 随机变量 $Z \geq 0, \text{a.s.}$, 且 $\mathbb{E}[Z] = 1$, 定义

$$Q(A) = \int_A Z(\omega) dP(\omega) = \int_{\Omega} Z(\omega) I_A(\omega) dP(\omega) = \mathbb{E}[ZI_A],$$

则 $Q(\cdot)$ 是 $(\Omega, \mathcal{F})$ 上的概率测度, 如果 X 是非负随机变量, 则有

$$E^Q(X) = \int_{\Omega} X(\omega) dQ(\omega) = \mathbb{E}[XZ] = \int_{\Omega} X(\omega)Z(\omega) dP(\omega).$$

如果 $Z > 0, \text{a.s.}$, 则对任意非负随机变量 Y 有

$$\mathbb{E}[Y] = \mathbb{E}^Q\left[\frac{Y}{Z}\right].$$

这里 $\mathbb{E}^Q[X]$ 定义为 $\int_{\Omega} X(\omega) dQ(\omega)$. 如果 X (或者 Y) 不是非负的, 但是上式两边之一存在, 则仍成立.

定义 1.2.1 概率测度等价

设 P 和 Q 是测度空间 $(\Omega, \mathcal{F})$ 上的两个概率测度, 如果

$$P(A) = 0 \iff Q(A) = 0, \forall A \in \mathcal{F},$$

称这两个概率测度等价.

定理 1.2.2

设 $(\Omega, \mathcal{F}, P)$ 为概率空间, 随机变量 $Z > 0, \text{a.s.}$, 且 $\mathbb{E}[Z] = 1$, 定义

$$Q(A) = \int_A Z(\omega) dP(\omega) = \mathbb{E}[ZI_A],$$

则 Q 是与 P 等价的概率测度.

定理 1.2.3

设 P 和 Q 是测度空间 $(\Omega, \mathcal{F})$ 上的两个等价的概率测度, 则必存在几乎必然为正的随机变量 Z , 满足 $\mathbb{E}[Z] = 1$, 使得

$$Q(A) = \int_A Z(\omega) dP(\omega), \forall A \in \mathcal{F},$$

称 Z 是 Q 对 P 的 Radon-Nikodym 导数, 记为 $\frac{dQ}{dP}(\omega)$.

在金融建模中经常利用测度变换. P 表示真实世界的概率模型, 而 Q 表示风险中性世界的概率模型, 两者等价, 且可以通过正值随机变量 Z 将两个测度联系起来. 因为等价性, 在两个不同世界其中之一几乎必然成立的事件, 在另一个世界也是几乎必然成立的.

例 1.2.1

设 X 是 $(\Omega, \mathcal{F}, P)$ 中的标准正态分布随机变量. 令

$$Y = X + \theta,$$

则 Y 是 $(\Omega, \mathcal{F}, P)$ 中 $N(\theta, 1)$ 随机变量. 求测度变换 Q 使得 Y 在 $(\Omega, \mathcal{F}, Q)$ 中服从标准正态分布.

Solution. 不妨设 $\theta > 0$. 取

$$Z = \exp\left(-\theta X - \frac{1}{2}\theta^2\right),$$

则 Z 是 $(\Omega, \mathcal{F}, P)$ 中取正值的随机变量,

$$\mathbb{E}[Z] = e^{-\frac{1}{2}\theta^2} \mathbb{E}[e^{-\theta X}] = 1.$$

令

$$Q(A) = \int_A Z(\omega) \, dP(\omega),$$

则 Q 是与 P 等价的测度, $Z = \frac{dQ}{dP}$, 随机变量 Y 在 $(\Omega, \mathcal{F}, Q)$ 中的矩母函数为

$$\begin{aligned} \mathbb{E}^Q[e^{tY}] &= \mathbb{E}[Ze^{t(X+\theta)}] = \mathbb{E}\left[\exp\left(-\theta X - \frac{1}{2}\theta^2 + tX + t\theta\right)\right] \\ &= \exp\left(-\frac{1}{2}\theta^2 + t\theta\right) \mathbb{E}[\exp((t-\theta)X)] \\ &= \exp\left(-\frac{1}{2}\theta^2 + t\theta\right) \exp\left(\frac{1}{2}(t-\theta)^2\right) \\ &= e^{\frac{1}{2}t^2}, \end{aligned}$$

即 Y 在 Q 概率测度下服从标准正态分布.

Chapter 2

随机过程的基本概念和基本类型

2.1 基本概念

定义 2.1.1

随机过程是概率空间 $(\Omega, \mathcal{F}, P)$ 上的一族随机变量 $\{X(t), t \in T\}$, 其中 t 是参数, 它属于某个指标集 T , T 称为参数集.

注.

- 当 $T = \{0, 1, 2, \dots\}$ 时称之为随机序列或时间序列
- 参数 t 经常被解释为时间.
- 随机过程 $\{X(t, \omega), t \in T, \omega \in \Omega\}$ 是定义在 $T \times \Omega$ 上的二元函数, 但仅要求对每个 $t \in T, X(t)$ 是随机变量; 仅在某些情景下才要求 $X(t, \omega)$ 是二元可测的.
- 参数空间 T 是向量集合时, 随机过程 $\{X(t), t \in T\}$ 称为随机场.

$X(t)$ 表示系统在时刻 t 所处的状态. $X(t)$ 的所有可能状态构成的集合为状态空间, 记为 S . 一般如果不作说明都认为状态空间是实数集 $\mathbb{R}$ 或 $\mathbb{R}$ 的子集.

随机过程的分类:

1. 依照状态空间可分为连续状态和离散状态;
2. 依照参数集, 可分为离散参数过程和连续参数过程.

2.2 有限维分布与 Kolmogorov 定理

定义 2.2.1

对任意有限个 $t_1, \dots, t_n \in T$, 定义随机过程的 n 维分布 $F_{t_1, \dots, t_n}(x_1, \dots, x_n)$:

$$F_{t_1, \dots, t_n}(x_1, \dots, x_n) = P(X(t_1) \leq x_1, \dots, X(t_n) \leq x_n).$$

随机过程的所有的一维分布, 二维分布,, n 维分布等等的全体

$$\{F_{t_1, \dots, t_n}(x_1, \dots, x_n) : t_1, \dots, t_n \in T, n \geq 1\}$$

称为随机过程 $\{X(t), t \in T\}$ 的**有限维分布族**.

注. 知道了随机过程的有限维分布族就知道了 $\{X(t), t \in T\}$ 中任意 n 个随机变量的联合分布, 也就掌握了这些随机变量之间的相互依赖关系. 但是, 对于连续参数的随机过程, 如果考虑涉及到一个区间上的随机过程的事件概率, 因为涉及到无穷且不可数个随机变量共同的事件概率, 仅有限维分布族不能完全确定这些事件的概率, 通常需要对随机过程添加一些额外的要求, 比如轨道连续, 均方连续等.

性质 2.2.1 分布族

1. 对称性: 对 $(1, 2, \dots, n)$ 的任一排列 $(j_1, j_2, \dots, j_n)$, 有

$$\begin{aligned} & F_{t_{j_1}, \dots, t_{j_n}}(x_{j_1}, \dots, x_{j_n}) \\ &= P(X(t_{j_1}) \leq x_{j_1}, \dots, X(t_{j_n}) \leq x_{j_n}) \\ &= P(X(t_1) \leq x_1, \dots, X(t_n) \leq x_n) \\ &= F_{t_1, \dots, t_n}(x_1, \dots, x_n). \end{aligned}$$

2. 相容性: 对于 $m < n$, 有

$$F_{t_1, \dots, t_m, t_{m+1}, \dots, t_n}(x_1, \dots, x_m, \infty, \dots, \infty) = F_{t_1, \dots, t_m}(x_1, \dots, x_m).$$

定理 2.2.1 Kolmogorov 存在性定理

设有限维分布函数 $\{F_{t_1, \dots, t_n}(x_1, \dots, x_n) : t_1, \dots, t_n \in T, n \geq 1\}$ 满足上述的对称性和相容性, 则必存在一个随机过程 $\{X(t), t \in T\}$, 使

$$\{F_{t_1, \dots, t_n}(x_1, \dots, x_n) : t_1, \dots, t_n \in T, n \geq 1\}$$

恰好是 $\{X(t), t \in T\}$ 的有限维分布族.

定义 2.2.2 高斯过程

若随机过程 $\{X(t), t \in T\}$ 的所有有限维分布都是多元正态分布, 则称 $\{X(t)\}$ 为**高斯过程**.

注. 随机过程的有限维分布族是随机过程概率特征的完整描述, 它是证明随机过程存在性的有力工具. 但是在实际问题中, 要知道随机过程的全部有限维分布是不可能的, 因此, 人们想到了用随机过程的某些数字特征来刻画随机过程.

定义 2.2.3

设 $\{X(t), t \in T\}$ 是一随机过程.

1. 称 $X(t)$ 的期望 $\mu_X(t) = \mathbb{E}[X(t)]$ 为过程的均值函数 (如果存在的话).
2. 如果 $\forall t \in T, \mathbb{E}[X^2(t)]$ 存在.

则称随机过程 $\{X(t), t \in T\}$ 为**二阶矩过程**.

此时, 称函数 $\gamma(t_1, t_2) = \mathbb{E}[(X(t_1) - \mu_X(t_1))(X(t_2) - \mu_X(t_2))], t_1, t_2 \in T$ 为过程的**协方差函数**; 称 $\text{Var}[X(t)] = \gamma(t, t)$ 为过程的**方差函数**. 由 Schwartz 不等式知, 二阶矩过程的协方差函数存在.

有些教材还定义如下的相关函数:

$$R(t_1, t_2) = \mathbb{E}[X(t_1)X(t_2)] = \gamma(t_1, t_2) + \mu_X(t_1)\mu_X(t_2).$$

协方差函数 $\gamma(s, t)$ 满足如下的性质:

1. 对称性: $\gamma(s, t) = \gamma(t, s)$;
2. 非负定性: 对任意正整数 n 和任意 $t_1, \dots, t_n \in T$, 任意实数 $a_1, \dots, a_n$, 都有

$$\sum_{i=1}^n \sum_{j=1}^n a_i a_j \gamma(t_i, t_j) \geq 0.$$

例 2.2.1

$X(t) = X_0 + tV, a \leq t \leq b$, 其中 X_0 和 V 是相互独立且服从 $N(0, 1)$ 分布的随机变量. 求均值函数和协方差函数.

Solution. 由多元正态分布的性质可知 $X(t)$ 服从正态分布, 且 $X(t_1), \dots, X(t_n)$ 也是 n 维正态分布. 所以只要知道它的一阶矩和二阶矩就完全确定了它的分布. 每一条轨道是一条直线, 截距和斜率都是随机变量的值.

$$\begin{aligned} \mu_X(t) &= \mathbb{E}[X(t)] = \mathbb{E}[X_0 + tV] = \mathbb{E}[X_0] + t\mathbb{E}[V] = 0, \\ \gamma(t_1, t_2) &= \mathbb{E}[X(t_1)X(t_2)] = \mathbb{E}[(X_0 + t_1V)(X_0 + t_2V)] \\ &= \mathbb{E}[X_0^2] + t_1t_2\mathbb{E}[V^2] = 1 + t_1t_2. \end{aligned}$$

定理 2.2.2 高斯过程存在定理

设 $\mu(t), t \in T$ 为实值函数, $\gamma(s, t), s, t \in T$ 为二元实值函数, 满足对称性与非负定性条件, 则存在高斯过程 $\{X(t), t \in T\}$ 使得 $\{X(t)\}$ 以 $\mu(t)$ 为均值函数, 以 $\gamma(s, t)$ 为协方差函数.

定义 2.2.4

设 $\{X(t), t \geq 0\}$ 和 $\{Y(t), t \geq 0\}$ 是两个随机过程. 若对任意的正整数 n, m 和任意的 $0 \leq t_1 < t_2 < \dots < t_n$ 和 $0 \leq s_1 < s_2 < \dots < s_m$, 随机向量 $(X(t_1), X(t_2), \dots, X(t_n))$ 与随机向量 $(X(s_1), X(s_2), \dots, X(s_m))$ 相互独立, 则称这两个随机过程相互独立.

命题 2.2.1

设 $\{X(t), t \geq 0\}$ 和 $\{Y(t), t \geq 0\}$ 是两个随机过程. 若对任意的正整数 n 和任意的 $0 \leq t_1 < t_2 < \cdots < t_n$, 随机向量 $(X(t_1), X(t_2), \dots, X(t_n))$ 与随机向量 $(Y(t_1), Y(t_2), \dots, Y(t_n))$ 相互独立, 则这两个随机过程相互独立.

2.3 随机过程的基本类型**2.3.1 平稳过程****定义 2.3.1 严平稳过程**

如果随机过程 $\{X(t), t \in T\}$ 对任意的 $t_1, \dots, t_n \in T$ 和任意的 h (使得 $t_i + h \in T$), $(X(t_1 + h), \dots, X(t_n + h))$ 与 $(X(t_1), \dots, X(t_n))$ 具有相同的联合分布, 记为

$$(X(t_1 + h), \dots, X(t_n + h)) \triangleq (X(t_1), \dots, X(t_n)),$$

则称 $\{X(t), t \in T\}$ 为**严平稳**的.

定义 2.3.2 宽平稳过程

如果 $X(t)$ 是二阶矩过程, 并且均值函数 $\mathbb{E}[X(t)] = \mu$ (不依赖于 t), 协方差函数 $\gamma(t, s)$ 只与时间差 $t - s$ 有关, 则称 $\{X(t), t \in T\}$ 为**宽平稳过程**或**二阶平稳过程**.

注.

- 对于宽平稳过程, 由于 $\gamma(s, t) = \gamma(0, t - s)$, $s, t \in \mathbb{R}$, 可记为 $\gamma(t - s)$;
- $\gamma(\tau)$ 为偶函数, 且 $\gamma(0) = \text{Var}(X(t))$, $|\gamma(\tau)| \leq \gamma(0)$;
- $\gamma(\tau)$ 具有非负定性, 即对任意时刻 t_k 和实数 $a_k, k = 1, 2, \dots, N$, 有

$$\sum_{i=1}^N \sum_{j=1}^N a_i a_j \gamma(t_i - t_j) \geq 0.$$

当参数 t 仅取整数值 $0, \pm 1, \pm 2, \dots$ 或 $0, 1, 2, \dots$ 时, 称宽平稳过程为宽平稳序列. 在时间序列分析中经常简称宽平稳序列为平稳列.

对于平稳序列, 如果我们要从实际数据建立平稳序列的模型, 就需要估计其均值和自协方差函数. 均值 $\mu = \mathbb{E}[X(t)]$ 和自协方差函数 $\gamma(k) = \mathbb{E}[(X(t) - \mu)(X(t + k) - \mu)] = \text{Cov}(X(t), X(t + k))$ 都是针对整个概率空间 Ω 的积分, 如

$$\mu = \mathbb{E}[X(t)] = \int_{\Omega} X(t, \omega) dP(\omega).$$

理论上, 这需要观察许多条独立的轨道, 对这些不同轨道的观测值进行平均. 但是, 实际中我们一般仅能观测到一条轨道, 需要从这一条轨道的有限个观测值估计平稳序列的均值和自协方差函数. 如果这样的估计是相合的, 就成这个平稳列具有某种“遍历性”.

定理 2.3.1

1. 设 $\{X(t), -\infty < t < \infty\}$ 是平稳过程, 则当且仅当

$$\lim_{B \rightarrow \infty} \frac{1}{B} \int_0^{2B} \left(1 - \frac{\tau}{2B}\right) \gamma(\tau) d\tau = 0$$

时

$$\mathbb{E} \left[\frac{1}{2B} \int_{-B}^B X(t) dt - \mathbb{E}[X(1)] \right]^2 \rightarrow 0, B \rightarrow \infty.$$

2. 设 $\{X_n, n \in \mathbb{Z}\}$ 是平稳序列, 其均值函数为 μ , 协方差函数为 $\gamma(\tau)$, 则当且仅当

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{\tau=0}^{N-1} \gamma(\tau) = 0.$$

时

$$\mathbb{E} \left[\frac{1}{N} \sum_{t=1}^N X(t) - \mathbb{E}[X(1)] \right]^2 \rightarrow 0, N \rightarrow \infty.$$

推论 2.3.1

若 $\int_{-\infty}^{\infty} |\gamma(\tau)| d\tau < \infty$, 则定理 2.5 中 (1) 的条件满足.

推论 2.3.2

对于平稳序列, 若 $\gamma(\tau) \rightarrow 0 (\tau \rightarrow \infty)$ 则定理 2.5 中 (2) 的条件满足.

定理 2.3.2

设 $\{X(t), t \in \mathbb{R}\}$ 为四阶矩有限的宽平稳过程, 均值为零, 则当且仅当

$$\lim_{B \rightarrow \infty} \frac{1}{B} \int_0^{2B} \left(1 - \frac{s}{2B}\right) [Q(s) - \gamma^2(\tau)] ds = 0, \forall \tau \in \mathbb{R}$$

时

$$\mathbb{E} \left[\frac{1}{2B} \int_{-B}^B X(t) X(t+\tau) dt - \gamma(\tau) \right]^2 \rightarrow 0, B \rightarrow \infty.$$

其中 $Q(s) = \mathbb{E}[X(t+\tau+s)X(t+s)X(t+\tau)X(t)]$.

2.3.2 独立增量和平稳增量**定义 2.3.3**

对随机过程 $\{X(t), t \geq 0\}$, 如果对任意正整数 n 和 $t_1, t_2, \dots, t_n$, 其中 $0 \leq t_1 < t_2 < \dots < t_n$, 随机变量 $X(t_1), X(t_2) - X(t_1), \dots, X(t_n) - X(t_{n-1})$ 是相互独立的, 则称 $X(t)$ 为**独立增量过程**.

如果对任意的 $t_1 < t_2$ 和 $h > 0$, $X(t_1 + h) - X(t_1)$ 与 $X(t_2 + h) - X(t_2)$ 分布相同, 则称 $\{X(t), t \in T\}$ 为是**平稳增量过程**. 兼有独立增量和平稳增量的过程称为**平稳独立增量过程**.

对于平稳独立增量过程, 设 $X(0) = 0, 0 \leq t_1 < t_2 < \cdots < t_n, h > 0$, 则 $(X(t_1), X(t_2) - X(t_1), \dots, X(t_n) - X(t_{n-1}))$ 与 $(X(t_1 + h), X(t_2 + h) - X(t_1 + h), \dots, X(t_n + h) - X(t_{n-1} + h))$ 有相同的联合分布.

随机过程 $\{X(t), t \geq 0\}$ 的特征函数为 $\psi_{X(t)}(u) = \mathbb{E}[e^{iuX(t)}]$, 我们有如下定理:

定理 2.3.3

设 $\{X(t), t \geq 0\}$ 是一个独立增量过程, $X(0) = 0$, 则 $X(t)$ 具有平稳增量的充分必要条件是: 其特征函数具有可乘性, 即

$$\psi_{X(t+s)}(u) = \psi_{X(t)}(u)\psi_{X(s)}(u).$$

Proof. 必要性: 注意到

$$X(t+s) = X(s) + [X(t+s) - X(s)]$$

可得.

充分性: 由独立增量性有

$$\begin{aligned} \psi_{X(t)}(u)\psi_{X(s)}(u) &= \psi_{X(t+s)}(u) \\ &= \mathbb{E}[e^{iuX(t+s)}] = \mathbb{E}[e^{iu\{X(t+s)-X(s)\}+iuX(s)}] \\ &= \mathbb{E}[e^{iu[X(t+s)-X(s)]}] \mathbb{E}[e^{iuX(s)}] \\ &= \psi_{X(t+s)-X(s)}(u)\psi_{X(s)}(u). \end{aligned}$$

从两边约掉 $\psi_{X(s)}(u)$, 得

$$\psi_{X(t)}(u) = \psi_{X(t+s)-X(s)}(u).$$

这说明 $X(t+s) - X(s)$ 与 $X(t) - X(0)$ 同分布. 从而有平稳增量

平稳独立增量过程的均值函数是时间 t 的线性函数. 本书后面将要介绍的泊松过程和布朗运动都是这类过程. 这两类过程是随机过程理论中的两块最重要的基石. 设 $\{X(t), t \geq 0\}$ 是平稳独立增量过程, $X(0) = 0, \mu(t) = \mathbb{E}[X(t)], b = \mu(1)$. 则

$$\mu(2) = \mathbb{E}[X(2) - X(0)] = \mathbb{E}[[X(2) - X(1)] + [X(1) - X(0)]] = 2b.$$

归纳可知 $\mu(k) = kb, k = 0, 1, 2, \dots$. 同理可知对有理数 p/q 有 $\mu(\frac{p}{q}) = b\frac{p}{q}$. 若假定 $\mu(t)$ 连续, 则有 $\mu(t) = bt$.

Chapter 3

泊松过程

3.1 泊松过程定义

定义 3.1.1 计数过程

随机过程 $\{N(t), t \geq 0\}$ 称为或**点过程**, 如果 $N(t)$ 表示从时刻 0 到 t 某一特定事件 A 发生的次数, 它具备以下两个特点:

1. $N(t) \geq 0$ 且取值为整数;
2. $s < t$ 时, $N(s) \leq N(t)$ 且 $N(t) - N(s)$ 表示 $(s, t]$ 时间内事件 A 发生的次数.

一般都设 $N(0) = 0$.

定义 3.1.2 泊松过程

计数过程 $\{N(t), t \geq 0\}$ 称为参数为 $\lambda (\lambda > 0)$ 的**泊松过程**, 如果

1. $N(0) = 0$;
2. 过程有独立增量;
3. 对任意的 $s, t \geq 0$,

$$P(N(t+s) - N(s) = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}, \quad n = 0, 1, 2, \dots$$

注.

1. 泊松过程是独立平稳增量的计数过程.
2. 由于 $E[N(t)] = \lambda t$, 于是可认为 λ 是单位时间内发生的事件的平均次数, 故一般称 λ 是泊松过程的强度或速率.

例 3.1.1

(泊松过程在排队论中的应用) 在随机服务系统中排队现象的研究中, 经常用到泊松过程模型. 例如, 到达电话总机的呼叫数目, 到达某服务设施的顾客数, 都可以用泊松过程来描述. 以某火车站售票处为例, 设从早上 8:00 开始, 此售票处连续售票, 乘客依 10 人/小时的平均速率到达, 则从 9:00 到 10:00 这 1 小时内最多有 5 名乘客来此购票的概率是多少? 从 10:00-11:00 没有人来买票的概率是多少?

Solution. 我们用一个泊松过程来描述. 设 8:00 为 0 时刻, 则 9:00 为 1 时刻, 参数 $\lambda = 10$. 由泊松过程的平稳增量性知

$$P(N(2) - N(1) \leq 5) = \sum_{n=0}^5 e^{-10 \cdot 1} \frac{(10 \cdot 1)^n}{n!},$$

$$P(N(3) - N(2) = 0) = e^{-10} \cdot \frac{(10)^0}{0!} = e^{-10}.$$

例 3.1.2

(事故发生次数与保险公司接到的索赔数) 若以 $N(t)$ 表示某场所在 $(0, t]$ 时间内发生不幸事故的数目, 则泊松过程就是 $\{N(t), t \geq 0\}$ 的一种很好近似. 例如, 保险公司接到赔偿请求的次数 (设一次事故就导致一次索赔) 都是可以应用泊松过程的模型. 我们考虑一种最简单情况, 设保险公司每次的赔付都是 1, 每月平均接到索赔要求 4 次, 则一年中它要付出的金额平均为多少?

Solution. 设一年开始为 0 时刻, 1 月末为时刻 1, 2 月末为时刻 2, ..., 则年末为时刻 12.

$$P(N(12) - N(0) = n) = \frac{(4 \times 12)^n}{n!} e^{-4 \times 12}.$$

均值

$$E[N(12) - N(0)] = 4 \times 12 = 48.$$

为什么实际中有这么多的现象可以用泊松过程来反映呢? 其根据是小概率事件原理. 我们在概率论的学习中已经知道, Bernoulli 试验中, 每次试验成功的概率很小而试验的次数很多时, 二项分布会逼近 Poisson 分布. 这一想法很自然地推广到随机过程情况. 比如上面提到的事故发生的例子, 在很短的时间内发生事故的概率是很小的, 但假如考虑很多个这样很短的时间的连接, 事故的发生将会有一个大致稳定的速率, 这很类似于 Bernoulli 试验以及二项分布逼近 Poisson 分布时的假定.

定义 3.1.3 泊松过程的第二等价定义

设 $\{N(t), t \geq 0\}$ 是一个计数过程, 若满足

- (1)' $N(0) = 0$;
- (2)' 过程有平稳独立增量;
- (3)' 存在 $\lambda > 0$, 当 $h \downarrow 0$ 时, $P(N(t+h) - N(t) = 1) = \lambda h + o(h)$;

(4)' 当 $h \downarrow 0$ 时, $P(N(t+h) - N(t) \geq 2) = o(h)$.

则称 $\{N(t), t \geq 0\}$ 为泊松过程.

事实上, 把 $[0, t]$ 划分为 n 个等间隔的时间区间, 则由条件 (4)' 可知, 当 $n \rightarrow \infty$ 时, 在每个小区间内事件发生两次或两次以上的概率可以近似为 0, 因此, 事件发生一次的概率 $p \approx \lambda \frac{t}{n}$ (显然 p 会很小), 事件不发生的概率为 $1 - p \approx 1 - \lambda \frac{t}{n}$, 这恰好是一次 Bernoulli 试验. 其中事件发生一次即为试验成功, 不发生即为失败, 再由条件 (2)' 给出的平稳独立增量性, $N(t)$ 就相当于 n 次独立 Bernoulli 试验中试验成功的总次数, 由 Poisson 分布的二项分布逼近可知 $N(t)$ 将服从参数为 λt 的 Poisson 分布.

定理 3.1.1

事件 A 的发生形成强度为 λ 的泊松过程 $\{N(t), t \geq 0\}$. 如果每次事件发生时以概率 p 能够被记录下来, 并以 $M(t)$ 表示到 t 时刻被记录下来的事件总数, 则 $\{M(t), t \geq 0\}$ 是一个强度为 λp 的泊松过程.

3.2 与泊松过程相联系的若干分布

首先给出泊松过程的有关记号:

- 泊松过程 $\{N(t), t \geq 0\}$ 的一条样本路径一般是跳跃高度为 1 的阶梯函数.
- $T_n, n = 1, 2, 3, \dots$ 表示第 n 次事件发生的时刻, 规定 $T_0 = 0$.
- $X_n, n = 1, 2, \dots$ 表示第 n 次与第 $n-1$ 次事件发生的时间间隔.

3.2.1 X_n 和 T_n 的分布

定理 3.2.1

$X_n, n = 1, 2, \dots$ 服从参数为 λ 的指数分布, 且相互独立.

Proof. 首先考虑 X_1 的分布, 注意到事件 $\{X_1 > t\}$ 等价于事件 $\{N(t) = 0\}$, 即 $(0, t]$ 内没有事件发生. 因此

$$P(X_1 > t) = P(N(t) = 0) = e^{-\lambda t}, t > 0,$$

说明 X_1 服从指数分布 $\text{Exp}(\lambda)$. 对于 X_2 ,

$$\begin{aligned} P(X_2 > t | X_1 = s) &= P(N(s+t) - N(s) = 0 | X_1 = s) \\ &= P(N(s+t) - N(s) = 0) \quad (\text{独立增量性}) \\ &= e^{-\lambda t}. \end{aligned}$$

所以 X_2 与 X_1 独立, 且都服从参数为 λ 的指数分布. 重复同样的推导, 可得定理结论.

上述结果应该是预料之中的, 由于泊松过程有平稳独立增量, 过程在任何时刻都“重新开始”, 换言之, 这恰好就是“无记忆”的体现, 与指数分布的“无记忆性”是对应的.

定理 3.2.2

$T_n, n = 1, 2, \dots$ 服从参数为 n 和 λ 的 Gamma 分布.

定义 3.2.1 泊松过程的第三等价定义

计数过程 $\{N(t), t \geq 0\}$ 是参数为 λ 的泊松过程, 如果每次事件发生的时间间隔 $X_1, X_2, \dots$ 相互独立, 且服从同一参数为 λ 的指数分布.

例 3.2.1

设从早上 8:00 开始有无穷多的人排队等候服务, 只有一名服务员, 且每个人接受服务的时间是独立的并服从均值为 20 分钟的指数分布, 则到中午 12:00 为止平均有多少人已经离去, 已有 9 个人接受服务的概率是多少?

Solution. 由所设条件可知, 离去的人数 $\{N(t)\}$ 是强度为 3 的泊松过程 (这里以小时为单位). 设 8:00 为零时刻则

$$P(N(4) - N(0) = n) = e^{-12} \frac{(12)^n}{n!}.$$

其均值为 12, 即到 12:00 为止, 离去的人平均是 12 名. 而有 9 个人接受过服务的概率是

$$P(N(4) = 9) = e^{-12} \frac{(12)^9}{9!}.$$

例 3.2.2

假定某天文台观测到的流星流是一个泊松过程, 根据以往资料统计为每小时平均观察到 3 颗流星. 试求: 在上午 8 点到 12 点期间, 该天文台没有观察到流星的概率.

Solution. 设早晨 8 时为 0 时刻, 以 $N(t)$ 表示 0 时到 t 时观测到的流星数, 则 $\{N(t)\}$ 是强度为 3 的泊松过程, 则有

$$N(4) - N(0) \sim \text{Poisson}(3 \times 4).$$

故在上午 8 点到 12 点期间, 该天文台没有观察到流星的概率为

$$P\{N(4) - N(0) = 0\} = e^{-12}.$$

3.2.2 事件发生时刻的条件分布**定理 3.2.3**

在已知 $[0, t]$ 内 A 只发生一次的前提下, A 发生的时刻在 $[0, t]$ 上是均匀分布.

Proof. 对于 $s \leq t$,

$$\begin{aligned}\Pr(T_1 \leq s | N(t) = 1) &= \frac{\Pr(T_1 \leq s, N(t) = 1)}{\Pr(N(t) = 1)} \\&= \frac{\Pr(A \text{ 发生在 } s \text{ 时刻之前, } (s, t] \text{ 内 } A \text{ 没有发生})}{\Pr(N(t) = 1)} \\&= \frac{\Pr(N(s) = 1) \cdot \Pr(N(t) - N(s) = 0)}{\Pr(N(t) = 1)} \\&= \frac{\lambda s e^{-\lambda s} \cdot e^{-\lambda(t-s)}}{\lambda t e^{-\lambda t}} = \frac{s}{t}.\end{aligned}$$

这个定理的逆命题也成立. 设事件发生时间间隔 X_n 独立同分布, $\{N(t)\}$ 是由 $\{X_n\}$ 定义的计数过程, 设 $P(X_n = 0) = 0$, 则若上述定理的条件分布成立, 则 $\{X(t)\}$ 必为泊松过程.

定理 3.2.4

在已知 $N(t) = n$ 的条件下, 事件发生的 n 个时刻 $T_1, T_2, \dots, T_n$ 的联合分布密度是

$$f(t_1, t_2, \dots, t_n) = \frac{n!}{t^n}, \quad 0 < t_1 < t_2 < \dots < t_n.$$

即 n 个独立同均匀分布 $U(0, t)$ 的随机变量的次序统计量的联合分布.

例 3.2.3

乘客按照强度为 λ 的泊松过程来到某火车站, 火车在时刻 t 启程, 计算在 $(0, t]$ 内到达的乘客等待时间的总和的期望值, 即求

$$E \left(\sum_{i=1}^{N(t)} (t - T_i) \right),$$

其中 T_i 是第 i 个乘客到来的时刻

Solution. 在 $N(t)$ 给定条件下, 取条件期望

$$E \left[\sum_{i=1}^{N(t)} (t - T_i) | N(t) = n \right] = E \left[\sum_{i=1}^n (t - T_i) | N(t) = n \right] = nt - E \left[\sum_{i=1}^n T_i | N(t) = n \right].$$

记 $U_1, U_2, \dots, U_n$ 为 n 个独立的服从 $(0, t]$ 上的均匀分布的随机变量, 由定理

$$E \left[\sum_{i=1}^n T_i | N(t) = n \right] = E \left[\sum_{i=1}^n U_i \right] = \frac{nt}{2}.$$

从而

$$E \left[\sum_{i=1}^n (t - T_i) | N(t) = n \right] = nt - \frac{nt}{2} = \frac{nt}{2}.$$

所以

$$\begin{aligned}
 & E \left[\sum_{i=1}^{N(t)} (t - T_i) \right] \\
 &= E \left[E \left(\sum_{i=1}^{N(t)} (t - T_i) \middle| N(t) \right) \right] \\
 &= \frac{t}{2} E[N(t)] = \frac{\lambda t^2}{2}.
 \end{aligned}$$

3.3 泊松过程的推广

3.3.1 非齐次泊松过程

定义 3.3.1 非齐次泊松过程

计数过程 $\{N(t), t \geq 0\}$ 称做强度函数为 $\lambda(t) > 0 (t \geq 0)$ 的非齐次泊松过程, 如果

1. $N(0) = 0$;
2. 过程有独立增量;
3. $P(N(t+h) - N(t) = 1) = \lambda(t)h + o(h)$;
4. $P(N(t+h) - N(t) \geq 2) = o(h)$.

类似于泊松过程, 非齐次泊松过程有如下的等价定义.

定义 3.3.2

计数过程 $\{N(t), t \geq 0\}$ 称为强度函数为 $\lambda(t) > 0 (t \geq 0)$ 的非齐次泊松过程, 若

1. $N(0) = 0$;
2. 过程有独立增量;
3. 对任意实数 $t \geq 0, s \geq 0, N(t+s) - N(t)$ 服从参数为

$$m(t+s) - m(t) = \int_t^{t+s} \lambda(u) du$$

的泊松分布.

3.3.1.0.1 注. $m(t) = \int_0^t \lambda(s) ds$. 对齐次 (时齐) 的泊松过程, $m(t) = \lambda \cdot t$, 不论时齐与否都有 $m(t) = E[N(t)]$, 即 $m(t)$ 是 $(0, t]$ 时间段发生的事件个数的期望值.

定理 3.3.1 泊松过程与非齐次泊松过程之间转换关系

设 $\lambda(t) > 0, \forall t \geq 0, m(t) = \int_0^t \lambda(u) du$. 若 $\{N(t), t \geq 0\}$ 是一个强度函数为 $\lambda(t)$ 的非齐次泊松过程. 令 $N^*(t) = N(m^{-1}(t))$, 则 $\{N^*(t)\}$ 是一个强度参数为 1 的泊松过程. 反之, 若 $\{N^*(t)\}$ 是一个强度参数为 1 的泊松过程, 则 $N(t) = N^*(m(t))$ 是一个强度函数为 $\lambda(t)$ 的非齐次泊松过程.

Proof. 用泊松过程的定义验证 $\{N^*(t)\}$ 是一个强度参数为 1 的泊松过程. 显然 $N^*(0) = 0$, 且具有独立增量, 只要证明 $N^*(t+s) - N^*(s)$ 服从参数为 t 的泊松分布. 事实上

$$\begin{aligned} & N^*(t+s) - N^*(s) \\ &= N(m^{-1}(t+s)) - N(m^{-1}(s)) \\ &\sim \text{Pois}[m(m^{-1}(t+s)) - m(m^{-1}(s)))] \\ &= \text{Pois}(t). \end{aligned}$$

反过来, 如果 $\{N^*(t)\}$ 是一个强度参数为 1 的泊松过程, $N(t) = N^*(m(t))$, 则 $N(0) = 0, \{N(t)\}$ 仍有独立增量,

$$\begin{aligned} & N(t+s) - N(s) \\ &= N^*(m(t+s)) - N^*(m(s)) \\ &\sim \text{Pois}[m(t+s) - m(s)], \end{aligned}$$

由非齐次泊松过程等价定义可知 $\{N(t)\}$ 是强度函数为 $\lambda(t)$ 的非齐次泊松过程.

3.3.1.0.2 注.

1. 用此定理可以简化非齐次泊松过程的问题到泊松过程中进行讨论. 也从一个参数为 1 的齐次泊松过程构造一个强度函数为 $\lambda(t)$ 的非齐次泊松过程.
2. 若 $m(t)$ 非严格单调增, 比如在某一区间 $\lambda(t) = 0$ 的情形, 可以取

$$m^{-1}(u) = \inf\{t : t > 0, m(t) \geq u\}, u > 0,$$

$$\text{这时 } u \leq m(t) \iff t \geq m^{-1}(u)$$

例 3.3.1

设某设备的使用期限为 10 年, 在前 5 年内它平均 2.5 需要维修一次, 后 5 年平均 2 年需维修一次. 试求它在使用期内只维修过一次的概率.

Solution. 用非齐次泊松过程考虑, 强度函数

$$\lambda(t) = \begin{cases} \frac{1}{2.5}, & 0 \leq t \leq 5, \\ \frac{1}{2}, & 5 < t \leq 10, \end{cases}$$

有

$$m(10) = \int_0^{10} \lambda(t) dt = \int_0^5 \frac{1}{2.5} dt + \int_5^{10} \frac{1}{2} dt = 4.5$$

因此

$$P(N(10) - N(0) = 1) = e^{-4.5} \frac{(4.5)^1}{1!} = \frac{9}{2} e^{-\frac{9}{2}}.$$

3.3.2 复合泊松过程

定义 3.3.3

称随机过程 $\{X(t), t \geq 0\}$ 为**复合泊松过程**, 如果对于 $t \geq 0$, $X(t)$ 可以表示为

$$X(t) = \sum_{i=1}^{N(t)} Y_i,$$

其中 $\{N(t), t \geq 0\}$ 是一个泊松过程, $Y_i, i = 1, 2, \dots$ 是一族独立同分布的随机变量, 并且与 $\{N(t), t \geq 0\}$ 也是独立的.

注: 复合泊松过程不一定是计数过程, 但是当 $Y_i \equiv c, i = 1, 2, \dots, c$ 为常数时, 可化为泊松过程. 定理 3.2 可以看成是 $Y_i \sim b(1, p)$ 的复合泊松过程, 但恰好构成了参数为 λp 的泊松过程.

例 3.3.2

1. 保险公司接到的索赔次数服从一个泊松过程 $\{N(t)\}$, 每次要求赔付的金额 Y_i 都相互独立, 且有同分布 F , 每次的索赔数额与它发生的时刻无关, 则 $[0, t]$ 时间区间内保险公司需要赔付的总金额 $\{X(t)\}$ 就是一个复合泊松过程,

$$X(t) = \sum_{i=1}^{N(t)} Y_i.$$

2. (顾客成批到达的排队系统) 设顾客到达某服务系统的时间 $S_1, S_2, \dots$ 形成一强度为 λ 的泊松过程, 在每个时刻 S_n 可以同时有多名顾客到达. Y_n 表示在时刻 S_n 到达的顾客人数, 假定 $Y_n, n = 1, 2, \dots$ 相互独立, 并且与 $\{S_n\}$ 也独立, 则在 $[0, t]$ 时间区间内到达服务系统的顾客总人数也可用一复合泊松过程来描述

例 3.3.3

假设顾客按照参数为 λ 的泊松过程进入一个商店, 又假设各顾客所花费的金额形成一族独立同分布的随机变量. 以 $X(t)$ 记到时间 t 为止顾客在此商店所花费的总额, 易知 $\{X(t), t \geq 0\}$ 是一个复合泊松过程.

定理 3.3.2

设 $\{X(t) = \sum_{i=1}^{N(t)} Y_i, t \geq 0\}$ 是一复合泊松过程, 泊松过程 $\{N(t), t \geq 0\}$ 的强度为 λ , 则

- (1) $X(t)$ 有独立增量;

$$(2) \quad EX(t) = \lambda t \cdot E(Y_1);$$

$$\text{Var}[X(t)] = \lambda t \cdot E(Y_1^2).$$

Proof.

1. 令 $0 \leq t_0 < t_1 < t_2 < \cdots < t_n$, 则

$$X(t_k) - X(t_{k-1}) = \sum_{i=N(t_{k-1})+1}^{N(t_k)} Y_i, \quad k = 1, 2, \dots, n,$$

由过程的独立增量性及各 $Y_i (i = 1, 2, \dots, n)$ 之间的独立性不难得出 $X(t)$ 的独立增量性.

2. 用全期望公式,

$$E[X(t)] = E[E(X(t)|N(t))],$$

其中

$$\begin{aligned} E(X(t)|N(t) = n) &= E\left(\sum_{i=1}^n Y_i | N(t) = n\right) \\ &= E\left(\sum_{i=1}^n Y_i\right) = nE(Y_1), \end{aligned}$$

故

$$E[X(t)] = E[N(t)E(Y_1)] = E[N(t)]E(Y_1).$$

对于 $\text{Var}(X(t))$, 要利用条件方差公式

$$\text{Var}(X(t)) = E\{\text{Var}[X(t)|N(t)]\} + \text{Var}\{E[X(t)|N(t)]\},$$

其中,

$$\begin{aligned} \text{Var}[X(t)|N(t) = n] &= E\left\{[X(t) - E(X(t)|N(t) = n)]^2 | N(t) = n\right\} \\ &= E\left\{\left[\sum_{i=1}^n Y_i - nE(Y_1)\right]^2 | N(t) = n\right\} \\ &= E\left\{\left[\sum_{i=1}^n Y_i - nE(Y_1)\right]^2\right\} \\ &= E\left\{\left[\sum_{i=1}^n (Y_i - EY_i)\right]^2\right\} \\ &= \text{Var}\left[\sum_{i=1}^n (Y_i - EY_i)\right] = n\text{Var}(Y_1), \end{aligned}$$

于是

$$\begin{aligned} \text{Var}(X(t)) &= E[N(t)\text{Var}(Y_1)] + \text{Var}(N(t)E(Y_1)) \\ &= \lambda t \text{Var}(Y_1) + \lambda t [E(Y_1)]^2 = \lambda t E(Y_1^2). \end{aligned}$$

3.3.3 条件泊松过程

定义 3.3.4

设随机变量 $\Lambda > 0$, 在 $\Lambda = \lambda$ 的条件下, 计数过程 $\{N(t), t \geq 0\}$ 是参数为 λ 的泊松过程. 则称 $\{N(t), t \geq 0\}$ 为条件泊松过程.

命题 3.3.1

设 Λ 的分布是 $G(\cdot)$, 那么在长度为 t 的时间区间内发生 n 次事件的概率为

$$P(N(t+s) - N(s) = n) = \int_0^\infty e^{-\lambda t} \frac{(\lambda t)^n}{n!} dG(\lambda).$$

Proof. 利用全期望公式. 记 I_A 为事件 A 的示性函数, 则 $E(I_A) = P(A)$,

$$\begin{aligned} P(N(t+s) - N(s) = n) &= E \left[I_{\{N(t+s) - N(s) = n\}} \right] \\ &= E \left\{ E \left[I_{\{N(t+s) - N(s) = n\}} | \Lambda \right] \right\} \\ &= \int_0^\infty E \left[I_{\{N(t+s) - N(s) = n\}} | \Lambda = \lambda \right] dG(\lambda) \\ &= \int_0^\infty P[N(t+s) - N(s) = n | \Lambda = \lambda] dG(\lambda) \\ &= \int_0^\infty e^{-\lambda t} \frac{(\lambda t)^n}{n!} dG(\lambda). \end{aligned}$$

定理 3.3.3

$\{N(t), t \geq 0\}$ 是条件泊松过程, 且 $E(\Lambda^2) < \infty$, 则

1. $E[N(t)] = tE(\Lambda)$;
2. $\text{Var}[N(t)] = t^2\text{Var}(\Lambda) + tE(\Lambda)$.

Proof.

$$1. E[N(t)] = E[E(N(t)|\Lambda)] = E(t\Lambda) = tE(\Lambda).$$

2.

$$\begin{aligned} \text{Var}(N(t)) &= E[N^2(t)] - [E(N(t))]^2 \\ &= E[\Lambda t + \Lambda^2 t^2] - [tE(\Lambda)]^2 \\ &= tE(\Lambda) + t^2E(\Lambda^2) - t^2[E(\Lambda)]^2 \\ &= tE(\Lambda) + t^2\text{Var}(\Lambda). \end{aligned}$$

Chapter 4

更新过程

略

Chapter 5

马尔可夫链

5.1 基本概念

5.1.1 定义和性质

定义 5.1.1

等价于随机过程 $\{X_n, n = 0, 1, 2, \dots\}$ 称为**马尔可夫链**（简称：马氏链），若它只取有限或可列个值（若不另外说明，以非负整数集 $\{0, 1, 2, \dots\}$ 来表示），并且对任意的 $n \geq 0$ ，及任意状态 $i, j, i_0, i_1, \dots, i_{n-1}$ ，有

$$\Pr(X_{n+1} = j \mid X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}, X_n = i) = \Pr(X_{n+1} = j \mid X_n = i)$$

其中 $X_n = i$ 表示过程在时刻 n 处于状态 i ，称 $\{0, 1, 2, \dots\}$ 为该过程的状态空间，记为 S 。上式刻画了马氏链的特性，称为马尔可夫性质（简称：马氏性）。

性质 5.1.1 条件独立性

设 A, B, C 为随机事件，若 $\Pr(BC) > 0$ ，则

$$\Pr(A|BC) = \Pr(A|B)$$

等价于

$$\Pr(AC|B) = \Pr(A|B) \Pr(C|B),$$

这时称给定 B 的条件下 A 和 C 相互独立。集合函数 $P_B(A) = \Pr(A|B)$ ($A \in \mathcal{F}$) 是一个概率测度，也有乘积公式、全概率公式等性质。

对随机变量 X, Y, Z ，若

$$\Pr(X \leq x, Y \leq y | Z = z) = \Pr(X \leq x | Z = z) \Pr(Y \leq y | Z = z)$$

则称 X 和 Y 在给定 Z 的条件下独立。 X, Y, Z 都服从离散分布时，条件独立性等价于

$$\Pr(X = x, Y = y | Z = z) = \Pr(X = x | Z = z) \Pr(Y = y | Z = z),$$

也等价于

$$\Pr(X = x | Y = y, Z = z) = \Pr(X = x | Z = z).$$

等价于 X_{n+1} 和 $X_0, \dots, X_{n-1}$ 在给定 X_n 的条件下条件独立。

定义 5.1.2

称马氏链定义式中的条件概率 $\Pr(X_{n+1} = j | X_n = i)$ 为马氏链 $\{X_n, n = 0, 1, 2, \dots\}$ 的**一步转移概率**, 简称为转移概率.

定义 5.1.3

当马氏链的一步转移概率 $\Pr(X_{n+1} = j | X_n = i)$ 只与状态 i, j 有关, 而与 n 无关时, 称此马氏链为**时齐马氏链**, 记 $\Pr(X_{n+1} = j | X_n = i) = p_{ij}$, 代表处于状态 i 的过程下一步转移到状态 j 的概率. 若 $\Pr(X_{n+1} = j | X_n = i)$ 与 n 有关, 就称该马氏链为**非时齐的**.

一般情况下, 转移概率与状态 i, j 和时刻 n 有关.

在本书中, 我们只讨论时齐马氏链, 并且简称为马氏链.

当马氏链的状态为有限时, 称为有限链, 否则称为无限链. 但无论状态有限还是无限, 我们都可以将 $p_{ij}(i, j \in S)$ 排成一个矩阵的形式. 令

$$P = (p_{ij}) = \begin{pmatrix} p_{00} & p_{01} & p_{02} & \cdots \\ p_{10} & p_{11} & p_{12} & \cdots \\ p_{20} & p_{21} & p_{22} & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

称 P 为转移概率矩阵, 一般简称为转移矩阵. 由于概率是非负的, 且过程必须转移到某个状态, 所以容易看出 $p_{ij}(i, j \in S)$ 有性质

- (1) $p_{ij} \geq 0, i, j \in S$;
- (2) $\sum_{j \in S} p_{ij} = 1, \forall i \in S$.

定义 5.1.4

称矩阵为**随机矩阵**, 若矩阵元素具有上述两条性质. 易见随机矩阵每一行元素的和都为 1.

例 5.1.1

(一个简单的疾病、死亡模型, Fix-Neyman)

考虑一个包含两个健康状态 S_1, S_2 以及两个死亡状态 S_3, S_4 (即由不同原因引起的死亡) 的模型. 若个体病愈, 则认为它处于状态 S_1 , 若患病, 说处于 S_2 , 个体可以从 S_1, S_2 进入 S_3 和 S_4 , 易见这是一个马氏链的模型, 转移矩阵为

$$P = \begin{pmatrix} p_{11} & p_{12} & p_{13} & p_{14} \\ p_{21} & p_{22} & p_{23} & p_{24} \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

例 5.1.2

(赌徒的破产或称带吸收壁的随机游动)

系统的状态是 $0 \sim n$, 反映赌博者在赌博期间拥有的钱数, 当他输光或拥有钱数为 n 时, 赌博

停止, 否则他将持续赌博. 每次以概率 p 赢得 1, 以概率 $q = 1 - p$ 输掉 1. 这个系统的转移矩阵为

$$P = \begin{pmatrix} 1 & 0 & 0 & 0 & \cdots & 0 & 0 & 0 \\ q & 0 & p & 0 & \cdots & 0 & 0 & 0 \\ 0 & q & 0 & p & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & q & 0 & p \\ 0 & 0 & 0 & 0 & \cdots & 0 & 0 & 1 \end{pmatrix}_{(n+1) \times (n+1)}$$

例 5.1.3

(带反射壁的随机游动)

设上例中当赌博者输光时将获得赞助 1 让他继续赌下去, 就如同一个在直线上做随机游动的球在到达左侧 0 点处就立刻反弹回 1 一样, 这就是一个一侧带有反射壁的随机游动. 此时转移矩阵为

$$P = \begin{pmatrix} 0 & 1 & 0 & 0 & \cdots & 0 & 0 & 0 \\ q & 0 & p & 0 & \cdots & 0 & 0 & 0 \\ 0 & q & 0 & p & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & q & 0 & p \\ 0 & 0 & 0 & 0 & \cdots & 0 & 0 & 1 \end{pmatrix}_{(n+1) \times (n+1)}$$

同样可考虑两侧均有反射壁的情况.

例 5.1.4

(M/G/1 排队系统) 假设顾客依照参数为 λ 的 Poisson 过程来到一个只有一名服务员的服务站, 若服务员空闲则顾客就能立刻得到服务, 否则排队等待直至轮到该顾客. 设每名顾客接受服务的时间是独立的随机变量有共同的分布 G , 而且与来到过程独立. 这个系统称为 M/G/1 排队系统, 字母 M 代表顾客来到的间隔服从指数分布, G 代表服务时间的分布, 数字 1 表示只有 1 名服务员. 考虑其中嵌入的马氏链.

Solution. 若以 $X(t)$ 表示时刻 t 系统中的顾客人数, 则 $\{X(t), t \geq 0\}$ 是不具备马氏性的, 因为若已知 t 时刻系统中的人数, 要预测未来, 虽然可以不用关心从最近的一位顾客到来又过去了多长时间 (因过程无记忆, 所以这段时间不影响下一位顾客的到来), 但要注意此刻在服务中的顾客已经接受了多长时间的服务 (因为 G 不是指数的, 不具备“无记忆性”, 所以已经服务过的时间将影响到他何时离去).

我们可以这样考虑, 令 X_n 表示第 n 位顾客走后剩下的顾客数, $n \geq 1$. 再令 Y_n 记第 $n+1$ 位顾客接受服务期间到来的顾客数, 则

$$X_{n+1} = \begin{cases} X_n - 1 + Y_n, & \text{若 } X_n > 0, \\ Y_n, & \text{若 } X_n = 0. \end{cases}$$

记 T_n 为第 n 位顾客到来的时刻, $N(t)$ 为截止到 t 时刻顾客到来的人数, 则 $\{N(t)\}$ 与 T_n 是参

数为 λ 的泊松过程以及相应的事件到来时刻.

如果 $X_n = 0$, 这表示第 n 位顾客接受完服务离开时没有其他顾客等候, 服务员变空闲, 直到 T_{n+1} 时第 $n+1$ 位顾客到来, 这位顾客是当时的唯一顾客, 马上接受服务, 在第 $n+1$ 位接受服务期间又到来 Y_n 位顾客排队等候, 所以在 $X_n = 0$ 条件下第 $n+1$ 位离开时系统中有 Y_n 位顾客.

如果 $X_n > 0$, 则第 n 位顾客接受完服务离开时排队的队首顾客是第 $n+1$ 位到来的顾客, 这位顾客马上接受服务, 还有 $X_n - 1$ 位顾客排队等待, 在第 $n+1$ 位顾客接受服务期间又到来 Y_n 位顾客加入排队, 所以在 $X_n > 0$ 条件下在第 $n+1$ 位顾客离开时队伍中共有 $X_n - 1 + Y_n$ 人.

——举例说明. 设 $n = 5$, X_5 表示第 5 位顾客走后剩余的顾客数, 为一个非负整数. X_6 表示第 6 位顾客走后剩余的顾客数, 这依赖于 X_5 的值和第 5 位顾客走后、第 6 位顾客走之前新到来的顾客人数 Y_5 . 分为两种情况, 若 $X_5 = 0$, 则第 6 位顾客到来时直接接受服务, 这期间又来了 Y_5 位顾客, 第 6 位顾客离开时还剩 Y_5 位顾客; 若 $X_5 > 0$, 则第 5 位顾客离开时第 6 位顾客是排在队首的顾客, 这时除了第 6 位顾客还有 $X_5 - 1 \geq 0$ 位顾客, 在第 6 位顾客接受服务期间又来了 Y_5 位顾客, 第 6 位离开时还剩下原来队伍中的 $X_5 - 1$ 位顾客和新来的 Y_5 位顾客.

可以证明 Y_n 的分布为:

$$\Pr(Y_n = j) = \int_0^\infty e^{-\lambda x} \frac{(\lambda x)^j}{j!} dG(x), \quad j = 0, 1, 2, \dots$$

设第 $n+1$ 位顾客接受服务的时间长度为 Z , $Z \sim G(\cdot)$, 在 $Z = x$ 条件下, 接受服务期间到达的顾客数 Y_n 服从 $\text{Poisson}(\lambda x)$ 分布, 于是

$$\Pr(Y_n = j | Z = x) = e^{-\lambda x} \frac{(\lambda x)^j}{j!},$$

由全期望公式,

$$\begin{aligned} \Pr(Y_n = j) &= \mathbb{E}[\Pr(Y_n = j | Z)] \\ &= \int_0^\infty \Pr(Y_n = j | Z = x) dG(x) \\ &= \int_0^\infty e^{-\lambda x} \frac{(\lambda x)^j}{j!} dG(x). \end{aligned}$$

这给出 $\{Y_n\}$ 的分布, 此分布并不依赖 $X_0, X_1, \dots, X_n$ 的值, 所以 $\Pr(X_{n+1} = j | X_n = i)$ 与给定 $X_0, X_1, \dots, X_n$ 的条件概率相同, X_n 马氏性成立. 所以由 (5.3)、(5.4) 式得 $\{X_n, n = 1, 2, \dots\}$ 是马氏链, 转移概率为

$$\begin{aligned} p_{0j} &= \Pr(X_{n+1} = j | X_n = 0) = \Pr(Y_n = j | X_n = 0) = \Pr(Y_n = j) \\ &= \int_0^\infty e^{-\lambda x} \frac{(\lambda x)^j}{j!} dG(x), \quad j \geq 0 \\ p_{ij} &= \Pr(X_{n+1} = j | X_n = i) \quad (i \geq 1) \\ &= \Pr(Y_n + i - 1 = j | X_n = i) \\ &= \Pr(Y_n = j - i + 1) \quad (i \geq 1, j \geq i - 1) \\ &= \int_0^\infty e^{-\lambda x} \frac{(\lambda x)^{j-i+1}}{(j-i+1)!} dG(x), \quad j \geq i - 1, i \geq 1, \end{aligned}$$

$p_{ij} = 0$, 其他

5.1.2 多步转移概率与 C-K 方程

命题 5.1.1

设 $\{X_n, n = 0, 1, \dots\}$ 是时齐离散时间离散状态马氏链, 状态空间为 S 则对任意 $n \geq 0, m \geq 1$ 和状态 $x_0, \dots, x_{n-1}, i, j \in S$, 有

$$\begin{aligned} & \Pr(X_{n+m} = j | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) \\ &= \Pr(X_{n+m} = j | X_n = i) \\ &= p_{ij}^{(m)}, \end{aligned}$$

与 n 无关.

当 $m = 1$ 时就是时齐马氏性的定义.

Proof. 对 m 用数学归纳法. 已知 $m = 1$ 时成立. 设已知结论对 $1, \dots, m$ 成立, 来证明结论对 $m+1$ 成立.

$$\begin{aligned} & \Pr(X_{n+m+1} = j | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) \\ &= \sum_{k \in S} \Pr(X_{n+m+1} = j, X_{n+m} = k | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) \\ &= \sum_{k \in S} \Pr(X_{n+m+1} = j | X_{n+m} = k, X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) \\ & \quad \Pr(X_{n+m} = k | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) \\ &= \sum_{k \in S} \Pr(X_{n+m+1} = j | X_{n+m} = k) \Pr(X_{n+m} = k | X_n = i) \\ &= \sum_{k \in S} p_{kj} p_{ik}^{(m)} \end{aligned}$$

与 n 和 $x_{n-1}, \dots, x_0$ 无关, 所以在 $X_n = i$ 条件下 X_{n+m+1} 与 $X_{n-1}, \dots, X_0$ 条件独立, 有

$$\begin{aligned} & \Pr(X_{n+m+1} = j | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) \\ &= \Pr(X_{n+m+1} = j | X_n = i) = p_{ij}^{(m+1)} \end{aligned}$$

与 n 无关.

定义 5.1.5

称条件概率

$$p_{ij}^{(n)} = \Pr(X_{m+n} = j | X_m = i), i, j \in S, m \geq 0, n \geq 1$$

为马氏链的 n 步转移概率, 相应地称 $P^{(n)} = (p_{ij}^{(n)})$ 为 n 步转移矩阵.

当 $n = 1$ 时, $p_{ij}^{(1)} = p_{ij}$, $P^{(1)} = P$, 此外规定

$$p_{ij}^{(0)} = \begin{cases} 0, & \text{当 } i \neq j, \\ 1, & \text{当 } i = j. \end{cases}$$

显然, n 步转移概率 $p_{ij}^{(n)}$ 指的就是系统从状态 i 经过 n 步后转移到 j 的概率, 它对中间的 $n-1$ 步转移经过的状态无要求.

下面的定理给出了 $p_{ij}^{(n)}$ 和 p_{ij} 的关系.

定理 5.1.1 C-K (Chapman-Kolmogorov) 方程

对一切 $n, m \geq 0, i, j \in S$ 有

$$1. p_{ij}^{(m+n)} = \sum_{k \in S} p_{ik}^{(m)} p_{kj}^{(n)};$$

$$2. P^{(n)} = P^n.$$

Proof.

$$\begin{aligned} p_{ij}^{(m+n)} &= \Pr(X_{m+n} = j | X_0 = i) \\ &= \frac{\Pr(X_{m+n} = j, X_0 = i)}{\Pr(X_0 = i)} \\ &= \sum_{k \in S} \frac{\Pr(X_{m+n} = j, X_m = k, X_0 = i)}{\Pr(X_0 = i)} \quad (\text{全概率公式}) \\ &= \sum_{k \in S} \frac{\Pr(X_{m+n} = j, X_m = k, X_0 = i)}{\Pr(X_0 = i)} \cdot \frac{\Pr(X_m = k, X_0 = i)}{\Pr(X_m = k, X_0 = i)} \\ &= \sum_{k \in S} \Pr(X_{m+n} = j | X_m = k, X_0 = i) \Pr(X_m = k | X_0 = i) \\ &= \sum_{k \in S} p_{kj}^{(n)} \cdot p_{ik}^{(m)} \\ &= \sum_{k \in S} p_{ik}^{(m)} p_{kj}^{(n)}. \end{aligned}$$

(2) 是 (1) 的矩阵形式, 利用矩阵乘法易得

推论 5.1.1

对于正整数 $n, m, k, n_1, n_2, \dots, n_k$ 和状态 i, j, l , 总有

$$\begin{aligned} (1) p_{ij}^{(n+m)} &\geq p_{il}^{(n)} p_{lj}^{(m)}; \\ (2) p_{ii}^{(n+k+m)} &\geq p_{ij}^{(n)} p_{jl}^{(k)} p_{li}^{(m)}; \\ (3) p_{ii}^{(n_1+n_2+\dots+n_k)} &\geq p_{ii}^{(n_1)} p_{ii}^{(n_2)} \dots p_{ii}^{(n_k)}; \\ (4) p_{ii}^{(nk)} &\geq (p_{ii}^{(n)})^k. \end{aligned}$$

例 5.1.5

设例 (赌徒的破产或称带吸收壁的随机游动) 中, $n = 3, p = q = \frac{1}{2}$. 赌博者从 2 元赌金开始赌博, 求解他经过 4 次赌博之后输光的概率解: 记 $p_{ij} = \Pr(X_{n+1} = j | X_n = i)$, 则对 $0 < i < 3$,

$p_{i,i-1} = p_{i,i+1} = \frac{1}{2}$; 对 $p_{0,0} = 1, p_{3,3} = 1$. 转移概率矩阵为

$$P = \begin{pmatrix} 1 & 0 & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 1 \end{pmatrix}.$$

依题意, $X_0 = 2$, 求 $p_{20}^{(4)}$. 这只要要求 P^4 的第 3 行第 1 列元素. 手工计算, 可以计算 P^2 再计算 $(P^2)^2$. 如果不要结果用有理数表示, 可以用如下 R 程序:

```
1 P <- rbind(  
2   c(1,0,0,0),  
3   c(0.5, 0, 0.5, 0),  
4   c(0, 0.5, 0, 0.5),  
5   c(0,0,0,1)  
6 )  
7 P4 <- P %**% P %**% P %**% P; P4
```

定理 5.1.2

设时齐马氏链 $\{X_n, n \geq 0\}$ 的状态转移矩阵为 P, X_0 的分布为 $\Pr(X_0 = j) = p_j, j \in S$, 则 $\{X_n\}$ 有限维分布完全被 $\{p_j\}$ 和 P 决定, 有

$$\Pr(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) = p_{i_0} p_{i_0 i_1} p_{i_1 i_2} \cdots p_{i_{n-1} i_n}.$$

Proof. 对时刻 $(0, 1, \dots, n)$, 由概率的乘法公式和马氏性有

$$\begin{aligned} & \Pr(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) \\ &= \Pr(X_n = i_n | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \cdots \Pr(X_1 = i_1 | X_0 = i_0) \Pr(X_0 = i_0) \\ &= p_{i_0} p_{i_0 i_1} p_{i_1 i_2} \cdots p_{i_{n-1} i_n}, \end{aligned}$$

仅依赖于初始分布和转移概率矩阵.

推论 5.1.2

设马氏链中 X_0 分布列为 $\pi_0 = (p_0, p_1, \dots)$, 则 X_n 的分布列为

$$\pi_n = \pi_0 P^n.$$

Proof.

$$\begin{aligned} \Pr(X_1 = j) &= \sum_{i \in S} \Pr(X_1 = j | X_0 = i) \Pr(X_0 = i) \\ &= \sum_{i \in S} p_i p_{ij}, \end{aligned}$$

记 π_1 表示 X_1 概率分布列, 可以写成

$$\pi_1 = \pi_0 P.$$

同理

$$\pi_n = \pi_{n-1} P.$$

于是递推可得结论.

例 5.1.6

(广告效益的推算)

某种啤酒 A 的广告改变了广告方式, 经调查发现买 A 种啤酒及另外三种啤酒 B, C, D 的顾客每两个月的平均转换率如下 (设市场中只有这四种啤酒):

$$\begin{array}{llll} A & \rightarrow & A(0.95) & B(0.02) & C(0.02) & D(0.01) \\ B & \rightarrow & A(0.30) & B(0.60) & C(0.06) & D(0.04) \\ C & \rightarrow & A(0.02) & B(0.01) & C(0.07) & D(0.00) \\ D & \rightarrow & A(0.20) & B(0.20) & C(0.10) & D(0.50) \end{array}$$

假设目前购买 A, B, C, D 四种啤酒的顾客的分布为 (25%, 30%, 35%, 10%), 试求半年后啤酒 A 的市场份额.

Solution. 令 P 为转移矩阵, 则显然有

$$P = \begin{pmatrix} 0.95 & 0.02 & 0.02 & 0.01 \\ 0.30 & 0.60 & 0.06 & 0.04 \\ 0.20 & 0.10 & 0.70 & 0.00 \\ 0.20 & 0.20 & 0.10 & 0.50 \end{pmatrix}$$

令

$$\mu = (\mu_1, \mu_2, \mu_3, \mu_4) = (0.25, 0.30, 0.35, 0.10),$$

计算经过半年后顾客在这四种啤酒上的转移概率 P^3 ,

$$P^2 = \begin{pmatrix} 0.9145 & 0.035 & 0.0352 & 0.0153 \\ 0.485 & 0.38 & 0.088 & 0.047 \\ 0.36 & 0.134 & 0.5 & 0.006 \\ 0.37 & 0.234 & 0.136 & 0.26 \end{pmatrix},$$

$$P^3 = \begin{pmatrix} 0.8894 & 0.0458 & 0.0466 & 0.01820 \\ 0.60175 & 0.2559 & 0.0988 & 0.04355 \\ 0.4834 & 0.1388 & 0.36584 & 0.01196 \\ 0.5009 & 0.2134 & 0.14264 & 0.14306 \end{pmatrix}.$$

我们关心啤酒 A 半年后的市场占有率, 即从 A, B, C, D 四种啤酒经 3 次转移后转到 A 的概率,

求得 A 的市场占有率变为

$$\begin{aligned}\Pr(X_3 = 1) &= \sum_{i=1}^4 \Pr(X_3 = 1 | X_0 = i) \Pr(X_0 = i) \\ &= (0.25, 0.3, 0.35, 0.10) \begin{pmatrix} 0.8894 \\ 0.60175 \\ 0.4834 \\ 0.5009 \end{pmatrix} \approx 0.624\end{aligned}$$

可见啤酒 A 的市场份额由原来的 25% 增至 62.4%, 新的广告方式很有效.

5.2 状态的分类及性质

本节我们首先来讨论一下马氏链各个状态之间的关系, 并以这些关系将状态分类, 最后来研究它们的性质.

定义 5.2.1

称状态 i 可达状态 $j (i, j \in S)$, 若存在 $n \geq 0$ 使得 $p_{ij}^{(n)} > 0$, 记为 $i \rightarrow j$. 若同时有 $j \rightarrow i$, 则称 i 与 j 互通, 记为 $i \leftrightarrow j$.

注: 定义中之所以用 $n \geq 0$ 而不是 $n > 0$, 是为了包含 $i = j$ 时 $p_{ii}^{(0)} = 1 > 0$ 的情况, 从而状态 i 与自身是互通的.

定理 5.2.1

互通是一种等价关系, 即满足:

1. 自返性: $i \leftrightarrow i$;
2. 对称性: $i \leftrightarrow j$, 则 $j \leftrightarrow i$;
3. 传递性: $i \leftrightarrow j, j \leftrightarrow k$, 则 $i \leftrightarrow k$.

Proof. 从互通的定义可知 1、2 是显然的, 只证 3. 由互通定义可知需证 $i \rightarrow k$ 且 $k \rightarrow j$. 首先, 由 $i \rightarrow j, j \rightarrow k$ 知道存在 $m, n \geq 0$, 使得 $p_{ij}^{(m)} > 0, p_{jk}^{(n)} > 0$. 再由 C-K 方程知道

$$p_{ik}^{(m+n)} = \sum_{l \in S} p_{il}^{(m)} p_{lk}^{(n)} \geq p_{ij}^{(m)} p_{jk}^{(n)} > 0,$$

故 $i \rightarrow k$. 同理可证 $k \rightarrow i$, 即有 $i \leftrightarrow k$.

我们把任何两个互通状态归为一类, 由上述定理可知, 同在一类的状态应该都是互通的, 并且任何一个状态不能同时属于两个不同的类.

定义 5.2.2

若马氏链只存在一个类, 就称它是不可约的 (irreducible); 否则称为可约的 (reducible).

定义 5.2.3

若集合 $\{n : n \geq 1, p_{ii}^{(n)} > 0\}$ 非空, 则称它的最大公约数 $d = d(i)$ 为状态 i 的周期.

若 $d > 1$, 称 i 是周期的; 若 $d = 1$, 称 i 是非周期的. 并特别规定上述集合为空集时, 称 i 的周期为无穷大.

注 1: 周期无穷大的状态 i , 是在这个状态下步必然离开而且永不返回的状态, 是吸收态的一个反面.

注 2: 由定义 5.8 知道, 即使 i 有周期 d , 但并不是对所有的 $n, p_{ii}^{(nd)} > 0$. 例如, 设集合 $\{n : n \geq 1, p_{ii}^{(n)} > 0\}$ 为 $\{3, 9, 18, 21, \dots\}$, 则最大公约数 $d = 3$, 即 3 是 i 的周期, 显然, $n = 6, 12, 15$ 都不属于此集合, 即 $p_{ii}^{(6)} = 0, p_{ii}^{(12)} = 0, p_{ii}^{(15)} = 0$. 类似地, 若非周期, 即 $d = 1$, 也不一定有 $p_{ii} > 0$, 如果 $p_{ii} = 0, p_{ii}^{(2)} > 0, p_{ii}^{(3)} > 0$, 则最大公约数也是 1. 但是可以证明, 当 n 充分大之后一定有 $p_{ii}^{(dn)} > 0$.

定理 5.2.2

若状态 i, j 同属一类, 则 $d(i) = d(j)$.

Proof. 由类的定义知 $i \leftrightarrow j$, 即存在 $m, n \geq 0$, 使 $p_{ij}^{(m)} > 0, p_{ji}^{(n)} > 0$, 则

$$p_{ii}^{(m+n)} = \sum_{k \in S} p_{ik}^{(m)} p_{ki}^{(n)} \geq p_{ij}^{(m)} p_{ji}^{(n)} > 0.$$

对所有使得 $p_{jj}^{(s)} > 0$ 的 s , 有 $p_{ii}^{(n+s+m)} \geq p_{ij}^{(m)} p_{jj}^{(s)} p_{ji}^{(n)} > 0$. 显然 $d(i)$ 应同时整除 $n+m$ 和 $n+m+s$, 贝它必定整除 s . 而 $d(j)$ 是 j 的周期, 所以也有 $d(i)$ 整除 $d(j)$. 反过来也可证明 $d(j)$ 整除 $d(i)$, 于是 $d(i) = d(j)$.

定义 5.2.4 首达概率

对于任何状态 i, j , 以 $f_{ij}^{(n)}$ 记从 i 出发经 n 步后首次到达 j 的概率, 记

$$f_{ij}^{(n)} = \Pr(X_n = j, X_k \neq j, k = 1, 2, \dots, n-1 | X_0 = i), n \geq 1,$$

$$f_{ij}^{(0)} = \delta_{i-j} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

令

$$f_{ij} = \sum_{n=1}^{\infty} f_{ij}^{(n)},$$

注: f_{ij} 是从 i 出发经过有限步可达状态 j 的概率. $i \rightarrow j$ 当且仅当 $f_{ij} > 0$.

定义 5.2.5 常返状态

若 $f_{jj} = 1$, 称状态 j 为常返状态 (recurrent); 若 $f_{jj} < 1$, 称状态 j 为非常返状态或瞬过状态.

注: 对常返状态 i , 从 i 出发以概率 1 在有限步内回到状态 i .

注: 对非常返状态 i , 有概率 $p = 1 - f_{ii} > 0$ 使得从 i 出发不再返回 i . 每次回到 i 后从 i 出发看成一个 Bernoulli 试验, 不返回视作成功, 返回视作失败, 记 Y 为这样的试验的次数, 则 Y 服从几何分布, 是取有限值的随机变量, 而每次这样的试验, 在成功 (一去不返) 前, 都是有限次状态转移, 所以从瞬态 i 出发在有限次状态转移之后必定一去不返.

对于常返状态 i , 令 T 表示从 i 出发首次返回 i 的时间, 即 $X_0 = i$ 条件下

$$T = \inf\{n \geq 1 : X_n = i\},$$

则 T 为一个取有限值的随机变量, $\Pr(T = n) = f_{ii}^{(n)}, n = 1, 2, \dots$, 期望值为

$$\mu_i = \mathbb{E}[T] = \sum_{n=1}^{\infty} n f_{ii}^{(n)},$$

即 μ_i 表示的是由 i 出发再返回到 i 所需的平均步数 (时间).

定义 5.2.6 正常返状态

对于常返状态 i , 若 $\mu_i < \infty$, 则称 i 为正常返状态; 若 $\mu_i = +\infty$, 则称 i 为零常返状态. 特别地, 若 i 为正常返状态, 且是非周期的, 则称之为遍历状态.

显然对于吸收态, $f_{ii}^{(1)} = p_{ii} = 1, f_{ii}^{(n)} = 0 (n \geq 2), f_{ii} = 1$, 有 $\mu_i = 1$, 是正常返状态.

例 5.2.1

设马氏链的状态空间为 $S = \{1, 2, 3, 4\}$, 其一步转移概率矩阵为

$$P = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & \frac{1}{3} & \frac{2}{3} & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \end{pmatrix}$$

试将状态进行分类.

Solution. 解: 由一步转移概率矩阵 P , 对一切 $n \geq 1, f_{44}^{(n)} = 0$, 从而

$$f_{44} = \sum_{n=1}^{\infty} f_{44}^{(n)} = 0 < 1,$$

故状态 4 是非常返态. 这就是周期等于正无穷的情况: 从状态 4 出发以概率 1 不再返回.

又

$$f_{33}^{(1)} = \frac{2}{3},$$

$$f_{33}^{(n)} = 0 (n \geq 2),$$

$$f_{33} = \sum_{n=1}^{\infty} f_{33}^{(n)} = \frac{2}{3} < 1,$$

故状态 3 是非常返态.

但状态 1 与 2 是常返态, 因为

$$f_{11} = f_{11}^{(1)} + f_{11}^{(2)} = \frac{1}{2} + \frac{1}{2} = 1,$$

$$f_{22} = \sum_{n=1}^{\infty} f_{22}^{(n)} = 0 + \frac{1}{2} + \frac{1}{2^2} + \frac{1}{2^3} + \cdots = 1.$$

事实上, 从状态 1 出发, 以概率 $\frac{1}{2}$ 在第一步回到 1, 以概率 $\frac{1}{2}$ 先去状态 2 然后从状态 2 在第二步返回状态 1. 从状态 2 出发, 必然在第一步去状态 1, 但从状态 1 又可以以概率 $\frac{1}{2}$ 在第二步回到状态 2, 也可能以概率 $(\frac{1}{2})^{n-2} \cdot \frac{1}{2}$ 在状态 1 停留 $n-2$ 步后才返回状态 2, 这样, $f_{22}^{(1)} = 0, f_{22}^{(2)} = \frac{1}{2}, f_{22}^{(n)} = (\frac{1}{2})^{n-1}$. 计算得

$$\mu_1 = \sum_{n=1}^{\infty} n f_{11}^{(n)} = 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{2} = \frac{3}{2} < \infty,$$

$$\mu_2 = \sum_{n=1}^{\infty} n f_{22}^{(n)} = 1 \cdot 0 + 2 \cdot \frac{1}{2} + 3 \cdot \frac{1}{2^2} + \cdots + n \cdot \frac{1}{2^{n-1}} = 3 < \infty,$$

故状态 1 与 2 都是正常返状态, 又因其周期都是 1, 故它们都是遍历态.

计算中用了

$$\sum_{n=2}^{\infty} n x^{n-1} = \frac{d}{dx} \sum_{n=2}^{\infty} x^n = \frac{d}{dx} x^2 \sum_{n=0}^{\infty} x^n = \frac{d}{dx} \frac{x^2}{1-x} = \frac{x(2-x)}{(1-x)^2}.$$

引理 5.2.1

对任意状态 i, j 及 $1 \leq n < \infty$, 有

$$p_{ij}^{(n)} = \sum_{l=1}^n f_{ij}^{(l)} p_{jj}^{(n-l)}.$$

Proof. 令

$$\begin{aligned} p_{ij}^{(n)} &= \Pr(X_n = j | X_0 = i) \\ &= P\left(\bigcup_{l=1}^n \{X_k \neq j, 1 \leq k \leq l-1, X_l = j, X_n = j\} | X_0 = i\right) \\ &= \sum_{l=1}^n P(X_k \neq j, 1 \leq k \leq l-1, X_l = j, X_n = j | X_0 = i) \\ &= \sum_{l=1}^n P(X_k \neq j, 1 \leq k \leq l-1, X_l = j | X_0 = i) \\ &\quad \Pr(X_n = j | X_k \neq j, 1 \leq k \leq l-1, X_l = j, X_0 = i) \\ &= \sum_{l=1}^n f_{ij}^{(l)} \Pr(X_n = j | X_l = j) \quad (\text{利用马氏性}) \\ &= \sum_{l=1}^n f_{ij}^{(l)} p_{jj}^{(n-l)}. \end{aligned}$$

以下我们首先引入常返性的另一个判定方法.

定理 5.2.3

状态 i 为常返的当且仅当 $\sum_{n=0}^{\infty} p_{ii}^{(n)} = \infty$; 状态 i 为非常返的当且仅当 $\sum_{n=0}^{\infty} p_{ii}^{(n)} < \infty$, 且这时有

$$\sum_{n=0}^{\infty} p_{ii}^{(n)} = \frac{1}{1 - f_{ii}}.$$

Proof. 常返时, $f_{ii} = 1$, 每次从 i 出发必然在有限步回到 i , 然后重新开始, 以回到 i 作为一次更新, 这是更新过程, 于是从 $X_0 = i$ 出发系统有无穷多次处于状态 i . 用 I_n 表示 $X_n = i$, 则常返时

$$\Pr\left(\sum_{n=1}^{\infty} I_n = +\infty | X_0 = i\right) = 1,$$

于是

$$\mathbb{E}\left[\sum_{n=1}^{\infty} I_n | X_0 = i\right] = +\infty,$$

但

$$\mathbb{E}\left[\sum_{n=1}^{\infty} I_n | X_0 = i\right] = \sum_{n=1}^{\infty} \mathbb{E}[I_n | X_0 = i] = \sum_{n=1}^{\infty} \Pr(X_n = i | X_0 = i) = \sum_{n=1}^{\infty} p_{ii}^{(n)},$$

所以常返时 $\sum_{n=1}^{\infty} p_{ii}^{(n)} = +\infty$.

Part V

回归分析

Part VI

时间序列分析

Part VII

广义回归分析

Part VIII

寿险精算学

Part IX

生物统计与生存分析

Chapter 1

Clinical Trial

1.1 Definitions

定义 1.1.1 Randomisation 随机化

Patients are randomly allocated to the treatments.
患者被随机分配到治疗中。

定义 1.1.2 Double-blind 双盲

None of the patient, the investigator or the medical team know which treatment is being given to the patient.
患者、调查员或医疗团队都不知道正在给患者进行哪种治疗。

定义 1.1.3 Placebo-controlled 安慰剂对照

One of the groups is receiving a placebo – a “treatment” identical in all ways to the main treatment other than the active ingredient. A placebo has no active ingredient.
一组正在接受安慰剂 – 一种除了活性成分外, 在所有方面都与主要治疗相同的“治疗”。安慰剂没有活性成分。

定义 1.1.4 Four main stages to the design of clinical trials 临床试验设计的四个主要阶段

Phase I – **Clinical Pharmacology and Toxicity**

– 临床药理学与毒理学

These are primarily concerned with drug safety, and are performed on healthy human volunteers (not patients). Dosing (剂量) schedules are also established.
这些主要关注药物安全性, 并在健康的人类志愿者（而非患者）身上进行。还建立了剂量安排。

Phase II – **Initial Clinical Investigation for Treatment Effect**

– 初始治疗疗效的临床研究

These are small scale studies in patients, looking at the effectiveness and safety of the drug. Is there any evidence that the drug actually works and is non-toxic (无毒的)? It is becoming increasingly common for phase II trials to be randomised, but in the (fairly recent) past they were generally uncontrolled (i.e. no control group).

这些是在患者中进行的小规模研究，观察药物的有效性和安全性。有证据表明该药物实际上有效且无毒吗？在 II 期临床试验中随机化变得越来越普遍，但在（相对较近的）过去，它们通常是未控制的（即没有对照组）。

Phase III – Full Scale Evaluation of Treatment

– 全面评估治疗方案

After a drug is shown to be reasonably effective and worthy of a full scale investigation, it is essential to compare it with current standard treatments for the same disease (or with a placebo) in a randomised controlled trial.

在一种药物被证明具有合理有效性和值得进行全面调查之后，将其与当前同种疾病的常规治疗方法（或安慰剂）进行随机对照试验比较是至关重要的。

Phase IV – Post-marketing Surveillance

– 上市后监测

If a drug is approved for marketing, its performance is still closely monitored for evidence of side effects (副作用) and to obtain more information about its long-term effectiveness. It is still possible for treatments to be withdrawn (撤回) at this stage if they produce serious side effects which are too rare to be detected (检测) in a phase III trial, and only become apparent when data are available for large numbers of treated patients.

如果一种药物获得市场批准，其性能仍会密切监控以获取关于其副作用证据以及更多关于其长期有效性的信息。如果治疗在此阶段产生严重副作用，而这些副作用在 III 期临床试验中难以检测到，只有在大量治疗患者的数据可用时才会显现，那么此时仍有可能撤回治疗。

定义 1.1.5 Meta-analysis and its main objectives 荟萃分析及其主要目标

Meta-analysis is the process of applying statistical methods to the problem of combining results from different clinical trial of the same treatment. Meta 分析是将统计方法应用于将同一治疗方法的不同临床试验结果相结合的问题的过程。

It has four main objectives:

- consistent, objective display of data from different clinical trials; 一致、客观地展示来自不同临床试验的数据;
- testing an overall hypothesis; 测试一个总体假设;
- estimation of an average treatment effect; 平均治疗效果的估计;
- investigation of statistical heterogeneity between trials. 试验间统计异质性的研究.


定义 1.1.6 Publication bias 发表偏差

It is widely recognised that clinical trials reporting large and significant treatment effects are more likely to be published in medical journals than trials with smaller, non-significant differences. 广泛认为，报告大型和显著治疗效果的临床试验比报告较小、非显著差异的试验更有可能发表在医学期刊上。Evidence of asymmetry in the funnel plots would suggest publication bias. 漏斗图中的不对称性证据表明存在发表偏倚。

例 1.1.1 via. 2023.Q1(d)-iii, 2022.Q3(c)

When there is evidence of funnel plot asymmetry regarding the published studies, publication bias is only one possible explanation.

当存在关于已发表研究的漏斗图不对称的证据时，发表偏差惟一可能的解释。



1.2 Hypothesis Test

	Reject H_0	Fail to reject H_0
H_0 真	Type 1 error: α	$1 - \alpha$
H_1 真	$1 - \beta$	Type 2 error: β

- Significance level (显著性水平): Type 1 error, 本来 H_0 是真的但是被拒绝, i.e.

$$\Pr(\text{Reject } H_0 \mid H_0 \text{ is true}) = \alpha.$$

- Power (功效): H_0 被正确拒绝, i.e.

$$\Pr(\text{Reject } H_0 \mid H_1 \text{ is true}) = 1 - \beta.$$

1.3 Sample Sizes Calculations

定理 1.3.1 临床试验所需患者数量计算

假设有两种治疗方案: A – Placebo (安慰剂); B – 喂药.

记 θ_A 和 θ_B 分别为服用 Placebo 和 临床试验药品 的患者在 1 年内死亡的概率. 我们希望测试的假设 (hypothesis) 是

$$H_0 : \theta_A = \theta_B \quad \text{vs.} \quad H_1 : \theta_A \neq \theta_B$$

with significant level of α and power of $1 - \beta$. 假设临床差异 (clinical difference) $\delta = \theta_A - \theta_B \sim \mathcal{N}$. 因此, 正态近似的患者数量为

$$N = \frac{\theta_A(1 - \theta_A) + \theta_B(1 - \theta_B)}{(\theta_A - \theta_B)^2} \left[\Phi^{-1} \left(1 - \frac{\alpha}{2} \right) + \Phi^{-1}(1 - \beta) \right]^2.$$

切记: 在这里, 我们希望拒绝 H_0 , 那么 power $1 - \beta$ 表明的是“药是有效的, 并被成功识别的概率”. 那么, if the power $1 - \beta$ decreases, N will decrease.

【A lower power means that we need a lower probability to detect a difference in the treatment effect (if an effect is there). That can be achieved with a smaller number of patients in each group, which corresponds to recruiting less patients. 较低的 power 意味着我们需要更低的概率来检测治疗效果中的差异 (如果存在效果)。这可以通过每组更少的患者数量来实现, 这对应于招募较少的患者。】

Proof. 假设有 $2N$ 个患者, 两个方案各有 N 个患者, 并设 (X_A, X_B) 为死亡患者数量, 因此有

$$X_i \sim \text{Binomial}(N, \theta_i).$$

若 N 足够大, 则可近似为正态分布, 即

$$X_i \sim \mathcal{N}(N\theta_i, N\theta_i(1 - \theta_i)).$$

记死亡率 $\hat{\theta}_i = \frac{X_i}{N}$, 那么 $\hat{\theta}_i \sim \mathcal{N}\left(\theta_i, \frac{\theta_i(1 - \theta_i)}{N}\right)$, 因此

$$\hat{\theta}_A - \hat{\theta}_B \sim \mathcal{N}\left(\delta = \theta_A - \theta_B, \frac{\theta_A(1 - \theta_A) + \theta_B(1 - \theta_B)}{N}\right).$$

我们希望 $\delta > 0$, 即不吃药的死的多, 根据 t 检验, 得到统计量

$$T = \frac{(\hat{\theta}_A - \hat{\theta}_B) - \delta}{\sqrt{\frac{\theta_A(1 - \theta_A) + \theta_B(1 - \theta_B)}{N}}} \xrightarrow{H_0: \delta=0} \frac{\hat{\theta}_A - \hat{\theta}_B}{\sqrt{\frac{\theta_A(1 - \theta_A) + \theta_B(1 - \theta_B)}{N}}} \sim \mathcal{N}(0, 1)$$

由于

$$\Pr(\text{Reject } H_0 \text{ at significance level } \alpha \mid \text{true difference is } \delta) = 1 - \beta,$$

which corresponds to $\Pr\left(|T| > \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)\right) = 1 - \beta$. 证明就到这里吧, 后面也没啥玩意了.

定理 1.3.2 临床试验所需患者数量计算

For continue response: two treatment have mean responses (μ_A, μ_B) , common std σ . Using a similar argument as before:

$$N = \frac{2\sigma^2}{(\mu_A - \mu_B)^2} \left[\Phi^{-1} \left(1 - \frac{\alpha}{2} \right) + \Phi^{-1} (1 - \beta) \right]^2.$$

特别地: 实践中未必有足够患者进行试验.

- **Reason:** Patients are likely withdraw from the trial.
- **Solution:** Estimate the likely withdraw rate from similar existing studies and scale up the sample size appropriately to account for this.

1.4 Meta-Analysis

即, 将多个研究结果进行统计分析的组合.

1.4.1 Main statistical objectives

- | | |
|---|-------------------------|
| 1. consistent and objective display of data from different clinical trials; | 1. 一致且客观地展示来自不同临床试验的数据; |
| 2. testing an overall hypothesis; | 2. 测试总体假设; |
| 3. estimation of an average treatment effect; | 3. 估计平均治疗效果; |
| 4. investigation of statistical heterogeneity between trials. | 4. 调查试验之间的统计异质性。 |

1.4.2 Binary response variables: Death (Failure) / Survival (Success)

Odd Ratio (OR, 比值比)

$$\begin{aligned} \Rightarrow \text{OR} &= \frac{\text{odd of failure on treatment}}{\text{odd of failure on control}} = \frac{a/b}{c/d} = \frac{ad}{bc} \\ \Rightarrow \log(\text{OR}) &= \log\left(\frac{ad}{bc}\right) = \log a - \log b - \log c + \log d. \\ \Rightarrow \text{Var}[\log(\text{OR})] &= \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d} \end{aligned}$$

	Failure	Success
Treatment	a	b
Control	c	d

Proof. Recall the Taylor expansion:

$$g(X) = g(\mu) + (X - \mu)g'(\mu) + \frac{(X - \mu)^2}{2}g''(\mu) + \dots,$$

then

$$\text{Var}[g(X)] \approx [g'(\mu)]^2 \cdot \text{Var}[X] = \left(\frac{dg(X)}{dX} \right)^2 \cdot \text{Var}[X],$$

therefore

$$\text{Var}[\log a] = \left(\frac{1}{a}\right)^2 \times a = \frac{1}{a}, \quad \left(X \sim \text{Binomial}(n, p) \xrightarrow{n \rightarrow \infty} \text{Poisson}(\lambda = np)\right).$$

例 1.4.1 via 2023.Q1(d)-iii

Table following was presented in a report of a meta-analysis of five trials of a new treatment for chronic kidney disease (CKD). Interpret the results in the table for each of the five studies as well as the result from all studies combined. What reservations, if any, may you attach to your interpretation? 请解释表中每个五项研究的成果以及所有研究合并的结果. 您对您的解释有何保留意见?

Study	Odd ratio (treatment/control)	95% Confidence Interval
1	0.42	0.15 to 1.08
2	0.33	0.07 to 1.98
3	0.59	0.29 to 1.01
4	0.41	0.18 to 1.23
5	0.25	0.03 to 0.88
All studies	0.44	0.41 to 0.82

Solution. Interpretation:

- In Table 1 the combined odds ratio is 0.44, so that the odds of death in the treated group is 0.44 times (around half) that of the control group.
- The confidence interval does not contain 1, so that the treatment is significantly better than the control.
- Note also that the confidence interval is still quite wide, so that the treatment effect is still not very precisely estimated. 请注意, 置信区间仍然相当宽, 因此治疗效果仍然没有非常精确地估计。

Reservations:

- No information/detail is provided about the individual trials.
- Were they all randomised, double blind, adequately controlled?
- Were patient selection criteria similar? Were the study protocols (方案) in general similar?
- How were the five studies selected – is there a possibility of bias in the selection of studies (such as publication bias)?

1.4.3 Meta-analytic models

假设有 C 次试验, 我们希望将这些试验的结果结合起来.

Notion

- $\hat{Y}_c$ – the continuous effect size in the c th trial, 如: $\log(\text{OR})$, 其中 $c = 1, 2, \dots, C$.
- W_c – the reciprocal (倒数) of the effect size variance, i.e., $W_c = \frac{1}{\text{Var}[\hat{Y}_c]}$. 作为权重意义出现, 方差越大权重越小.

1.4.3.1 Fix effect approach

固定效应方法: 假设存在一个单一的真实效应量 (μ , true effect size, unknown), 每个 C 试验都估计了这个效应量, 从而得到简单模型

$$\hat{Y}_c \sim \mathcal{N}\left(\mu, \frac{1}{W_c}\right), \text{ for } c = 1, 2, \dots, C$$

(i) Then maximum likelihood estimation yields the estimator:

$$\hat{\mu}_{\text{FE}} = \frac{\sum_{c=1}^C W_c \hat{Y}_c}{\sum_{c=1}^C W_c}.$$

Proof. 有空再写, 反正就是 MLE. 然后还是 unbiased 的.

(ii) The variance of $\hat{\mu}_{\text{FE}}$ is $\text{Var}[\hat{\mu}_{\text{FE}}] = \frac{1}{\sum_{c=1}^C W_c}$, which yields the sampling distribution:

$$\hat{\mu}_{\text{FE}} = \frac{\sum_{c=1}^C W_c \hat{Y}_c}{\sum_{c=1}^C W_c} \sim \mathcal{N}\left(\mu, \frac{1}{\sum_{c=1}^C W_c}\right).$$

Proof. $\text{Var}[\hat{\mu}_{\text{FE}}] = \text{Var}\left[\frac{\sum_{c=1}^C W_c \hat{Y}_c}{\sum_{c=1}^C W_c}\right] = \frac{\sum_{c=1}^C W_c^2 \text{Var}[\hat{Y}_c]}{\left(\sum_{c=1}^C W_c\right)^2} = \frac{\sum_{c=1}^C W_c^2 \cdot (1/W_c)}{\left(\sum_{c=1}^C W_c\right)^2} = \frac{1}{\sum_{c=1}^C W_c}.$

(iii) A 95% confidence interval for the population effect μ is then given by

$$\hat{\mu}_{\text{FE}} \pm 1.96 \sqrt{\text{Var}[\hat{\mu}_{\text{FE}}]}.$$

(iv) Hypothesis test: $H_0 : \mu = 0$ vs. $H_1 : \mu \neq 0$. The test statistic in this case under H_0 is given by

$$Z = \frac{\hat{\mu}_{\text{FE}}}{\sqrt{\text{Var}[\hat{\mu}_{\text{FE}}]}} \sim \mathcal{N}(0, 1) \text{ under } H_0.$$

This test statistic can then be compared against the appropriate percentiles of a standard normal distribution, which would be $[-1.96, 1.96]$ for a 5% significance level.

1.4.3.2 Random effect approach

随机效应方法: 假设存在每个试验都有各自的真实效应量 (μ_c), 从而有

$$\hat{Y}_c \sim \mathcal{N}\left(\mu_c, \frac{1}{W_c}\right), \text{ for } c = 1, 2, \dots, C, \quad \mu_c \sim \mathcal{N}(\mu, \tau^2).$$

This model thus partitions the variation in the data into two sources: (i) within trial uncertainty in the estimated effect captured by $\frac{1}{W_c}$; and (ii) between trial variation in the true effect sizes captured by τ^2 . The model can be simplified to

$$\hat{Y}_c \sim \mathcal{N}\left(\mu, \frac{1}{W_c} + \tau^2\right), \text{ for } c = 1, 2, \dots, C.$$

so the two parameters to be estimated are the overall effect size μ and the between trial heterogeneity τ^2 . Then the maximum likelihood estimator of μ conditional on τ^2 is given by

$$\hat{\mu}_{\text{RE}} = \frac{\sum_{c=1}^C \frac{1}{\frac{1}{W_c} + \tau^2} \hat{Y}_c}{\sum_{c=1}^C \frac{1}{\frac{1}{W_c} + \tau^2}}.$$

在随机效应模型中, 估计 $\tau_c^2 = \max\left(0, \frac{Q - (C - 1)}{S_1 - \frac{S_1}{S_2}}\right)$,

其中统计量 Q 用来衡量不同试验效果之间的差异 $Q = \sum_{c=1}^C W_c \left(\hat{Y}_c - \hat{\mu}_{\text{FE}}\right)^2$, $(C - 1)$ 为自由度.

S_1 与 S_2 指权重和与权重平方和, 即 $S_1 = \sum_{c=1}^C W_c$, $S_2 = \sum_{c=1}^C W_c^2$, 用来调整 Q 值, 已获得更稳健的 τ_c^2 估计.

Chapter 2

Epidemiology

2.1 Definitions

2.2 Sensitivity (敏感度) & Specificity (特异性)

以下, 红色为患者实际有病 (阳性), 蓝色为患者实际没病 (阴性).

$$\left. \begin{aligned} \text{Sensitivity} &= \frac{\text{Number of diseased people who screen positive}}{\text{Total number of diseased people}} \quad (\text{有病的人显阳性}) \\ \text{Specificity} &= \frac{\text{Number of diseased people who screen negative}}{\text{Total number of healthy people}} \quad (\text{没病的人显阴性}) \end{aligned} \right\} \text{显示的都是准确性}$$

这些统计量的反面是:

$$\text{False negative rate (FNR)} = \frac{\text{Number of diseased people who screen negative}}{\text{Total number of diseased people}} = 1 - \text{Sensitivity} \quad (\text{误诊为阴性})$$

$$\text{False positive rate (FPR)} = \frac{\text{Number of diseased people who screen positive}}{\text{Total number of healthy people}} = 1 - \text{Specificity} \quad (\text{误诊为阳性})$$

例 2.2.1 via 2023.Q3(c)

A new screening test was developed for bronchitis, and a number of patients that potentially had the disease were given the test following a GP consultation. The results are depicted in the contingency table below.

		Disease		
		Yes	No	
Screening Test	Positive	32	29	61
	Negative	14	84	98
		46	113	159

Q. Compute the sensitivity, specificity, false negative rate (FNR) and false positive rate (FPR) from the screening test. Interpret each statistic.

Solution.

$$\text{Sensitivity} = \frac{32}{46} = 0.70.$$

$$\text{Specificity} = \frac{84}{113} = 0.74.$$

$$\text{False negative rate (FNR)} = 1 - 0.70 = 0.30.$$

$$\text{False positive rate (FPR)} = 1 - 0.74 = 0.26.$$

A sensitivity of approximately 0.70 means that 70% of diseased patients are correctly identified as having bronchitis. A false negative rate of approximately 0.30 means that 30% of diseased patients are incorrectly identified as not bronchitis. 约 0.70 的敏感性意味着 70% 的患病患者被正确识别为患有支气管炎. 约 0.30 的假阴性率意味着 30% 的患病患者被错误地识别为非支气管炎.

A specificity of approximately 0.74 means that 74% of healthy patients are correctly identified as not having bronchitis. A false positive rate of approximately 0.26 means that 26% of healthy patients are incorrectly identified as having bronchitis. 约 0.74 的特异性意味着 74% 的健康患者被正确识别为没有支气管炎. 约 0.26 的假阳性率意味着 26% 的健康患者被错误地识别为患有支气管炎.

2.3 Standardisation

2.3.1 Direct standardisation

Notion:

$$\left. \begin{array}{l} y_i \text{ — 研究人群中第 } i \text{ 个年龄组的死亡人数} \\ n_i \text{ — 研究人群中第 } i \text{ 个年龄组的总人数} \end{array} \right\} \text{ study population} \quad \left. \begin{array}{l} N_i \text{ — 参考人群中第 } i \text{ 个年龄组的总人数} \\ \text{— reference population} \end{array} \right\} i = 1, 2, \dots, G \text{ (依据年龄分成 } G \text{ 组)}$$

1. 粗死亡率:

$$\text{crude mortality rate} = \frac{\sum_{i=1}^G n_i}{\sum_{i=1}^G y_i} = \frac{\text{总死亡人数}}{\text{总人数}} \quad (\text{study population})$$

2. 特定年龄组死亡率:

$$\text{Age specific mortality rate for the } i\text{th group} = \frac{y_i}{n_i}$$

3. 特定年龄预期死亡人数:

$$\text{Expected number of mortalities for the } i\text{th group} = \frac{y_i}{n_i} \times N_i$$

4. 年龄标准化死亡率:

$$\text{Age standardised mortality rate (ASMR)} = \frac{\sum_{i=1}^G \frac{y_i}{n_i} \times N_i}{\sum_{i=1}^G N_i}$$

若 $y_i \sim \text{Poisson}(n_i \theta_i)$, 其中 θ_i 是死亡率, 则

$$\hat{\theta}_{i_{\text{MLE}}} = \frac{y_i}{n_i} \Rightarrow \text{Var}[\hat{\theta}_i] = \frac{\theta_i}{n_i} \Rightarrow \text{Var}[\text{ASMR}] = \text{Var}\left[\frac{\sum_{i=1}^G \hat{\theta}_i N_i}{\sum_{i=1}^G N_i}\right] = \frac{\sum_{i=1}^G N_i^2 \frac{\hat{\theta}_i}{n_i}}{\left(\sum_{i=1}^G N_i\right)^2}.$$

此公式可用于根据高斯假设计算基于 ASMR 的 95% 置信区间:

$$\text{ASMR} \pm 1.96 \times \text{Var}[\text{ASMR}].$$

2.3.2 Indirect standardisation

Notion:

$$\left. \begin{array}{l} r_i \text{ — 参考人群中第 } i \text{ 个年龄组的死亡率} \\ E \text{ — 研究人群的预期死亡人数} \Rightarrow E = \sum_{i=1}^G n_i r_i \\ Y \text{ — 研究人群的总死亡人数} \Rightarrow Y = \sum_{i=1}^G y_i \end{array} \right\} \begin{array}{l} \text{reference population} \\ \text{study population} \end{array} \quad \left. \vphantom{\begin{array}{l} r_i \\ E \\ Y \end{array}} \right\} i = 1, 2, \dots, G$$

1. 标准化死亡率 (standardised mortality ratio, SMR):

$$\text{SMR} = \frac{\text{Observed deaths}}{\text{Expected deaths}} = \frac{Y}{E} = \frac{\sum_{i=1}^G y_i}{\sum_{i=1}^G n_i r_i}$$

$$\Rightarrow \left\{ \begin{array}{l} \text{SMR} = 1 \Rightarrow \text{死亡人数与预期相同} \Rightarrow \text{研究和参考人群的死亡率风险相同} \\ \text{SMR} \neq 1 \Rightarrow \text{研究人群中死亡人数超过/低于预期} \end{array} \right.$$

2. 构建简单的泊松模型 $Y = \sum_{i=1}^G y_i \sim \text{Poisson}(ER)$, 其中 $\hat{R}_{\text{MLE}} = \frac{Y}{E}$

$$\text{Var}[\text{SMR}] = \text{Var}\left[\frac{Y}{E}\right] = \frac{\text{Var}[Y]}{E^2} = \frac{ER}{E^2} = \frac{R}{E}.$$

实践中, R 是未知的, 并用 MLE 估计值代替. 因此, 基于正态性, SMR 的大约 95% 置信区间为

$$\text{SMR} = \pm 1.96 \times \sqrt{\frac{Y}{E^2}}.$$

2.4 Measuring the Association between a Risk Factor and Disease

	Disease	No disease	
Risk factor	a	b	$a + b$
No risk factor	c	d	$c + d$
	$a + c$	$b + d$	n

1. 相对风险 (relative risk, RR):

$$\text{RR} = \frac{\text{Pr}(\text{disease in the group with the risk factor})}{\text{Pr}(\text{disease in the group without the risk factor})} = \frac{a/(a+b)}{c/(c+d)} \begin{cases} = 1 & \text{零相对风险 (无差异)} \\ \neq 1 & \text{有风险因素患病风险更高/低} \end{cases}$$

$$\Rightarrow \text{Var}[\log(\text{RR})] = \frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d} \Rightarrow 95\% \text{CI: } \left(\log(\text{RR}) \pm 1.96 \sqrt{\text{Var}[\log(\text{RR})]} \right)$$

2. 比值比 (odd ratio, OR) is similar to 1.4.2,

$$OR = \frac{a/b}{c/d} = \frac{ad}{bc} \Rightarrow \text{Var}[\log(OR)] = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}$$

3. 归因 (相差) 风险度 (attributable risk, AR):

$$\begin{aligned} AR &= \text{Pr}(\text{disease with the risk factor}) - \text{Pr}(\text{disease without the risk factor}) \\ &= \frac{a}{a+b} - \frac{c}{c+d} \stackrel{d}{=} P_1 - P_2 \end{aligned}$$

4. 人口归因风险 (population attributable risk, PAR): 从群体角度, 而非个体 (归因风险因素占总人口比例).

$$PAR = \frac{(a+c) - nP_2}{(a+c)} \quad \begin{array}{l} \leftarrow -nP_2: \text{减去总人数的预期无风险患病人数} \\ \leftarrow (a+c): \text{总患病人数} \end{array}$$

例 2.4.1 via. 2022.Q2(b)

The table below presents the results of a case-control study, which was carried out to investigate the association between smoking and lung cancer.

Smoking (cigarettes smoked/day)	Lung Cancer (Cases)	No Lung Cancer (Controls)
0	48	172
1 – 10	162	272
11 – 20	321	134
21 – 35	111	15
35+	220	20
Total	862	613

The contingency table is:

	Lung Cancer (Cases)	No Lung Cancer (Controls)	Total
Smokers	$A = 814$	$B = 441$	1255
Non Smokers	$C = 48$	$D = 172$	220
Total	862	613	1475

Solution. The **attributable risk** (AR) is:

$$AR = P_1 - P_2 = \frac{A}{A+B} - \frac{C}{C+D} = \frac{814}{1255} - \frac{48}{220} = 0.43.$$

The AR of 0.43 indicates that more than one-third of the lung cancer occurrences were due to the exposure of smoking. 超过三分之一的肺癌发生是由于吸烟暴露引起的。

The **population attributable risk** (PAR) is:

$$PAR = \frac{(A+C) - nP_2}{(A+C)} = \frac{(862) - 1475 \times \frac{48}{220}}{862} = 0.62.$$

The PAR of 0.62 indicates the proportion of the lung cancer occurrences in the population which was attributable to the exposure of smoking. 表示在人群中由于吸烟暴露导致的肺癌发生比例。

2.5 Stratification (分层)

与2.4类似, 只不过分成 G 组, 即 2×2 表格变为

	Disease	No disease	
Risk factor	a_i	b_i	$a_i + b_i$
No risk factor	c_i	d_i	$c_i + d_i$
	$a_i + c_i$	$b_i + d_i$	n_i

$$1. \text{ 第 } i \text{ 组的比值比: } OR_i = \frac{a_i/b_i}{c_i/d_i} = \frac{a_i d_i}{b_i c_i},$$

$$\Rightarrow \text{权重: } w_i = \frac{1}{\text{Var}[\log(OR_i)]} = \frac{1}{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}} \approx \frac{b_i c_i}{n_i}.$$

2. Mantel-Haenszel 方法:

$$OR_{MH} = \frac{\sum_{i=1}^G w_i OR_i}{\sum_{i=1}^G w_i} = \frac{\sum_{i=1}^G \frac{b_i c_i}{n_i} \times \frac{a_i d_i}{b_i c_i}}{\sum_{i=1}^G \frac{b_i c_i}{n_i}} = \frac{\sum_{i=1}^G \frac{a_i d_i}{n_i}}{\sum_{i=1}^G \frac{b_i c_i}{n_i}}$$

$$\Rightarrow \text{Var}[\log(OR_{MH})] = \frac{\sum_{i=1}^G w_i^2 v_i}{\left(\sum_{i=1}^G w_i\right)^2}, \quad \text{where } v_i = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}.$$

例 2.5.1 via 2023.Q3(a)

The table of the lung cancer cases between smokers and non-smokers stratified by age is as following.

Smokes tobacco	Age < 50 years		Age ≥ 50 years	
	with lung cancer	no lung cancer	with lung cancer	no lung cancer
Yes	68	22	43	47
No	23	13	45	66
Total	91	35	88	113

Calculate the odds ratio of developing lung cancer for the group who smoke tobacco compared to the group who do not smoke, unadjusted for age, and construct the corresponding 95% confidence interval. Comment on your results.

Solution. Ignoring the age stratification, the odds ratio of lung cancer is:

$$OR = \frac{a \times d}{b \times c} = \frac{(68 + 43) \times (13 + 66)}{(22 + 47) \times (23 + 45)} = \frac{111 \times 79}{69 \times 68} = 1.87.$$

The variance of the $\log(OR)$ is:

$$\text{Var}[\log(OR)] = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d} = \frac{1}{111} + \frac{1}{69} + \frac{1}{68} + \frac{1}{79} = 0.05.$$

The 95% CI for $\log(\text{OR})$ is:

$$\begin{aligned} & \log(\text{OR}) \pm 1.96 \times \sqrt{\text{Var}[\log(\text{OR})]} \\ & \log(1.87) \pm 1.96 \times \sqrt{0.05} \\ & (0.19, 1.07). \end{aligned}$$

Hence, the 95% CI for the OR is: $(\exp(0.19), \exp(1.07)) = (1.21, 2.92)$.

Interpretation: tobacco smokers have significantly higher odds of lung cancer (on average 87% higher odds) compared to non-smokers as the 95% confidence interval does not contain 1. 吸烟者患肺癌的几率显著高于非吸烟者 (平均高出 87%), 因为 95% 置信区间不包含 1.

Calculate the odds ratios of developing lung cancer for smokers against non-smokers for each group separately, i.e. $\text{age} < 50$ years and $\text{age} \geq 50$ years, and construct the corresponding 95% confidence intervals. Comment on your results and compare them to the results in Q1.

Solution.

- 1 Among patients aged < 50 years, the odds ratio of lung cancer for smokers vs. non-smokers is:

$$\text{OR}_{\text{age} < 50 \text{ years}} = \frac{a \times d}{b \times c} = \frac{68 \times 13}{22 \times 23} = 1.75.$$

The 95% CI for $\log(\text{OR}_{\text{age} < 50 \text{ years}})$ is:

$$\begin{aligned} & \log(\text{OR}_{\text{age} < 50 \text{ years}}) \pm 1.96 \times \sqrt{\text{Var}[\log(\text{OR}_{\text{age} < 50 \text{ years}})]} \\ & \log(1.75) \pm 1.96 \times \sqrt{\frac{1}{68} + \frac{1}{22} + \frac{1}{23} + \frac{1}{13}} \\ & 0.56 \pm 1.96 \times \sqrt{0.18} \\ & (-0.27, 1.39). \end{aligned}$$

The 95% CI for $\text{OR}_{\text{age} < 50 \text{ years}}$ is $(\exp(-0.27), \exp(1.39)) = (0.76, 4.01)$.

Interpretation: Among patients of age < 50 years, smokers have on average 75% times higher odds of lung cancer compared to non-smokers. However, due to variability, the result does not appear significant since the 95% CI includes 1. 在年龄小于 50 岁的患者中, 吸烟者患肺癌的几率比非吸烟者平均高出 75%. 然而, 由于变异性, 结果并不显著, 因为 95% 置信区间包括 1.

- 2 Among patients aged ≥ 50 years, the odds ratio of lung cancer for smokers vs. non-smokers is:

$$\text{OR}_{\text{age} \geq 50 \text{ years}} = \frac{a \times d}{b \times c} = \frac{43 \times 66}{47 \times 45} = 1.34.$$

The 95% CI for $\log(\text{OR}_{\text{age} \geq 50 \text{ years}})$ is:

$$\begin{aligned} & \log(\text{OR}_{\text{age} \geq 50 \text{ years}}) \pm 1.96 \times \sqrt{\text{Var}[\log(\text{OR}_{\text{age} \geq 50 \text{ years}})]} \\ & \log(1.34) \pm 1.96 \times \sqrt{\frac{1}{43} + \frac{1}{47} + \frac{1}{45} + \frac{1}{66}} \\ & 0.29 \pm 1.96 \times \sqrt{0.08} \\ & (-0.26, 0.84). \end{aligned}$$

The 95% CI for $\text{OR}_{\text{age} \geq 50 \text{ years}}$ is $(\exp(-0.26), \exp(0.84)) = (0.77, 2.32)$.

Interpretation: Among patients of age ≥ 50 years, smokers have on average 34% times higher odds of lung cancer compared to non-smokers. However, the result does not appear significant since the 95% CI includes 1. 在年龄不小于 50 岁的患者中, 吸烟者患肺癌的几率比非吸烟者平均高出 34%. 然而, 结果并不显著, 因为 95% 置信区间包括 1.

Comparison to Q1: We observe that: the odds ratios of lung cancer were not statistically significant (95% CIs include 1). The stratified odds ratios differ from the unadjusted (unstratified) odds ratio $\text{OR} = 1.87$ (both being lower). This is an indication that the effect of smoking on developing lung cancer changes when we stratify by age, hence age is a confounder. Therefore, we need to make use of the Mantel-Haenszel odds ratio for a more precise estimate, adjusting for the confounding effect of age. 我们观察到: 肺癌的比值比没有统计学意义 (95% CI 包括 1). 分层比值比与未调整 (未分层) 的比值比 $\text{OR} = 1.87$ (两者都较低) 不同. 这表明, 当按年龄分层时, 吸烟对发展肺癌的影响会发生变化, 因此年龄是一个混杂因素. 因此, 我们需要利用 Mantel-Haenszel 比值比进行更精确的估计, 调整年龄的混杂效应.

Calculate the Mantel-Haenszel odds ratio and its corresponding 95% confidence interval. Comment on your results.

Solution.

$$\text{OR}_{\text{MH}} = \frac{\sum_{i=1}^G w_i \text{OR}_i}{\sum_{i=1}^G w_i} = \frac{\sum_{i=1}^G \frac{b_i c_i}{n_i} \times \frac{a_i d_i}{b_i c_i}}{\sum_{i=1}^G \frac{b_i c_i}{n_i}} = \frac{\sum_{i=1}^G \frac{a_i d_i}{n_i}}{\sum_{i=1}^G \frac{b_i c_i}{n_i}} = \frac{\frac{68 \times 13}{91+35} + \frac{43 \times 66}{88+113}}{\frac{22 \times 23}{91+35} + \frac{47 \times 45}{88+113}} = 1.45.$$

The variance of the OR_{MH} is:

$$\begin{aligned} \text{Var}[\log(\text{OR}_{\text{MH}})] &= \frac{\sum_{i=1}^G w_i^2 v_i}{\left(\sum_{i=1}^G w_i\right)^2} = \frac{\sum_{i=1}^G \left(\frac{b_i c_i}{n_i}\right)^2 \left(\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}\right)}{\left(\sum_{i=1}^G \frac{b_i c_i}{n_i}\right)^2} \\ &= \frac{\left(\frac{22 \times 23}{91+35}\right)^2 \left(\frac{1}{68} + \frac{1}{22} + \frac{1}{23} + \frac{1}{13}\right) + \left(\frac{43 \times 66}{88+113}\right)^2 \left(\frac{1}{43} + \frac{1}{47} + \frac{1}{45} + \frac{1}{66}\right)}{\left(\frac{22 \times 23}{91+35} + \frac{43 \times 66}{88+113}\right)^2} \\ &= 0.06. \end{aligned}$$

The 95% CI for $\log(\text{OR}_{\text{MH}})$ is:

$$\begin{aligned} & \log(\text{OR}_{\text{MH}}) \pm 1.96 \times \sqrt{\text{Var}[\log(\text{OR}_{\text{MH}})]} \\ & \log(1.45) \pm 1.96 \times \sqrt{0.06} \\ & (-0.11, 0.85). \end{aligned}$$

The 95% CI for OR_{MH} is $(\exp(-0.11), \exp(0.85)) = (0.90, 2.34)$.

After adjusting for the confounding effect of age, the OR of lung cancer did not differ significantly in smokers and non-smokers (95% CI includes 1) despite an OR of 1.45.

Chapter 3

Survival Analysis

3.1 Fundamentals

Denote the time to **the event of interest** (e.g., death) as T , a positive random variable with c.d.f. $F(t) = \Pr(T < t)$ and p.d.f. $f(t)$.

- The **survival function** (生存函数):

$$S(t) = \Pr(T > t) = 1 - F(t), \quad \text{for any } t > 0,$$

and is the probability of an individual surviving beyond time t (t 时刻后还活着).

此外, 生存函数是一个单调递减函数, $S(0) = 1$ and decreasing to 0 as $t \rightarrow \infty$.

- The **hazard function** (危害函数) 是指在个体存活到该点的情况下, 个体在下一个小时时间间隔内可能经历感兴趣事件 (e.g., death) 的概率:

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(T \leq t + \Delta t \mid T \geq t)}{\Delta t}.$$

There are many general shapes for the hazard function. The only restriction on $h(t)$ is that it is non-negative i.e., $h(t) \geq 0$.

- The **cumulative hazard function**:

$$H(t) = \int_0^t h(u) \, du.$$

定理 3.1.1 Relationship between $h(t)$ and $S(t)$ (1)

$$h(t) = \frac{f(t)}{S(t)}.$$

Proof.

$$\begin{aligned}
 h(t) &= \lim_{\Delta t \rightarrow 0} \frac{\Pr(T \leq t + \Delta t \mid T \geq t)}{\Delta t} \\
 &= \lim_{\Delta t \rightarrow 0} \frac{\Pr(T \leq t + \Delta t \cap T \geq t) / \Pr(T \geq t)}{\Delta t} \\
 &= \lim_{\Delta t \rightarrow 0} \frac{\Pr(t \leq T \leq t + \Delta t)}{\Pr(T \geq t) \Delta t} \\
 &= \frac{1}{\Pr(T \geq t)} \lim_{\Delta t \rightarrow 0} \frac{\Pr(t \leq T \leq t + \Delta t)}{\Delta t} \\
 &= \frac{f(t)}{S(t)}.
 \end{aligned}$$

定理 3.1.2 Relationship between $h(t)$ and $S(t)$ (2)

$$S(t) = \exp \left(- \int_0^t h(u) \, du \right).$$

Proof.

$$\begin{aligned}
 \frac{dS(t)}{dt} &= \frac{d(1 - F(t))}{dt} = -f(t) \\
 \Rightarrow h(t) &= \frac{f(t)}{S(t)} = \frac{-\frac{dS(t)}{dt}}{S(t)} = -\frac{d \log S(t)}{dt} \\
 \Rightarrow S(t) &= \exp \left(- \int_0^t h(u) \, du \right).
 \end{aligned}$$

3.1.1 The exponential distribution

When the survival time $T \sim \text{Exp}(\lambda)$ then

$$\left. \begin{aligned}
 F(t) = 1 - \exp(-\lambda t) &\Rightarrow f(t) = F'(t) = \lambda \exp(-\lambda t) \\
 &\Rightarrow S(t) = 1 - F(t) = \exp(-\lambda t) \end{aligned} \right\} \Rightarrow h(t) = \frac{f(t)}{S(t)} = \lambda.$$

The mean and variance are

$$\mathbb{E}[T] = \frac{1}{\lambda}, \quad \text{Var}[T] = \frac{1}{\lambda^2}.$$

- Hazard rate (λ) $\left\{ \begin{array}{ll} \text{Large} & \rightarrow \text{High hazard \& Short survival} \\ \text{Small} & \rightarrow \text{Low hazard \& Long survival} \end{array} \right.$

- **Lack of memory property** (无记忆性): 导致无论 t 如何变化, 失败 (死) 的可能性都一样.
NOT VERY REALISTIC!

3.1.2 The Weibull distribution

When the survival time $T \sim \text{Weibull}(\lambda, \gamma)$, where $\lambda > 0$ and $\gamma > 0$, the shape and scale parameters respectively, then:

$$\left. \begin{aligned} F(t) = 1 - \exp\{-(\lambda t)^\gamma\} &\Rightarrow f(t) = F'(t) = \lambda^\gamma \gamma t^{\gamma-1} \exp\{-(\lambda t)^\gamma\} \\ &\Rightarrow S(t) = 1 - F(t) = \exp\{-(\lambda t)^\gamma\} \end{aligned} \right\} \Rightarrow h(t) = \frac{f(t)}{S(t)} = \lambda^\gamma \gamma t^{\gamma-1}.$$

The mean and variance are

$$\mathbb{E}[T] = \frac{1}{\lambda} \Gamma\left(1 + \frac{1}{\gamma}\right), \quad \text{Var}[T] = \frac{1}{\lambda^2} \left[\Gamma\left(1 + \frac{2}{\gamma}\right) - \Gamma^2\left(1 + \frac{1}{\gamma}\right) \right].$$

where $\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt$, $x \in \mathbb{R}$ or $\Gamma(n) = (n-1)!$, $n \in \mathbb{N}$

3.2 Exploratory analyses for survival data

3.2.1 Estimating the survival function

1. The **empirical distribution function (EDF)** estimator is defined as

$$\hat{S}_{\text{EDF}}(t) = \frac{\text{number surviving beyond } t}{\text{number in the sample}} = \frac{\sum_{i=1}^n \mathbb{1}_{\{t_i > t\}}}{n}.$$

2. The **Kaplan-Meier (KM)** estimator (比 EDF 更好).

n 个观测时间 $(t_1, t_2, \dots, t_n)$, m 个独特时间 $(t_{(1)}, t_{(2)}, \dots, t_{(m)})$ 且最多 $(n-m)$ 个 censored (截尾/删失) 观测值. 加入 $t_{(0)} = 0$, 且 $\Pr(T > t_{(0)}) = 1$.

$$\begin{aligned} S(t_{(i)}) &= \Pr(T > t_{(i)}) = \Pr(T > t_{(i)} \cap T > t_{(i-1)}) \\ &= \Pr(T > t_{(i)} \mid T > t_{(i-1)}) \Pr(T > t_{(i-1)}) \\ &= \Pr(T > t_{(i)} \mid T > t_{(i-1)}) \Pr(T > t_{(i-1)} \mid T > t_{(i-2)}) \Pr(T > t_{(i-2)}) \\ &= \left[\prod_{j=1}^i \Pr(T > t_{(j)} \mid T > t_{(j-1)}) \right] \Pr(T > t_{(0)}) \\ &= \prod_{j=1}^i \Pr(T > t_{(j)} \mid T > t_{(j-1)}) \end{aligned}$$

Notion

- r_j : 在 $t_{(j)}$ 之前仍然存活的个体数量;
- $s_j = r_j - d_j$: 至少存活到 $t_{(j)}$ 的个体数量, 其中 d_j 为在 $t_{(j)}$ 发生死亡的数量 (不包括 censored 观测数据)

Then the Kaplan-Meier estimator is given by

$$\hat{S}_{\text{KM}}(t) = \prod_{j=1}^i \frac{s_j}{r_j}, \quad \text{for } t_{(i)} \leq t < t_{(i+1)}, \quad i = 1, 2, \dots, m,$$

since the estimate of $\Pr(T > t_{(j)} \mid T > t_{(j-1)})$ will be $\frac{s_j}{r_j}$.

例 3.2.1 via 2023.Q2(b)


Suppose one has the following small sample of survival data (in days) where a + denotes a censored observation:

$$2+, 3, 3, 5+, 6, 6, 9, 10+, 12, 13.$$

Solution. Here there are $m = 5$ distinct event times (3, 6, 9, 12, 13), and hence one can construct the Kaplan-Meier estimate for these data in the form of a table as follows

Event time t_i	Number at risk at time $t_{(i)}$ r_i	Number surviving beyond time $t_{(i)}$ $s_i = r_i - d_i$	Estimated survival at time $t_{(i)}$ $\hat{S}(t_{(i)})$
0	10 都活着	10	$10/10 = 1$
3	9 2+ 死了, 3 还没死	$9 - 2 = 7$	$1 \times 7/9 = 7/9$
6	6 2+, 3, 3, 5+ 死了	$6 - 2 = 4$	$7/9 \times 4/6 = 14/27$
9	4 9, 10+, 12, 13 活着	$4 - 1 = 3$	$14/27 \times 3/4 = 7/18$
12	2 12, 13 还活着	$2 - 1 = 1$	$7/18 \times 1/2 = 7/36$
13	1 只剩 13 活着	$1 - 1 = 0$	$7/36 \times 0/1 = 0$

It is now essential to plot such an estimate as in the figure below.



Q. What are the estimated survival probabilities at times 7 and 8?

A. At times 7 and 8 the estimated survival probabilities are both the same and equal to $14/27 = 0.5185$.

Q. Based on your answer to the question above, give one drawback to the Kaplan-Meier estimator of the survival function and explain briefly how this could be rectified.

A. The previous answer illustrates that the Kaplan-Meier estimator is a step function, so the probabilities of surviving beyond times 7 and 8 are the same when one would expect the latter to be smaller. One could get around this discontinuous estimator by applying a smoother to it. 前一个答案说明 Kaplan-Meier 估计量是一个阶梯函数, 因此当人们预期后者更小的时候, 超过 7 和 8 时间的生存概率是相同的。可以通过对其应用平滑器来绕过这个不连续的估计量。

3.2.2 Quantifying uncertainty in the survival function

$$\text{Recall } \text{Var} [\log(X)] \approx \frac{\text{Var} [X]}{(\mathbb{E} [X])^2} \Leftrightarrow \text{Var} [X] \approx (\mathbb{E} [X])^2 \text{Var} [\log(X)]$$

Proof. $\log(X)$ 在 μ 附近的 Taylor 展开为

$$\begin{aligned} \log(X) &= \log(\mu) + \frac{1}{\mu}(X - \mu) - \frac{1}{2\mu^2}(X - \mu)^2 + \cdots \approx \log(\mu) + \frac{1}{\mu}(X - \mu) \\ \Rightarrow \mathbb{E} [\log(X)] &\approx \mathbb{E} [\log(\mu)] + \frac{1}{\mu} \mathbb{E} [X - \mu] = \log(\mu) \\ \Rightarrow \mathbb{E} [(\log(X))^2] &\approx \mathbb{E} \left[\left(\log(\mu) + \frac{1}{\mu}(X - \mu) \right)^2 \right] \\ &= (\log(\mu))^2 + 2\log(\mu) \frac{1}{\mu} \mathbb{E} [X - \mu] + \frac{1}{\mu^2} \mathbb{E} [(X - \mu)^2] \\ &= (\log(\mu))^2 + \frac{\text{Var} [X]}{\mu^2} \\ \Rightarrow \text{Var} [\log(X)] &\approx \mathbb{E} [(\log(X))^2] - (\mathbb{E} [\log(X)])^2 = \frac{\text{Var} [X]}{\mu^2} = \frac{\text{Var} [X]}{(\mathbb{E} [X])^2} \end{aligned}$$

The Kaplan-Meier estimator is a product, and thus variances are difficult to compute. We overcome this by turning it into a sum by a natural log transformation as follows

$$\log \left(\hat{S}_{\text{KM}}(t) \right) = \log \left(\prod_{j=1}^i \frac{s_j}{r_j} \right) = \sum_{j=1}^i \log \left(\frac{s_j}{r_j} \right), \quad \text{for } t_{(i)} \leq t < t_{(i+1)}$$

Assumption $s_j \sim \text{Binomial}(r_j, \theta_j) \Rightarrow \hat{\theta}_{j\text{MLE}} = \frac{s_j}{r_j}$, so that

$$\text{Var} [\hat{\theta}_j] = \text{Var} \left[\frac{s_j}{r_j} \right] = \frac{1}{r_j^2} \text{Var} [s_j] = \frac{\theta_j(1 - \theta_j)}{r_j} \approx \frac{\hat{\theta}_j(1 - \hat{\theta}_j)}{r_j}$$

As a result, the variance of $\log \left(\hat{S}_{\text{KM}}(t) \right)$ for any $t_{(i)} \leq t < t_{(i+1)}$ can be computed as follows

$$\begin{aligned} \text{Var} \left[\log \left(\hat{S}_{\text{KM}}(t) \right) \right] &= \sum_{j=1}^i \text{Var} \left[\log \left(\frac{s_j}{r_j} \right) \right] = \sum_{j=1}^i \text{Var} \left[\log \left(\hat{\theta}_j \right) \right] \\ &\simeq \sum_{j=1}^i \frac{\text{Var} [\hat{\theta}_j]}{(\mathbb{E} [\hat{\theta}_j])^2} \\ &= \sum_{j=1}^i \frac{1}{\hat{\theta}_j^2} \times \frac{\hat{\theta}_j(1 - \hat{\theta}_j)}{r_j} \\ &= \sum_{j=1}^i \frac{1 - \frac{s_j}{r_j}}{\frac{s_j}{r_j} \cdot r_j} = \sum_{j=1}^i \frac{r_j - s_j}{r_j s_j}, \end{aligned}$$

which assumes independence between successive time periods and uses the approximate variance result above. Using this result a second time the other way around (i.e. $\text{Var}[X] \approx (\mathbb{E}[X])^2 \text{Var}[\log(X)]$) yields

$$\text{Var}[\hat{S}_{\text{KM}}(t)] = \left(\hat{S}_{\text{KM}}(t)\right)^2 \sum_{j=1}^i \frac{r_j - s_j}{r_j s_j}, \quad \text{for } t_{(i)} \leq t < t_{(i+1)}, \quad i = 1, 2, \dots, m.$$

Then assuming normality yields a pointwise 95% confidence interval for the survival function at any specified time point, $t > 0$, as

$$\hat{S}_{\text{KM}}(t) \pm 1.96 \sqrt{\text{Var}[\hat{S}_{\text{KM}}(t)]} = \hat{S}_{\text{KM}}(t) \pm 1.96 \hat{S}_{\text{KM}}(t) \sqrt{\sum_{j=1}^i \frac{r_j - s_j}{r_j s_j}}.$$

3.2.3 Estimating the hazard function

A natural method of estimating the **hazard function** for a single sample of survival data is 计算给定事件时间发生事件的数量 与该时间点处于风险中的个体数量 之比, 即

$$\hat{h}(t_{(j)}) = \frac{d_j}{I_j t_j},$$

where $d_j = r_j - s_j$ is the number of events at the j th event time $t_{(j)}$, $j = 1, 2, \dots, m$ and $I_j = t_{(j+1)} - t_{(j)}$ is the length of the interval between successive (连续) real event times. 请注意, 无法估计在始于最终死亡时间的区间内的 hazard function, 因为此区间是开放端点的.

Nelson (1972) and Aalen (1978) proposed estimating the **cumulative hazard function**, which is the total hazard up to time t , as:

$$\hat{H}_{\text{NA}}(t) = \sum_{j=1}^i \frac{d_j}{r_j}, \quad \text{for } t_{(i)} \leq t < t_{(i+1)},$$

where again $d_j = r_j - s_j$ is the number of deaths in the j th time interval. This function is thus the sum of the estimated conditional probabilities of death from the first to the i th time interval for $i = 1, 2, \dots, m$.

Since $S(t) = \exp\left(-\int_0^t h(u) du\right)$ and $H(t) = \int_0^t h(u) du$, then $S(t) = \exp(-H(t))$ and $H(t) = -\log S(t)$. As a result,

$$\hat{H}_{\text{KM}}(t) = -\log(\hat{S}_{\text{KM}}(t)),$$

is an alternative estimator of the cumulative hazard at time t .

3.2.4 Assessing the proportional hazards assumption

考虑两组随机分配接受标准治疗或新治疗的病人, 令 $h_S(t)$ 和 $h_N(t)$ 分别为标准治疗 (S , standard) 和新治疗 (N , new) 病人在时间 t 的死亡风险函数。比例风险假设 (**proportional hazards assumption**) 可以表示为:

$$h_N(t) = \Psi \times h_S(t) \quad \text{or} \quad \frac{h_N(t)}{h_S(t)} = \Psi,$$

for any non-negative time t where Ψ is a positive constant over time. 这里, 新治疗方案患者在时间 t 的风险 (hazard) 与标准治疗方案患者在同一时间的 hazard 成比例.

$$\Psi = \frac{h_N(t)}{h_S(t)} \begin{cases} < 1, \text{ 则 } h_N(t) \text{ 小于 } h_S(t), \text{ 因此新治疗方案的 hazard 比标准治疗方案小} \\ > 1, \text{ 则 } h_N(t) \text{ 大于 } h_S(t), \text{ 因此新治疗方案的 hazard 更大, 因此标准治疗方案更优越} \end{cases}$$

The estimate of the **cumulative hazard function** can be used to provide a simple graphical test of the proportional hazards assumption. Recall that two groups of patients have proportional hazards if $h_N(t) = \Psi \times h_S(t)$, and hence $H_N(t) = \Psi \times H_S(t)$. Moreover, as $H(t) = -\log(S(t))$ then

$$-\log(S_N(t)) = \Psi \times [-\log(H_S(t))].$$

If we take logs again then

$$\log[-\log(S_N(t))] = \log(\Psi) + \log[-\log(H_S(t))].$$

因此, 如果我们将对数累积风险函数 ($\log$ cumulative hazard function) 作图, 即 $\log H(t) = \log[-\log S(t)]$ 随时间作图, 并对比来自两个不同人群的样本, 那么如果这两条曲线呈现出平行的线条 (即曲线之间有一个固定的垂直差距), 也就是有一个常数差值 $\log(\Psi)$. 那就说明, 这两个群体之间满足比例风险假设 (proportional hazards assumption).

3.3 Hypothesis testing for survival functions

介绍名为 **log rank test** 的 χ^2 检验, 用于比较每个群体中观察到的事件数与在两个群体之间无差异的零假设下, 每个群体中对应预期事件数的比较. The hypotheses are:

- H_0 : The survival functions for the two populations are the same.
- H_1 : The survival functions for the two populations are different.

假设两个群体中有 m 个不同时间. Then suppose that at time $t_{(j)}$:

- d_{1j} 和 d_{2j} : 分别表示两个群体在时间 $t_{(j)}$ 发生的事件数. 不包括 censored observations. 因此 $d_j = d_{1j} + d_{2j}$.
- r_{1j} 和 r_{2j} : 分别表示两个群体在时间 $t_{(j)}$ 之前发生的事件数. 因此 $r_j = r_{1j} + r_{2j}$.

如果, 在时间区间 $[t_j, t_{j+1})$, 事件发生的个体占比估计为

$$\hat{\theta}_j = \frac{d_j}{r_j} = \frac{d_{1j} + d_{2j}}{r_{1j} + r_{2j}}$$

那么, 在时间 t_j 的 **expected number of events** (预期事件数) 分别为

$$E_{1j} = r_{1j}\hat{\theta}_j = \frac{r_{1j}d_j}{r_j}, \quad E_{2j} = r_{2j}\hat{\theta}_j = \frac{r_{2j}d_j}{r_j}.$$

因此, 定义 **observed and expected numbers of events in each sample**:

- $E_1 = \sum_{j=1}^m E_{1j}$ and $E_2 = \sum_{j=1}^m E_{2j}$
- $O_1 = \sum_{j=1}^m d_{1j}$ and $O_2 = \sum_{j=1}^m d_{2j}$

Then the test statistic is given by:

$$\begin{aligned} \chi_{LR}^2 &= \frac{(O_1 - E_1)^2}{E_1} + \frac{(O_2 - E_2)^2}{E_2} \\ &= \frac{\left(\sum_{j=1}^m (E_{1j} - d_{1j})\right)^2}{\sum_{j=1}^m E_{1j}} + \frac{\left(\sum_{j=1}^m (E_{2j} - d_{2j})\right)^2}{\sum_{j=1}^m E_{2j}} \end{aligned}$$

在零假设下, 将近似服从 χ_1^2 分布.

例 3.3.1 via 2023.Q2(d)

Consider data on survival times from a clinical trial of 2 treatments, A and B as detailed below, where a $+$ denotes a censored observation.

$$\begin{aligned} A : & 2, \quad 3+, \quad 5+, \quad 7, \quad 7, \quad 11 \\ B : & 4, \quad 5, \quad 6, \quad 8+, \quad 9+, \quad 11+ \end{aligned}$$

Construct a table of the combined samples as follows.

$t_{(i)}$	d_{Ai}	d_{Bi}	d_i	r_{Ai}	r_{Bi}	r_i	E_{Ai}	E_{Bi}
2	1	0	1	6	6	12	$6 \times 1/12 = 1/2$	$6 \times 1/12 = 1/2$
4	0	1	1	4	6	10	$4 \times 1/10 = 2/5$	$6 \times 1/10 = 3/5$
5	0	1	1	4	5	9	$4 \times 1/9 = 4/9$	$5 \times 1/9 = 5/9$
6	0	1	1	3	4	7	$3 \times 1/7 = 3/7$	$4 \times 1/7 = 4/7$
7	2	0	2	3	3	6	$3 \times 2/6 = 1$	$3 \times 2/6 = 1$
11	1	0	1	1	1	2	$1 \times 1/2 = 1/2$	$1 \times 1/2 = 1/2$
Total	$O_A = 4$	$O_B = 3$					$E_A = 3.27$	$E_B = 3.73$

Then the test statistic is given by:

$$\chi_{\text{LR}}^2 = \frac{(O_A - E_A)^2}{E_A} + \frac{(O_B - E_B)^2}{E_B} = \frac{(4 - 3.27)^2}{3.27} + \frac{(3 - 3.73)^2}{3.73} = 0.31 < \chi_1^2(0.95) = 3.84.$$

hence we fail to reject the null hypothesis and conclude that the survival functions for the two samples are the same.

3.4 Modelling survival data – the Cox proportional hazards model

Let $h(t, \mathbf{z}_i)$ be the hazard function at time t for individual i with covariate vector $\mathbf{z}_i = (z_{i1}, z_{i2}, \dots, z_{ip})$, and suppose we have data for $i = 1, 2, \dots, n$ individuals. Then the **Cox proportional hazards model** (PHM) is defined as

$$h(t, \mathbf{z}_i) = h_0(t) \exp(\mathbf{z}_i^\top \boldsymbol{\beta}),$$

where, $h_0(t)$ is an arbitrary-shaped baseline hazard function and $\boldsymbol{\beta}$ is a set of unknown parameters in the regression part of the model that measure the effects of the potential explanatory variables on the hazard function for each individual i . The parameters act multiplicatively on the hazard function so that it can be written as the following product:

$$h(t, \mathbf{z}_i) = h_0(t) \exp(z_{i1}\beta_1) \exp(z_{i2}\beta_2) \cdots \exp(z_{ip}\beta_p).$$

The *proportional hazards model* (比例风险模型) 的使用源于以下事实: 对于任何两个具有协变量 $\mathbf{z}_i$ 和 $\mathbf{z}_j$ 的个体, 在任何时间 t 的 hazard function 之比完全不依赖于 t 或 $h_0(t)$, 即,

$$\frac{z_i}{z_j} = \frac{h_0(t) \exp(\mathbf{z}_i^\top \boldsymbol{\beta})}{h_0(t) \exp(\mathbf{z}_j^\top \boldsymbol{\beta})} = \exp((\mathbf{z}_i - \mathbf{z}_j)^\top \boldsymbol{\beta}).$$

Q. Describe two model assumptions made by the proportional hazards model (PHM).

A. The PHM assumes that the hazard functions for any two individuals are proportional over time, and the logarithm of the hazard rate is linear in each explanatory variable.

T. PHM 假设任何两个个体的风险函数随时间呈比例，且风险率的对数在每个解释变量中呈线性。

例 3.4.1 via 2023.Q2(c)-iii

The hazards for two subjects are proportional if:

$$h(t, \mathbf{z}_1) = C \times h(t, \mathbf{z}_2), \quad \forall t,$$

where C is a constant. The proportional hazards assumption for a set of patients can be assessed via plotting the log-cumulative hazard functions against survival time as seen in the lecture materials (一组患者的比例风险假设可以通过将累积风险函数的对数与生存时间绘制成图来评估). Starting from the mathematical equation above, derive the log-cumulative hazard functions for $\mathbf{z}_1$ and $\mathbf{z}_2$, respectively. **Make sure to explain your reasoning behind every step.** Next, **explain what this plot should look like if the proportionality hazards assumption is satisfied.**

Solution. One may express this proportionality assumption using cumulative hazards instead by writing:

$$H(t, \mathbf{z}_1) = C \times H(t, \mathbf{z}_2).$$

The cumulative hazard function and survival function are linked by the relationship $H(t) = -\log(S(t))$. Hence

$$-\log(S(t, \mathbf{z}_1)) = C \times [-\log(S(t, \mathbf{z}_2))].$$

Taking the log again gives

$$\log[-\log(S(t, \mathbf{z}_1))] = \log(C) + \log[-\log(S(t, \mathbf{z}_2))].$$

Hence

$$X_1(t) = \log[-\log(S(t, \mathbf{z}_1))] = \log[H(t, \mathbf{z}_1)]$$

$$X_2(t) = \log[-\log(S(t, \mathbf{z}_2))] = \log[H(t, \mathbf{z}_2)].$$

To assess if the proportional hazards assumption is valid, one plots the quantities $\log[H(t, \mathbf{z}_1)]$ and $\log[H(t, \mathbf{z}_2)]$ against survival time and checks if the two curves are parallel.

The survival function corresponding to this model for individual i is given by:

$$\begin{aligned}
 S(t|\mathbf{z}_i) &= \exp\left(-\int_0^t h(s, \mathbf{z}_i) \, ds\right) \\
 &= \exp\left(-\int_0^t h_0(s) \exp(\mathbf{z}_i^\top \boldsymbol{\beta}) \, ds\right) \\
 &= \exp\left(-\exp(\mathbf{z}_i^\top \boldsymbol{\beta}) \int_0^t h_0(s) \, ds\right) \\
 &= \left[\exp\left(-\int_0^t h_0(s) \, ds\right)\right]^{\exp(\mathbf{z}_i^\top \boldsymbol{\beta})} = [S_0(t)]^{\exp(\mathbf{z}_i^\top \boldsymbol{\beta})}
 \end{aligned}$$

where $S_0(t)$ is the baseline survival function and can be simply written in terms of the baseline hazard function as

$$S_0(t) = \exp\left(-\int_0^t h_0(s) \, ds\right).$$

The probability density function from this model is obtained from

$$\begin{aligned}
 f(t|\mathbf{z}_i) &= h(t|\mathbf{z}_i)S(t|\mathbf{z}_i) \\
 &= h_0(t) \exp(\mathbf{z}_i^\top \boldsymbol{\beta}) [S_0(t)]^{\exp(\mathbf{z}_i^\top \boldsymbol{\beta})}
 \end{aligned}$$

Finally, given a sample of n observations of survival data $\{t_i, \delta_i, \mathbf{z}_i\}$, then from Section 3.1 the full data likelihood function is given by

$$\prod_{i=1}^n \{(f(t_i|\mathbf{z}_i))^{\delta_i} (S(t_i|\mathbf{z}_i))^{1-\delta_i}\}.$$

where $\delta_i \in \{0, 1\}$, 即

- $\delta_i = 1$, 事件发生, 则我们观察到精确的死亡时间 t_i , 其概率为 $f(t_i|\mathbf{z}_i)$.
- $\delta_i = 0$, 数据删失, 则此人在 t_i 时还活着, 其概率为 $\Pr(T > t_i|\mathbf{z}_i) = S(t_i|\mathbf{z}_i)$.

例 3.4.2 via. 2022.Q2(a)

Represent the survival time by the random variable, T , and assume its cumulative distribution function is given below:

$$\begin{cases} \frac{41}{40} \frac{0.1t^2}{1 + 0.1t^2}, & 0 < t \leq 20, \\ 1, & t > 20. \end{cases}$$

Solution. The **survival function** is computed as:

$$S(t) = 1 - F(t) = 1 - \frac{41}{40} \frac{0.1t^2}{1 + 0.1t^2} = \frac{40(1 + 0.1t^2) - 4.1t^2}{40(1 + 0.1t^2)} = \frac{40 - 0.1t^2}{40(1 + 0.1t^2)}.$$

To compute the hazard function, we first need to compute the probability density function $f(t)$ by

differentiating $F(t)$ as follows:

$$\begin{aligned} f(t) &= \frac{d}{dx} F(x) = \frac{d}{dx} \left(\frac{41}{40} \frac{0.1t^2}{1 + 0.1t^2} \right) \\ &= \frac{41}{40} (0.1) \frac{2t(1 + 0.1t^2) - t^2(0.2t)}{(1 + 0.1t^2)^2} \\ &= \frac{41}{40} \frac{0.2t}{(1 + 0.1t^2)^2}, \end{aligned}$$

therefore:

$$f(t) = \begin{cases} \frac{41}{40} \frac{0.2t}{(1 + 0.1t^2)^2}, & 0 < t \leq 20, \\ 0, & t > 20. \end{cases}$$

The **hazard function** is derived as:

$$h(t) = \frac{f(t)}{S(t)} = \frac{\frac{41}{40} \frac{0.2t}{(1+0.1t^2)^2}}{\frac{40-0.1t^2}{40(1+0.1t^2)}} = \frac{8.2t}{(40 - 0.1t^2)(1 + 0.1t^2)}.$$

Consider the following sample of survival data:

$$2, 6, 8^+, 15^+, 19,$$

where a $+$ denotes a censored observation. The **joint likelihood** for n observations is:

$$\begin{aligned} &L(t_1, \dots, t_5, \delta_1, \dots, \delta_5) \\ &= \prod_{i=1}^5 \{ (f(t_i | \mathbf{z}_i))^{\delta_i} (S(t_i | \mathbf{z}_i))^{1-\delta_i} \} = f(2) \times f(6) \times S(8) \times S(15) \times f(19) \\ &= \frac{41}{40} \frac{0.2(2)}{(1 + 0.1(2)^2)^2} \times \frac{41}{40} \frac{0.2(6)}{(1 + 0.1(6)^2)^2} \times \frac{40 - 0.1(8)^2}{40(1 + 0.1(8)^2)} \times \frac{40 - 0.1(15)^2}{40(1 + 0.1(15)^2)} \times \frac{41}{40} \frac{0.2(19)}{(1 + 0.1(19)^2)^2} \\ &= 7.27 \times 10^{-8} \end{aligned}$$

Therefore the **log-likelihood** is: $\log(L(t_1, \dots, t_5, \delta_1, \dots, \delta_5)) = -16.44$.

Part X

非寿险精算学

Part XI

空间统计

Chapter 1

Introduction

本书的空间统计部分主要围绕三个部分进行讲解, 即地统计学过程, 区域单元 (面元) 过程和空间点过程. 首先对他们的基础, 即空间随机过程, 进行定义

定义 1.0.1 Spatial stochastic process (空间随机过程)

A **spatial stochastic process** is a family of random variables

$$\{Z(\mathbf{s}) : \mathbf{s} \in D\},$$

indexed by spatial locations $\mathbf{s} \in D$.

- D 是过程的空间域 (**spatial domain**), 即可以进行的观测的地理区域;
- $Z(\mathbf{s})$ 是一个随机变量, 表示在位置 $\mathbf{s}$ 处测量的量.

存在三种不同的空间数据类型, 每种类型的统计模型都不同, 且在空间域 D 的定义上差异很大.

1.1 地统计学过程

1.1.1 定义

定义 1.1.1 Geostatistical process (地统计学过程)

A **geostatistical process** is also known as a **point-referenced process** (点参考过程), and is the stochastic process

$$\{Z(\mathbf{s}) : \mathbf{s} \in D\},$$

其中 D 是二维空间 $\mathbb{R}^2$ 的一个固定子集. 数据可能发生的位置 $\mathbf{s}$ 在 D 上连续变化. 然而, 在实践中, 数据是在有限的位置上观测的, 相应的随机变量表示为 $\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))$.

1.1.2 目标

1. 找到一个能够充分解释数据中观察到的空间趋势和依赖性的统计模型.
2. 预测未测量位置的空间过程 (以及不确定性度量), 并创建整个研究区域的过程预测图.

3. 使用预测地图来对正在研究的过程进行推断。
4. 估计在空间上与响应位置相同的协变量测量的影响。

1.2 区域单元 (面元) 过程

1.2.1 定义

定义 1.2.1 Areal unit process (区域单元过程)

Areal unit process is also known as **lattice process (格点过程)**, 空间域 D 被划分为 n 个不重叠 (non-overlapping, 不相交, disjoint) 的面元, 记为

$$D = \{B_1, B_2, \dots, B_n\}.$$

这一组 areal units 可以形成一个规则的 grid (lattice), 也可以是不规则的形状单元, 但必须满足

- $\bigcup_{i=1}^n B_i = D$ (即区域被划分成的子域没有遗漏), 和
- $B_i \cap B_j = \emptyset$ for each $i \neq j$ (即不重叠).

根据这个研究区域划分, areal unit process 是一个随机过程

$$\mathbf{Z} = (Z(B_1), \dots, Z(B_n))$$

只定义在 n 个 areal units $\{B_1, B_2, \dots, B_n\}$ 上, 而不是无限多可能的位置上.

有时会使用另一种表述来表示 areal unit process, 即

$$\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))$$

其中, 每个 $\mathbf{s}_i \in B_i \subset D$ 表示代表该区域 B_i 的位置, 一般用其中心点 (central point, 质心, centroid).

1.2.2 目标

1. 找到一个能够充分解释数据中观察到的趋势和依赖关系的统计模型, 以理解其空间模式.
对于疾病数据, 这个研究领域通常被称为疾病制图 (disease mapping).
2. 使用统计模型来估计暴露对反应的影响, 同时考虑到残差在空间上是自相关的.
这个研究领域通常被称为生态回归 (ecological regression).

1.3 空间点过程

1.3.1 定义

定义 1.3.1 Point process (点过程)

考虑一个空间域 D , 并令 $A \subset D$. 然后令 $Z(A)$ 表示在 A 中出现的点的数量. 因此集合

$$Z = \{Z(A) : A \subset D\},$$

是一个空间点过程.

空间点过程有两种类型:

- 对于**无标记 (unmarked) 点过程**, 仅记录数据的位置.
- 对于**标记 (marked) 点过程**, 记录数据的位置, 以及每个位置的相关测量值.

1.3.2 目标

1. 可视化和描述数据中的空间依赖结构.
2. 拟合模型以识别任何有许多点聚集在一起形成集群的位置.
3. 估计协变量对数据点位置的影响.

Chapter 2

Geostatistics (地统计学)

定义 2.0.1 Geostatistical process (地统计学过程)

A **geostatistical process** is also known as a **point-referenced process** (点参考过程), and is the stochastic process

$$Z(\mathbf{s}) : \mathbf{s} \in D,$$

其中 D 是二维空间 $\mathbb{R}^2$ 的一个固定子集. 数据可能发生的位置 $\mathbf{s}$ 在 D 上连续变化. 然而, 在实践中, 数据是在有限的位置上观测的, 相应的随机变量表示为 $\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))$.

2.1 Geostatistical theory (理论)

2.1.1 Means, variances and covariances (均值, 方差和协方差)

定义 2.1.1 Mean function

The **mean function** of the stochastic process $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is

$$\mu(\mathbf{s}) = \mathbb{E}[Z(\mathbf{s})], \quad \forall \mathbf{s} \in D.$$

它是位置 $\mathbf{s}$ 的理论均值 (期望), 是在随机过程 $Z(\mathbf{s})$ 可能生成的所有值的分布上取的.

$$\mu(\mathbf{s}) = \mathbb{E}[Z(\mathbf{s})] = \int_{-\infty}^{\infty} z(\mathbf{s})f(z(\mathbf{s})) \, dz(\mathbf{s}) \quad \text{或者} \quad \mu(\mathbf{s}) = \mathbb{E}[Z(\mathbf{s})] = \sum_{z_i(\mathbf{s}) \in \mathcal{S}} z_i(\mathbf{s})f(z_i(\mathbf{s})).$$

定义 2.1.2 Autocovariance function

The **autocovariance function** of the stochastic process $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is

$$\begin{aligned} C(\mathbf{s}, \mathbf{t}) &= \text{Cov}[Z(\mathbf{s}), Z(\mathbf{t})] \\ &= \mathbb{E}[(Z(\mathbf{s}) - \mu(\mathbf{s}))(Z(\mathbf{t}) - \mu(\mathbf{t}))] \\ &= \mathbb{E}[Z(\mathbf{s})Z(\mathbf{t})] - \mu(\mathbf{s})\mu(\mathbf{t}), \end{aligned}$$

for 2 locations $(\mathbf{s}, \mathbf{t})$. 自协方差衡量了 $Z(\mathbf{s})$ 和 $Z(\mathbf{t})$ 之间的线性依赖性的强度.

The **variance function** of $Z(\mathbf{s})$ is the special case of the autocovariance with $\mathbf{s} = \mathbf{t}$, which gives

$$\begin{aligned}\text{Var}[Z(\mathbf{s})] &= C(\mathbf{s}, \mathbf{s}) = \text{Cov}[Z(\mathbf{s}), Z(\mathbf{s})] \\ &= \mathbb{E}[(Z(\mathbf{s}) - \mu(\mathbf{s}))^2] \\ &= \nu(\mathbf{s}).\end{aligned}$$

定理 2.1.1 Symmetric (对称性)

The autocovariance function is symmetric in its arguments, that is $C(\mathbf{s}, \mathbf{t}) = C(\mathbf{t}, \mathbf{s})$ for each $\mathbf{s}, \mathbf{t} \in D$.

定理 2.1.2 Nonnegative definite (非负定性)

The autocovariance function is $C(\mathbf{s}, \mathbf{t})$ is a nonnegative definite function, 即其满足

$$\sum_{i=1}^n \sum_{j=1}^n a_i a_j C(\mathbf{s}_i, \mathbf{s}_j) \geq 0.$$

定义 2.1.3 Autocorrelation function

The autocorrelation function of $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is given by

$$\rho(\mathbf{s}, \mathbf{t}) = \text{Corr}[Z(\mathbf{s}), Z(\mathbf{t})] = \frac{C(\mathbf{s}, \mathbf{t})}{\sqrt{C(\mathbf{s}, \mathbf{s})C(\mathbf{t}, \mathbf{t})}}.$$

自相关函数衡量 $Z(\mathbf{s})$ 和 $Z(\mathbf{t})$ 之间的线性相关性的强度, 并且只是自协方差函数的缩放版本.

2.1.2 Stationarity and isotropy (平稳性与各向同性)

定义 2.1.4 Strictly Stationary (严平稳)

A geostatistical process $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is **strictly stationary** if

$$f(Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n)) = f(Z(\mathbf{s}_1 + \mathbf{h}), \dots, Z(\mathbf{s}_n + \mathbf{h})).$$

for any displacement (位移, spatial lag) vector $\mathbf{h}$ and any set of n locations $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$. 本质上这意味着一组随机变量的联合分布不受空间平移的影响.

定义 2.1.5 Weakly Stationary (宽平稳)

A geostatistical process $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is **weakly stationary** if

1. $\mathbb{E}[Z(\mathbf{s})] = \mu(\mathbf{s}) = \mu$ for some finite constant μ which does not depend on $\mathbf{s}$.
2. $\text{Cov}[Z(\mathbf{s}), Z(\mathbf{s} + \mathbf{h})] = C(\mathbf{s}, \mathbf{s} + \mathbf{h}) = C(\mathbf{h}) < \infty$, a finite constant that can depend on $\mathbf{h}$ but not on $\mathbf{s}$.

定义 2.1.6 Isotropic (各向同性)

A weakly stationary geostatistical process $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is **isotropic** if the autocovariance function $C(Z(\mathbf{s}), Z(\mathbf{s} + \mathbf{h})) = C(\mathbf{h})$ can be further simplified to

$$C(\mathbf{h}) = C(h = \|\mathbf{h}\|),$$

where $h = \|\mathbf{h}\|$ denotes the length of the lag vector $\mathbf{h}$ as measured by its Euclidean distance. That is in two dimensions for $\mathbf{h} = (h_1, h_2)$ we have that $\|\mathbf{h}\| = \sqrt{h_1^2 + h_2^2}$.

如果自协方差/自相关函数是宽平稳且各向同性的, 它们就变成一个关于一维量 $h = (h_1, h_2)$ 的函数, 即所讨论的两个点之间的距离.

2.1.3 Gaussian process (高斯过程)**定义 2.1.7 Gaussian process (高斯过程)**

A geostatistical process $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is a **Gaussian process**, if 对于任何 n 个位置的集合 $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$, 随机变量 $\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))$ 的联合分布是多元高斯 (正态) 分布, 即

$$\mathbf{Z} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

for a mean $\boldsymbol{\mu}$ and a covariance matrix $\boldsymbol{\Sigma}$.

我们将重点关注在通过回归模型去除任何空间趋势后, 对**高斯宽平稳各向同性过程**进行建模, 这意味着表示在 n 个位置的随机过程 $\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))$ 服从多元高斯分布, 其矩为:

$$\begin{aligned} \mathbb{E}[Z(\mathbf{s})] &= \mu, \\ \text{Var}[Z(\mathbf{s})] &= \nu^2, \\ C(\mathbf{s}, \mathbf{s} + \mathbf{h}) &= C(h = \|\mathbf{h}\|) \Leftrightarrow \rho(\mathbf{s}, \mathbf{s} + \mathbf{h}) = \rho(h = \|\mathbf{h}\|). \end{aligned}$$

From this the joint probability density function is given by

$$f(\mathbf{z}) = \frac{1}{\sqrt{(2\pi)^n |\boldsymbol{\Sigma}|}} \exp\left(-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{z} - \boldsymbol{\mu})\right)$$

where $\boldsymbol{\mu} = (\mu, \dots, \mu)_{n \times 1}^\top$ and the (j, k) element of the autocovariance matrix $\boldsymbol{\Sigma}$ is $\Sigma_{jk} = C(\|\mathbf{s}_j - \mathbf{s}_k\|)$.

2.1.4 Valid covariance function (协方差函数的有效性判断)**定理 2.1.3 Bochner's theorem (博克纳定理)**

Define mathematically the two conditions that a general function $C(\mathbf{h})$ must satisfy to be a **valid covariance function** for a weakly stationary process.

1. The function $C(\mathbf{h})$ must be an even function as $C(-\mathbf{h}) = C(\mathbf{h})$ for all $\mathbf{h}$;

2. The function $C(\mathbf{s}, \mathbf{s} + \mathbf{h})$ must be non-negative definite, which means that

$$C(\mathbf{s}, \mathbf{s} + \mathbf{h}) = \sum_{j=1}^n \sum_{k=1}^n a_j a_k C(\mathbf{s}_j, \mathbf{s}_k) \geq 0,$$

for any scalars $(a_1, \dots, a_n)$, and any locations $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$.

类似地, 自相关函数 $\rho(\mathbf{h})$ 的有效性亦为如此.

例 2.1.1 Bookwork 2.2.4

Consider a weakly stationary and isotropic mean zero white noise process with autocovariance function

$$C(h) = \begin{cases} \tau^2, & \text{if } h = 0, \\ 0, & \text{otherwise.} \end{cases}$$

Solution. This is clearly a valid autocovariance function under Bochner's theorem, because:

1. It is even as $C(h) = C(-h) = 0$ for $h \neq 0$.
2. Consider n scalars $(a_1, \dots, a_n)$ and n locations $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$, and let $h_{jk} = \|\mathbf{s}_j - \mathbf{s}_k\|$. Then

$$\begin{aligned} \sum_{j=1}^n \sum_{k=1}^n a_j a_k C(\mathbf{s}_j, \mathbf{s}_k) &= \sum_{j=1}^n \sum_{k=1}^n a_j a_k C(h_{jk}) \\ &= \sum_{j=1}^n a_j^2 \tau^2 \geq 0. \end{aligned}$$

hence it is non-negative definite.

2.1.5 Variogram (变异函数)

定义 2.1.8 Semi-variogram (半变异函数)

A **semi-variogram** of a geostatistical process $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is a function denoted by $\gamma(\mathbf{s}, \mathbf{s} + \mathbf{h})$, and measures the variance of the difference in the process at two spatial locations $\mathbf{s}$ and $\mathbf{s} + \mathbf{h}$. It is defined as:

$$\gamma(\mathbf{s}, \mathbf{s} + \mathbf{h}) = \frac{1}{2} \text{Var} [Z(\mathbf{s}) - Z(\mathbf{s} + \mathbf{h})],$$

where traditionally $2\gamma(\mathbf{s}, \mathbf{s} + \mathbf{h})$ is called the **variogram** and $\gamma(\mathbf{s}, \mathbf{s} + \mathbf{h})$ is called the **semi-variogram**.

使用协方差规则, 我们可以将半变异图与自协方差函数关联起来, 如下所示:

$$\begin{aligned}\gamma(\mathbf{s}, \mathbf{s} + \mathbf{h}) &= \frac{1}{2} \text{Var} [Z(\mathbf{s}) - Z(\mathbf{s} + \mathbf{h})] \\ &= \frac{1}{2} \text{Cov} [Z(\mathbf{s}) - Z(\mathbf{s} + \mathbf{h}), Z(\mathbf{s}) - Z(\mathbf{s} + \mathbf{h})] \\ &= \frac{1}{2} (C(\mathbf{s}, \mathbf{s}) - 2C(\mathbf{s}, \mathbf{s} + \mathbf{h}) + C(\mathbf{s} + \mathbf{h}, \mathbf{s} + \mathbf{h})).\end{aligned}$$

当过程是宽平稳时, 即 $C(\mathbf{s}, \mathbf{s} + \mathbf{h}) = C(\mathbf{h})$, 我们可以将其简化为

$$\begin{aligned}\gamma(\mathbf{s}, \mathbf{s} + \mathbf{h}) &= \gamma(\mathbf{h}) = \frac{1}{2} (2C(\mathbf{0}) - 2C(\mathbf{h})) \\ &= C(\mathbf{0}) - C(\mathbf{h}) \\ &= \nu^2 - C(\mathbf{h}),\end{aligned}$$

并且在各向同性条件下, 即 $C(\mathbf{h}) = C(h = \|\mathbf{h}\|)$, 我们得到

$$\gamma(\mathbf{h}) = \gamma(h) = C(0) - C(h) = \nu^2 - C(h),$$

其中, $h = \|\mathbf{h}\|$, 以及 $\nu^2 = \text{Var} [Z(\mathbf{s})]$.

例 2.1.2 from 2021.Q1(a)-iii

Derive the semi-variogram that corresponds to the covariance function

$$C(\mathbf{s}, \mathbf{s} + \mathbf{h}) = C(h = \|\mathbf{h}\|) = \begin{cases} \tau^2, & \text{if } h = 0, \\ \frac{\theta}{h+1}, & \text{otherwise.} \end{cases}$$

Solution.

- For $h = 0$, we have that $\gamma(0) = C(0) - C(0) = 0$.
- For $h > 0$, we have that $\gamma(h) = C(0) - C(h) = \tau^2 - \frac{\theta}{h+1}$.

Thus we have that

$$\gamma(h) = \begin{cases} \tau^2 - \frac{\theta}{h+1}, & h > 0, \\ 0, & h = 0. \end{cases}$$

例 2.1.3

Consider the following semi-variogram model for an isotropic geostatistical process $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$,

$$\gamma_Z(h) = \begin{cases} 0, & h = 0, \\ h^2, & h > 0, \end{cases}$$

which is accompanied by the mean model $\mu_Z(\mathbf{s}) = 0$ for all $\mathbf{s} \in D$. Is this geostatistical process weakly stationary? Justify your answer.

Solution. 宽平稳性要求两个条件:

- **Mean constant:** mean model $\mu_Z(\mathbf{s}) = 0$ for all $\mathbf{s} \in D$.
- **Covariance finite constantly and only depend on h :** $C(h) = C(0) - \gamma_Z(h) = C(0) - h^2$. As h increases, $C(h)$ tends towards negative infinity, leading to a negative covariance even potentially unbounded.

因此不满足宽平稳条件.

2.2 Autocovariance and semi-variogram models (自协方差和半变异模型)

命题 2.2.1 Parameters

In summary, the following parameters are often used to describe variograms:

- **Nugget** (块金): is the limiting value of the **semi-variogram** as $h \rightarrow 0$, from the right.
 - 如果没有 Nugget, 即 $\text{Nugget} = 0$, 则曲线从 $(0, 0)$ 平滑开始.
 - 如果存在 Nugget, 即 $\text{Nugget} > 0$, 曲线会在 $h = 0$ 处有一个垂直的跳跃, 然后再平滑增长.
- **Sill** (基台): 半变异函数的 **稳定值**. 如果没有稳定值, 即不收敛, 则过程不平稳.
- **Partial sill** = Sill – Nugget.
- **Range** (变程): 使半变异函数达到 Sill 的 **距离** h .

	用 $\gamma(h)$ 计算		用 $C(h)$ 计算
Nugget	$\lim_{h \rightarrow 0+} \gamma(h)$	Sill	$C(0)$
Sill	$\lim_{h \rightarrow \infty} \gamma(h)$	Partial sill	$\lim_{h \rightarrow 0+} C(h)$
Partial sill	Sill – Nugget	Nugget	Sill – Partial sill
Range	$\gamma(h) = \text{Sill}$ 时的距离	Range	$C(h) = 0$ 时的距离

例 2.2.1 T1-Q2.(b)

Suppose that $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ is a stationary isotropic geostatistical process with zero-mean and an autocovariance function given by

$$C(h) = \begin{cases} \sigma^2 \exp(-|h/\phi|^r), & h > 0, \\ \sigma^2 + \tau^2, & h = 0, \end{cases}$$


where $0 < r < 2$. What are the range, sill, nugget, and partial sill for this autocovariance model?

Solution. 我们可以得到:


$$\gamma(h) = C(0) - C(h) = \begin{cases} \sigma^2 + \tau^2 - \sigma^2 \exp(-|h/\phi|^r), & h > 0 \\ 0, & h = 0. \end{cases}$$

	用 $\gamma(h)$ 计算
Nugget	$\lim_{h \rightarrow 0+} \gamma(h) = \tau^2$
Sill	$\lim_{h \rightarrow \infty} \gamma(h) = \sigma^2 + \tau^2$
Partial sill	Sill - Nugget = σ^2
Range	$\gamma(h) = \text{Sill}$ 时的距离

	用 $C(h)$ 计算
Sill	$C(0) = \sigma^2 + \tau^2$
Partial sill	$\lim_{h \rightarrow 0+} C(h) = \sigma^2$
Nugget	Sill - Partial sill = τ^2
Range	$C(h) = 0$ 时的距离



(a) Variogram $\gamma(h)$



(b) Covariance function $C(h)$

定义 2.2.1 Exponential autocovariance function

The most commonly used parametric model.

$$C(h) = \begin{cases} \sigma^2 \exp(-h/\phi), & h > 0, \\ \tau^2 + \sigma^2, & h = 0. \end{cases}$$

定义 2.2.2 Gaussian semi-variogram model

$$\gamma(h) = \begin{cases} \tau^2 + \sigma^2(1 - \exp(-h^2/\phi)), & h > 0, \\ 0, & h = 0. \end{cases}$$

定义 2.2.3 Spherical (球面) autocovariance function

$$C(h) = \begin{cases} 0, & h > \phi \\ \sigma^2 \left[1 - \frac{3}{2}(h/\phi) + \frac{1}{2}(h/\phi)^3 \right], & 0 < h \leq \phi, \\ \tau^2 + \sigma^2, & h = 0, \end{cases}$$

with semi-variogram

$$\gamma(h) = \begin{cases} \tau^2 + \sigma^2, & h > \phi \\ \tau^2 + \sigma^2 \left[\frac{3}{2}(h/\phi) - \frac{1}{2}(h/\phi)^3 \right], & 0 < h \leq \phi, \\ 0, & h = 0. \end{cases}$$

定义 2.2.4 Wave autocovariance function

$$C(h) = \begin{cases} \sigma^2 \left[\frac{\sin(h/\phi)}{(h/\phi)} \right], & h > 0, \\ \tau^2 + \sigma^2, & h = 0, \end{cases}$$

with semi-variogram

$$\gamma(h) = \begin{cases} \tau^2 + \sigma^2 \left[1 - \frac{\sin(h/\phi)}{(h/\phi)} \right], & h > 0, \\ 0, & h = 0, \end{cases}$$

2.3 Geostatistical modelling (建模)

2.3.1 Overall modelling strategy (建模策略)

假设我们观察到以下地统计数据:

1. 响应数据 $\mathbf{z} = (z(\mathbf{s}_1), \dots, z(\mathbf{s}_n))$.
2. 协变量 (covariate) 风险因素 $\mathbf{x}(\mathbf{s}_i) = (x_1(\mathbf{s}_i), \dots, x_p(\mathbf{s}_i))$ 在每个位置 $\mathbf{s}_i$, 其中 $x_1(\mathbf{s}_i) = 1$ 对应于截距项, 所有 n 个位置的全部协变量都包含在设计矩阵 $\mathbf{X}_{n \times p}$ 中.

响应数据 $\mathbf{z}$ 是地统计过程 $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ 的一个实现, 我们希望对 $\{Z(\mathbf{s}) : \mathbf{s} \in D\}$ 在任意位置 $\mathbf{s}$ 的概率分布进行推断. 我们假设所建模的过程具有某种**空间平滑性 (spatial smoothness)**, 因为这允许我们在未测量位置进行过程预测. 一种常见的建模方法是加性分解:

$$Z(\mathbf{s}) = \mu(\mathbf{s}) + \epsilon(\mathbf{s}),$$

其中:

- $\mu(\mathbf{s}) = \mathbb{E}[Z(\mathbf{s})] = \mathbf{x}(\mathbf{s})^\top \boldsymbol{\beta}$ 是空间变化的均值.
- $\epsilon(\mathbf{s})$ 是一个空间地统计误差过程.

假设 $\epsilon(\mathbf{s})$ 是高斯分布, 均值为零, 并且具有弱平稳和各向同性的自协方差函数 $C(\mathbf{s}, \mathbf{s} + \mathbf{h}) = C(h)$.

考虑高斯模型:

$$\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n)) \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \boldsymbol{\Sigma}(\boldsymbol{\theta})),$$

其中:

- $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)$ 是要估计的回归参数向量, 并形成线性回归模型.
- $\boldsymbol{\Sigma}(\boldsymbol{\theta})$ 是由自协方差函数 $C(h, \boldsymbol{\theta})$ 隐含的弱平稳各向同性协方差矩阵, 其中 $\boldsymbol{\theta} = (\sigma^2, \tau^2, \phi)$ 分别描述自相关结构的 partial sill, nugget 和 range.

例 2.3.1

考虑给定的指数自协方差函数

$$C(h) = \begin{cases} \sigma^2 \exp(-h/\phi), & h > 0, \\ \tau^2 + \sigma^2, & h = 0. \end{cases}$$

那么 $\mathbf{Z}$ 对应的协方差矩阵 $\boldsymbol{\Sigma}(\boldsymbol{\theta})$ 为

$$\boldsymbol{\Sigma}(\boldsymbol{\theta}) = \sigma^2 \exp(-\mathbf{D}/\phi) + \tau^2 \mathbf{I},$$

其中 $\mathbf{D} = (d_{ij})$ 是一个 $n \times n$ 的距离矩阵, 其值 $d_{ij} = \|\mathbf{s}_i - \mathbf{s}_j\|$, 并且 $\mathbf{I}$ 是单位矩阵.

2.3.2 Exploratory data analysis (EDA)

大多数 EDA 技术强调数据的某些特征, 而隐藏其他特征, 因此在一个数据集上使用多种不同的 EDA 技术是一个好主意. EDA 有时被认为**琐碎 (trivial) 且不重要**, 但如果操作不当, 它可能会导致后续建模问题. EDA **很重要**.

2.3.3 Plotting the data (制图)

EDA 的第一阶段是绘制数据的空间地图, 有许多软件包可以做到这一点. 其中一个不错的叫做 **leaflet**, 因为它将数据叠加在 OpenStreetMap 上.

注意, 要使用 **leaflet**, 数据坐标系统必须是经度和纬度.

2.3.4 Modelling the mean function (均值函数建模)

该过程与非空间数据相同, 建立如下模型

$$\mu(\mathbf{s}) = \mathbb{E}[Z(\mathbf{s})] = \mathbf{x}(\mathbf{s})^\top \boldsymbol{\beta} = \beta_1 + x_2(\mathbf{s}_i)\beta_2 + \dots + x_p(\mathbf{s}_i)\beta_p$$

其中, $x_i(\mathbf{s}_i)$ 可以是经度 (longitude), 纬度 (latitude), 海拔 (elevation), 以及等等感兴趣的变量.

2.3.5 Investigating the presence of spatial autocorrelation (调查空间自相关是否存在)

一种调查**数据集或残差** (来自拟合趋势模型) $\mathbf{y} = (y(\mathbf{s}_1), \dots, y(\mathbf{s}_n))$ 中**空间自相关**存在的方法是估计其**经验半变异函数 (empirical semi-variogram)**.

空间过程 $\{Y(\mathbf{s}) : \mathbf{s} \in D\}$ 的半变异函数为

$$\begin{aligned}\gamma(\mathbf{s}, \mathbf{s} + \mathbf{h}) &= \frac{1}{2} \text{Var}[Y(\mathbf{s}) - Y(\mathbf{s} + \mathbf{h})] \\ &= \frac{1}{2} \mathbb{E}[(Y(\mathbf{s}) - Y(\mathbf{s} + \mathbf{h}))^2],\end{aligned}$$

这里我们假设趋势被去除, 那么 $\mathbb{E}[Y(\mathbf{s}) - Y(\mathbf{s} + \mathbf{h})] = 0$. 这种估计的直观给出为

$$\gamma_{ij} = \frac{1}{2} [y(\mathbf{s}_i) - y(\mathbf{s}_j)]^2,$$

这样可以针对每对数据点 $(y(\mathbf{s}_i), y(\mathbf{s}_j))$ for $i \neq j$ 进行计算. 假设过程是平稳且各向同性的, 那么 γ_{ij} vs. $h_{ij} = \|\mathbf{s}_i - \mathbf{s}_j\|$ 的图称为 **variogram cloud**.

但是这图很难去看, 因为会有太多噪点. 因此考虑分组进行.

定义 2.3.1 Binned empirical semi-variogram (分组经验半变异函数)

假设我们将 all pairs of points 之间的距离范围划分为 K 个区间 (interval or bins)

$$I_k = (h_{k-1}, h_k], \quad k = 1, \dots, K,$$

其中, $0 = h_0 < h_1 < \dots < h_K$. 令 $h_k^m = \frac{h_{k-1} + h_k}{2}$ 表示表示第 k 个区间的中点 (midpoint). 然后令

$$N(h_k) = \{(\mathbf{s}_i, \mathbf{s}_j) : \|\mathbf{s}_i - \mathbf{s}_j\| \in I_k\},$$

表示距离落在 I_k 这个区间的点对 $(\mathbf{s}_i, \mathbf{s}_j)$ 的集合. Then the **binned empirical semi-variogram** is

$$\hat{\gamma}(h_k^m) = \frac{1}{|2N(h_k)|} \sum_{(\mathbf{s}_i, \mathbf{s}_j) \in N(h_k)} [y(\mathbf{s}_i) - y(\mathbf{s}_j)]^2.$$

2.3.5.0.1 用途: 检验各向同性 将经验半变异函数在不同方向上分别绘制 (见章末).

1. 如果曲线在所有方向上相似, 则数据是**各向同性 (isotropy)** 的.
2. 如果不同方向的曲线形状差异大, 则数据存在**各向异性 (anisotropy)**.

定义 2.3.2 Monte Carlo envelope (蒙特卡洛包络)

The **Monte Carlo envelope** for the binned empirical semi-variogram based on independence is computed by repeating the following steps a large number, say $j = 1, \dots, 1000$ times.


For $j = 1, \dots, 1000$,

- (a) Create a pseudo data set $\mathbf{y}^{(j)} = (y^{(j)}(\mathbf{s}_1), \dots, y^{(j)}(\mathbf{s}_n))$ by randomly permuting (排列) the n data points to the n spatial locations, $\mathbf{s} = \{\mathbf{s}_1, \dots, \mathbf{s}_n\}$.
- (b) Compute the binned empirical semi-variogram for each mid distance $(\hat{\gamma}^{(j)}(h_1^m), \dots, \hat{\gamma}^{(j)}(h_K^m))$ for this pseudo data set $\mathbf{y}^{(j)}$.

由于这些排列中的每一个都是 n 数据点到 n 位置的随机重新分配 (random re-allocation), 因此伪数据集 $\mathbf{y}^{(j)}$ 不应有空间自相关.

因此, 对于每个距离 h_i^m , 在假设**独立性**的情况下, 95% 的 $\hat{\gamma}(h_i^m)$ 包络计算为集合 $\{\hat{\gamma}^{(j)}(h_i^m)\}_{j=1}^{1000}$ 的 [2.5%, 97.5%] 百分位数.

Thus if the empirical semi-variogram for the data lies **completely inside** these envelopes, then **independence** is likely. If it does **not** then **spatial autocorrelation** is likely.



There is clear evidence of **spatial autocorrelation** present because the empirical semi-variogram (dots) **lies outside** the Monte Carlo envelopes (lines) at the left side of the plot.

定义 2.3.3 Binned empirical covariogram

An estimate of the autocovariance function is called the **binned empirical covariogram** and is given by

$$\hat{C}(h_k^m) = \frac{1}{|2N(h_k)|} \sum_{(s_i, s_j) \in N(h_k)} [y(s_i) - \bar{y}] [y(s_j) - \bar{y}].$$


其中 $\bar{y} = \frac{1}{n} \sum_{i=1}^n y(s_i)$ 是数据的样本均值.

这个估计是有偏的, 但随着配对数量的增加, 偏差会减小.

到目前为止所有空间依赖性度量都假设**各向同性**, 即 autocovariance 或 semi-variogram 仅取决于数据位置之间的**距离**, 而与**方向**无关. 文献中有多种方法来**评估各向同性**是否是地质统计数据的合理假设. 最简单的方法是限制经验半变异图或协方差图中出现的数据点对, 以便我们仅测量沿某些方向 (或方向范围) 的依赖性. 我们称这种显示为**方向性变异图 (directional variograms, or covariograms)**. 如果过程是各向同性的, 那么无论我们朝哪个方向看, 变异图都应该相似 (同样需要

注意我们没有不确定性度量).

我们可以计算拟合均值模型到数据残差的 4 个方向的 directional variograms, 如下所示. 这里的方向是: 0 度 (北到南 ↓), 45 度 (东北到西南 ↘); 90 度 (东到西 ←); 和 135 度 (西北到东南 ↗).



正如所见, 半变差图在左侧看起来有些相似 (右侧非常不确定), 因此各向同性在这里似乎是一个合理的假设.

2.4 Parameter estimation (参数估计)

对于我们使用的数据 $\mathbf{z} = (z(\mathbf{s}_1), \dots, z(\mathbf{s}_n))$ 有如下形式 (高斯模型):

$$\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n)) \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \boldsymbol{\Sigma}(\boldsymbol{\theta})),$$

因此, 有两种类型的参数需要估计:

- 均值模型中的参数 $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)$.
- 协方差模型中的参数 $\boldsymbol{\theta} = (\sigma^2, \tau^2, \phi)$.

参数估计有两种通用方法, 即 frequentist inference using maximum likelihood (or least squares) 和 Bayesian inference using Markov chain Monte Carlo simulation. 我们在此重点介绍最大似然估计的频率推断. 为了说明, 我们假设使用的是 exponential autocovariance 模型, 即

$$\boldsymbol{\Sigma}(\boldsymbol{\theta}) = \sigma^2 \exp(-\mathbf{D}/\phi) + \tau^2 \mathbf{I},$$

其中, 如前所述 $\mathbf{D} = (d_{ij})$ 是一个 $n \times n$ 的距离矩阵, 其值 $d_{ij} = \|\mathbf{s}_i - \mathbf{s}_j\|$, 并且 $\mathbf{I}$ 是单位矩阵. 该多元高斯分布的似然函数由下式给出

$$\begin{aligned} f(\boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{z}) &= \frac{1}{\sqrt{(2\pi)^n |\boldsymbol{\Sigma}|}} \exp\left(-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{z} - \boldsymbol{\mu})\right) \\ &= (2\pi)^{-\frac{n}{2}} \left| \sigma^2 \exp(-\mathbf{D}/\phi) + \tau^2 \mathbf{I} \right|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\sigma^2 \exp(-\mathbf{D}/\phi) + \tau^2 \mathbf{I} \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})\right). \end{aligned}$$

Then after removing unnecessary constants $(2\pi)^{-\frac{n}{2}}$ the log-likelihood function is given by

$$\log [f(\boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{z})] = -\frac{1}{2} \log \left| \sigma^2 \exp(-\mathbf{D}/\phi) + \tau^2 \mathbf{I} \right| - \frac{1}{2} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\sigma^2 \exp(-\mathbf{D}/\phi) + \tau^2 \mathbf{I} \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta}).$$

由此很容易看出 (σ^2, τ^2) 被限制在一个逆矩阵和一个行列式内. 因此为了简化估计, 我们采用变换 $\xi^2 = \frac{\tau^2}{\sigma^2}$, 其中 ξ^2 被称为**信噪比 (noise to signal ratio)**. 用 $\tau^2 = \xi^2 \sigma^2$ 替换 τ^2 后, 对数似然函数此时为

$$\begin{aligned} \log [f(\boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{z})] &= -\frac{1}{2} \log \left| \sigma^2 \exp(-\mathbf{D}/\phi) + \xi^2 \sigma^2 \mathbf{I} \right| - \frac{1}{2} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\sigma^2 \exp(-\mathbf{D}/\phi) + \xi^2 \sigma^2 \mathbf{I} \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta}) \\ &= -\frac{n}{2} \log(\sigma^2) - \frac{1}{2} \log \left| \exp(-\mathbf{D}/\phi) + \xi^2 \mathbf{I} \right| - \frac{1}{2\sigma^2} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\exp(-\mathbf{D}/\phi) + \xi^2 \mathbf{I} \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta}). \end{aligned}$$

这是因为矩阵 $\mathbf{A}$ 的行列式满足性质 $|\alpha \mathbf{A}| = \alpha^n |\mathbf{A}|$. 在以下内容中, 我们用 $\mathbf{V}(\phi, \xi^2) = \exp(-\mathbf{D}/\phi) + \xi^2 \mathbf{I}$ 表示, 以简化记号, 使得 $\boldsymbol{\Sigma}(\boldsymbol{\theta}) = \sigma^2 \mathbf{V}(\phi, \xi^2)$, 并且对数似然函数给出

$$\log [f(\boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{z})] = -\frac{n}{2} \log(\sigma^2) - \frac{1}{2} \log |\mathbf{V}(\phi, \xi^2)| - \frac{1}{2\sigma^2} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta}).$$

例 2.4.1 Estimation of $\boldsymbol{\beta}$ using MLE

仅保留对 $\boldsymbol{\beta}$ 依赖的似然函数部分, 我们得到

$$\begin{aligned} \log [f(\boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{z})] &= \frac{1}{2\sigma^2} \left(2\boldsymbol{\beta}^\top \mathbf{X}^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} \mathbf{z} - \boldsymbol{\beta}^\top \mathbf{X}^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} \mathbf{X}\boldsymbol{\beta} \right) \\ \frac{d}{d\boldsymbol{\beta}} \log [f(\boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{z})] &= \frac{1}{2\sigma^2} \left(2\mathbf{X}^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} \mathbf{z} - 2\mathbf{X}^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} \mathbf{X}\boldsymbol{\beta} \right). \end{aligned}$$

Setting the latter equal to zero and solving gives:

$$\hat{\boldsymbol{\beta}}(\phi, \xi^2) = \left(\mathbf{X}^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} \mathbf{X} \right)^{-1} \mathbf{X}^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} \mathbf{z}.$$

which depends on the covariance parameters (ϕ, ξ^2) but not on σ^2 .

例 2.4.2 Estimation of σ^2 using MLE

仅保留对 σ^2 依赖的似然函数部分, 我们得到

$$\begin{aligned} \log [f(\boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{z})] &= -\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta}) \\ \frac{d}{d\sigma^2} \log [f(\boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{z})] &= -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta}). \end{aligned}$$

Setting the latter equal to zero and solving gives:

$$\hat{\sigma}^2(\boldsymbol{\beta}, \phi, \xi^2) = \frac{1}{n} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta}).$$

虽然与标准线性模型一样, 但是 MLE 是有偏的, 因此使用替代方案

$$\hat{\sigma}^2(\boldsymbol{\beta}, \phi, \xi^2) = \frac{1}{n-p} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^\top \left[\mathbf{V}(\phi, \xi^2) \right]^{-1} (\mathbf{z} - \mathbf{X}\boldsymbol{\beta}),$$

其中 p 是均值模型中的参数数量.

例 2.4.3 Estimation of (ϕ, ξ^2)

用不了 MLE, 因为这俩参数都在矩阵里, 并进行了逆和行列式运算, 因此把 β 和 σ^2 的 MLE 代入.

$$\begin{aligned}\log [f(\phi, \xi^2 | z)] &= -\frac{n}{2} \log(\hat{\sigma}^2) - \frac{1}{2} \log |\mathbf{V}(\phi, \xi^2)| - \frac{1}{2\hat{\sigma}^2} (z - \mathbf{X}\hat{\beta})^\top [\mathbf{V}(\phi, \xi^2)]^{-1} (z - \mathbf{X}\hat{\beta}) \\ &= -\frac{n}{2} \log(\hat{\sigma}^2(\hat{\beta}, \phi, \xi^2)) - \frac{1}{2} \log |\mathbf{V}(\phi, \xi^2)|.\end{aligned}$$

注意, 上述完整对数似然函数中的第三项 (二次型) 已被消去为常数. 这被称为 (ϕ, ξ^2) 的 **轮廓似然 (profile likelihood)** 或 **简化似然 (reduced likelihood)**, 必须通过计算机使用数值优化方法来最大化.

因此, 在估计 (β, σ^2) 时, 不允许 $(\hat{\phi}, \hat{\xi}^2)$ 存在不确定性, 这可以被视为具有限制性. 顺便一提, 贝叶斯估计方法可以克服这一局限性.

例 2.4.4 95% confidence interval of $\hat{\beta}$

$$\begin{aligned}\text{Var} [\hat{\beta}] &= \text{Var} \left[(\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} z \right] \\ &= (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \text{Var} [z] \mathbf{V}^{-1} \mathbf{X} (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \\ &= (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \Sigma \mathbf{V}^{-1} \mathbf{X} (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \\ &\stackrel{\Sigma = \sigma^2 \mathbf{V}}{=} (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} (\sigma^2 \mathbf{V}) \mathbf{V}^{-1} \mathbf{X} (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \\ &= \sigma^2 (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X} (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \\ &= \sigma^2 (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1}.\end{aligned}$$

from which 95% confidence intervals can be constructed as

$$\hat{\beta}_i \pm t_{0.975}(n-p) \times \sigma \sqrt{\left((\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \right)_{ii}}$$

- **MLE:** $\hat{\beta}(\hat{\phi}, \hat{\xi}^2) = \left(\mathbf{X}^\top [\mathbf{V}(\hat{\phi}, \hat{\xi}^2)]^{-1} \mathbf{X} \right)^{-1} \mathbf{X}^\top [\mathbf{V}(\hat{\phi}, \hat{\xi}^2)]^{-1} z$, 通过 $(\hat{\phi}, \hat{\xi}^2)$ 考虑空间自相关性.
- **OLS:** $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top z$, 假设具有独立性.

这俩哪个好? 有三个标准指标来衡量这一点.

1. **Bias:** 真实值 β 与估计值之间的差异是多少.

$$\text{Bias}(\beta) = \mathbb{E} [\hat{\beta}] - \beta = \frac{1}{n} \sum_{j=1}^n \hat{\beta}_j - \beta.$$

2. **Root mean square error (RMSE, 均方误差):** 估计值之间的变异程度是多少.

$$\text{RMSE}(\beta) = \mathbb{E} \left[(\hat{\beta} - \beta)^2 \right] = \sqrt{\frac{1}{n} \sum_{j=1}^n (\hat{\beta}_j - \beta)^2}.$$

3. **Coverage probability (覆盖率):** 每个数据集都产生一个 β 的估计值和 95% 置信区间, 有多少百分比的 95% 置信区间包含真实值 β .

一般来说, **bias** 基本不受影响, MLE 的 **RMSE** 略好. 然而主要区别在于**覆盖率**, MLE 的覆盖率在 95% 左右基本正确. 基于独立性的 OLS 估计的覆盖率非常低, 表明其 95% 置信区间过于狭窄. 原因在于它假设数据是独立的, 因此你有 n 个独立的信息片段来估计 β . 实际上这些数据点是相关的, 因此你拥有的独立信息片段要少得多. 因此, 不确定性被低估了.

2.5 Model adequacy and comparison (模型适宜度与比较)

2.5.1 Spatial residuals (空间残差)

简单原始残差 $\epsilon(s_i)$ 给出:

$$\epsilon(s_i) = z(s_i) - \mathbf{x}(s_i)^\top \beta, \quad \text{for } i = 1, \dots, n,$$

并且, 在向量形式下 $\mathbf{z} \sim \mathcal{N}(\mathbf{X}\beta, \Sigma(\theta))$, 则 $\boldsymbol{\epsilon} = (\epsilon(s_1), \dots, \epsilon(s_n)) = \mathbf{z} - \mathbf{X}\beta \sim \mathcal{N}(\mathbf{0}, \Sigma(\theta))$.

设 $\Sigma(\hat{\theta}) = \hat{\sigma}^2 \mathbf{V}(\hat{\phi}, \hat{\xi}^2 = \hat{\tau}^2 / \hat{\sigma}^2)$ 表示估计的协方差矩阵. 它的 Cholesky 分解 (decomposition) 为

$$\Sigma(\hat{\theta}) = \mathbf{L}\mathbf{L}^\top,$$

其中 $\mathbf{L}$ 是具有正对角线元素的实数下三角矩阵. 它能这么分解是因为 $\Sigma(\hat{\theta})$ 是对称正定矩阵. 新的残差称为**创新 (innovations)**, 并定义为

$$\mathbf{u} = \mathbf{L}^{-1}\hat{\boldsymbol{\epsilon}},$$

其中, $\mathbf{u} = (u(s_1), \dots, u(s_n))$.

例 2.5.1

Show that $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, where $\mathbf{I}$ is the identity matrix, so that these **innovations** are independent under the correct autocovariance model.

Solution. 首先我们有 $\hat{\boldsymbol{\epsilon}} \sim \mathcal{N}(\mathbf{0}, \Sigma(\theta))$, 然后

$$\mathbf{u} = \mathbf{L}^{-1}\hat{\boldsymbol{\epsilon}} \sim \mathcal{N}(\mathbf{L}^{-1}\mathbf{0} = \mathbf{0}, \mathbf{L}^{-1}\Sigma(\theta)\mathbf{L}^{-\top}).$$

然后你可以重新排列 $\Sigma(\theta) = \mathbf{L}\mathbf{L}^\top$ 到 $\mathbf{L}^{-1}\Sigma(\theta) = \mathbf{L}^\top$, 因此

$$\mathbf{L}^{-1}\Sigma(\theta)\mathbf{L}^{-\top} = \mathbf{L}^\top\mathbf{L}^{-\top} = \mathbf{I},$$

然后上面的分布简化为

$$\mathbf{u} = \mathbf{L}^{-1}\hat{\boldsymbol{\epsilon}} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

因此, 要检查使用**创新 (innovations)** 来拟合模型的良好性, 你可以:

1. 检查它们接近均值为零.
2. 将它们与拟合值绘制在一起以检查方差是否恒定.
3. 创建一个 Q-Q 图以检查正态性.
4. 创建一个经验半变异函数 (empirical semi-variogram) 以检查独立性.

2.5.2 Model selection (模型选择)

Overall model fit (整体模型拟合)

我们希望最小化 Kullback-Leibler 信息的估计值, 这是一种比较**真实模型**与每个我们拟合的**估计模型**的似然度量. 下是两种最常用的信息准则.

定义 2.5.1 Akaike information criterion (AIC)

$$\text{AIC} = -2\ell(\hat{\beta}, \hat{\sigma}^2, \hat{\phi}, \hat{\xi}^2) + 2q,$$

其中 q 是模型中的总参数数量, $\ell(\hat{\beta}, \hat{\sigma}^2, \hat{\phi}, \hat{\xi}^2)$ 是在参数估计处评估的对数似然函数。

定义 2.5.2 Bayesian information criterion (BIC)

$$\text{BIC} = -2\ell(\hat{\beta}, \hat{\sigma}^2, \hat{\phi}, \hat{\xi}^2) + \log(n)q.$$

Predictive performance using cross validation (使用交叉验证的预测性能)

上述信息准则衡量模型拟合**观测数据**的程度. 如果建模过程的目标是预测模型在未测量位置的**预测能力**, 那么拟合数据可能不是模型选择诊断的最佳选择.

Instead, 我们可以采用**交叉验证方法**, 这些方法量化了模型预测未测量位置上地质统计过程的能力. 交叉验证有多种形式, 这里描述的最简单的是**留一交叉验证 (leave-one-out cross validation)**.

Repeat the process for $i = 1, \dots, n$.

1. 构建数据集 $\mathbf{z}_{-i} = (z(\mathbf{s}_1), \dots, z(\mathbf{s}_{i-1}), z(\mathbf{s}_{i+1}), \dots, z(\mathbf{s}_n))$, 其中第 i 个观测值被移除.
2. 将所提出的地质统计模型应用于 $\mathbf{z}_{-i}$, 并使用它来预测缺失位置 $\mathbf{s}_i$ 上的过程 (下一节将说明如何进行预测). 将此预测称为 $P_{\mathbf{z}_{-i}}(\mathbf{s}_i)$.

然后, 通过**均方根预测误差 (root mean square prediction error, RMSPE)** 总结模型的预测质量, 其定义为

$$\text{RMSPE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (z(\mathbf{s}_i) - P_{\mathbf{z}_{-i}}(\mathbf{s}_i))^2}.$$

最小化 RMSPE 的模型是最好的. 注意 RMSPE 是预测能力最常用的指标, 但也有许多其他指标.

2.6 Spatial prediction (空间预测)

地统计分析的主要目标之一是预测未测量位置 $\mathbf{s}_0$ 处的过程. 如果这在未测量的规则网格 (regular grid) 上进行, 就可以生成研究区域感兴趣的底层过程 (underlying process) 的**地图 (map)**. 假设我们有以下数据模型

$$\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n)) \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \boldsymbol{\Sigma}(\boldsymbol{\theta})),$$

其中协方差矩阵 $\boldsymbol{\Sigma}(\boldsymbol{\theta})$ 由一个平稳且各向同性的自协方差函数 $C(h, \boldsymbol{\theta})$ 定义.

定义 2.6.1 Linear prediction operator (线性预测算子)

For some constant a_0 and prediction weights $\mathbf{a} = (a_1, \dots, a_n)$, the **linear prediction operator**, P , is defined as

$$P_{\mathbf{z}}(\mathbf{s}_0) = a_0 + \sum_{i=1}^n a_i z(\mathbf{s}_i).$$

预测的一个简单观点是, 由于数据在空间上是自相关的, 因此可以预期, 距离未测量位置 $\mathbf{s}_0$ 更近的数据点的预测权重可能会更大.

定义 2.6.2 Inverse distance weighted predictor (反距离加权预测器)

根据距离更近的点受到的权重就更大的观点, 有

$$P_{\mathbf{z}}(\mathbf{s}_0) = \frac{\sum_{i=1}^n \frac{z(\mathbf{s}_i)}{d_{i0}}}{\sum_{i=1}^n \frac{1}{d_{i0}}},$$

where $a_0 = 0$ and $a_i \propto \frac{1}{d_{i0}}$. Here $d_{i0} = \|\mathbf{s}_i - \mathbf{s}_0\|$, the distance between the i th data location $\mathbf{s}_i$ and the prediction location $\mathbf{s}_0$.

缺点:

- 权重的理论依据是什么 $\frac{1}{d_{i0}}$? 存在许多替代方案, 例如 $\exp(-d_{i0})$ 或 $\frac{1}{d_{i0}^2}$.
- 如何量化预测中的不确定性.

2.6.1 Kriging (克里金插值)

该方法基于推导出**最佳线性无偏预测 (Best Linear Unbiased Prediction, BLUP)**, 给定数据 $\mathbf{z} = (z(\mathbf{s}_1), \dots, z(\mathbf{s}_n))^T$. BLUP 可以通过选择 $(a_0, \mathbf{a})$ 来获得, 以最小化**均方预测误差 (mean squared prediction error, MSPE)**.

定义 2.6.3 Mean squared prediction error (MSPE)

$$\text{MSPE} = \mathbb{E} \left[(Z(\mathbf{s}_0) - P_{\mathbf{z}}(\mathbf{s}_0))^2 \right],$$

where $U(\mathbf{s}_0) = Z(\mathbf{s}_0) - P_{\mathbf{z}}(\mathbf{s}_0)$ is the prediction error at $\mathbf{s}_0$.

一般来说, 我们有一个随机变量向量 $\mathbf{Y}$ (其现值已被观察到), 以及一个需要预测的随机变量 T (其现值未知). 此外, 设 $\hat{T} = t(\mathbf{Y})$ 是 T 的一个点预测器, 即任何关于观察到的随机变量 $\mathbf{Y}$ 的函数. 那么, 如之前定义的, $\hat{T}$ 的 MSPE 是

$$\text{MSPE}(\hat{T}) = \mathbb{E} \left[(\hat{T} - T)^2 \right],$$

其中期望是关于联合分布 $(T, \mathbf{Y})$ 的. 最优预测器的推导使用了以下两个结果.

定理 2.6.1

MSPE($\hat{T}$) 在 $\hat{T} = \mathbb{E}[T|\mathbf{Y}]$ 时取最小值.

Proof. 根据全期望公式,

$$\text{MSPE}(\hat{T}) = \mathbb{E} \left[(\hat{T} - T)^2 \right] = \mathbb{E} \left[\mathbb{E} \left[(\hat{T} - T)^2 | \mathbf{Y} \right] \right],$$

其中, 内层期望为

$$\mathbb{E} \left[(\hat{T} - T)^2 | \mathbf{Y} \right] = \text{Var} [\hat{T} - T | \mathbf{Y}] + \left(\mathbb{E} [\hat{T} - T | \mathbf{Y}] \right)^2.$$

由于是 given $\mathbf{Y}$ 的, 那么 $\hat{T} = t(\mathbf{Y})$ 则应为一常数. 因此上式简化为

$$\mathbb{E} \left[(\hat{T} - T)^2 | \mathbf{Y} \right] = \text{Var} [T | \mathbf{Y}] + \left(\hat{T} - \mathbb{E} [T | \mathbf{Y}] \right)^2.$$

那么对上式取期望就得到了 MSPE, 即

$$\text{MSPE}(\hat{T}) = \mathbb{E} [\text{Var} [T | \mathbf{Y}]] + \mathbb{E} \left[\left(\hat{T} - \mathbb{E} [T | \mathbf{Y}] \right)^2 \right].$$

第一项不依赖 predictor $\hat{T}$, 因此可以视为 constant, 那么它就是一个关于 $\hat{T}$ 的函数. 因此若使 MSPE($\hat{T}$) 最小, 则需使第二项 $\mathbb{E} \left[\left(\hat{T} - \mathbb{E} [T | \mathbf{Y}] \right)^2 \right] = 0$, 即 $\hat{T} = \mathbb{E} [T | \mathbf{Y}]$.

引理 2.6.1 分块矩阵的逆 (非本课程内容 @ 高等代数)

分块矩阵 $\mathbf{X} = \begin{pmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{pmatrix}$ 的逆矩阵 $\mathbf{X}^{-1} = \begin{pmatrix} \mathbf{F}_1 & -\mathbf{F}_1 \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{F}_1 & \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{F}_1 \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \end{pmatrix}$,
其中, $\mathbf{F}_1 = (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21})^{-1}$.

Proof. 假设 $\mathbf{X} = \begin{pmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{pmatrix}$ 的逆矩阵 $\mathbf{B} = \mathbf{X}^{-1} = \begin{pmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{pmatrix}$, 且有 $\mathbf{AB} = \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{0} & \mathbf{I} \end{pmatrix}$, 即

$$\left\{ \begin{array}{l} \mathbf{A}_{11} \mathbf{B}_{11} + \mathbf{A}_{12} \mathbf{B}_{21} = \mathbf{I} \\ \mathbf{A}_{11} \mathbf{B}_{12} + \mathbf{A}_{12} \mathbf{B}_{22} = \mathbf{0} \\ \mathbf{A}_{21} \mathbf{B}_{11} + \mathbf{A}_{22} \mathbf{B}_{21} = \mathbf{0} \\ \mathbf{A}_{21} \mathbf{B}_{12} + \mathbf{A}_{22} \mathbf{B}_{22} = \mathbf{I} \end{array} \right\} \Rightarrow \left\{ \begin{array}{l} \mathbf{B}_{21} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{B}_{11} \\ \mathbf{B}_{22} = \mathbf{A}_{22}^{-1} (\mathbf{I} - \mathbf{A}_{21} \mathbf{B}_{12}) = \mathbf{A}_{22}^{-1} - \mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{B}_{12} \end{array} \right.$$

将 $\mathbf{B}_{21}$ 代入第 1 个式子中, 得:

$$\begin{aligned} \mathbf{A}_{11} \mathbf{B}_{11} + \mathbf{A}_{12} (-\mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{B}_{11}) &= \mathbf{I} \\ (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}) \mathbf{B}_{11} &= \mathbf{I} \end{aligned}$$

记 $\mathbf{F}_1 := \mathbf{B}_{11} = (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21})^{-1}$, 则 $\mathbf{B}_{21} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{F}_1$. 然后, 将 $\mathbf{B}_{22}$ 代入第 2 个式子

中, 得:

$$\begin{aligned} \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}(\mathbf{A}_{22}^{-1} - \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{B}_{12}) &= \mathbf{0} \\ (\mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21})\mathbf{B}_{12} &= -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{B}_{12} &= -(\mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21})^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ &= \boxed{-\mathbf{F}_1\mathbf{A}_{12}\mathbf{A}_{22}^{-1}} = \mathbf{B}_{21}^\top \end{aligned}$$

最后, 将 $\mathbf{B}_{12}$ 代入 $\mathbf{B}_{22}$ 中, 得:

$$\begin{aligned} \mathbf{B}_{22} &= \mathbf{A}_{22}^{-1} - \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{B}_{12} \\ &= \mathbf{A}_{22}^{-1} - \mathbf{A}_{22}^{-1}\mathbf{A}_{21}(-\mathbf{F}_1\mathbf{A}_{12}\mathbf{A}_{22}^{-1}) \\ &= \boxed{\mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{F}_1\mathbf{A}_{12}\mathbf{A}_{22}^{-1}} \end{aligned}$$

得证.

定理 2.6.2

令 $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2)^\top$ 为长度为 n 的向量分为两个子向量的长度 $(q, n-q)$. 假设 $\mathbf{X}$ 服从多元高斯分布, 即

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}\right).$$

Then the conditional distribution of $\mathbf{X}_1|\mathbf{X}_2$ is given by

$$\mathbf{X}_1|\mathbf{X}_2 \sim \mathcal{N}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}).$$

很显然, $\mathbf{X}_1 \sim \mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$, $\mathbf{X}_2 \sim \mathcal{N}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22})$, 并且 $\text{Cov}[\mathbf{X}_1, \mathbf{X}_2] = \boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21}^\top$. 因此

- $\mathbb{E}[\mathbf{X}_1|\mathbf{X}_2]$ = 原均值 + 协方差占比 $\times$ (观测值 - 对应均值).
- $\text{Var}[\mathbf{X}_1|\mathbf{X}_2]$ = 原方差 - 可被 $\mathbf{X}_2$ 解释的部分.

Proof. 根据多元正态密度函数公式 (joint p.d.f.):

$$f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) = \frac{1}{\sqrt{(2\pi)^n |\boldsymbol{\Sigma}|}} \exp\left(-\frac{1}{2} \begin{pmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{pmatrix}^\top \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}^{-1} \begin{pmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{pmatrix}\right).$$

$$\text{记 } \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}^{-1} = \begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^\top & \mathbf{D} \end{pmatrix}^{-1}, \text{ 其中 } \begin{cases} \mathbf{A} = (\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21})^{-1}, \\ \mathbf{B} = -\mathbf{A}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}, \\ \mathbf{D} = \boldsymbol{\Sigma}_{22}^{-1} + \boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}\mathbf{A}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}. \end{cases} \quad \text{化简指数内的二次型得:}$$

$$(\mathbf{x}_1 - \boldsymbol{\mu}_1)^\top \mathbf{A}(\mathbf{x}_1 - \boldsymbol{\mu}_1) + 2(\mathbf{x}_1 - \boldsymbol{\mu}_1)^\top \mathbf{B}(\mathbf{x}_2 - \boldsymbol{\mu}_2) + (\mathbf{x}_2 - \boldsymbol{\mu}_2)^\top \mathbf{D}(\mathbf{x}_2 - \boldsymbol{\mu}_2).$$

在条件密度中, $\mathbf{x}_2$ 是已知常量, 所以我们只看这是一个关于 $\mathbf{x}_1$ 的二次函数. 然后再配方得,

$$\begin{aligned} & (\mathbf{x}_1 - \boldsymbol{\mu}_1)^\top \mathbf{A}(\mathbf{x}_1 - \boldsymbol{\mu}_1) + 2(\mathbf{x}_1 - \boldsymbol{\mu}_1)^\top \mathbf{B}(\mathbf{x}_2 - \boldsymbol{\mu}_2) + \text{const.} \\ &= \left((\mathbf{x}_1 - \boldsymbol{\mu}_1) + \mathbf{A}^{-1}\mathbf{B}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \right)^\top \mathbf{A} \left((\mathbf{x}_1 - \boldsymbol{\mu}_1) + \mathbf{A}^{-1}\mathbf{B}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \right) + \text{const.} \end{aligned}$$

因此可知

$$\begin{aligned} \mathbb{E}[\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2] &= \boldsymbol{\mu}_1 - \mathbf{A}^{-1}\mathbf{B}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \\ &= \boldsymbol{\mu}_1 - \mathbf{A}^{-1}(-\mathbf{A}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1})(\mathbf{x}_2 - \boldsymbol{\mu}_2) \\ &= \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \\ \text{Var}[\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2] &= \mathbf{A}^{-1} \\ &= \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}. \end{aligned}$$

得证.

现在, 我们有 $\mathbf{Z} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \boldsymbol{\Sigma}(\boldsymbol{\theta}))$, 则随机向量 $\mathbf{Z}^* = (Z(s_0), \mathbf{Z})$ 具有以下分布

$$\mathbf{Z}^* = \begin{pmatrix} Z(s_0) \\ \mathbf{Z} \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mathbf{x}(s_0)^\top \boldsymbol{\beta} \\ \mathbf{X}\boldsymbol{\beta} \end{pmatrix}, \begin{pmatrix} C(0, \boldsymbol{\theta}) & \mathbf{C}(s_0, \boldsymbol{\theta})^\top \\ \mathbf{C}(s_0, \boldsymbol{\theta}) & \boldsymbol{\Sigma}(\boldsymbol{\theta}) \end{pmatrix} \right),$$

其中

- $\mathbf{x}(s_0)$ 是未观测 (预测) 位置 s_0 的协变量向量.
- $C(0, \boldsymbol{\theta}) = \text{Var}[\mathbf{Z}(s_0)]$ 是预测位置的方差.
- $\mathbf{C}(s_0, \boldsymbol{\theta}) = (C(\|s_1 - s_0\|, \boldsymbol{\theta}), \dots, C(\|s_n - s_0\|, \boldsymbol{\theta}))$ 是预测位置与 n 个数据位置之间的协方差向量.

然后利用这些定理的结果, 在 MSPE 意义上给出了最优预测器, 即

$$\mathbb{E}[Z(s_0) | \mathbf{Z}] = \mathbf{x}(s_0)^\top \boldsymbol{\beta} + \mathbf{C}(s_0, \boldsymbol{\theta})^\top \boldsymbol{\Sigma}(\boldsymbol{\theta})^{-1}(\mathbf{Z} - \mathbf{X}\boldsymbol{\beta}),$$

这被称为 **Universal Kriging Predictor (通用克里金预测器)**. 预测器的方差是

$$\text{Var}[Z(s_0) | \mathbf{Z}] = C(0, \boldsymbol{\theta}) - \mathbf{C}(s_0, \boldsymbol{\theta})^\top \boldsymbol{\Sigma}(\boldsymbol{\theta})^{-1} \mathbf{C}(s_0, \boldsymbol{\theta}),$$

它量化了预测中的不确定性.

在实践中 $(\boldsymbol{\beta}, \boldsymbol{\theta})$ 是未知的, 因此实际上在高斯过程假设下, 我们有一个在 MSPE 意义下的最优预测器是

$$Z(s_0) | \mathbf{Z} \sim \mathcal{N} \left(\mathbb{E}[\widehat{Z(s_0)} | \mathbf{Z}], \text{Var}[\widehat{Z(s_0)} | \mathbf{Z}] \right),$$

其中

- $\mathbb{E}[\widehat{Z(s_0)} | \mathbf{Z}] = \mathbf{x}(s_0)^\top \widehat{\boldsymbol{\beta}} + \mathbf{C}(s_0, \widehat{\boldsymbol{\theta}})^\top \boldsymbol{\Sigma}(\widehat{\boldsymbol{\theta}})^{-1}(\mathbf{Z} - \mathbf{X}\widehat{\boldsymbol{\beta}}).$
- $\text{Var}[\widehat{Z(s_0)} | \mathbf{Z}] = C(0, \widehat{\boldsymbol{\theta}}) - \mathbf{C}(s_0, \widehat{\boldsymbol{\theta}})^\top \boldsymbol{\Sigma}(\widehat{\boldsymbol{\theta}})^{-1} \mathbf{C}(s_0, \widehat{\boldsymbol{\theta}}).$

这直接导致了一个 95% 预测区间,

$$\mathbb{E} \left[\widehat{Z(s_0)} \middle| \mathbf{Z} \right] \pm 1.96 \sqrt{\text{Var} \left[\widehat{Z(s_0)} \middle| \mathbf{Z} \right]}$$

如果均值 $\mu(\mathbf{s}) = \mu$ 是常数, 那么它被称为 **Ordinary Kriging** 普通克里金, 但如果均值不是常数, 则称为 **Universal Kriging** (通用克里金).

Chapter 3

Areal unit processes (区域单元过程)

定义 3.0.1 Areal unit process (区域单元/面元过程)

Areal unit process is also known as **lattice process** (格点过程), 空间域 D 被划分为 n 个不重叠 (non-overlapping, 不相交, disjoint) 的 **面元 (areal unit)** 或 **分区 (partition)**, 记为

$$D = \{B_1, B_2, \dots, B_n\}.$$

Then the **areal process** is a stochastic process $\mathbf{Z} = (Z(B_1), Z(B_2), \dots, Z(B_n))$.

这一组 areal units 可以形成一个规则的 grid (lattice), 也可以是不规则的形状单元, 但必须满足

- $\bigcup_{i=1}^n B_i = D$ (即区域被划分成的子域没有遗漏), 和
- $B_i \cap B_j = \emptyset$ for each $i \neq j$ (即不重叠).

3.1 Exploratory Analysis for Areal Unit Data (EDA)

3.1.1 Mapping (制图)

探索性数据分析的第一阶段是绘制数据的空间地图, 以及区域单元的边界 ($B_1, \dots, B_n$). 在大多数情况下, 这需要获得两个不同的量:

- 每个 areal unit 需要映射 (mapped) 的数据.
- 一个包含每个 areal unit 多边形轮廓 (outlines of the polygons) 的 **shapefile**. Shapefile 是一组具有相同名称但扩展名不同的不同文件类型, 包括 *.shp*, *.dbf*, *.shx* 等.

3.1.2 Defining spatial closeness (空间邻近性)

在区域数据中定义和建模空间依赖性的一个重要概念是 **neighbourhood** (邻域) 或 **adjacency matrix** (邻接矩阵), $\mathbf{W}$, 它定义了不同的区域彼此之间的空间邻近程度. 该矩阵的值可以是

- **Binary**: 哪些区域在空间上接近其他区域.

- **Continuous:** 测量区域对之间空间接近程度的范围.

令 $\mathbf{W} = (w_{ij})$ 表示一个非负的 $n \times n$ 矩阵, 其中 (i, j) 项 w_{ij} 表示区域 B_i 和 B_j 之间的空间接近程度.

- 如果 $w_{ij} = 0$, 则区域 (B_i, B_j) 在空间上不接近. 显然, 对角线上元素 $w_{ii} = 0$.
- 如果 $w_{ij} > 0$ 则区域 (B_i, B_j) 在空间上接近, 并且 w_{ij} 越大, 两个区域就越接近.

定义 3.1.1 Binary $\mathbf{W}$ matrix

为 $\mathbf{W}$ 提供二元规范, 即 w_{ij} 的值为 0 或 1. 如果区域 (B_i, B_j) 被定义为 **neighbour**, 则 $w_{ij} = 1$.

指定 neighbour 的方法有很多, 最常见的是:

- 如果区域 (B_i, B_j) 公用一个边界.
- 如果区域 B_j 是按其质心 (centroid, centre point) 之间的距离而言, 区域 B_i 最近的 k 个区域之一. 尽管 k 的选择并不明显.

定义 3.1.2 Non-binary $\mathbf{W}$ matrix

通常基于距离, 两个区域相距越远, 权重越小.

以下是基于距离的 $\mathbf{W}$ 的常见规范, 并依赖于区域 (B_i, B_j) 的质心 $(\mathbf{s}_i, \mathbf{s}_j)$.

- $w_{ij} = \frac{1}{\|\mathbf{s}_i - \mathbf{s}_j\|}$.
- $w_{ij} = \exp(-\|\mathbf{s}_i - \mathbf{s}_j\|)$.

这里 $\|\cdot\|$ 表示欧几里得距离. 对于这两种规范, $\mathbf{W}$ 不是一个 sparse (稀疏, 即有很多零) 的矩阵, 这使得模型拟合速度大大降低.

3.1.3 Estimating the extent of spatial autocorrelation (估计空间自相关程度)

定义 3.1.3 Moran's I

Moran's I statistic computed for data $\mathbf{z} = (z_1, \dots, z_n)$ with a neighbourhood matrix $\mathbf{W}$ is defined as

$$I = \frac{n \sum_{i=1}^n \sum_{j=1}^n w_{ij} (z_i - \bar{z})(z_j - \bar{z})}{\left(\sum_{i=1}^n \sum_{j=1}^n w_{ij} \right) \sum_{i=1}^n (z_i - \bar{z})^2}.$$

它测量了区域数据中 **线性关联强度 (strength of the linear association)**, 并根据其空间位置进行了适当的加权. 与 acf 和 Pearson 一致, $-1 < I < 1$, and

$$I = \begin{cases} -1, & \text{perfect dispersion (分散),} \\ 0, & \text{a random arrangement,} \\ 1, & \text{perfect autocorrelation.} \end{cases}$$

定义 3.1.4 Permutation test (置换检验)

置换检验通常用于评估空间自相关的显著性. The hypotheses for this test are:

$$H_0 : \text{no spatial autocorrelation} \quad \text{vs.} \quad H_1 : \text{positive spatial autocorrelation.}$$

Moran's I 统计量用于 K 组不同数据随机排列. 该检验的 p 值为

$$p = \frac{1}{K+1} \sum_{k=1}^K \mathbb{1}_{\{I_k > I_{\text{obs}}\}}.$$

例 3.1.1 Bookwork 3.2.3

考虑一个简单的 1 维空间数据, 有 4 个区域按顺序为 $[A|B|C|D]$, 并有一个相应的邻域矩阵

$$W = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}.$$

so that the only neighbour pairs are (A, B) , (B, C) and (C, D) . Then suppose that $z(A) = 3$, $z(B) = 4$, $z(C) = 5$ and $z(D) = 6$. Compute the **Moran's I** statistic.

Solution.

- First, $\sum_{i=1}^n \sum_{j=1}^n w_{ij} = 6$, and $\bar{z} = 4.5$.

- Second, $\sum_{i=1}^n (z_i - \bar{z})^2 = (3 - 4.5)^2 + (4 - 4.5)^2 + (5 - 4.5)^2 + (6 - 4.5)^2 = 5$.

- Third,

$$\begin{aligned} \sum_{j=1}^n w_{ij} (z_i - \bar{z})(z_j - \bar{z}) &= 2 \times \left((z(A) - \bar{z})(z(B) - \bar{z}) + (z(B) - \bar{z})(z(C) - \bar{z}) + (z(C) - \bar{z})(z(D) - \bar{z}) \right) \\ &= 2 \times ((3 - 4.5)(4 - 4.5) + (4 - 4.5)(5 - 4.5) + (5 - 4.5)(6 - 4.5)) \\ &= 2.5. \end{aligned}$$

Hence Moran's I is given by

$$I = \frac{n \sum_{i=1}^n \sum_{j=1}^n w_{ij} (z_i - \bar{z})(z_j - \bar{z})}{\left(\sum_{i=1}^n \sum_{j=1}^n w_{ij} \right) \sum_{i=1}^n (z_i - \bar{z})^2} = \frac{4 \times 2.5}{6 \times 5} = \frac{1}{3} = 0.3333.$$

定义 3.1.5 Geary's contiguity ratio (邻接比)

C is defined by

$$C = \frac{(n-1) \sum_{i=1}^n \sum_{j=1}^n w_{ij} (z_i - z_j)^2}{2 \left(\sum_{i=1}^n \sum_{j=1}^n w_{ij} \right) \sum_{i=1}^n (z_i - \bar{z})^2} \Rightarrow C_i = \sum_{j=1}^n w_{ij} (z_i - z_j)^2.$$

This is a positively valued statistic where:

$$C \begin{cases} \rightarrow 0^+, & \text{strong positive autocorrelation.}, \\ \approx 1, & \text{perfect independence,} \\ > 1, & \text{negative autocorrelation.} \end{cases}$$

定义 3.1.6 Local Indicator of Spatial Association (LISA, 局部空间关联指标)

One approach is a local version of Moran's I, which for region i is given by

$$I_i = \frac{n(z_i - \bar{z}) \sum_{j=1}^n w_{ij} (z_j - \bar{z})}{\sum_{i=1}^n (z_i - \bar{z})^2}.$$

If area i is an outlier that has a much different value to all of its neighbours, then its LISA will be negative.

例 3.1.2 via 2021.Q2(a)

Consider a simple 1-dimensional spatial data set with 4 regions ordered as $[\mathcal{A}_1 | \mathcal{A}_2 | \mathcal{A}_3 | \mathcal{A}_4]$, with a corresponding neighbourhood matrix

$$W = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}.$$

Then suppose that $Z_1 = 100$, $Z_2 = 101$, $Z_3 = 100$ and $Z_4 = 90$. Compute the **local indicators of spatial association** based on Moran's I statistic for areal units $\mathcal{A}_2$ and $\mathcal{A}_4$, and interpret what these statistics tell you about the data.

Solution. First $n = 4$ and $\bar{Z} = 97.75$ and we have $\sum_{i=1}^4 (Z_i - \bar{Z})^2 = 80.75$. Then for area $\mathcal{A}_2$ we have

$$I_2 = \frac{4(101 - 97.75) [1 \times (100 - 97.75) + 0 \times (101 - 97.75) + 1 \times (100 - 97.75) + 0 \times (90 - 97.75)]}{80.75} = 0.7244.$$

Then for area $\mathcal{A}_4$ we have

$$I_4 = \frac{4(90 - 97.75) [0 \times (100 - 97.75) + 0 \times (101 - 97.75) + 1 \times (100 - 97.75) + 0 \times (90 - 97.75)]}{80.75} = -0.864.$$

As I_2 is positive it tells us that the data value Z_2 is positively correlated (similar) to its neighbours, but as I_4 is negative it tells us that the data value Z_4 is negatively correlated (very different) to it

neighbours.

由于 I_2 为正, 这告诉我们数据值 Z_2 与其邻居呈正相关 (相似), 但 I_4 为负, 这告诉我们数据值 Z_4 与其邻居呈负相关 (非常不同).

3.2 Gaussian Markov random field theory (高斯马尔可夫随机场理论)

高斯马尔可夫随机场 (Gaussian Markov random fields, GMRFs) 作为一种机制, 来构建区域过程 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 中随机变量之间的依赖关系. 这类模型包括许多不同类型的模型, 而我们在这里考虑的特殊情况是条件自回归 (Conditional Autoregressive, CAR) 模型. CAR 模型是目前在区域单元数据中模拟空间自相关的最常用方法, 并且它们是时间序列 AR 模型的一个直接扩展.

例 3.2.1

考虑 AR(1) 模型

$$X_t = \alpha X_{t-1} + Z_t, \quad Z_t \sim \mathcal{N}(0, \sigma^2).$$

- $\alpha = 0$: 数据是独立的.
- $\alpha = 1$: 数据具有强的时间自相关性, 并且过程是非平稳的. 这是一个一阶随机游走过程.
- $\alpha \in (0, 1)$: 过程是自相关的, 均值和方差一定, 即宽平稳.

因此, AR(1) 过程是一系列条件分布

$$f(X_t | X_{t-1}) = \mathcal{N}(\alpha X_{t-1}, \sigma^2).$$

为了确定 $\mathbf{X} = (X_1, \dots, X_n)$ 的有效的联合概率分布, 根须条件概率公式 $f(A, B) = f(A|B)f(B)$, 有:

$$\begin{aligned} f(X_1, \dots, X_n) &= f(X_1) \times f(X_2 | X_1) \times f(X_3 | X_2, X_1) \times \dots \times f(X_n | X_{n-1}, \dots, X_1) \\ &= f(X_1) \prod_{t=2}^n f(X_t | X_{t-1}, \dots, X_1) \\ &= f(X_1) \prod_{t=2}^n f(X_t | X_{t-1}) \\ &= \mathcal{N}(X_1 | 0, \sigma^2) \prod_{t=2}^n \mathcal{N}(X_t | \alpha X_{t-1}, \sigma^2). \end{aligned}$$

我们称该过程为 **一阶时间马尔可夫 (Markov-in-time of order one)**. AR(1) 过程只是高斯马尔可夫随机场 (GMRF) 的一个特例.

在空间数据案例中, 我们根据两个数据点是否被定义为彼此的邻居 (如 $\mathbf{W}$ 所定义) 来衡量它们的空间邻近度. 因此, 令

$$N_{Z_i} = \{j | w_{ij} > 0\},$$

为区域 i 的邻域集合. 那么, 对于建模空间数据 $\mathbf{Z}$ 的类似结果 (analogous result) 将是

$$f(Z_1, \dots, Z_n) = \prod_{i=1}^n f(Z_i | \{Z_j : j \in N_{Z_i}\}),$$

每个 Z_i 在仅定义为其邻居的其他随机变量的条件下, 是单变量**全条件分布** (full conditional distributions) 的乘积. 当上式中所有条件分布和联合分布都是高斯分布时, 该过程称为**高斯马尔可夫随机场** (Gaussian Markov random field, GMRF).

3.2.1 Hammersley-Clifford theorem (GMRF 的充分条件)

这个定理旨在告诉我们, 联合分布 $f(\mathbf{Z}_1, \dots, \mathbf{Z}_n)$ 必须采取的什么样的形式才能成为高斯马尔可夫随机场.

定义 3.2.1 Clique (团)

在整体域 D 中的**团** (clique) 用 $\mathcal{C}$ 表示, 它是 n 个区域的一个子集, 使得团 $\mathcal{C}$ 中所有的区域对都是彼此的邻居. 对于不满足此条件的区域 j , 团可能是一个单独的区域.

比如, 如果区域 (B_1, B_2, B_3) 是团, 那么需使 $w_{12} = w_{21} > 0$, $w_{13} = w_{31} > 0$, 且 $w_{23} = w_{32} > 0$.

定义 3.2.2 Potential function (势函数)

一个 size 为 k 的团 $\mathcal{C}$ 的**势函数** (potential function) 或**势** (potential) $f_{\mathcal{C}}(\mathbf{Z})$ 是一个关于团中 k 个元素的函数, 其参数是可交换 (对称) 的.

比如,

- $f_{\mathcal{C}}(Z_i, Z_j) = (Z_i - Z_j)^2$: 在 GMRF 模型中最有可能用, 因为其出现在正态分布的指数中.
- $f_{\mathcal{C}}(Z_i, Z_j) = Z_i Z_j$: 出现在二元空间数据的 Ising 模型 (不知道是啥) 中.
- $f_{\mathcal{C}}(Z_i, Z_j) = Z_i Z_j + (1 - Z_i)(1 - Z_j)$.

定理 3.2.1 Hammersley-Clifford theorem

一个对于 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 的 GMRF 模型的联合分布可以表示为:

$$f(Z_1, \dots, Z_n) = \frac{1}{K} \exp \left(\gamma \sum_{\mathcal{C} \in cl(D)} f_{\mathcal{C}}(\mathbf{Z}) \right),$$

其中 $cl(D)$ 表示在域 D 上的所有团的集合, K 是一个归一化常数.

这个定理告诉我们, 在将提出的全条件分布相乘后, 你必须能够将乘积写成团集上势能的指数和的形式. 这种联合分布被称为**吉布斯分布** (Gibbs distribution). 这些势函数定义了**局部**依赖结构, 进而定义了 GMRF 的联合**全局**分布.

这个定理告诉我们如何从一个全条件分布集合推导出有效的联合分布, 但反过来呢? 如果我写下联合多元高斯分布, 我如何获得它的全条件分布, 以知道它们是否仅在邻域集上具有马尔可夫性质?

如定理 2.6.2 所述, 若将随机向量分割为 $\mathbf{Z} = (\mathbf{Z}_1, \mathbf{Z}_2)^\top$, 它们的联合分布为

$$\mathbf{Z} = \begin{pmatrix} \mathbf{Z}_1 \\ \mathbf{Z}_2 \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix} \right),$$

then the conditional distribution of $\mathbf{Z}_1|\mathbf{Z}_2$ is given by

$$\mathbf{Z}_1|\mathbf{Z}_2 \sim \mathcal{N}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{Z}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}).$$

This can be applied with $\mathbf{Z}_1 = Z_j$ and $\mathbf{Z}_2 = \mathbf{Z}_{-j}$, where $\mathbf{Z}_{-j} = (Z_1, \dots, Z_{j-1}, Z_{j+1}, \dots, Z_n)$ denotes all elements in $\mathbf{Z}$ except Z_j .

然而, 在 GMRF 模型中, 通常使用精度矩阵 (precision matrix) $\mathbf{Q} = \boldsymbol{\Sigma}^{-1}$ 而不是 $\boldsymbol{\Sigma}$, 引出以下定理.

定理 3.2.2 Precision matrix $\mathbf{Q} = \boldsymbol{\Sigma}^{-1}$

Consider partitioning the random vector $\mathbf{Z} = (\mathbf{Z}_1, \mathbf{Z}_2)$, where its joint distribution is given by

$$\mathbf{Z} = \begin{pmatrix} \mathbf{Z}_1 \\ \mathbf{Z}_2 \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \boldsymbol{\Sigma} = \mathbf{Q}^{-1} = \begin{pmatrix} \mathbf{Q}_{11} & \mathbf{Q}_{12} \\ \mathbf{Q}_{21} & \mathbf{Q}_{22} \end{pmatrix}^{-1} \right)$$

Then the conditional distribution of $\mathbf{Z}_1|\mathbf{Z}_2$ is given by

$$\mathbf{Z}_1|\mathbf{Z}_2 \sim \mathcal{N}(\boldsymbol{\mu}_1 - \mathbf{Q}_{11}^{-1}\mathbf{Q}_{12}(\mathbf{Z}_2 - \boldsymbol{\mu}_2), \mathbf{Q}_{11}^{-1})$$

Proof. Given that $\mathbf{Q} = \boldsymbol{\Sigma}^{-1}$, it must be that

$$\begin{pmatrix} \mathbf{Q}_{11} & \mathbf{Q}_{12} \\ \mathbf{Q}_{21} & \mathbf{Q}_{22} \end{pmatrix} \times \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix} = \begin{pmatrix} \mathbf{I}_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_2 \end{pmatrix}.$$

Taking the top row of this block matrix equation gives:

$$\begin{aligned} \mathbf{Q}_{11}\boldsymbol{\Sigma}_{11} + \mathbf{Q}_{12}\boldsymbol{\Sigma}_{21} &= \mathbf{I} \Rightarrow \boldsymbol{\Sigma}_{11} = \mathbf{Q}_{11}^{-1}(\mathbf{I} - \mathbf{Q}_{12}\boldsymbol{\Sigma}_{21}) \\ \mathbf{Q}_{11}\boldsymbol{\Sigma}_{12} + \mathbf{Q}_{12}\boldsymbol{\Sigma}_{22} &= \mathbf{0} \Rightarrow \boldsymbol{\Sigma}_{12} = -\mathbf{Q}_{11}^{-1}\mathbf{Q}_{12}\boldsymbol{\Sigma}_{22} \end{aligned}$$

Thus subbing these into the mean and variance formula stated above that uses the variance matrix $\boldsymbol{\Sigma}$ gives:

$$\begin{aligned} \mathbb{E}[\mathbf{Z}_1|\mathbf{Z}_2] &= \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{Z}_2 - \boldsymbol{\mu}_2) \\ &= \boldsymbol{\mu}_1 + (-\mathbf{Q}_{11}^{-1}\mathbf{Q}_{12}\boldsymbol{\Sigma}_{22})\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{Z}_2 - \boldsymbol{\mu}_2) \\ &= \boldsymbol{\mu}_1 - \mathbf{Q}_{11}^{-1}\mathbf{Q}_{12}(\mathbf{Z}_2 - \boldsymbol{\mu}_2) \\ \text{Var}[\mathbf{Z}_1|\mathbf{Z}_2] &= \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21} \\ &= \mathbf{Q}_{11}^{-1}(\mathbf{I} - \mathbf{Q}_{12}\boldsymbol{\Sigma}_{21}) - (-\mathbf{Q}_{11}^{-1}\mathbf{Q}_{12}\boldsymbol{\Sigma}_{22})\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21} \\ &= \mathbf{Q}_{11}^{-1} - \mathbf{Q}_{11}^{-1}\mathbf{Q}_{12}\boldsymbol{\Sigma}_{21} + \mathbf{Q}_{11}^{-1}\mathbf{Q}_{12}\boldsymbol{\Sigma}_{21} \\ &= \mathbf{Q}_{11}^{-1} \end{aligned}$$

这里一定要注意一件事: 将向量 $\mathbf{Z}$ 拆成两部分 $(\mathbf{Z}_1, \mathbf{Z}_2)$, 其中 $\mathbf{Z}_1$ 是我们感兴趣的子向量, $\mathbf{Z}_2$ 是已知变量, 那么 $\mathbf{Q}_{11}$ 实际是从整个 $\mathbf{Q}$ 中提取的矩阵. 换句话说, 如果 $\mathbf{Z} = (Z_i, Z_j, Z_k, \dots)$, 那么 $\mathbf{Q}_{11}$ 应该是由 $\mathbf{Q}$ 的第 $i, j, k, \dots$ 行和第 $i, j, k, \dots$ 列提取出来的子阵.

3.2.2 Conditional autoregressive (CAR) models (条件自回归模型)

定义 3.2.3 Conditional autoregressive (CAR) models (条件自回归模型)

考虑数据 $\mathbf{Z} = (Z_1, \dots, Z_n)$, 具有完全条件分布的一类条件自回归模型 (conditional autoregressive models) 满足

$$Z_i | \mathbf{Z}_{-i} \sim \mathcal{N} \left(\sum_{j=1}^n b_{ij} Z_j, \tau_i^2 \right), \quad \text{where } b_{ii} = 0.$$

然后这些完全条件分布与联合分布兼容, 该联合分布为

$$f(Z_1, \dots, Z_n) \propto \exp \left(-\frac{1}{2} \mathbf{Z}^\top \mathbf{D}^{-1} (\mathbf{I} - \mathbf{B}) \mathbf{Z} \right),$$

其中, $\mathbf{B} = (b_{ij})$ 是一个包含回归系数的 $n \times n$ 矩阵, 而 $\mathbf{D} = \text{diag}(\tau_1^2, \dots, \tau_n^2)$ 是一个包含方差的对角矩阵. 这个联合概率密度函数看起来像

$$\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q} = \mathbf{\Sigma}^{-1} = \mathbf{D}^{-1}(\mathbf{I} - \mathbf{B})),$$

即 $\mathbf{\Sigma} = (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D}$. 在我们能够说 $\mathbf{\Sigma}$ 是一个有效的协方差矩阵之前, 我们需要确保 $\mathbf{Q} = \mathbf{D}^{-1}(\mathbf{I} - \mathbf{B})$ 是对称的, 即只需保证 $\mathbf{D}^{-1} \mathbf{B}$ 是对称的. 如果 $\mathbf{Q}$ 不是对称的, 那么它不是一个有效的精度矩阵, 因此 $\mathbf{\Sigma} = \mathbf{Q}^{-1}$ 不是一个有效的协方差矩阵. 确保这必须成立的简单条件是

$$\frac{b_{ij}}{\tau_i^2} = \frac{b_{ji}}{\tau_j^2}, \quad \forall i, j.$$

这意味着 $\mathbf{B}$ 不需要是对称矩阵. 满足此约束的最简单规定是设置

$$b_{ij} = \frac{w_{ij}}{\sum_{j=1}^n w_{ij}}, \quad \tau_i^2 = \frac{\tau^2}{\sum_{j=1}^n w_{ij}},$$

在邻域矩阵 $\mathbf{W}$ 对称的条件下, 这满足此约束.

定义 3.2.4 Intrinsic conditional autoregressive (ICAR) model (内在条件自回归模型)

最简单的条件自回归模型是 内在条件自回归 (ICAR) 模型, 其给定了一个非标准的多元高斯分布:

$$\mathbf{Z} \sim \mathcal{N} \left(\mathbf{0}, \tau^2 [\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}]^- \right),$$

其中, $\mathbf{A}^-$ 表示矩阵 $\mathbf{A}$ 的广义逆 (generalised inverse).

精度矩阵 $\mathbf{Q} = \frac{1}{\tau^2} [\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}]$ 是秩亏 (rank deficient) 的 (秩为 $n - 1$ 而不是 n), 因此是

奇异 (singular, 不满秩的方阵, 导致行列式为 0) 的. 这很容易发现, 因为 $\mathbf{Q}$ 每行之和均为零, 因为

$$\begin{aligned} \mathbf{Q} &= \frac{1}{\tau^2} [\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}] = \frac{1}{\tau^2} \left\{ \text{diag} \left[\begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nn} \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \right] - \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nn} \end{pmatrix} \right\} \\ &= \frac{1}{\tau^2} \left\{ \text{diag} \begin{pmatrix} \sum_{j=1}^n w_{1j} \\ \sum_{j=1}^n w_{2j} \\ \vdots \\ \sum_{j=1}^n w_{nj} \end{pmatrix} - \begin{pmatrix} 0 & w_{12} & \cdots & w_{1n} \\ w_{21} & 0 & \cdots & w_{2n} \\ \vdots & \vdots & & \vdots \\ w_{n1} & w_{n2} & \cdots & 0 \end{pmatrix} \right\} \quad \text{due to } w_{ii} = 0 \\ &= \frac{1}{\tau^2} \begin{pmatrix} \sum_{j=1}^n w_{1j} & -w_{12} & \cdots & -w_{1n} \\ -w_{21} & \sum_{j=1}^n w_{2j} & \cdots & -w_{2n} \\ \vdots & \vdots & & \vdots \\ -w_{n1} & -w_{n2} & \cdots & \sum_{j=1}^n w_{nj} \end{pmatrix}. \end{aligned}$$

尽管 ICAR 模型的联合分布是非标准的, 但完全条件分布 $Z_i | \mathbf{Z}_{-i}$ 是标准的, 并且可以使用上述多元高斯结果推导出来, 即

$$\begin{aligned} \mathbb{E}[Z_i | \mathbf{Z}_{-i}] &= \boldsymbol{\mu}_1 - \mathbf{Q}_{ii}^{-1} \mathbf{Q}_{i,-i} (\mathbf{Z}_{-i} - \boldsymbol{\mu}_{-i}) \\ &= 0 - \left(\frac{1}{\tau^2} \sum_{j=1}^n w_{ij} \right)^{-1} \left(\frac{1}{\tau^2} \sum_{j \neq i} (-w_{ij})(Z_j - 0) \right) \\ &= \frac{\sum_{j \neq i} w_{ij} Z_j}{\sum_{j=1}^n w_{ij}} = \frac{\sum_{j=1}^n w_{ij} Z_j}{\sum_{j=1}^n w_{ij}} \quad \text{due to } d_{ii} = 0 \\ \text{Var}[Z_i | \mathbf{Z}_{-i}] &= \mathbf{Q}_{ii}^{-1} \\ &= \left(\frac{1}{\tau^2} \sum_{j=1}^n w_{ij} \right)^{-1} \\ &= \frac{\tau^2}{\sum_{j=1}^n w_{ij}} \end{aligned}$$

因此我们有:

$$Z_i | \mathbf{Z}_{-i} \sim \mathcal{N} \left(\frac{\sum_{j=1}^n w_{ij} Z_j}{\sum_{j=1}^n w_{ij}}, \frac{\tau^2}{\sum_{j=1}^n w_{ij}} \right).$$

利用上述多元高斯结果, 我们可以计算 $(Z_i, Z_j) | \mathbf{Z}_{-ij}$ 之间的偏 (条件) 自相关 (partial (conditional) autocorrelation). 利用上述定理从联合分布中获得条件分布, 得到以下结果, 其中 $\mathbf{Q}_{ij}$

是 $\mathbf{Q}$ 的对应于第 i 行和第 j 列的 2×2 子矩阵.

$$\begin{aligned} \text{Var}[(Z_i, Z_j)|\mathbf{Z}_{-ij}] &= \tau^2 [\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}]_{ij}^{-1} = \mathbf{Q}_{ij}^{-1} \\ &= \tau^2 \begin{pmatrix} \sum_{k=1}^n w_{ik} & -w_{ij} \\ -w_{ji} & \sum_{k=1}^n w_{jk} \end{pmatrix}^{-1} = \frac{\tau^2}{d_{ij}} \begin{pmatrix} \sum_{k=1}^n w_{jk} & w_{ij} \\ w_{ji} & \sum_{k=1}^n w_{ik} \end{pmatrix}, \end{aligned}$$

其中, d_{ij} 为行列式, 即 $d_{ij} = \left(\sum_{k=1}^n w_{ik}\right) \left(\sum_{k=1}^n w_{jk}\right) - w_{ij}^2$, 二阶矩阵的逆“主对调, 副变号”.

因此, 偏 (条件) 自相关为

$$\begin{aligned} \text{Corr}[(Z_i, Z_j)|\mathbf{Z}_{-ij}] &= \frac{\text{Cov}[(Z_i, Z_j)|\mathbf{Z}_{-ij}]}{\sqrt{\text{Var}[Z_i|\mathbf{Z}_{-ij}] \text{Var}[Z_j|\mathbf{Z}_{-ij}]}} \\ &= \frac{w_{ij}}{\sqrt{\left(\sum_{k=1}^n w_{ik}\right) \left(\sum_{k=1}^n w_{jk}\right)}} \end{aligned}$$

这意味着,

- 对于相邻区域, 即 $w_{ij} \neq 0$ 时, 数据 (Z_i, Z_j) 是 **部分 (条件) 相关的 (partially (conditionally) correlated)**;
- 对于非相邻区域, 即 $w_{ij} = 0$ 时, 数据 (Z_i, Z_j) 是 **条件独立的 (conditionally independent)**.

因此, 邻域矩阵 $\mathbf{W}$ 中的 0 意味着精度矩阵 $\mathbf{Q}$ 中的 0, 这意味着给定其余数据值, 数据是条件独立的.

例 3.2.2 via 2021.Q2(b)-ii

The researcher decides to model the data with the following CAR model (后面定义 3.4.3):

$$\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{Q}(\mathbf{W}, \rho)^{-1}),$$

where the ij th element of precision matrix $\mathbf{Q}(\mathbf{W}, \rho)$ is given by

$$\mathbf{Q}(\mathbf{W}, \rho)_{ii} = \rho \sum_{j=1}^n w_{ij} + 1 - \rho \quad \text{and} \quad \mathbf{Q}(\mathbf{W}, \rho)_{ij} = -\rho w_{ij}$$

Using the multivariate Gaussian theory that was presented in the lectures, we have that

$$\begin{aligned} \text{Var}[Z_i, Z_j|\mathbf{Z}_{-ij}] &= \tau^2 \mathbf{Q}_{ij}^{-1} = \tau^2 \begin{pmatrix} \mathbf{Q}_{ii} & \mathbf{Q}_{ij} \\ \mathbf{Q}_{ji} & \mathbf{Q}_{jj} \end{pmatrix}^{-1} \\ &= \frac{\tau^2}{\mathbf{Q}_{ii}\mathbf{Q}_{jj} - \mathbf{Q}_{ij}^2} \begin{pmatrix} \mathbf{Q}_{jj} & -\mathbf{Q}_{ij} \\ -\mathbf{Q}_{ji} & \mathbf{Q}_{ii} \end{pmatrix} \\ \text{Corr}[Z_i, Z_j|\mathbf{Z}_{-ij}] &= \frac{\text{Cov}[Z_i, Z_j|\mathbf{Z}_{-ij}]}{\sqrt{\text{Var}[Z_i|\mathbf{Z}_{-ij}] \text{Var}[Z_j|\mathbf{Z}_{-ij}]}} = \frac{\mathbf{Q}_{ij}}{\sqrt{\mathbf{Q}_{ii}\mathbf{Q}_{jj}}}. \end{aligned}$$

Q. 此 CAR 模型在 $w_{ij} = 0$ (即区域 $\mathcal{A}_i, \mathcal{A}_j$ 不相邻) 的情况下, 对 (Z_i, Z_j) 之间的依赖性假设?

A. If $w_{ij} = 0$ then this model assumes that (Z_i, Z_j) are **conditionally independent** (the conditional correlation in the previous question is clearly zero) given the remaining data points, that is $\text{Corr}[Z_i, Z_j|\mathbf{Z}_{-ij}] = 0$.

3.3 Modelling areal unit data (建模)

3.3.1 Modelling framework (建模框架)

建模 areal unit data 的最简单方法是基于联合数据似然模型进行估计

$$\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \tau^2 [\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}]).$$

这可以通过调整模型来扩展, 包括协变量

$$\mathbf{Z} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \tau^2 [\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}]),$$

但是这并不常用, 因为精度矩阵是奇异的, 则方差矩阵亦不存在; 此外, 该模型只适用于连续数据, 不适用离散数据.

因此, 通常将 CAR 模型指定为一组随机效应的先验分布, 而不是直接指定为数据似然模型. 这克服了上述两个限制, 因为先验分布可以是非正态的, 而数据模型则可以自由地采用任何适当的分布.

定义 3.3.1 贝叶斯方法 – 分层模型 (hierarchical model)

$$\left. \begin{aligned} Z_i &\sim f(Z_i|\mu_i), \quad i = 1, \dots, n \\ g(\mu_i) &= \mathbf{x}_i\boldsymbol{\beta} + \phi_i \end{aligned} \right\} \text{generalised linear mixed model}$$

$$\phi_i|\phi_{-1} \sim \mathcal{N}\left(\frac{\sum_{j=1}^n w_{ij}Z_j}{\sum_{j=1}^n w_{ij}}, \frac{\tau^2}{\sum_{j=1}^n w_{ij}}\right)$$

$$\boldsymbol{\beta} \sim \mathcal{N}(\boldsymbol{\mu}_\beta, \mathbf{V}_\beta)$$

$$\tau^2 \sim \text{Inverse-gamma}(a, b)$$

假设数据在空间自相关的随机效应 (random effects, ϕ) 下是条件独立的, 因此数据似然模型为

$$f(\mathbf{Z}|\boldsymbol{\beta}, \phi, \tau^2) = \prod_{i=1}^n f(Z_i|\boldsymbol{\beta}, \phi),$$

联合先验分布为

$$\begin{aligned} f(\boldsymbol{\beta}, \phi, \tau^2) &= f(\boldsymbol{\beta})f(\phi|\tau^2)f(\tau^2) \\ &= \mathcal{N}(\boldsymbol{\beta}|\boldsymbol{\mu}_\beta, \mathbf{V}_\beta) \times \text{ICAR}(\phi|\tau^2, \mathbf{W}) \times \text{Inverse-gamma}(\tau^2|a, b), \end{aligned}$$

其中, $(\boldsymbol{\mu}_\beta, \mathbf{V}_\beta, a, b)$ 被称为 **hyperparameters (超参数)**, 人为选择, 通常 $(\boldsymbol{\mu}_\beta = \mathbf{0}, \mathbf{V}_\beta = 100,000\mathbf{I}, a = 1, b = 0.01)$ 确保先验信息微弱.

最常用的 generalised linear mixed model 有如下三种:

1. **Binomial logistic model (二项逻辑模型):** $Z_i \sim \text{Binomial}(N_i, \theta_i)$

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^\top \boldsymbol{\beta} + \phi_i.$$

这里 N_i 是区域 i 的试验次数, θ_i 是每次试验的成功概率. 当然, 也可以使用正态分布 (probit, 概率单位) 而不是逻辑回归.

2. Gaussian linear model (高斯线性模型): $Z_i \sim \mathcal{N}(\mu_i, \sigma^2)$

$$\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \phi_i.$$

此处, 数据误差方差 σ^2 将被赋予与 τ^2 相同弱信息的 (weakly informative) inverse-gamma 先验分布。

3. Poisson log-linear model (泊松对数线性模型): $Z_i \sim \text{Poisson}(\mu_i)$

$$\log(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} + \phi_i.$$

3.3.2 Parameter estimation (参数估计)

如前所述, 参数估计将在贝叶斯框架下进行, 目标是估计后验分布

$$\begin{aligned} f(\boldsymbol{\Theta}|\mathbf{Z}) &\propto f(\mathbf{Z}|\boldsymbol{\Theta})f(\boldsymbol{\Theta}) \\ &= \left[\prod_{i=1}^n f(Z_i|\boldsymbol{\beta}, \phi_i) \right] \mathcal{N}(\boldsymbol{\beta}|\boldsymbol{\mu}_\beta, \mathbf{V}_\beta) \times \text{ICAR}(\boldsymbol{\phi}|\tau^2, \mathbf{W}) \times \text{Inverse-gamma}(\tau^2|a, b) \times \text{Inverse-gamma}(\sigma^2|a, b), \end{aligned}$$

其中 $\boldsymbol{\Theta} = (\boldsymbol{\beta}, \boldsymbol{\phi}, \tau^2, \sigma^2)$ 表示所有模型参数 (如果数据模型是高斯的, 则只需要 σ^2). 这通常使用马尔可夫链蒙特卡罗 (Markov chain Monte Carlo, MCMC) 模拟来完成, 这是一种迭代算法, 从该联合后验分布中抽取样本。

3.3.3 An alternative estimation approach (参数估计的替代办法)

对于这些层次高斯马尔可夫随机场模型, 存在一种贝叶斯推理的替代方法. 它被称为**集成嵌套拉普拉斯近似 (Integrated Nested Laplace Approximations, INLA)**, 通过拉普拉斯分布来近似每个单变量参数的后验分布, 而不是从中抽取随机样本。

- 优点:
 - 它非常快, 比 MCMC 快得多.
 - 有一个 R package *INLA*, 因此实现这些模型所需的编码很少.
- 缺点: 它具有局限性 (restrictive), 因为它只能适用于特定类型的模型.

3.4 Extensions to the ICAR model (内在条件自回归模型的扩展)

- Multivariate form (多元形式):

$$\boldsymbol{\phi} \sim \mathcal{N}(\mathbf{0}, \tau^2 [\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}]^-).$$

- Conditional form (条件形式):

$$\phi_i|\boldsymbol{\phi}_{-i} \sim \mathcal{N}\left(\frac{\sum_{j=1}^n w_{ij}\phi_j}{\sum_{j=1}^n w_{ij}}, \frac{\tau^2}{\sum_{j=1}^n w_{ij}}\right).$$

这是 CAR 类中首次提出的模型, 但它存在以下缺陷:

- 它是时间序列一阶随机游走过程的空间类比, 因此其在空间上是非平稳的.
- 它只模拟强自相关, 有时会对随机效应施加过多的空间平滑. 这是因为它不包含平滑或自相关参数, 这允许从数据中估计自相关的强度. 条件方差参数 τ^2 并不控制过程中的平滑程度, 因为如果你将 ϕ 乘以 10, 那么方差 τ^2 将明显增加, 因为 $\text{Var}[aX] = a^2\text{Var}[X]$, 但过程的光滑度并没有改变.
- 其联合分布的多变量高斯表示是不恰当的, 因为精度矩阵是奇异的.

因此, 已提出许多该模型的扩展, 它们克服了其中一些或所有所有问题.

定义 3.4.1 Convolution (卷积) 或 BYM (Besag-York-Mollié)

The **Convolution or BYM CAR** model for ϕ is given by the following linear combination:

$$\begin{aligned}\phi_i &= \phi_i^{(1)} + \phi_i^{(2)} \\ \phi_i^{(1)} | \phi_{-i}^{(1)} &\sim N\left(\frac{\sum_{j=1}^n w_{ij} \phi_j^{(1)}}{\sum_{j=1}^n w_{ij}}, \frac{\tau_1^2}{\sum_{j=1}^n w_{ij}}\right) \\ \phi_i^{(2)} &\sim \mathcal{N}(0, \tau_2^2).\end{aligned}$$

- 该模型是实践中最常用的 CAR 模型.
- BYM 模型通过添加一组具有零均值和恒定方差的 i.i.d. 随机效应来扩展 ICAR 模型. 因此, 它是由相关且独立过程 (或求和) 的卷积组成的.
- ϕ 中元素的空间平滑程度由两个方差 $\frac{\tau_1^2}{\tau_2^2}$ 的比值决定.
- 因此, 克服了 ICAR 模型过于平滑且不让数据选择空间自相关强度的问题.

3.4.0.0.1 Disadvantages:

- 第一个分量 $\phi^{(1)}$ 是 ICAR 先验, 仍然具有不适当的多变量高斯分布.
- 在拟合该模型时, 人们试图为每个数据点 Z_i 估计两个随机效应 ($\phi_i^{(1)}, \phi_i^{(2)}$), 并且只有它们的和 $\phi_i^{(1)} + \phi_i^{(2)}$ 可以从数据中可靠地估计出来. 对于两个方差参数 (τ_1^2, τ_2^2) 也存在类似的问题.

定义 3.4.2 Proper CAR

The **proper CAR** model 引入了 ρ 来控制空间自相关的程度, 即

$$\phi \sim \mathcal{N}\left(\mathbf{0}, \tau^2 [\text{diag}(\mathbf{W}\mathbf{1}) - \rho\mathbf{W}]^{-1}\right).$$

如果 $\rho \in [0, 1)$, 则精度矩阵 $\mathbf{Q} = \frac{1}{\tau^2} [\text{diag}(\mathbf{W}\mathbf{1}) - \rho\mathbf{W}]$ 是可逆的. 这意味着对于 $\rho \in [0, 1)$, 此模型指定了一个适当的多变量高斯分布. 应用关于条件分布的多变量高斯结果, 得到完全条件分布为

$$\phi_i | \phi_{-i} \sim N\left(\rho \frac{\sum_{j=1}^n w_{ij} \phi_j}{\sum_{j=1}^n w_{ij}}, \frac{\tau^2}{\sum_{j=1}^n w_{ij}}\right).$$

从这个条件规范中很容易看出, ρ 控制了数据中空间自相关的程度,

- $\rho = 0$: independence in space.

- $\rho = 1$: strong spatial dependence.

此模型因此是 AR(1) 过程的空间类似物, 因为它可以写成

$$\phi_i | \phi_{-i} = \rho \bar{\phi}_i + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \tau_i^2),$$

其中 $\bar{\phi}_i = \frac{\sum_{j=1}^n w_{ij} \phi_j}{\sum_{j=1}^n w_{ij}}$, 邻近区域的随机效应的均值.

空间背景下的区域单元不是规则的, 因此条件方差 $\text{Var}[\phi_i | \phi_{-i}] = \frac{\tau^2}{\sum_{j=1}^n w_{ij}}$ 会随着从区域到区域的移动而变化 (即, 其邻域起不到任何作用). 这在时间序列背景下并不存在这个问题, 因此我们希望方差是恒定的.

定义 3.4.3 Leroux CAR

The **Leroux CAR** model has a multivariate representation given by

$$\phi \sim \mathcal{N}\left(\mathbf{0}, \tau^2 [\rho(\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}) + (1 - \rho)\mathbf{I}]\right).$$

如果 $\rho \in [0, 1)$, 则精度矩阵 $\mathbf{Q} = \frac{1}{\tau^2} [\rho(\text{diag}(\mathbf{W}\mathbf{1}) - \mathbf{W}) + (1 - \rho)\mathbf{I}]$ 是可逆的. 这意味着对于 $\rho \in [0, 1)$, 此模型指定了一个适当的多变量高斯分布. 此时, $\mathbf{Q}$ 的元素为:

- $Q_{ij} = -\frac{1}{\tau^2} \rho w_{ij}$.
- $Q_{ii} = \frac{1}{\tau^2} \left(\rho \sum_{j=1}^n w_{ij} + 1 - \rho \right)$.

因此应用关于条件分布的多元高斯结果, 得到完整的条件分布:

$$\phi_i | \phi_{-i} \sim \mathcal{N}\left(\frac{\rho \sum_{j=1}^n w_{ij} \phi_j}{\rho \sum_{j=1}^n w_{ij} + (1 - \rho)}, \frac{\tau^2}{\rho \sum_{j=1}^n w_{ij} + (1 - \rho)}\right).$$

从这个条件规范中很容易看出, ρ 再次控制了数据中空间自相关的程度,

- $\rho = 0$: independence in space, 即 $\phi_i \sim \mathcal{N}(0, \tau^2)$, 其中均值为零且方差为常数.
- $\rho = 1$: strong spatial dependence, 即 **ICAR** 模型.

因此, 这通常是一个用于捕捉全球空间自相关的非常有用的 CAR 模型.

Chapter 4

Point Process (点过程)

定义 4.0.1 Point process (点过程)

考虑一个空间域 $D \subset \mathbb{R}^2$, 并令 $A \subset D$. 然后令 $Z(A)$ 表示在 A 中出现的点的数量. 因此集合

$$Z = \{Z(A) : A \subset D\},$$

是一个空间点过程.

空间点过程有两种类型:

- 对于无标记 (unmarked) 点过程, 仅记录数据的位置.
- 对于标记 (marked) 点过程, 记录数据的位置, 以及每个位置的相关测量值.

空间点过程本质上就是一个随机过程, 描述的是在一个二维区域 (空间) 中, 随机“落点”的方式和数量. 这些“点”可以是: 病例, 星星, 雷达信号等.

定义 4.0.2 Spatial dependence (空间依赖性)

通常, 空间点过程可以表现出三种不同类型的空间依赖性:

1. Complete spatial randomness (CSR) 完全空间随机

The points are randomly scattered across the study region D , which corresponds to independence in space.

点在研究区域 D 中随机分布, 这对应于空间上的独立性。

2. Clustered process 聚集过程

The points are clustered together in groups, which corresponds to positive spatial dependence.

点聚集在一起形成群组, 这对应于正空间依赖性。

3. Regular process 规则过程

The points stay far away from other points, which corresponds to negative spatial dependence.

这些点彼此距离很远, 这对应于负空间依赖性。

例 4.0.1 via 2021.Q3(c)

Q. 如何描述一组数据在空间图上的分布?

A. The trees appear to be fairly evenly (相当均匀) spread across the region, with a few visible clusters (易见的簇) and a few visible gaps (易见的间隙). Therefore initially, **complete spatial randomness** does not look unreasonable. There also does not appear to be any pattern to the species of the trees, as both species types are found in most parts of the forest.

4.1 Point process theory (理论)

在统计学中, 兴趣通常在于估计一个均值函数, 该函数量化了感兴趣变量的预期响应。在空间点过程设置中, 均值函数对应于在任何给定区域内过程的预期点数, 这被称为其**强度 (intensity)**。

定义 4.1.1 First order intensity function (一阶强度函数)

设 $A \subset D$, 并设 $Z(A)$ 表示在 A 中出现的观测点的数量. 那么 A 中的点数期望为

$$\mu(A) = \mathbb{E}[Z(A)] = \int_A \lambda(\mathbf{s}) \, d\mathbf{s},$$

其中 $\lambda(\mathbf{s})$ 被称为**一阶强度函数 (first order intensity function)**, 用于衡量位置 $\mathbf{s}$ 处点数期望的局部贡献 (local contribution).

设 $d\mathbf{s}$ 表示以点 $\mathbf{s}$ 为中心, 面积为 $|d\mathbf{s}|$ 的小圆形区域. 那么**一阶强度函数**定义为

$$\lambda(\mathbf{s}) = \lim_{|d\mathbf{s}| \rightarrow 0} \frac{\mathbb{E}[Z(d\mathbf{s})]}{|d\mathbf{s}|},$$

为在位置 $\mathbf{s}$ 附近点的预期数量.

定义 4.1.2 Second order intensity function (二阶强度函数)

Given 2 locations $(\mathbf{s}, \mathbf{t})$ the **second order intensity function** is defined to be

$$\lambda_2(\mathbf{s}, \mathbf{t}) = \lim_{|d\mathbf{s}| \rightarrow 0, |d\mathbf{t}| \rightarrow 0} \frac{\mathbb{E}[Z(d\mathbf{s})Z(d\mathbf{t})]}{|d\mathbf{s}||d\mathbf{t}|},$$

并测量空间点过程中的空间依赖性. 它本质上是两个随机变量乘积期望的空间点过程的类似 (analogue).

定义 4.1.3 Covariance density (协方差密度) & Pair correlation function (对关联函数)

The **covariance density** is defined to be:

$$\gamma(\mathbf{s}, \mathbf{t}) = \lambda_2(\mathbf{s}, \mathbf{t}) - \lambda(\mathbf{s})\lambda(\mathbf{t}),$$

and the **pair correlation function** is defined to be

$$\rho(\mathbf{s}, \mathbf{t}) = \frac{\lambda_2(\mathbf{s}, \mathbf{t})}{\lambda(\mathbf{s})\lambda(\mathbf{t})}.$$

4.2. MODELLING AND TESTING FOR COMPLETE SPATIAL RANDOMNESS (CSR) (完全随机的建模与测试)

与地统计学一样, 建模一般空间依赖性 is 困难的, 因此可以做出以下简化假设.

定义 4.1.4

- **Stationary (平稳):** 将区域 A 平移到空间任意位置, $Z(A)$ 的概率分布保持不变.
- **Isotropic (各向同性):** 将区域 A 旋转 (rotating), $Z(A)$ 的概率分布保持不变.

如果过程 Z 是平稳 且各向同性 的, 那么

- (一阶) 强度函数恒定, 即 $\lambda(\mathbf{s}) = \lambda, \mathbf{s} \in D$.
- 二阶强度函数仅取决于 $\mathbf{s}$ 和 $\mathbf{t}$ 之间的距离, 即 $\lambda_2(\mathbf{s}, \mathbf{t}) = \lambda_2(\|\mathbf{s} - \mathbf{t}\|)$.
- 对关联函数也仅取决于彼此的距离, 即 $\rho(\mathbf{s}, \mathbf{t}) = \rho(\|\mathbf{s} - \mathbf{t}\|)$.

4.2 Modelling and testing for complete spatial randomness (CSR) (完全随机的建模与测试)

4.2.1 A model for complete spatial randomness (CSR 的建模)

定义 4.2.1 Homogeneous Poisson process (HPP, 齐次泊松过程)

一个空间点过程 Z 在一个空间域 $D \subset \mathbb{R}^2$ 中是 **homogeneous Poisson process (HPP)**, 如果

1. For any measurable set $A \subset D$,

$$Z(A) \sim \text{Poisson}(\lambda|A|),$$

where $|A|$ is the area of A .

2. 在 A 中的观测点 $\{s_1, \dots, s_n\}$ 是从 A 上的均匀分布中独立抽取的随机样本.
3. 对于任何不相交的子区域 (disjoint sub-regions) $A, B \subset D$

$$Z(A) \perp Z(B), \quad \text{i.e. } Z(A) \text{ is independent of } Z(B).$$

This model corresponds to complete spatial randomness (CSR) because:

- 点的位置在空间上独立地从上述第 2 点和第 3 点中抽取.
- 一阶强度函数在整个域 D 上是恒定的, 因为:

$$\lambda(\mathbf{s}) = \lim_{|d\mathbf{s}| \rightarrow 0} \frac{\mathbb{E}[Z(d\mathbf{s})]}{|d\mathbf{s}|} = \frac{\lambda|d\mathbf{s}|}{|d\mathbf{s}|} = \lambda.$$

例 4.2.1 Bookwork 4.4.1: deriving the data likelihood

估计恒定一阶强度函数 λ , 这可以通过 MLE 来完成, 这里有两个随机量:

- 空间点过程中的点的数量: $Z(D) = n$.

- 空间点过程中的点 $\{s_1, \dots, s_n\}$ 的位置.

Solution. 完整的数据似然为:

$$f(\{s_1, \dots, s_n\}, Z(D) = n) = f(Z(D) = n) \times f(\{s_1, \dots, s_n\} | Z(D) = n)$$

1. 从齐次泊松过程的定义来看, $Z(D) \sim \text{Poisson}(\lambda|D|)$.
2. 在已知总共有 $Z(D) = n$ 个点的条件下, 空间位置点 $\{s_1, \dots, s_n\}$ 的联合概率密度是

$$f(\{s_1, \dots, s_n\} | Z(D) = n) = \prod_{i=1}^n f(s_i | Z(D) = n) = \prod_{i=1}^n \frac{\lambda}{\lambda|D|} = \left(\frac{1}{|D|}\right)^n.$$

因此, 完整数据的似然函数为

$$f(\{s_1, \dots, s_n\}, Z(D) = n) = \frac{\lambda|D|^n}{n!} \exp(-\lambda|D|) \times \left(\frac{1}{|D|}\right)^n.$$

Log-likelihood:

$$\log[f(\{s_1, \dots, s_n\}, Z(D) = n)] = n \log(\lambda|D|) - \log(n!) - \lambda|D| - n \log(|D|).$$

Differentiate w.r.t. λ :

$$\frac{d}{d\lambda} \log[f(\{s_1, \dots, s_n\}, Z(D) = n)] = n \frac{1}{\lambda|D|} |D| - |D| = \frac{n}{\lambda} - |D|.$$

Setting equal to zero and solving yields:

$$\hat{\lambda} = \frac{n}{|D|}.$$

例 4.2.2 Bookwork 4.4.1: covariance density & pair correlation function

考虑一个齐次泊松点过程, 然后我们可以计算其协方差密度和对关联函数.

首先, 当 $s \neq t$ 时, $Z(ds) \perp Z(dt)$, 即只要 (ds, dt) 不重叠, 就有 $\mathbb{E}[Z(ds)Z(dt)] = \mathbb{E}[Z(ds)]\mathbb{E}[Z(dt)]$. 因此, 二阶强度函数为

$$\lambda_2(s, t) = \lim_{|ds| \rightarrow 0, |dt| \rightarrow 0} \frac{\mathbb{E}[Z(ds)Z(dt)]}{|ds||dt|} = \lim_{|ds| \rightarrow 0, |dt| \rightarrow 0} \frac{\mathbb{E}[Z(ds)]\mathbb{E}[Z(dt)]}{|ds||dt|} = \lambda(s)\lambda(t) = \lambda^2.$$

Thus its **covariance density** is given by:

$$\gamma(s, t) = \lambda_2(s, t) - \lambda(s)\lambda(t) = \lambda^2 - \lambda \times \lambda = 0,$$

and the **pair correlation function** is defined to be

$$\rho(s, t) = \frac{\lambda_2(s, t)}{\lambda(s)\lambda(t)} = \frac{\lambda^2}{\lambda \times \lambda} = 1.$$

因此, 一个独立过程的对关联函数为 1, 因此 ‘correlation’ 这个名字并不是这个函数的最佳名称. 因此, 我们可以将泊松点过程视为空间统计中白噪声过程类似的东西.

4.2.2 Testing for complete spatial randomness (CSR 的测试)

定理 4.2.1 Hypothesis test based on quadrat (方格) counts

首先将一个由大小相等且不重叠的正方形 (称为 quadrat) 组成的矩形网格叠加到域 D 上, 使得它被划分为不重叠的子区域. 假设在这个规则网格中有 r 行和 c 列, 总共形成 $r \times c$ 个网格方格. 然后对于第 i 行第 j 列的网格方格:

- 令 n_{ij} 表示第 i 行和第 j 列的网格方格中的点数, 其中显然 $\sum_{i=1}^r \sum_{j=1}^c n_{ij} = n$.
- 基于 CSR, 所有网格方块都将有相同数量的预期点数, 因为强度函数 $\lambda(s) = \lambda$ 在 D 上是常数. 因此, 由于有 $r \times c$ 个网格方块, 每个网格方块中的预期点数是 $\bar{n} = \frac{n}{rc}$.

然后可以进行一个 χ^2 检验, 比较观测到的和预期的网格正方形计数, 该检验具有以下假设:

- H_0 : the point pattern is **consistent** with CSR.
- H_1 : the point pattern is **not consistent** with CSR.

The test statistic is given by:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - \bar{n})^2}{\bar{n}} \sim \chi_{rc-1}^2.$$

- Under H_0 of **complete spatial randomness** the test statistic $\chi^2 \sim \chi_{rc-1}^2$, i.e.

$$F_{rc-1}^{-1}(2.5\%) < \chi^2 < F_{rc-1}^{-1}(97.5\%) \Leftrightarrow 0.025 < p < 0.975 \Rightarrow \text{fail to reject } H_0.$$

- If the point process is **clustered**, then $(n_{ij} - \bar{n})^2$ will be larger than under the random Poisson assumption, and hence you will reject H_0 by χ^2 being too **large**, p -value being too **small**, i.e.

$$\chi^2 > F_{rc-1}^{-1}(97.5\%) \Leftrightarrow p < 0.025 \Rightarrow \text{reject } H_0 \text{ in favour of } H_1.$$

- If the point process is **regular**, then $(n_{ij} - \bar{n})^2$ will be smaller than under the random Poisson assumption, and hence you will reject H_0 by χ^2 being too **small**, p -value being too **large**, i.e.

$$\chi^2 < F_{rc-1}^{-1}(2.5\%) \Leftrightarrow p > 0.975 \Rightarrow \text{reject } H_0 \text{ in favour of } H_1.$$

定义 4.2.2 Ripley's K -function

For homogeneous point process **Ripley's K -function** is defined to be

$$K(t) = 2\pi \int_0^t r \rho(r) \, dr,$$

其中 $\rho(r)$ 是距离为 $r = \|\mathbf{s} - \mathbf{t}\|$ 的对关联函数.

注意, 在 CSR 条件下, 过程是弱平稳且各向同性的, 因此我们有简化公式, 对于任意点 $(\mathbf{s}, \mathbf{t})$:

- $\lambda(\mathbf{s}) = \lambda, \forall \mathbf{s} \in D$.
- $\lambda_2(\mathbf{s}, \mathbf{t}) = \lambda_2(r = \|\mathbf{s} - \mathbf{t}\|)$.

$$\bullet \rho(\mathbf{s}, \mathbf{t}) = \rho(r = \|\mathbf{s} - \mathbf{t}\|).$$

定义 4.2.3 Ripley's K -function (alternative)

An alternative definition for the $K(t)$ function is given by

$$K(t) = \frac{\mathbb{E}[\text{Number of points within a circle of radius } t \text{ centred at a current point}]}{\lambda},$$

圆心位于当前点, 半径为 t 的圆内点的期望数量与 λ 的比值.

总体思路是我们可以对观察到的空间点模式估计 $K(t)$, 然后将其与在完全空间随机性 (complete spatial randomness, CSR) 下预期的结果进行比较。这可以做到, 因为,

$$K(t) \begin{cases} < K_{\text{CSR}}(t), & \text{clustered process,} \\ > K_{\text{CSR}}(t), & \text{regular processes,} \end{cases} \quad \text{at a shorter distance } t.$$

例 4.2.3 Spatial point pattern comparison

For a homogeneous Poisson process $Z(\mathcal{C}) \sim \text{Poisson}(\lambda|\mathcal{C}|)$ we have:

$$K(t) = 2\pi \int_0^t r \rho_Z(r) \, dr = 2\pi \int_0^t r \times 1 \, dr = \pi t^2.$$

This gives the same answer as under the **alternative expectation definition** given above, because for a homogeneous Poisson process with intensity λ , the expected number of points within a circle $\mathcal{C}$ of radius t , is $\lambda|\mathcal{C}| = \lambda\pi t^2$. Hence $K(t) = \frac{\lambda\pi t^2}{\lambda} = \pi t^2$.

在 Ripley's K function 中,

- **CSR:** 距离 r 的值为 πr^2 .
- **Clustered:** 在较小的距离 r 上会大于 πr^2 .
- **Regular:** 在较小的距离 r 上会小于 πr^2 .

因此, 我们可以绘制 $K(r) - \pi r^2$ 关于距离 r 的图, 并在 r 值较小的情况下寻找正值, 负值或接近 0 的值.

定义 4.2.4 Estimate K -function using method of moment estimation (MME, 矩估计)

K -function 测量的是距离过程任意点 t 处点的期望数量. 基于观测数据 $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$, 可以使用矩估计法估计 K -function, 其表达式为:

$$\hat{K}(t) = \frac{|D|}{n(n-1)} \sum_{i=1}^n \sum_{j \neq i} w_{ij} \mathbb{1}_{\{\|\mathbf{s}_i - \mathbf{s}_j\| \leq t\}}.$$

使用 R 中的 $Kest()$ 函数来估计 K -function. 通过绘制 $\hat{K}(t) - \pi t^2$ vs. t 图, 来查看与 CSR 的偏差, 即在短距离 t 下:

- **Clustering:** $\hat{K}(t) - \pi t^2 > 0$.
- **Regularity:** $\hat{K}(t) - \pi t^2 < 0$.

4.3 Modelling spatially varying intensities (空间变化强度的建模)

4.3.1 Model and data likelihood (模型与数据似然)

定义 4.3.1 Inhomogeneous Poisson process (IPP, 非齐次泊松过程)

在空间域 $D \subset \mathbb{R}^2$ 中的空间点过程 Z 是一个非齐次泊松过程 (Inhomogeneous Poisson process, IPP), 其强度函数为 $\lambda(\mathbf{s})$, 如果:

1. 对于 D 中的任何可测集 A , 有

$$Z(A) \sim \text{Poisson}(\mu(A)), \quad \text{where } \mu(A) = \int_A \lambda(\mathbf{s}) \, d\mathbf{s},$$

其中, $\mu(A)$ 是集合 A 中预期的点的数量.

2. 观测点 $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$ 在 A 中是从一个与 $\lambda(\mathbf{s})$ 成比例的分布 A 上抽取的独立随机样本.
3. 对于任何 $A, B \subset D$, 若 $A \cap B = \emptyset$, 则 $Z(A) \perp Z(B)$.

例 4.3.1 Bookwork 4.5.1: deriving the data likelihood

IPP 的数据似然与 HPP 的数据似然具有相同的结构, 即存在两个随机量:

- 空间点过程中的点的数量: $Z(D) = n$.
- 空间点过程中的点 $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$ 的位置.

Solution. 完整的数据似然为:

$$f(\{\mathbf{s}_1, \dots, \mathbf{s}_n\}, Z(D) = n) = f(Z(D) = n) \times f(\{\mathbf{s}_1, \dots, \mathbf{s}_n\} | Z(D) = n)$$

1. 从 IPP 的定义来看, $Z(D) \sim \text{Poisson}\left(\int_D \lambda(\mathbf{s}) \, d\mathbf{s}\right)$.
2. 在已知总共有 $Z(D) = n$ 个点的条件下, 空间位置点 $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$ 的联合概率密度是

$$f(\{\mathbf{s}_1, \dots, \mathbf{s}_n\} | Z(D) = n) = \prod_{i=1}^n f(\mathbf{s}_i | Z(D) = n) = \prod_{i=1}^n \frac{\lambda(\mathbf{s}_i)}{\int_D \lambda(\mathbf{s}) \, d\mathbf{s}}.$$

这既源于 IPP 中点的独立性, 也源于一个点在任何单个位置 $\mathbf{s}_i$ 的概率与其一阶强度函数 $\lambda(\mathbf{s}_i)$ 成正比这一事实.

因此, 完整数据的似然函数为

$$f(\{\mathbf{s}_1, \dots, \mathbf{s}_n\}, Z(D) = n) = \frac{\left(\int_D \lambda(\mathbf{s}) \, d\mathbf{s}\right)^n}{n!} \exp\left(-\int_D \lambda(\mathbf{s}) \, d\mathbf{s}\right) \times \prod_{i=1}^n \frac{\lambda(\mathbf{s}_i)}{\int_D \lambda(\mathbf{s}) \, d\mathbf{s}}.$$

Log-likelihood:

$$\begin{aligned}
& \log [f(\{\mathbf{s}_1, \dots, \mathbf{s}_n\}, Z(D) = n)] \\
&= n \log \left(\int_D \lambda(\mathbf{s}) \, d\mathbf{s} \right) - \log(n!) - \int_D \lambda(\mathbf{s}) \, d\mathbf{s} + \sum_{i=1}^n \left[\log(\lambda(\mathbf{s}_i)) - \log \left(\int_D \lambda(\mathbf{s}) \, d\mathbf{s} \right) \right] \\
&= n \log \left(\int_D \lambda(\mathbf{s}) \, d\mathbf{s} \right) - \log(n!) - \int_D \lambda(\mathbf{s}) \, d\mathbf{s} + \sum_{i=1}^n \log(\lambda(\mathbf{s}_i)) - n \log \left(\int_D \lambda(\mathbf{s}) \, d\mathbf{s} \right) \\
&\propto \sum_{i=1}^n \log(\lambda(\mathbf{s}_i)) - \int_D \lambda(\mathbf{s}) \, d\mathbf{s}
\end{aligned}$$

4.3.2 Non-parametric estimation of $\lambda(\mathbf{s})$ (强度函数的非参数估计)

如果不假设 $\lambda(\mathbf{s})$ 的任何模型或结构, 那么可以用非参数平滑方法来估计它. 最简单的方法是基于 quadrat 计数进行估计, 但这会导致一个非平滑 (马赛克状, pixelated) 的估计. 作为替代, 使用核密度估计来根据观测数据 $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$ 来估计 $\lambda(\mathbf{s})$.

定义 4.3.2 Kernel density estimate (核密度估计)

一阶强度函数 (first order intensity function) 的**核密度估计 (kernel density estimate)** 为:

$$\hat{\lambda}(\mathbf{s}) = \frac{\sum_{i=1}^n k(\mathbf{s} - \mathbf{s}_i | b)}{\int_D k(\mathbf{s} - \mathbf{u} | b) \, d\mathbf{u}},$$

其中 $k(\cdot | b)$ 是一个**核函数 (kernel function)**, 它根据数据位置 $\mathbf{s}_i$ 与估计点 $\mathbf{s}$ 之间的距离来估计任何点的强度. 它是关于距离 $\|\mathbf{s}_i - \mathbf{s}\|$ 的减函数, 因此:

- 对于靠近数据点 $\{\mathbf{s}_1, \dots, \mathbf{s}_n\}$ 的位置 $\mathbf{s}$, 强度会很大.
- 对于远离数据点的位置 $\mathbf{s}$, 强度将较小.

核函数是一个关于原点对称的双变量 (bivariate) 概率密度函数. 参数 b , 即带宽 (bandwidth) 控制平滑的程度.

- b 的值越小, 估计结果越粗糙.
- b 的值越大, 估计结果越平滑.

需要在估计中过多偏差和过多变异性之间进行权衡, 并提出了一系列不同的估计方法. 在上面强度函数的估计中, 归一化常数

$$K(\mathbf{s}) = \int_D k(\mathbf{s} - \mathbf{u} | b) \, d\mathbf{u},$$

是一种边缘校正 (edge correction), 仅确保强度 $\hat{\lambda}_Z(\mathbf{s})$ 在正确的尺度上. 可以使用多种不同的核函数, 其中一种是高斯核函数 (Gaussian kernel function), 其表达式为:

$$k(\mathbf{s} - \mathbf{s}_i | b) = \frac{1}{\sqrt{2\pi}b} \exp \left(-\frac{\|\mathbf{s} - \mathbf{s}_i\|^2}{2b} \right).$$

4.3.3 Parametric models for $\lambda(s)$ (强度函数的参数模型)

定义 4.3.3 Log-linear model (对数线性模型)

一个适用于非均匀泊松过程 (IPP) 的通用**对数线性模型 (log-linear model)** 为:

$$Z(D) \sim \text{Poisson} \left(\int_D \lambda(s) \, ds \right)$$

$$\log(\lambda(s)) = \mathbf{x}(s)^\top \boldsymbol{\beta}$$

其中 $\mathbf{x}(s)$ 是一个 $p \times 1$ 的协变量向量 (包括截距项的 1), 而 $\boldsymbol{\beta}$ 是 $p \times 1$ 的待估参数向量.

该模型的数据似然性, 使用 $\lambda(s) = \exp(\mathbf{x}(s)^\top \boldsymbol{\beta})$ 给出

$$\begin{aligned} \log[f(\{\mathbf{s}_1, \dots, \mathbf{s}_n\}, Z(D) = n)] &\propto \sum_{i=1}^n \log(\lambda(\mathbf{s}_i)) - \int_D \lambda(s) \, ds \\ &= \sum_{i=1}^n \log(\mathbf{x}(\mathbf{s}_i)^\top \boldsymbol{\beta}) - \int_D \exp(\mathbf{x}(s)^\top \boldsymbol{\beta}) \, ds. \end{aligned}$$

无法获得封闭形式的解, 因此需要使用数值优化算法, 例如 Newton-Raphson 算法.

4.4 Overview of models for clustered point processes (聚类点过程的模型)

4.4.1 Processes with offspring (后代)

考虑以下生成空间点模式的方法:

- 从强度为 λ_P 的齐次泊松过程 (HPP) 中模拟父点 (parent).
- 对于每个父点, 独立同分布地生成 S 个后代, 其后代位置相对于父点的分布是独立同分布的, 且与父点的距离存在某种密度 $h(\cdot)$, 该密度随距离的增加而减小.

然后我们研究的点模式仅仅是后代, 这被称为**泊松聚类过程 (Poisson cluster process)**.

4.4.2 Processes generated by thinning (稀疏/减薄/抽稀)

当我们将空间点过程进行**抽稀 (thin)** 时, 会根据某种规则随机移除点. 我们讨论**独立性抽稀 (independent thinning)**. 对于每个点 $\mathbf{s}_i$, 我们独立地以概率 p 保留它. 通过独立抽稀 Z , 一个强度为 λ 的齐次泊松过程 (HPP), 我们得到一个强度为 $p\lambda$ 的 HPP.

在**依赖性抽稀 (dependent thinning)** 中, 我们以随空间变化的概率保留点. 设 Z 为一个点过程, 并设 $\{0 < \pi(s) < 1 : s \in D\}$ 表示一个随机概率过程, 称之为**抽稀场 (thinning field)**, 它表示在位置 s 保留点的概率. 然后, **依赖性抽稀过程 (dependently thinned process)** Y 包含在以概率 $\{\pi(s)\}$ 抽样后保留的 Z 的实现. 也就是说, 属于过程 Z 的点 $\mathbf{s}_i \in D$ 是:

- 以概率 $\pi(\mathbf{s}_i)$ 保留在抽样过程 Y 中.
- 以概率 $1 - \pi(\mathbf{s}_i)$ 从抽样过程 Y 中移除.

4.4.3 Log Gaussian Cox processes

定义 4.4.1 Log Gaussian Cox processes

一个定义在空间域 D 的 **log Gaussian Cox processes** 由下式给出:

$$Z(D) \sim \text{Poisson} \left(\int_D \lambda(\mathbf{s}) \, d\mathbf{s} \right)$$

$$\log(\lambda(\mathbf{s})) = \mathbf{x}(\mathbf{s})^\top \boldsymbol{\beta} + \psi(\mathbf{s})$$

其中 $\psi(\mathbf{s})$ 是一个零均值的高斯过程, 并且其空间协方差函数为 $C(\cdot)$.

它反映了空间点模式中协变量无法解释的空间结构. 如果需要, 可以移除协变量.

空间协方差函数可以是之前我们见过的一种. 比如, 一个平稳且各向同性的零点核指数模型是

$$C(h = \|\mathbf{s} - \mathbf{u}\|) = \sigma^2 \exp(-h/\phi).$$

在这个模型下, 可以分两个阶段模拟聚类数据.

1. 使用高斯过程估计一阶强度函数的自然对数.
2. 使用估计的强度函数来模拟点过程.

Chapter 5

Supplement

5.1 OLS

考虑一个空间线性模型：

$$\mathbf{z} = \mathbf{x}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \boldsymbol{\Sigma}).$$

既然 $\boldsymbol{\epsilon} \sim \mathcal{N}(0, \boldsymbol{\Sigma})$, 那么 $\mathbf{z} \sim \mathcal{N}(\mathbf{x}\boldsymbol{\beta}, \boldsymbol{\Sigma})$, 那么

$$f(\mathbf{z}) = (2\pi)^{-\frac{n}{2}} |\boldsymbol{\Sigma}|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\mathbf{z} - \mathbf{x}\boldsymbol{\beta})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{z} - \mathbf{x}\boldsymbol{\beta})\right).$$

计算它的 log-likelihood function,

$$\ell(\boldsymbol{\beta}) = \log f(\mathbf{z}) = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2}(\mathbf{z} - \mathbf{x}\boldsymbol{\beta})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{z} - \mathbf{x}\boldsymbol{\beta}),$$

计算极值,

$$\begin{aligned} \frac{\partial \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} &= \frac{\partial}{\partial \boldsymbol{\beta}} \left(-\frac{1}{2}(\mathbf{z} - \mathbf{x}\boldsymbol{\beta})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{z} - \mathbf{x}\boldsymbol{\beta}) \right) \\ &= -\frac{1}{2} \cdot 2\mathbf{x}^\top \boldsymbol{\Sigma}^{-1}(\mathbf{z} - \mathbf{x}\boldsymbol{\beta}) \\ &= \mathbf{x}^\top \boldsymbol{\Sigma}^{-1}(\mathbf{z} - \mathbf{x}\boldsymbol{\beta}) \\ &= -\mathbf{x}^\top \boldsymbol{\Sigma}^{-1}\mathbf{z} + \mathbf{x}^\top \boldsymbol{\Sigma}^{-1}\mathbf{x}\boldsymbol{\beta}. \end{aligned}$$

令 $\frac{\partial \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = 0$ 得,

$$\hat{\boldsymbol{\beta}} = (\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1} \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{z}.$$

由于 $\mathbf{z} \sim \mathcal{N}(\mathbf{x}\boldsymbol{\beta}, \boldsymbol{\Sigma})$, 那么

$$\begin{aligned} \text{Var} [\hat{\boldsymbol{\beta}}] &= \left((\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1} \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \right) \boldsymbol{\Sigma} \left((\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1} \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \right)^\top \\ &= (\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1} \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\Sigma} \boldsymbol{\Sigma}^{-1} \mathbf{x} (\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1} \\ &= (\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1} \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x} (\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1} \\ &= (\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1}. \end{aligned}$$

因此, the confidence interval with significance level of 95% is

$$\left(\hat{\boldsymbol{\beta}} \pm 1.96 \sqrt{\text{Var} [\hat{\boldsymbol{\beta}}]} \right) = \left(\hat{\boldsymbol{\beta}} \pm 1.96 \sqrt{(\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x})^{-1}} \right).$$

如果考虑协方差为 $\Sigma = \sigma^2 \mathbf{I}$, 即观测值之间独立 (忽略了空间相关性), 则

$$\hat{\beta} = (\mathbf{x}^\top \mathbf{x})^{-1} \mathbf{x}^\top \mathbf{z}$$

因此, the confidence interval with significance level of α is

$$\left(\hat{\beta} \pm 1.96 \cdot \sigma \sqrt{(\mathbf{x}^\top \mathbf{x})^{-1}} \right).$$

The point estimate of β will be unbiased but its 95% confidence interval will be too narrow. 出现这种情况的原因是: 在独立性的假设下, 错误地认为你有 n 个独立的信息片段来估计 β . 然而, 如果数据相关, 实际上你拥有的独立信息片段少于 n 个, 导致更大的不确定性, 从而使得置信区间更宽.

5.2 Research (past paper Q4)

5.2.1 2021 – areal process

研究者想了解格拉斯哥社区中呼吸系统疾病 (respiratory ill health) 的空间分布模式, 以及其潜在驱动因素. 数据如下:

- 每个 GP 诊所在 2020 年开出的呼吸类药物总数.
- 每个 GP 诊所注册人口数.
- 每个诊所的经纬度 (但不清楚确切服务的地理区域).
- 计算得到: 每人平均呼吸药物使用率 (非负的比率型变量).

因为每个病人不住在诊所内, 所以这属于离散区域分析 (areal process), 而不是连续地理坐标的地统计分析 (geostatistical process).

例 5.2.1 2021 Q4(a)

如何基于 k 近邻规则构建邻接矩阵 $\mathbf{W}$, 以及这种方法的两个限制与解决方案. [5 MARKS]

定义 $\mathbf{W} = (w_{ij})$ 的 k 近邻规则指定 (specify), 如果区域 j 是区域 i 的 k 个最近邻之一, 则 $w_{ij} = 1$, 否则 $w_{ij} = 0$. 另外, 对于所有 i 有 $w_{ii} = 0$.

- **Limitation 1:** 在这种定义下, $\mathbf{W}$ 可能不是对称的.
 - **Solution:** 如果 $w_{ij} = 1$ 且 $w_{ji} = 0$, 则令 $w_{ji} = 1$.
- **Limitation 2:** k 值的选择.
 - **Solution:** 使用敏感性分析 (sensitivity analysis), 尝试不同的 k 值 (例如 $k = 3, \dots, 10$), 如果模型结果变化不大, 说明模型对 k 不敏感, 即 k 的选择不影响结果.

例 5.2.2 2021 Q4(b)

估计空气污染浓度 (air pollution concentrations) 和社会经济剥夺 (socioeconomic deprivation) 是否与呼吸道 (respiratory) 相关疾病水平增加有关. 写下 SAP. [15 MARKS]

1. 需要收集的数据和变量.

[4 MARKS]

- 除了量化每个全科医生诊所呼吸用药使用率的统计数据外, 研究人员还需要收集关于暴露的数据, 即空气污染浓度. 鉴于参加每个全科医生诊所的人口居住在诊所周围而不是在诊所内, 因此诊所周围的平均浓度是一个合适的衡量指标.
- 另外, 他们还需要关于其他“暴露”的数据, 即社会经济剥夺, 如平均收入或平均房价,
- 最后, 他们需要考虑影响呼吸疾病率的其他干扰因素 (confounder), 包括吸烟率和每个全科医生诊所注册人口的年龄分布 (呼吸用药数据仅考虑了人口规模) .

2. 一个合适的数据似然模型. [3 MARKS]

- 响应数据是比率 (药物数量/人口规模), 它们是连续的, 因此高斯 (正态) 线性模型是合适的.
- 然而, 比率是非负的, 并且通常向右偏斜, 因此可能需要对高斯模型进行转换才能合适. 对数或平方根转换可能是合适的转换.

3. 分析中将采取哪些步骤. [5 MARKS]

- 探索性数据分析 (exploratory data analysis):** 例如使用成对图来检查协变量之间的共线性 (collinearity) 以及协变量-响应关系的形式 (是否具有线性模式).
- 拟合协变量线性模型:** 仅确定一个初始协变量 (无相关性) 的正常线性模型, 使用适当的模型构建策略 (OLS 拟合), 然后使用残差诊断检查模型的充分性. 例如, 使用 QQ 图检查残差的正态性, 并在必要时考虑响应的转换.
- 检查空间自相关:** 一旦您有一个合适的协变量模型, 然后评估其残差以检查是否存在空间相关性, 例如使用 Moran's I 测试.
- 包含空间相关性:** 如果残差包含空间相关性, 则通过向线性预测器添加一组空间相关随机效应来扩展正常线性模型, 例如使用 CAR 类型模型.

$$Y = \beta X + \phi + \epsilon, \quad \text{or} \quad g(\mu_i) = \mathbf{x}_i^\top \beta + \phi_i.$$

- 模型评估与结果解释:** 一旦评估此模型是充分的, 呈现分析结果. 例如协变量对响应的影响; 回归系数及其置信区间等.

4. 可以进行哪些敏感性分析以确保结果对模型假设的变化具有稳健性. [3 MARKS]

- 协变量的敏感性:** 添加或移除不同的混杂因素, 以观察这对呼吸药物使用率和空气污染/贫困之间的估计关系有何影响.
- k 的敏感性:** 对构建邻域矩阵中 k 的选择, 改变 k 值看模型参数估计是否稳定.
- 先验分布的敏感性:** 因为区域数据 CAR 模型通常在贝叶斯设置中进行拟合.

总结: 这题其实就是“如何做一份空间版的线性回归分析”, 只不过数据不是点位置 (经纬度), 而是每个诊所代表的服务区域, 模型稍微加了一点空间统计的味道。

5.2.2 2022 – geostatistical

研究者在一个南太平洋岛屿的 $n = 153$ 个位置上测量了放射性 (radioactivity) 计数 (即单位时间内的光子 (photon) 发射 (emission) 次数, 记为 $\{z(\mathbf{s}_i)\}$), 并在每个位置采集了一组协变量 $\{x(\mathbf{s}_i)\}$, 比如地质类型, 土壤性质等, 来研究放射性高的驱动因素以及进行全岛放射性分布预测. 感兴趣的问题包括:

1. 估计高放射性水平的原因.
2. 预测岛屿上的放射性水平, 以识别可能对人类有害的高放射性水平地点.

例 5.2.3 2022 Q4(a)i

识别类型: geostatistical? areal unit? point process type?

[2 MARKS]

Geostatistical. 因为在理论上她可以在岛屿的任何地方测量放射性水平, 并且她已经选择了测量位置.

Geostatistical: 连续空间变量 + 坐标点观测 (而非面状单元, 也非事件点).

例 5.2.4 2022 Q4(a)ii

应该拟合的模型结构.

[6 MARKS]

1. **The data likelihood model:** 因为数据 $\{z(\mathbf{s}_i)\}$ 是计数, 所以 Poisson data likelihood model 是合适的:

$$Z(\mathbf{s}_i) \sim \text{Poisson}(\mu(\mathbf{s}_i)),$$

其中 $\mu(\mathbf{s}_i)$ is the mean of the process at location $\mathbf{s}_i$.

2. **The link function & the linear predictor:** 泊松模型中通常使用 log 链接函数, 确保预测均值 $\mu(\mathbf{s}_i)$ 为正数, 则有线性预测算子

$$\log[\mu(\mathbf{s}_i)] = \mathbf{x}(\mathbf{s}_i)^\top \boldsymbol{\beta} + \psi(\mathbf{s}_i),$$

其中, $\mathbf{x}(\mathbf{s}_i)^\top \boldsymbol{\beta}$ 是协变量效应 (covariate effect), 当中的 $\boldsymbol{\beta}$ 是待预测的回归参数; $\psi(\mathbf{s}_i)$ 是空间相关的随机效应项.

3. **How spatial correlation will be accounted for in the model:** Spatial correlation is allowed for via the random effects $\{\psi(\mathbf{s}_i)\}$, which could be modelled by a zero-mean geostatistical process with a spatially correlated covariance matrix, 即

$$\boldsymbol{\psi} = (\psi(\mathbf{s}_1), \dots, \psi(\mathbf{s}_n)) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}(\boldsymbol{\theta})),$$

其中协方差矩阵 $\boldsymbol{\Sigma}(\boldsymbol{\theta})$ 是空间协方差函数 (如指数型或高斯型) 生成的矩阵 $\boldsymbol{\theta}$ 包括 sill, range, nugget 等参数.

例 5.2.5 2022 Q4(a)iii

针对研究员感兴趣的两个问题, 应该建一个模型? 还是分别建模?

[3 MARKS]

研究人员应该考虑构建两个不同的模型来回答这两个不同的问题, 因为最适合数据的模型 (the model best fits the data) 不一定能提供最佳的预测性能 (provides the best predictive performance). 此外, 只在 n 个数据位置拥有协变量使得预测变得困难 (并非不可能).

Comparison: 最佳解释模型 $\neq$ 最佳预测模型.

- 问题 (i) 是解释性分析 (解释协变量对响应的因果或相关影响), 需要关注模型拟合优度和解释性.
- 问题 (ii) 是预测性分析, 重点在于预测误差最小化.

例 5.2.6 2022 Q4(a)iv

针对研究员感兴趣的两个问题, 如何选择最佳模型?

[4 MARKS]

1. 对于问题 (i), 研究人员需要开展 (undertake) 模型构建练习, 并选择最适合观察数据的协变量模型, 同时不违反 (invalidate) 模型假设. 比如:
 - 采用 AIC, BIC 等准则选择拟合好的模型;
 - 或者基于协变量的显著性和解释力选择;
 - 注重模型残差的诊断 (比如残差独立性, 方差齐性等).
2. 对于问题 (ii),
 - the researcher needs to undertake an out-of-sample predictive assessment (e.g. by leave-one-out cross validation) of a range of different models (e.g. different with covariance functions), and
 - choose the one that optimises predictive accuracy such as minimising the root mean square prediction error (RMSPE/MSPE; RMSE/MSE).

例 5.2.7 2022 Q4(a)v

研究人员在进行 EDA 时, 发现数据仅在空间上略有相关性. 他们是否应该拟合一个允许空间相关性的模型?

[2 MARKS]

是的, 他们应该将空间相关性模型应用于数据, 因为空间相关性模型 (如具有指数协方差函数的地统计模型) 具有控制相关性强度的参数, 因此它们可以表示边缘 (marginal) 相关性以及强烈的空间相关性.

例 5.2.8 2022 Q4(a)vi

给出三个研究者应产生的模型输出, 以回答那两个感兴趣的问题.

[3 MARKS]

1. 协变量效应的点估计 (point estimates) 表和 95% 不确定区间 (uncertainty intervals) 表.
2. 全岛放射性水平 (radioactivity levels) 预测图 (prediction map).
3. 预测不确定性地图 (a map of prediction uncertainty), e.g. 预测标准误 (prediction standard errors), 以量化预测中的不确定性.

5.2.3 2024 – mixed process

研究者希望研究 NO_2 浓度与呼吸疾病死亡之间的关系, 掌握潜在的环境风险. 掌握数据如下:

- 在 $N = 135$ 个城市站点, 测得 2023 年 NO_2 年均浓度;

- 对应这些站点收集了一些协变量 (天气, 交通等).
- 在 $M = 1279$ 个中间区域 (Intermediate Zones) 中, 收集了呼吸系统疾病的死亡人数 (areal units 数据, 平均每区 4000 人);
- 对应这些区域的协变量, 比如预计死亡人数 (调整人口结构后) 和贫困指标.

研究人员计划通过两阶段建模法 (two-stage modelling approach) 来建立关联:

1. 使用可用的协变量来模拟 NO_2 浓度的空间变化, 并预测每个中间区域每年的平均 NO_2 浓度.
2. 模拟呼吸死亡数据的空间变化, 包括可用的协变量以及第一阶段模型预测的空气污染浓度. 然而, 他们不确定如何进行建模, 并请求您的帮助.

例 5.2.9 2024 Q4(a)

对 NO_2 浓度数据应进行的三个 EDA.

[3 MARKS]

1. **协变量与 NO_2 的关系图:** 以确定是否应在均值模型中包含线性或非线性关系.
2. **残差半变异函数 (empirical semi-variogram):** 拟合一个没有空间结构的普通线性回归, 计算其残差, 作图分析空间自相关是否存在.
3. **QQ 图检查残差:** 以查看正态性假设是否有效, 或者是否需要变换 (transformation: log, Box-Cox).

例 5.2.10 2024 Q4(b)

研究人员决定使用地统计学模型来模拟 NO_2 浓度, 该模型包括均值模型中的可用协变量和空间自相关误差.

[8 MARKS]

1. 如何选取最佳协变量和空间相关函数 (协方差模型)? [3 MARKS]
 - 作为模型的目标是预测每个中间区域中的 NO_2 浓度, 模型的预测能力应该得到优化. 为此, 可以通过留一法交叉验证 (leave-one-out cross validation) (或另一种交叉验证策略) 比较每个候选均值和自相关模型的预测能力, 最佳模型是使均方根预测误差 (root mean square prediction error, RMSPE) 最小化的模型.
2. 如何为每个 Intermediate Zone (区域, 而非点) 预测一个代表性 NO_2 浓度? [2 MARKS]
 - 最好的方法是预测苏格兰 (研究区域) 一系列高分辨率 (high resolution) 等间距点的 NO_2 浓度 (说白了就是建立细网格, fine grid).
 - 在这些小网格点上用 Kriging 进行 NO_2 浓度预测.
 - 对每个 Intermediate Zone, 计算其内部网格点预测值的平均值, 作为代表性 NO_2 浓度.
 - (可以给 [1 MARKS] 的答案) 以每个区域的 centroid 作为代表点.
3. 如果协变量只有在 135 个站点测得, Kriging 时会遇到什么问题? 怎么解决? [3 MARKS]
 - 通过 Kriging 预测 NO_2 浓度需要知道这些未测量地点的协变量值, 但它们在 Intermediate Zone 是未知的.
 - 这可以通过先用 Kriging 或倒数距离加权 (inverse distance weighted) 来预测所需预测地点的每个协变量值来克服, 然后直接将这预测值用于 Kriging 方程中.

例 5.2.11 2024 Q4(c)

直接将第一阶段的预测 NO_2 用于第二阶段会怎么样?

[3 MARKS]

- **优点:** 简单易操作, 实现起来方便快捷.
- **缺点:** 忽略了预测的不确定性 (导致第二阶段的估计结果对 NO_2 的效应低估或标准误低估).
- **解决办法:** 在 stage 1 的预测中, 就把其不确定性考虑进去, 加一个度量 (比如预测标准差, 置信区间等). 把这个不确定性代入 stage 2 的模型中, 比如贝叶斯方法等.

例 5.2.12 2024 Q4(d)

给出第二阶段 (呼吸系统死亡建模) 的完整模型形式.

[4 MARKS]

由于呼吸死亡数据以每个中间区域死亡人数的计数形式呈现, 因此泊松对数线性模型是合适的.

$$Y_k \sim \text{Poisson}(e_k \theta_k) \quad \text{for } k = 1, \dots, M$$

$$\log(\theta_k) = \mathbf{x}_k \boldsymbol{\beta} + \phi_k$$

其中,

- Y_k : 第 k 个 Intermediate Zone 的呼吸疾病死亡数;
- e_k : 该区的预期死亡数;
- θ : 标准化死亡率;
- $\mathbf{x}_k$: 预测的 NO_2 浓度和其他协变量组成的向量, 参数为 $\boldsymbol{\beta}$;
- ϕ_k : 空间随机效应 (spatial random effect), 可以用 CAR 建模得到.

例 5.2.13 2024 Q4(e)

本次分析最核心的输出是什么? 如何表达?

[4 MARKS]

分析的主要输出结果是估计的 NO_2 浓度对呼吸死亡的影响, 应作为相对风险 (relative risk 即 $\text{RR} = \exp(\beta_{\text{NO}_2})$) 和 95% 不确定区间来呈现, 因为疾病数据是计数.